



Universidad Nacional Mayor de San Marcos
Universidad del Perú. Decana de América

Dirección General de Estudios de Posgrado

Facultad de Ingeniería Industrial

Unidad de Posgrado

**Algoritmo genético de operadores de cruce y mutación
(ALGOCYM) para la optimización de la distribución en
planta en organizaciones de manufactura**

TESIS

**Para optar el Grado Académico de
Doctor en Ingeniería Industrial**

AUTOR

Mg. Edgar Cruz RUIZ LIZAMA

ASESOR

Dr. Orestes CACHAY BOZA

Lima, Perú

2021



Reconocimiento - No Comercial - Compartir Igual - Sin restricciones adicionales

<https://creativecommons.org/licenses/by-nc-sa/4.0/>

Usted puede distribuir, remezclar, retocar, y crear a partir del documento original de modo no comercial, siempre y cuando se dé crédito al autor del documento y se licencien las nuevas creaciones bajo las mismas condiciones. No se permite aplicar términos legales o medidas tecnológicas que restrinjan legalmente a otros a hacer cualquier cosa que permita esta licencia.

Referencia bibliográfica

Ruiz, E. (2021). *Algoritmo genético de operadores de cruce y mutación (ALGOCYM) para la optimización de la distribución en planta en organizaciones de manufactura*. [Tesis de doctorado, Universidad Nacional Mayor de San Marcos, Facultad de Ingeniería Industrial, Unidad de Posgrado]. Repositorio institucional Cybertesis UNMSM.

Metadatos complementarios

Datos de autor	
Nombres y apellidos	Edgar Cruz RUIZ LIZAMA
Tipo de documento de identidad	DNI
Número de documento de identidad	08004558
URL de ORCID	https://orcid.org/0000-0001-9403-1358
Datos de asesor	
Nombres y apellidos	Orestes CACHAY BOZA.
Tipo de documento de identidad	DNI
Número de documento de identidad	08446599
URL de ORCID	https://orcid.org/0000-0002-7244-583X
Datos del jurado	
Presidente del jurado	
Nombres y apellidos	CEVALLOS AMPUERO JUAN MANUEL
Tipo de documento	DNI
Número de documento de identidad	07855059
Miembro del jurado 1	
Nombres y apellidos	GARCÍA ZAPATA TEONILA DORIA
Tipo de documento	DNI
Número de documento de identidad	10185405
Miembro del jurado 2	
Nombres y apellidos	TEJADA MUÑOZ GUILLERMO
Tipo de documento	DNI
Número de documento de identidad	06717637
Miembro del jurado 3	
Nombres y apellidos	ROSALES LÓPEZ PEDRO PABLO
Tipo de documento	DNI

Número de documento de identidad	10419269
Datos de investigación	
Línea de investigación	C.0.4.1 Desarrollo de modelos, simulación y optimización de procesos
Grupo de investigación	Círculo de Investigación y Desarrollo de Software - CIDESOFT
Agencia de financiamiento	Perú. Universidad Nacional Mayor de San Marcos. Vicerrectorado de Investigación y Posgrado. Estudio CON/CON 161701071
Ubicación geográfica de la investigación	Edificio: Facultad de Ingeniería Industrial – Universidad Nacional Mayor de San Marcos País: Perú Departamento: Lima Provincia: Lima Distrito: Cercado de Lima Avenida: Germán Amezaga 325 Latitud: -12.05715 Longitud: -77.08341
Año o rango de años en que se realizó la investigación	2016 - 2021
URL de disciplinas OCDE	<p>Ingeniería Industrial: https://purl.org/pe-repo/ocde/ford#2.11.04</p> <p>Otras ingenierías y tecnologías: http://purl.org/pe-repo/ocde/ford#2.11.02</p>



UNIVERSIDAD NACIONAL
MAYOR DE SAN MARCOS

Universidad del Perú, DECANA DE AMERICA

UNIDAD DE POSGRADO

ACTA DE SUSTENTACIÓN VIRTUAL Nº16-UPG-FII-2021

SUSTENTACIÓN DE TESIS VIRTUAL PARA OPTAR EL GRADO ACADÉMICO
DE DOCTOR EN INGENIERÍA INDUSTRIAL

En la ciudad de Lima, del día veintidós del mes de octubre del dos mil veintiuno, siendo las quince horas, de forma virtual se instaló el Jurado Examinador para la Sustentación de la Tesis titulada: **"ALGORITMO GENÉTICO DE OPERADORES DE CRUCE Y MUTACIÓN (ALGOCY) PARA LA OPTIMIZACIÓN DE LA DISTRIBUCIÓN EN PLANTA EN ORGANIZACIONES DE MANUFACTURA"**, para optar el Grado Académico de Doctor en Ingeniería Industrial.

Luego de la exposición y absueltas las preguntas del Jurado Examinador se procedió a la calificación individual y secreta, habiendo sido **APROBADO** con la calificación de **QUINCE (15) BUENO**.

El Jurado recomienda que la Facultad acuerde el otorgamiento del Grado Académico de Doctor en Ingeniería Industrial, al **Mg. EDGAR CRUZ RUIZ LIZAMA.**

En señal de conformidad, siendo las **17:24** horas se suscribe la presente acta en cuatro ejemplares, dándose por concluido el acto.

UNMSM

Firmado digitalmente por CEVALLOS
AMPUERO Juan Manuel FAU
20148092282 soft
Motivo: Soy el autor del documento
Fecha: 22.10.2021 18:06:09 -05:00

UNMSM

Firmado digitalmente por GARCIA
ZAPATA Teonila Doria FAU
20148092282 soft
Motivo: Soy el autor del documento
Fecha: 23.10.2021 12:58:32 -05:00

Dr. CEVALLOS AMPUERO JUAN MANUEL
Presidente

Dra. GARCÍA ZAPATA TEONILA DORIA
Miembro

Dr. TEJADA MUÑOZ GUILLERMO
Miembro

Dr. ROSALES LOPEZ PEDRO PABLO
Miembro

Dr. CACHAY BOZA ORESTES
Asesor

Dedicatoria

A mi esposa y a nuestros hijos.

A Lucila mi madre amada.

A Alejandro mi padre; en el cielo.

Agradecimientos

Este trabajo se realizó sin duda con el apoyo de las personas más importantes en mi vida: Mi familia a quienes agradezco su paciencia, tolerancia, amor y comprensión todo este largo tiempo: los Amo.

Expreso mi agradecimiento al Vice Rectorado de Investigación y Posgrado VRI-UNMSM por el apoyo brindado al proyecto con código 161701071 “*Algoritmos genéticos en el problema de distribución de planta*” del cual fui responsable; el auspicio permitió sentar las bases iniciales de la presente tesis. Agradezco a mi Asesor el Dr. Orestes Cachay Boza quien, a pesar de su recargada agenda como autoridad de la UNMSM, siempre estuvo dispuesto a recibirme y darse el tiempo para revisar los avances del trabajo: Gracias Dr. Orestes. También agradezco a mi Maestro el ingeniero Eduardo Raffo Lecca, quien me propuso la idea inicial del tema, Eduardo maestro y amigo; eres grande entre los grandes, muchas gracias por todas tus enseñanzas. Mención especial al Dr. Adolfo Acevedo Borrego, por el aporte inicial en la matriz de consistencia del proyecto, al Dr. Alfonso Ramon Chung Pinzás, por el planteamiento inicial de los experimentos.

Finalmente debo agradecer a todos aquellos innumerables y destacados académicos e investigadores de talla mundial, dedicados al tema del Facility Layout Planning Problem (FLP), los algoritmos genéticos y las metaheurísticas, a quienes cito en el documento y también en la sección de referencias; porque gracias a ellos, es posible el aporte que se presenta en esta tesis. Sin duda tal como lo expresó Isaac Newton (1643 – 1727): “*Si he logrado ver más lejos ha sido porque he subido a hombros de gigantes*”. En ese sentido, humildemente expreso que todos ellos, son verdaderos gigantes, son ellos los que abren el camino y permiten acercarse al noble objetivo de la ciencia que es la creación de conocimiento.

Índice General

Índice General	v
Lista de tablas	viii
Lista de figuras	xi
Resumen	xv
Abstract	xvi
CAPITULO 1: INTRODUCCIÓN	1
1.1 Situación problemática	1
1.2 Formulación del problema	3
1.3 Justificación de la investigación	3
1.3.1 <i>Justificación teórica</i>	4
1.3.2 <i>Justificación práctica</i>	5
1.4 Objetivos de la investigación	5
1.4.1 <i>Objetivo</i>	5
1.4.2 <i>Objetivos específicos</i>	6
CAPITULO 2: MARCO TEORICO	7
2.1 Marco filosófico o epistemológico de la investigación	7
2.1.1 <i>Naturaleza de los problemas</i>	8
2.1.2 <i>Las heurísticas y las metaheurísticas</i>	9
2.1.3 <i>Optimización: Una visión resumida</i>	11
2.1.4 <i>La complejidad de la resolución de problemas</i>	13
2.1.5 <i>La teoría computacional de la complejidad en términos de los problemas P y NP</i>	15
2.2 Antecedentes del problema	20
2.2.1 <i>Metodologías empleadas para resolver problemas de optimización</i>	38
2.2.2 <i>Clasificación de las metaheurísticas</i>	40
2.3 Metodología de los algoritmos evolutivos (EAs) y algoritmos genéticos (AGs)	42
2.3.1 <i>Algoritmos genéticos y distribución de plantas</i>	44

2.4 El árbol de cortes	47
2.4.1 <i>Determinación del árbol de cortes</i>	48
2.4.2 <i>Determinando la distribución layout optima</i>	51
2.4.3 <i>Los operadores genéticos</i>	54
2.4.4 <i>La nueva propuesta de Tam</i>	57
2.4.5 <i>Formulación del modelo</i>	59
2.5 Glosario	61
CAPITULO 3: METODOLOGIA	63
3.1 Hipótesis general	63
3.1.1 <i>Hipótesis específicas</i>	63
3.2 Identificación de variables	64
3.2.1 <i>Variables dependientes</i>	64
3.2.2 <i>Variables independientes</i>	64
3.3 Operacionalización de variables	65
3.4 Tipo y diseño de investigación	66
3.5 El algoritmo propuesto	67
3.5.1 <i>Paso 1: Buscar el árbol con el mejor potencial geométrico</i>	68
3.5.2 <i>Paso 2: Buscar el árbol de cortes que represente la mejor solución</i>	88
3.6 Unidad de análisis	91
3.6.1 <i>Caso I: Tam 8 (T8)</i>	96
3.6.2 <i>Caso II: Van Camp (vC10)</i>	101
3.6.3 <i>Caso III: Bazaraa 14 (B14)</i>	106
3.6.4 <i>Caso IV: Armour y Buffa 20 (AB20)</i>	111
3.7 Población de estudio	117
3.8 Tamaño de la muestra	118
3.9 Selección de la muestra	118
3.10 Técnicas de recolección de datos	120
3.11 El algoritmo ALGOCYM	124
3.11.1 <i>Diagramas del algoritmo</i>	124
3.12 La implementación informática	131
3.12.1 <i>Objetivos del diseño de la aplicación</i>	132
3.13 Detalles del uso de la aplicación	139
3.13.1 <i>Ingreso de datos – Paso 1</i>	139

3.13.2 <i>Ejecución de una solución</i>	146
3.13.3 <i>Ingreso de datos – Paso 2</i>	157
CAPITULO 4: RESULTADOS Y DISCUSION	163
4.1 Análisis y discusión de resultados	163
4.1.1 Caso I: Tam 8 – T8	163
4.1.2 Caso II: van Camp – vC10	173
4.1.3 Caso III: Bazaraa 14 – B14	177
4.1.4 Caso IV: Armour & Buffa 20 – AB20	182
4.2 Análisis y discusión de los tiempos de ejecución	187
4.2.1 Caso I: Tam 8 – T8	187
4.2.2 Caso II: van Camp – vC10	190
4.2.3 Caso III: Bazaraa 14 – B14	192
4.2.4 Caso IV: Armour y Buffa 20 – AB20	195
4.2.5 Tiempos promedios totales	197
4.3 Comparación de resultados	202
4.4 Aportes de la tesis	206
CONCLUSIONES	209
RECOMENDACIONES	213
REFERENCIAS	214
ANEXOS	224
ANEXO 1 Operacionalizacion de variables	225
ANEXO 2 Matriz de consistencia	227
ANEXO 3 Resultados experimentales caso I.- Tam 8	228
ANEXO 4 Resultados experimentales caso II.- van Camp vC10	233
ANEXO 5 Resultados experimentales caso III.- Bazaraa B14	235

Lista de tablas

Tabla 1 Clasificación de las metaheurísticas	41
Tabla 2 Aplicaciones y técnicas usadas por los GA en FLP	45
Tabla 3 Identificación de variables	65
Tabla 4 Matriz de flujos para 5 departamentos (Tam5)	67
Tabla 5 Departamentos y ratios de aspecto (Tam5)	67
Tabla 6 Número de árboles de corte para n instalaciones	69
Tabla 7 Selección por ruleta para Tam 5 aplicando ALGOCYM	86
Tabla 8 Matriz de flujos para Tam de 8 departamentos (Tam8)	92
Tabla 9 Matriz de flujos para van Camp de 10 departamentos (vC10)	93
Tabla 10 Matriz de flujos para Bazaraa de 14 departamentos (B14)	93
Tabla 11 Matriz de flujos para Armour y Buffa de 20 departamentos (AB20)	94
Tabla 12 Parámetros Layout I	94
Tabla 13 Parámetros Layout II	95
Tabla 14 Caso I: Tam8 - Paso 1 – Datos de entrada	96
Tabla 15 Caso I: Tam 8 - Paso 2 – Datos de entrada	98
Tabla 16 Caso II: van Camp vC10 - Paso 1 – Datos de entrada	101
Tabla 17 Caso II: van Camp vC10 - Paso 2 – Datos de entrada	103
Tabla 18 Caso III: Bazaraa 14 - Paso 1 – Datos de entrada	106
Tabla 19 Caso III: Bazaraa 14 - Paso 2 – Datos de entrada	108
Tabla 20 Caso IV: Armour & Buffa AB20 - Paso 1 – Datos de entrada	111
Tabla 21 Caso IV: Armour & Buffa AB20 - Paso 2 – Datos de entrada	113
Tabla 22 Experimentos Caso IV AB20 – Paso 1	122
Tabla 23 Experimentos Caso IV AB20 – Paso 2	123
Tabla 24 Configuración del servidor en la nube	135
Tabla 25 Ratios de proximidad para Algocym	145
Tabla 26 Diseño de experimento para determinar el tamaño de la muestra	164
Tabla 27 Estadísticos descriptivos del tamaño de la muestra con relación al porcentaje de mutación	165

Tabla 28 Resultados de ANOVA para tamaño de la muestra con relación al porcentaje de mutación	167
Tabla 29 Diseño de experimento para encontrar el mejor árbol de cortes	170
Tabla 30 Prueba de igualdad de Levene de varianzas de error	171
Tabla 31 Prueba ANOVA para el paso 1. Caso Tam 8	172
Tabla 32 Comparaciones múltiples	172
Tabla 33 Prueba de igualdad de Levene de varianzas de error	174
Tabla 34 Prueba ANOVA para el paso 1. Caso vC10	174
Tabla 35 Comparaciones múltiples	175
Tabla 36 Subconjuntos homogéneos	176
Tabla 37 Prueba de igualdad de Levene de varianzas de error	177
Tabla 38 Prueba ANOVA para el paso 1. Caso Bazara 14	178
Tabla 39 Comparaciones múltiples	178
Tabla 40 Subconjuntos homogéneos	180
Tabla 41 Prueba de igualdad de Levene de varianzas de error	181
Tabla 42 Pruebas de efectos inter-sujetos	181
Tabla 43 Subconjuntos homogéneos	182
Tabla 44 Prueba de igualdad de Levene de varianzas de error	183
Tabla 45 Pruebas de efectos inter-sujetos	184
Tabla 46 subconjuntos homogéneos	184
Tabla 47 Prueba de igualdad de Levene de varianzas de error	185
Tabla 48 Pruebas de efectos inter-sujetos	186
Tabla 49 Subconjuntos homogéneos	186
Tabla 50 Tiempos promedio de ejecución de los cuatro casos – Paso 1	197
Tabla 51 Tiempos promedios de ejecución expresados en porcentajes – Paso 1	199
Tabla 52 Tiempos promedio de ejecución de los cuatro casos – Paso 2	199
Tabla 53 Tiempos promedios de ejecución expresados en porcentajes – Paso 2	200
Tabla 54 Tiempos promedios totales	201
Tabla 55 Resumen de datos iniciales de los cuatro casos	202
Tabla 56 Comparación de valores de la función de adaptación con otros autores	203
Tabla 57 Tiempos en segundos empleados en obtener la solución	205

Tabla 58 Operacionalización de variables	225
Tabla 59 La matriz de consistencia	227
Tabla 60 Experimentos para una población de 30 individuos	228
Tabla 61 Experimentos para una población de 60 individuos	229
Tabla 62 Experimentos para una población de 100 individuos	230
Tabla 63 Tam 8: Paso 1 Obtener el mejor árbol de cortes	231
Tabla 64 Tam 8: Paso 2 Obtener el mejor layout	232
Tabla 65 Van Camp vC10: Paso 1 Obtener el mejor árbol de cortes	233
Tabla 66 Van Camp vC10: Paso 2 Obtener el mejor layout	234
Tabla 67 Bazaraa 14: Paso 1 Obtener el mejor árbol de cortes	235
Tabla 68 Bazaraa 14: Paso 2 Obtener el mejor layout	236

Lista de figuras

Figura 1 Definición de heurístico, ca	9
Figura 2 Modelamiento clásico versus modelamiento en el contexto de las ciencias de la complejidad	14
Figura 3 Clases de problemas P y NP	16
Figura 4 Identificación de los problemas P vs. NP	18
Figura 5 Marco para un posible algoritmo hiperheurístico	19
Figura 6 Seudocódigo para un algoritmo evolutivo	44
Figura 7 Floorplan y su representación mediante un árbol de cortes	48
Figura 8 Tipos de corte para los nodos de un árbol	50
Figura 9 Codificación de la distribución de un árbol de cortes	51
Figura 10 Actividades según su orientación fija y libre	52
Figura 11 Cruce en un único punto	56
Figura 12 Mutación	57
Figura 13 Codificación de un individuo	59
Figura 14 Número de instalaciones versus número de árboles de corte	69
Figura 15 Obtención de árboles de corte y codificación de cadenas en ALGOCYM para el caso Tam5	71
Figura 16 Decodificación de cadenas (cromosomas) según ALGOCYM para obtener el árbol de cortes que representan para Tam5	72
Figura 17 Configuraciones posibles al aplicar un corte en un árbol de cortes	74
Figura 18 Dominio mediante ratio alto-ancho y mediante ángulo	74
Figura 19 Cromosoma que representa un individuo no viable	81
Figura 20 Operador de cruce en ALGOCYM para Tam 5	83
Figura 21 Operador de mutación en ALGOCYM para Tam 5	84
Figura 22 Selección por la ruleta para 6 individuos en Tam 5 aplicando ALGOCYM	87
Figura 23 Codificación del paso 2 en ALGOCYM que obtiene el layout óptimo para Tam 5	89
Figura 24 Representación de las distancias euclídea y manhattan entre dos puntos P y Q	91
Figura 25 Árbol de cortes obtenido por Algocym para Tam8 en el paso 1	97
Figura 26 Evolución de las generaciones para Tam8 – Paso 1	98

Figura 27 Layout óptimo para Tam 8 – Paso 2	100
Figura 28 Evolución de las generaciones para Tam 8 – Paso 2	101
Figura 29 Árbol de cortes obtenido por Algocym para vC10 en el paso 1	102
Figura 30 Evolución de las generaciones para vC 10 – Paso 1	103
Figura 31 Layout óptimo para vC10 – Paso 2	105
Figura 32 Evolución de las generaciones para vC 10 – Paso 2	105
Figura 33 Árbol de cortes obtenido por Algocym para B14 en el paso 1	107
Figura 34 Evolución de las generaciones para B14 – Paso 1	108
Figura 35 Layout óptimo para B14 – Paso 2	110
Figura 36 Evolución de las generaciones para B14 – Paso 2	111
Figura 37 Árbol de cortes obtenido por Algocym para AB20 en el paso 1	112
Figura 38 Evolución de las generaciones para AB20 – Paso 1	113
Figura 39 Layout óptimo para AB20 – Paso 2	116
Figura 40 Evolución de las generaciones para AB20 – Paso 2	116
Figura 41 Abstracción básica de Algocym	124
Figura 42 Diagrama de flujo del paso 1	125
Figura 43 Procedimiento para generar población de árboles de corte de tamaño n	126
Figura 44 Procedimiento para determinar el punto de cruce - operador de cruce	127
Figura 45 Procedimiento para el operador de mutación	128
Figura 46 Procedimiento para intensificar la búsqueda en la selección	129
Figura 47 Diagrama de flujo del paso 2	130
Figura 48 Procedimiento para el elitismo	131
Figura 49 Logotipo de Odoo ERP	132
Figura 50 Aplicaciones que pueden realizarse con Odoo	133
Figura 51 Logotipo de PosgreSQL	133
Figura 52 Logotipo de Google Cloud	134
Figura 53 Modelo conceptual de los servicios Docker en Linux	135
Figura 54 Diagrama de clases UML para ALGOCYMY	137
Figura 55 La aplicación Algocym	139
Figura 56 Detalles iniciales de la aplicación Algocym	140
Figura 57 Caja de dialogo Crear Problema	141
Figura 58 Ingresar matriz de flujos (pestaña Flow)	142

Figura 59 Clic en Agregar línea	143
Figura 60 Ingreso uno a uno en la matriz de flujos	143
Figura 61 Pestaña establecer relaciones	144
Figura 62 Ratios de proximidad para Algocym	145
Figura 63 Ingreso de parámetros Paso 1	146
Figura 64 Botón Ejecutar Paso 1	147
Figura 65 Programación concurrente en Algocym	147
Figura 66 Botón Obtener mejor árbol	148
Figura 67 Pestaña ejecuciones Paso 1	149
Figura 68 Vista de la base de datos de las ejecuciones del paso 1	149
Figura 69 Detalles de resultados de la ejecución del paso 1 para el mejor árbol	150
Figura 70 Conformación del mejor árbol de cortes	151
Figura 71 Detalles finales del mejor árbol de círculos	152
Figura 72 Parámetros de entrada y los tiempos del algoritmo en el paso 1	153
Figura 73 Vista de la base de datos de las ejecuciones en el paso 1	154
Figura 74 Exportando los datos de una generación hacia una hoja de cálculo	154
Figura 75 Aplicando filtros para una determinada generación	155
Figura 76 Agrupando los resultados de una generación	155
Figura 77 Generación 222 del paso 1 (parte 1)	156
Figura 78 Generación 222 del paso 1 (parte 2)	156
Figura 79 Detalles del individuo 19 de la generación 222	157
Figura 80 Ingreso de parámetros del paso 2	158
Figura 81 Ejecuciones del paso 2	159
Figura 82 Obteniendo el mejor layout en el paso 2	159
Figura 83 Detalles de la mejor solución del paso 2	160
Figura 84 Resultados del paso 2	161
Figura 85 Generaciones del paso 2	162
Figura 86 Detalles de una generación en el paso 2	162
Figura 87 Gráfica de residuos función de adaptación para un tamaño de muestra igual a 30	168
Figura 88 Gráfica de residuos función de adaptación para un tamaño de muestra igual a 60	168

Figura 89 Grafica de residuos función de adaptación para un tamaño de muestra igual a 100	169
Figura 90 Tam 8: Tiempos de ejecución para 10 réplicas – Paso 1	187
Figura 91 Tam 8: Tiempos promedio – Paso 1	188
Figura 92 Tam 8: Tiempos promedio (porcentual) – Paso 1	188
Figura 93 Tam 8: Tiempos promedio – Paso 2	189
Figura 94 Tam 8: Tiempos promedio (porcentual) – paso 2	189
Figura 95 vC10: Tiempos de ejecución para 10 réplicas – Paso 1	190
Figura 96 vC10: Tiempos promedio – Paso 1	190
Figura 97 vC10: Tiempos promedio (porcentual) – Paso 1	191
Figura 98 vC10: Tiempos promedio – Paso 2	191
Figura 99 vC10: Tiempos promedio (porcentual) – Paso 2	192
Figura 100 B14: Tiempos de ejecución para 10 réplicas – Paso 1	192
Figura 101 B14: Tiempos promedio – Paso 1	193
Figura 102 B14 Tiempos promedio (porcentual) – Paso 1	193
Figura 103 B14: Tiempos promedio – Paso 2	194
Figura 104 B14: Tiempos promedio (porcentual)– Paso 2	194
Figura 105 AB20: Tiempos de ejecución para 10 réplicas – Paso 1	195
Figura 106 AB20: Tiempos promedio – Paso 1	195
Figura 107 AB20: Tiempos promedio (porcentual) – Paso 1	196
Figura 108 AB20: Tiempos promedio – Paso 2	196
Figura 109 AB20: Tiempos promedio (porcentual) – Paso 2	197
Figura 110 Gráfico lineal de tiempos promedio de los cuatro casos – Paso 1	198
Figura 111 Gráfico lineal de tiempos promedio de los cuatro casos – Paso 2	200
Figura 112 Histograma de los tiempos promedios totales	201

Resumen

El objetivo de la investigación es desarrollar un algoritmo genético para optimizar la distribución en planta en organizaciones de manufactura. Al ser este, un problema combinatorio de optimización, el algoritmo resulta de gran utilidad en la toma de decisiones. Esta investigación es de tipo experimental por simulación. Se propone un algoritmo en dos pasos que emplea la estructura del árbol de cortes y la metodología por algoritmos genéticos. Para probar el algoritmo se desarrolla una aplicación informática que combina programación genética, programación concurrente y se ejecuta en la nube bajo el sistema operativo Linux. El algoritmo obtiene una solución a cuatro casos experimentales conocidos en la temática: Tam de ocho, Van Camp de diez, Bazaraa de catorce, Armour y Buffa de veinte instalaciones respectivamente; considerando dimensiones como: área total, área individual, ratios, flujos, y relaciones entre ellos. El estudio experimental se propone en bloques, estableciendo combinaciones entre porcentajes de cruce (de 0.6 a 0.9), porcentajes de mutación (0.05, 0.08, 0.1, 0.2, 0.3) y elitismo. Los resultados de las pruebas estadísticas ANOVA aplicados a tamaños de población de 30, 60, 100 individuos, conducen a determinar que el tamaño de 30 individuos es significativo. En cuanto a la mutación, se encuentra que un nivel de 5 por ciento es significativo para encontrar resultados óptimos; en tanto el grado de aplicación del operador de cruce es no significativo. Respecto a los tiempos de ejecución, se determina que las operaciones de evaluación y selección consumen mayor tiempo frente a las de cruce, mutación y elitismo.

Palabras clave

Distribución en planta, algoritmo genético, optimización, operadores de cruce y mutación, árbol de cortes.

Abstract

The objective of the research is to develop a genetic algorithm to optimize the plant distribution in manufacturing organizations. As this is a combinatorial optimization problem, the algorithm is very useful when making decisions. This research is quasi-experimental by simulation. A two-step algorithm is proposed that uses the cut tree structure and the methodology by genetic algorithms. To test the algorithm, a computer application is developed that combines genetic programming, concurrent programming, and runs on cloud under the Linux operating system. The algorithm obtains a solution to four known experimental cases on the subject: Tam of eight, Van Camp of ten, Bazaraa of fourteen and Armor and Buffa of twenty installations respectively; considering dimensions such as: total area, individual area, ratios, flows, and relationships between them. The experimental study is proposed in blocks, establishing combinations between percentages of crossing (from 0.6 to 0.9), percentages of mutation (0.05, 0.08, 0.1, 0.2, 0.3) and elitism. The results of the ANOVA statistical tests applied to population sizes of 30, 60, 100 individuals, lead to determine that the size of 30 individuals is significant. Regarding the mutation, it is found that a level of 5 percent is significant to find optimal results, while degree of application of the operator of crossing is not significant. In regard to the execution times, it is determined that the evaluation and selection operations consume more time compared to those of crossing, mutation and elitism .

Key words

Facility layout, genetic algorithm, optimization, crossover and mutation operators, slicing tree.

CAPITULO 1: INTRODUCCIÓN

1.1 Situación problemática

La distribución en planta es un problema que se plantea como la colocación de un conjunto de departamentos de área conocida y desigual en un área o región plana de dimensiones largo y anchos conocidos; sin que existan solapamientos entre ellos. El objetivo es que se minimicen los costos asociados a la interacción entre ellos. Los costos asociados a la distribución de los departamentos reflejan tanto los costos de transporte de materiales entre departamentos, como los derivados del incumplimiento de ciertas preferencias de carácter cualitativo y cuantitativo, como por ejemplo, la necesidad de adyacencia o precedencia entre determinadas instalaciones derivadas del propio sistema productivo o la existencia de condiciones que garanticen la seguridad e higiene en el trabajo (Diego-Más, 2006).

Según (Tompkins et al., 84) en las operaciones de manufactura de los

gastos totales se puede atribuir entre un 20 y un 50% al transporte de materiales, por lo que una distribución adecuada de las actividades y sus colocaciones pueden reducir estos costos entre un 10 al 30%.

Adicionalmente, en organizaciones de manufactura la distribución en planta es de suma importancia ya que mediante ella se logra un uso ordenado de las áreas de trabajo de manera tal que se optimice el uso de espacios (instalaciones), que redundan en menores costos y tiempos.

Según (Gupta y Seifoddini, 2007) un tercio de las empresas estadounidenses se someten a una reorganización importante de sus

instalaciones de producción cada dos años, y por término medio, el 40% de las ventas de una empresa proceden de nuevos productos (Drira et al., 2007). En (Hosseini-Nasab et al., 2018) se indica que de acuerdo con Shore y Tompkins, algunos de los factores que provocan un cambio en el flujo de materiales entre las instalaciones de manufactura son:

1. Ciclos de vida más cortos del producto.
2. Cambios en el diseño de un producto existente.
3. Adición o eliminación de un producto.
4. Cambios en las cantidades de producción y los programas asociados de producción.
5. Reemplazo de equipo de producción existente.

Lo anterior denota la importancia de una adecuada distribución de las instalaciones en los procesos de manufactura en general. En ese sentido los tomadores de decisiones procuran soluciones optimas a este tipo de problemas en gestión de operaciones. En esta clase de problemas existe un conjunto de ellos que son difíciles de resolver. Este tipo de problemas en el ámbito académico se conocen como NP-hard" (Non Polynomial hard) que puede traducirse como "problemas difíciles no polinomiales". En este conjunto de problemas se encuentran: el problema del agente viajero TSP (Travelling Salesman Problem), la secuenciación de proyectos PS (Project Scheduling), el problema de la programación o secuenciación de tareas JSP (Job Shop Scheduling Problem), la localización y/o distribución de instalaciones conocido como el FLP (Facility Layout Planning Problem) (Ruiz, 2014). Para este conjunto de problemas existe una gran variedad de métodos que aproximan a la solución.

La presente investigación plantea un algoritmo genético de operadores de cruce y mutación para la optimización del problema de la distribución en planta, mediante la metodología de los algoritmos genéticos.

1.2 Formulación del problema

Problema general

¿Cómo debe ser el algoritmo genético de operadores de cruce y mutación ALGOCYM que permita optimizar la distribución en planta en organizaciones de manufactura?

Problemas específicos

- a) ¿Cómo se aplica el árbol de cortes por algoritmos genéticos para optimizar el área de la distribución en planta?
- b) ¿Cómo es el algoritmo genético ALGOCYM que genera una solución óptima del problema de distribución en planta?
- c) ¿Cómo se plantean los experimentos numéricos con el algoritmo genético ALGOCYM para cuantificar sus resultados?
- d) ¿Cómo es el diseño e implementación de la aplicación informática que pruebe la bondad del algoritmo genético ALGOCYM?

1.3 Justificación de la investigación

La distribución de planta es aplicable a aquellos eventos donde es necesaria la disposición de unos medios físicos (instalaciones o máquinas) en procesos industriales o de servicios, por lo que en muchas situaciones representa un problema complejo. En ese sentido la presente investigación propone un algoritmo genético que contribuya a generar conocimiento en el tema del layout de planta en las organizaciones de manufactura.

1.3.1 Justificación teórica

La utilización de los algoritmos genéticos AG, son una clase de métodos aproximados que están diseñados para resolver problemas difíciles de optimización combinatoria, donde los métodos tradicionales, no son efectivos (Nathan & Scobell, 2012).

Según (Anjos & Vieira, 2017) los problemas de distribución de instalaciones FLP, son una clase importante de problemas de investigación de operaciones que viene estudiándose en las últimas décadas. Para los autores la mayoría de las variantes del diseño de las instalaciones constituyen problemas NP-hard (NP-difíciles); pues las soluciones optimas globales son difíciles o imposibles de calcular en un tiempo razonable de cómputo. No obstante, se tiene enfoques de optimización matemática que garantizan la optimización global de las soluciones estableciendo límites en las restricciones en cuanto al valor óptimo global que se aplica con éxito a variantes del diseño de las instalaciones.

La presente investigación pretende contribuir con una solución óptima al problema que tiene toda organización manufacturera, en torno a la toma de decisiones que implica establecer la configuración o el diseño de sus instalaciones. Para ello se revisa los conceptos y fundamentos de los algoritmos y la programación genética, con miras a plantear un algoritmo genético que aplique los operadores de cruce y mutación en la búsqueda de soluciones al problema de la distribución de instalaciones FLP.

El desarrollo del presente tema de investigación constituye un aporte al conocimiento y metodología de los algoritmos genéticos aplicados a la búsqueda de soluciones optimas del FLP.

Una vez optimizada la distribución en planta, en muchas situaciones ayuda al mejoramiento de la calidad y puede reducir hasta en un 50% del total de los costos operativos de la empresa (G. Aiello et al., 2013).

1.3.2 Justificación práctica

Esta investigación propone un algoritmo genético a partir de la revisión de los algoritmos genéticos existentes aplicados al problema de distribución en planta, tal que brinde una solución óptima al problema FLP. El algoritmo se elabora a partir de la aplicación de los operadores de cruce, mutación para generar soluciones factibles que resuelven el problema del arreglo físico de las instalaciones en una planta; problema que envuelve restricciones en la forma de las configuraciones geométricas, en las precedencias o en los espacios mínimos y máximos requeridos dentro de un área no cuadrada de dimensiones conocidas.

Por ello la presente investigación beneficiara a toda aquella organización manufacturera que pretenda optimizar la distribución en planta de sus instalaciones (FLP) mediante la aplicación de un algoritmo genético.

1.4 Objetivos de la investigación

1.4.1 *Objetivo*

Desarrollar el algoritmo genético de operadores de cruce y mutación ALGOCYM que permita optimizar la distribución en planta en organizaciones de manufactura.

1.4.2 *Objetivos específicos*

- a) Aplicar el árbol de cortes por algoritmos genéticos para optimizar el área de la distribución en planta.
- b) Elaborar un algoritmo genético (ALGOCYM) que genere una solución óptima al problema de la distribución en planta.
- c) Plantear experimentos numéricos para cuantificar los resultados del algoritmo genético ALGOCYM.
- d) Diseñar e implementar la aplicación informática que pruebe la bondad del algoritmo genético ALGOCYM.

CAPITULO 2: MARCO TEORICO

2.1 Marco filosófico o epistemológico de la investigación

La presente tesis trata del uso y aplicación de las metaheurísticas como una metodología de investigación para proponer una solución o aproximar una solución a problemas complejos. Acerca de esta clase de problemas Maldonado, anota lo siguiente:

“Las metaheurísticas constituyen uno de los conjuntos de las metodologías en el trabajo y la investigación con fenómenos, sistemas y comportamientos caracterizados por no-linealidad, autoorganización, complejidad creciente, emergencia (de emergente) y otras propiedades semejantes y conocidas”

(Maldonado, 2016).

Dado el tema del presente estudio, es conveniente plantear el marco filosófico o epistemológico en el que se sostiene la propuesta de esta tesis. Para ello, se plantea revisar la naturaleza de los problemas complejos, las heurísticas y las metaheurísticas, la optimización, la complejidad de la resolución de problemas y la teoría computacional de la complejidad en términos de los problemas P y NP.

2.1.1 *Naturaleza de los problemas*

El esquema tradicional del quehacer científico ha sufrido en las últimas décadas profundas y numerosas transformaciones. Se sabe que la filosofía se ocupa de responder preguntas y problemas. Por ejemplo: ¿Qué es el hombre?, ¿De dónde viene?, ¿Hacia a dónde va?, ¿Qué es la libertad?, y preguntas similares. Por otro lado: el encontrar la solución a un problema o establecer que dicho problema puede tener una solución; esto es el que hacer de la ciencia (Maldonado, 2016). En este contexto, el que hacer de la ciencia consiste en resolver problemas.

En el sentido tradicional la ciencia se ocupa de “objetos” y por derivación de “temas”, de “campos”, lo que deviene en ciencia clásica, (Maldonado, 2013). Sin embargo, con los aportes de Imre Lakatos, en el contexto de la discusión entre Khun y Popper en cuanto a los criterios de demarcación de la ciencia (Stadler, 2010) se establecen los “criterios de demarcación” acuñados por la Escuela de Viena en cuanto a la distinción entre la ciencia y la metafísica, (Maldonado, 2016).

En el contexto de diferenciación entre los “programas de investigación científicos” y “los programas de investigación metafísicos” es que aparece el concepto de heurística. Lakatos sostiene de manera frontal que la ciencia trata con problemas, y que lo concerniente a la investigación científica es desarrollar unos criterios de identificación y solución de un problema dado. Para (Michalewicz, Z.; Fogel, 2000) eso es exactamente la heurística.

Actualmente la ciencia se ocupa de “problemas”, de “resolver problemas”. Los problemas se pueden clasificar en problemas fáciles y problemas difíciles o problemas complejos. Dicho en términos actuales, la ciencia ahora; se encarga esencialmente de formular problemas, estas formulaciones son tarea de los científicos que tienen un espíritu o una sensibilidad filosófica, (Maldonado, 2016).

2.1.2 ***Las heurísticas y las metaheurísticas***

Según el diccionario de la lengua española se tiene el siguiente significado acerca de la palabra heurística, ver figura 1.

Figura 1

Definición de heurístico, ca

Del gr. εὑρίσκειν **heurískein** 'hallar', 'inventar' y -tico.

1. adj. Perteneciente o relativo a la **heurística**.
2. f. Técnica de la indagación y del descubrimiento.
3. f. Búsqueda o investigación de documentos o fuentes históricas.
4. f. En algunas ciencias, manera de buscar la solución de un problema mediante métodos no rigurosos, como por tanteo, reglas empíricas, etc.

Fuente: REAL ACADEMIA ESPAÑOLA: Diccionario de la lengua española, 23.^a ed., [versión 23.3 en línea]. <<https://dle.rae.es>> [Fecha de la consulta: 20 de setiembre de 2020].

En tanto la palabra meta heurística o metaheurística no existe en el diccionario de la Real academia española.

El sentido actual de la palabra heurística fue introducido por Imre Lakatos quién hace referencia a la búsqueda de la solución a un problema en términos exactos. De otro lado las metaheurísticas trabajan con un *conjunto de problemas* en la *búsqueda de espacios de solución*. Dicho de otro modo, las metaheurísticas desplazan la búsqueda de soluciones exactas o precisas, para enfocarse en soluciones aproximadas; las mismas que paradójicamente, suelen ser más precisas y exactas que las heurísticas (Maldonado, 2016).

De acuerdo con (Doerner et al., 2007), las meta heurísticas nacen y prosperan con el desarrollo de las ciencias de la computación, especialmente en el estudio y la aplicación a problemas de optimización. El

fundamento de las meta heurísticas son las matemáticas aplicadas siendo el hilo que las une los algoritmos – justamente la aplicación a la resolución de problemas de optimización (Boschetti, Marco Antonio; Maniezzo, Vittorio; Roffilli, Matteo; Röhler, 2009)

Un algoritmo es un conjunto ordenado y finito de operaciones que permite hallar la solución de un problema (Real Academia Española, 2019). Una ventaja de las metaheurísticas es la de ser por su naturaleza exploratorias y abiertas, no restrictivas ni axiomáticas (Chen et al., 2016). Las metaheurísticas operan mediante algoritmos (Maldonado, 2016), con la característica que estos, no son comunes; pues son especiales, puesto que no se rigen por un patrón predictivo, ni causal, ni organizado; si no que son por naturaleza aleatorios. Dentro de este enfoque el algoritmo adquiere su “forma óptima” mediante sucesivas iteraciones o pruebas que se aproximan cada vez más a la solución, dentro del espacio solución, por ejemplo, mediante métodos de búsqueda basados en gradientes (Chen et al., 2016).

Dentro de las ramas de la teoría de la computación, la teoría computacional de la complejidad consiste en estudiar, clasificar e identificar los problemas computacionales en función a su dificultad. El primero y tal vez el más importante y estudiado de los problemas computacionales (o de optimización) es el problema del agente viajero (o del vendedor viajero), que fue inicialmente formulado en los años de 1930 (Maldonado, 2016). En términos computacionales se dice que un problema es complejo en función o correspondencia con el tiempo necesario de computación para hallar su solución o resolución, de otro modo, se dice que está en correspondencia, según la longitud de un lenguaje computacional (lenguaje de programación); es decir, la expresividad del lenguaje que permite formular el problema y resolverlo.

Resumiendo, la complejidad de un problema está en correspondencia con la complejidad computacional del mismo.

Los algoritmos metaheurísticos más conocidos son los algoritmos genéticos (Genetic Algorithms – GA), la búsqueda tabú (Tabú Search – TS), algoritmos de optimización por colonia de hormigas (Ant Colony Optimization - ACO), el recocido simulado (Simulated Annealing – SA), los de optimización por partículas de enjambre (Particle Swarm Optimization - PSO) y los algoritmos evolutivos (Evolutionary Algorithms – EA), los de procedimientos de búsqueda miope, aleatorizados y adaptativos (Greedy Randomized Adaptive Search Procedure - GRASP). Todos estos algoritmos tienen un propósito general que les es común: tratar de recorrer el espacio de soluciones evitando quedar “atrapados” en aquellas zonas conocidas como óptimos locales, que pueden ser “mínimos locales” o “máximos locales”, según sea el caso, (Maldonado, 2016).

2.1.3 ***Optimización: Una visión resumida***

Los problemas y temas de optimización se dan en ciencia y también en la vida cotidiana, y conciernen por igual a científicos, matemáticos, ingenieros, empresarios, estrategas, tomadores de decisiones en cualquier ámbito (producción, servicios). Este proceso se puede resumir del modo siguiente:

1. Formular o identificar un problema.
2. Construir un modelo que representa el problema. El modelo puede ser: matemático, lógico o computacional.
3. Se procede a optimizar el problema; es decir se busca “una buena solución”.
4. Implementar la solución.

En otras palabras, un problema de optimización consiste en encontrar las soluciones posibles o factibles al problema y expresar las funciones de las soluciones. En ese orden de ideas, el objetivo principal es encontrar el óptimo global de las soluciones. Generalizando, los modelos de optimización incorporan:

1. Modelos de programación matemática.
2. Modelos de optimización combinatoria
3. Modelos de restricciones y
4. Modelos analíticos.

Estos modelos se pueden implementar mediante programación continua, entera y mixta, y se pueden articular como modelos lineales o no lineales (Talbi, 2009).

Lo cierto es que numerosos problemas de optimización son no tratables. Esto significa que en este campo se tiene: problemas decidibles y problemas indecidibles (o no decidibles), estos temas fueron tratados por Hilbert, Turing y Gödel. Se dice que un problema es decidible si es comprensible, y que un problema es indecidible si no existe un algoritmo de solución dados recursos, tiempo y espacios ilimitados. En la “práctica” la complejidad se concentra en el conjunto de problemas decidibles, (Maldonado, 2016).

Resumiendo, la complejidad de un problema equivale a la complejidad del mejor algoritmo para resolverlo. En otras palabras, se dice que un problema es tratable (esto significa, fácil), si existe (o se puede crear) un algoritmo que lo resuelva en tiempo polinomial. En contra parte, si no existe (o no se puede desarrollar) un algoritmo en tiempo polinomial que pueda resolver el problema; se dice entonces, que dicho problema es intratable. Se habla de tiempo polinomial, en el sentido en que el algoritmo puede encontrar la solución en términos de gestión del tiempo expresado en términos de minutos, horas, días, semanas, meses, o incluso años; de manera que la búsqueda de solución al problema se expresa en unidades de tiempo real, (Maldonado, 2016).

2.1.4 *La complejidad de la resolución de problemas*

Los recientes desarrollos en matemáticas, lógica y computación permiten ahora abordar trabajos referentes a optimización los cuales corresponden a problemas de alta complejidad combinatoria.

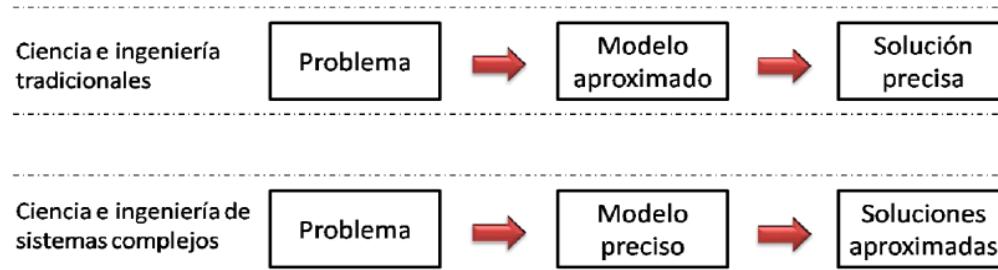
En la actualidad es posible establecer la diferencia entre ciencia clásica y ciencias de la complejidad. En cuanto a la ciencia clásica, esta busca soluciones precisas o exactas a los problemas, aun sabiendo que estos modelos pueden tener falencias o incluso ser aproximados, (Maldonado, 2016). De otro lado en el marco de la ciencia actual para aquellos problemas o fenómenos de complejidad creciente, se desarrollan o proponen modelos precisos que apuntan a soluciones aproximadas, las cuales resultan ser paradójicamente, más exactas precisas o viables que los que la ciencia y los enfoques normales proponen (Maldonado, 2016).

Adicionalmente es preciso señalar que la expresión “ciencia e ingeniería tradicionales”, y “ciencias de la complejidad e ingeniería de sistemas complejos” deben incluir todos los campos de trabajo e investigación, en el sentido inclusivo y amplio en planos como estudios políticos, económicos, militares, de táctica y estrategia, administración, ciencias sociales, sin dejar de lado los relativos a la educación, (Gómez-Cruz & Maldonado, 2011).

La figura 2, ilustra gráficamente las diferencias entre ciencias e ingeniería tradicionales y ciencias e ingeniería de sistemas complejos.

Figura 2

Modelamiento clásico versus modelamiento en el contexto de las ciencias de la complejidad



Fuente:(Gómez-Cruz & Maldonado, 2011)

Haciendo una generalización las metaheurísticas se pueden clasificar en dos grandes grupos: (a) metaheurísticas orientadas a soluciones singulares y (b) metaheurísticas orientadas a conjuntos de soluciones (aquellas basadas en poblaciones). No obstante, dado el auge de las ciencias de la computación, actualmente se habla de metaheurísticas paralelas (Alba, 2005), distribuidas y metaheurísticas híbridas (Blum et al., 2008). A esto se añaden las hyperheurísticas que están en estrecha relación con las metaheurísticas multinivel y las auto adaptativas. Con todo esto, actualmente las metaheurísticas son un campo vivo de investigación cuya esencia constituye la comprensión de lo que es en sí mismo un problema complejo y en los esfuerzos desplegados para establecer la solución de esta clase de problemas. Este campo de investigación está en proceso (Maldonado, 2015).

Las metaheurísticas abren nuevos campos de trabajo e investigación tales como optimización numérica, algoritmos evolutivos, computación evolutiva, programación evolucionaria, e inteligencia computacional, las mismas que tienen en común resolver problemas (Maldonado, 2016).

2.1.5 *La teoría computacional de la complejidad en términos de los problemas P y NP*

Tal como se ha visto en 2.1.4, el trabajo de las metaheurísticas es proponer algoritmos aproximados y no algoritmos exactos; esto permite tratar temas complejos como los de optimización aun en condiciones de incertidumbre. Estos temas ahora son abordados por las ciencias de la complejidad; es decir permiten abordar la complejidad y avanzar hacia su comprensión y entendimiento.

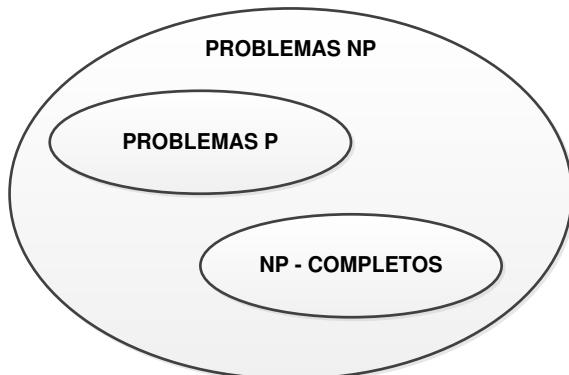
El trabajo con problemas constituye sin duda uno de los rasgos que permite identificar cómo y en qué está trabajando la ciencia actual, la ciencia de punta (Maldonado, 2013). En este punto lo que se debe destacar es que los problemas que trata la ciencia de punta son los problemas de frontera (front-end-problems).

En la literatura acerca de la complejidad, se dice que un problema es de frontera cuando una sola disciplina o ciencia no es capaz de resolverlo por sí misma. De allí, que necesita de otras disciplinas, otras metodologías, otros modelos, otros lenguajes, otros enfoques. Surge entonces la hoy llamada “interdisciplinariedad”. Ahora bien, gracias a los problemas de frontera, emergen ciencias de frontera. Estas constituyen un paso adelante que abandona la tradición disciplinar de la ciencia (Maldonado, 2013).

La presente tesis trata un problema complejo como es el Facility Layout Problem FLP (Problema de Distribución en Planta). Una manera de abordar los problemas complejos es clasificar la complejidad de los problemas de decisión. En ese sentido la clasificación más general son los problemas P (problemas polinomiales) versus NP (problemas no polinomiales) (Fortnow, 2013). La figura 3, ilustra esta clasificación.

Figura 3

Clases de problemas P y NP



Fuente: Recuperado de NP para no matemáticos / El blog de MAHT (wordpress.com)

Fecha de Visita: 23 de noviembre de 2020

Fueron tres los primeros investigadores (de manera independiente, pero simultánea) los que hablaron de los problemas P y NP: (Cook, 1971), (Karp, 1972) y (Levin, 1973). El marco amplio para abordar los problemas P y NP es la lógica en general, sin embargo, la motivación particular es la teoría de la información y más exactamente la teoría de la computación. En el sentido estricto, se trata de los problemas lógicos y matemáticos de la computación que involucran análisis combinatorios y constituyen una sola unidad (Maldonado, 2013).

En el mundo real los problemas se pueden dividir en dos grandes grupos: (1) problemas decidibles y (2) problemas indecidibles. La decidibilidad de un problema hace referencia al famoso decimo problema formulado por D. Hilbert en el congreso mundial de 1900 (Gray, 2006) conocido como problema de detención o de la parada (*Halting problem*) desde el punto de vista de la máquina de Turing (Maldonado, 2013).

Problemas como la vida misma, la justicia, la igualdad, la moral, son problemas indecidibles, dado que no existe un algoritmo que permita resolverlos, incluso si se tuviera dinero y recursos ilimitados. Esto significa

que este tipo de problemas no puede ser abordado mediante las reglas, procedimientos o formulas conocidas y probadas anteriormente (Maldonado, 2013).

En oposición a los problemas indecidibles se encuentran los problemas decidibles. Un problema es decidable cuando es *comprendible*; la compresibilidad hace referencia a un algoritmo o fórmula en el que el problema (o lenguaje o programa) puede ser condensado, resumido o expresado. Por contraste los problemas indecidibles son incomprensibles (Maldonado, 2013).

Según (Maldonado, 2013) Los problemas decidibles se dividen en dos: Los problemas P y los problemas NP. Se dice que los problemas son P cuando son polinomiales; es decir, aquellos problemas que pueden ser abordados y resueltos descomponiendo el problema en los términos que los componen. Ejemplo de esta clase de problemas son todos aquellos que se pueden resolver en términos de fluogramas, diagramas de flujo, diagramas UML o diagramas similares. Adicionalmente se dice que los problemas P computacionalmente se resuelven en un tiempo polinomial; esto significa que el tiempo de solución se puede expresar mediante una función polinómica.

Los problemas P son aquellos problemas que abordan las ciencias normales. En términos de las matemáticas esta clase de problemas son fáciles porque se resuelven o por que se pueden resolver (Maldonado, 2013).

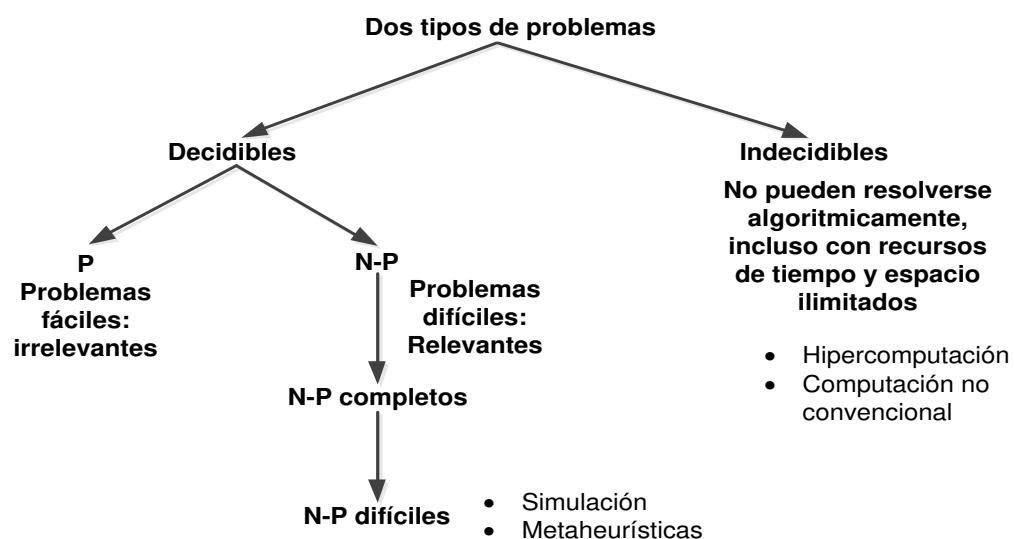
De otro lado, se consideran problemas NP todos aquellos problemas que son no polinomiales, por lo que, en consecuencia, no se abordan, no se pueden descomponer, ni resolver en términos de sus componentes. Sin embargo; esta clase de problemas se puede resolver y deben resolverse en un tiempo polinomial; es decir, en el tiempo práctico que caracteriza las actividades normales de los seres humanos (Maldonado, 2013).

En matemáticas los problemas NP se dice que son problemas difíciles y por lo tanto son problemas relevantes. Para la lógica y las matemáticas, un problema es relevante si no es fácil, si no se resuelve o si no se puede resolver o no se sabe si puede ser resuelto; aun cuando cabe la posibilidad de que eventual u ocasionalmente, se pueda resolver, pero no se tiene certeza de cómo, ni cuando pueda resolverse (Maldonado, 2013).

Dentro del conjunto de problemas NP existen problemas que pueden resolverse en un tiempo polinomial no determinista. A estos problemas se los conoce como problemas NP-difíciles (del inglés *NP-hard*). Así mismo, se tiene los problemas NP-complejos que son aquellos que son NP y al mismo tiempo NP-hard. Una característica de este grupo de problemas es que no es posible situarlos en términos de una solución rápida. Esto significa que el tiempo requerido para solucionar esta clase de problemas crece tan rápidamente como crece el tamaño del mismo problema. En términos simples: el proceso de crecimiento del problema incrementa proporcionalmente el tiempo requerido para su solucionar (Maldonado, 2013). La figura 4, presenta la identificación de los problemas P versus NP.

Figura 4

Identificación de los problemas P vs. NP



Fuente: (Maldonado, 2013)

Como se puede ver en la figura 4, se presenta el termino hipercomputación (hypercomputing). Este término refiere una nueva tendencia emergente en la tecnología moderna de búsqueda de solución a problemas en los últimos 20 años que está llamándose hiperheurísticas (del inglés *hyper-heuristics*) (Johnes.Jill, 2016). La clave de las hiperheurísticas es aplicar una heurística razonablemente conocida que permita transformar el estado de un problema. El sustento de esta afirmación es simple; la fuerza de la heurística a menudo radica en su capacidad para tomar buenas decisiones en el camino hacia la construcción de una excelente solución (Burke et al., 2003).

Por otro lado (Burke et al., 2003) plantean el siguiente marco para un posible algoritmo hiperheurístico (ver figura 5).

Figura 5

Marco para un posible algoritmo hiperheurístico

Inicio Hiperheurístico

1. Comience con un conjunto H de ingredientes heurísticos, cada uno de los cuales es aplicable a un estado problemático y lo transforma en un nuevo estado problemático. Ejemplos de tales ingredientes en bin-packing son solo una iteración de nivel superior de 'Exact Fit' o una única iteración de nivel superior de 'el mayor primero, el primer ajuste';
 2. Haga que el estado del problema inicial sea S_0
 3. Si el estado del problema es S_i , entonces encuentra el ingrediente que en algún sentido es más adecuado para transformar ese estado. Aplicarlo, para obtener un nuevo estado del problema S_{i+1} ;
 4. Si el problema está resuelto, detente. De lo contrario, vaya a 3.
- Fin_Hiperheurístico**

Fuente: (Burke et al., 2003)

El problema del facility layout – FLP, que se trata en la presente tesis es un problema de optimización y pertenece al grupo de problemas NP-

difíciles, cuyo planteamiento de solución es la aplicación de metaheurísticas; siendo los algoritmos genéticos un grupo importante de ellas. Este problema posee una complejidad algorítmica por un lado y por otro lado una complejidad computacional para su implementación, prueba y experimentación.

2.2 Antecedentes del problema

Para estudiar la relevancia del problema y los planteamientos de resolución se presenta una breve descripción de los trabajos de investigación relativos al problema del planeamiento del diseño de las instalaciones (Facility Layout Planning Problem - FLP) en los últimos 5 años.

(Erfani et al., 2020) En esta investigación se estudia el diseño dinámico de las instalaciones y los problemas de programación del taller de manera simultánea. El trabajo mide la sinergia entre estos dos problemas. El artículo propone un modelo de programación no lineal de enteros mixtos de múltiples objetivos donde las áreas de los departamentos son no iguales. En el documento se calcula los puntajes de calificación de lejanía y de cercanía de los departamentos. Otra característica es la consideración de puntos de entrada y salida para cada departamento, que es crucial para el establecimiento de diseños prácticos de instalaciones en el mundo real. Adicionalmente para la programación del problema, se considera que la demora en el transporte entre departamentos y el tiempo de configuración de las máquinas afectan el problema de distribución dinámica de las instalaciones. Dado que se trata de un problema integrado, se plantea un algoritmo híbrido de dos fases como método de resolución. En la primera fase, el algoritmo híbrido incorpora el algoritmo genético de clasificación no dominado. En la segunda fase se aplica dos algoritmos de búsqueda local. En la primera fase se utiliza el método de diseño experimental de Taguchi para incrementar su eficacia. Luego se generan aleatoriamente 20 instancias de diferentes tamaños. Los resultados numéricos muestran que la segunda fase del algoritmo híbrido mejora significativamente la primera fase. Los

resultados también demuestran que la optimización simultánea de esos dos problemas reduce el tiempo medio de flujo de los trabajos en aproximadamente un 10% en comparación con su optimización por separado.

(Garcia-Hernandez et al., 2020) Destacan que el Unequal Area (UA–FLP) es un problema de optimización difícil, donde los enfoques metaheurísticos son una buena opción para afrontarlos y obtener soluciones competitivas. Sin embargo, muchos de estos enfoques computacionales generalmente caen en óptimos locales y adolecen de falta de diversidad en su población, principalmente debido a los enormes espacios de búsqueda. En el artículo se propone un enfoque metaheurístico híbrido novedoso, que combina un algoritmo de optimización de arrecifes de coral (Coral Reefs Optimization - CRO) con un algoritmo de variable de búsqueda del vecindario (Variable Neighborhood Search - VNS) y una representación del problema llamada estructura de bahía flexible relajada (Relaxed Flexible Bay Structure - RFBS) para simplificar la codificación y hacer que el entorno de fitness sea más asequible, así como también el RFBS permite una mejor gestión del espacio libre en el diseño de la planta. La estrategia combinada presentada en el artículo es probada en un conjunto de instancias UA-FLP de diferentes tañamos, que fueron abordados previamente en la literatura con metaheurísticas alternativas. En todos los casos los resultados muestran un muy buen desempeño.

(Pourvaziri et al., 2020) El artículo destaca la importancia de los pasillos que son los caminos para el movimiento de los trabajadores, dispositivos de transporte, y paso de materiales. La estructura del pasillo contribuye a la eficiencia del diseño al reducir los costos de manipulación de materiales, el tiempo medio del flujo, la cantidad de espacio necesario, y facilitar el transporte entre las instalaciones. El artículo analiza los requisitos para un diseño de una estructura de pasillo eficiente y propone una formulación del problema de disposición como un modelo matemático de programación lineal entera mixta. Esta formulación permite optimizar simultáneamente el diseño de las instalaciones en áreas desiguales y la estructura del pasillo. En

la optimización de la estructura de los pasillos, los autores estudian cuestiones como la optimización del número, la posición y el ancho de los pasillos, la posición de las puertas de entrada y salida y cómo conectarlas a los pasillos. Al optimizar el número y el ancho de los pasillos, el enfoque propuesto contribuye a optimizar el tráfico de transporte. La propuesta utiliza un algoritmo de ramificación y corte, mejorado para agregar cortes y estrategias más eficientes de ramificación y nodos para resolver el problema. Los resultados experimentales presentados, muestran la efectividad del modelo propuesto.

(Sunardi et al., 2020) presentan un problema real en la planta de producción de Cahaya Bintang Mas Company Surabaya, donde la disposición de las instalaciones de producción no es óptima porque la distancia de manipulación de materiales es bastante grande. Para superar este problema se plantea el rediseño del diseño de la instalación en el piso de producción se utiliza el método de planificación de diseño sistemático (Systematic Layout Planning - SLP). Los resultados mostraron que la distancia total de la distancia de manipulación de materiales para el diseño actual tiene una distancia total de 508,6 m. Mediante el método SLP puede reducir la distancia de manipulación de materiales, el diseño de la alternativa 1 tiene una distancia total de 324,8 metros (36,1%). y el diseño alternativo 2 tiene una distancia total de 215,5 metros.

(Chraibi et al., 2019) El problema del diseño adaptativo para quirófano (Adaptive Layout for Operating Theatre - ALOT) en hospitales busca determinar la ubicación del diseño “más eficiente” de un conjunto de instalaciones operativas de atención médica, pasillos y ascensores, en un área determinada, sujeta a un conjunto de restricciones en los estándares profesionales médicos. Tales estándares incluyen regulaciones sobre: higiene, seguridad y protección de las partes interesadas (médicos, personal médico, pacientes y visitantes); movimientos de tecnologías y especificaciones de los quirófanos (funciones, orientaciones, tamaño de los espacios y cercanía deseada). Los diseños de ALOT existentes se generan principalmente a partir de diseños basados en juicios experienciales de

expertos. Debido a la falta de rigor científico y al enorme impacto del diseño de maquetación en la eficiencia y efectividad de un quirófano, el documento propone modelos mixtos de programación lineal entera para encontrar diseños óptimos en tres variantes de diseño diferentes: ALOT con múltiples secciones; ALOT con varias filas y ALOT con varios pisos. Cada variante tiene diferentes demandas de personal, pacientes y tecnologías en un horizonte de planificación. Las instalaciones operativas pueden intercambiar funciones a costos de reordenamiento de un período a otro para satisfacer las demandas cambiantes. El objetivo general consta de dos subobjetivos: el primer subobjetivo es minimizar la suma total de la reordenación y los costos de viaje, mientras que el segundo subobjetivo es maximizar la suma total de la cercanía deseada entre las instalaciones. Las experiencias computacionales se presentan en un conjunto de instancias de datos quasi reales para un hospital en Francia. Los resultados de los experimentos demuestran la eficacia de las formulaciones para proporcionar diseños óptimos para instancias de tamaño realista.

(La Scalia et al., 2019) El trabajo analiza el problema UA-FLP, con el fin de minimizar la suma de los costos de manipulación de materiales teniendo en cuenta la satisfacción de la relación de aspecto solicitada. Los autores proponen por primera vez un algoritmo denominado Firefly basado en la codificación de la estructura de corte. El método propuesto fue probado comparando los resultados con los de otros autores frente a similares instancias de la literatura. Los resultados confirman la efectividad del algoritmo Firefly en la resolución del problema del diseño de las instalaciones al generar mejores soluciones con respecto a las proporcionadas por anteriores investigaciones.

(X. Xiao et al., 2019) Debido al dramático aumento de la demanda individualizada, la personalización masiva de producción no convencional, con incertidumbres en las demandas logísticas en cada etapa de producción, los autores proponen un modelo híbrido de optimización robusto para problemas de disposición de instalaciones dinámicas de área desigual (UA – DFLP) considerando la ubicación de los puntos de recogida (pick-up) y

entrega(drop-off) puntos (Puntos P/D). Se desarrolla un algoritmo mejorado de optimización de enjambre de partículas (PSO) para resolver el modelo propuesto. El modelo se aplica a un caso real adquirido de una línea de montaje que posee una variedad personalizada de productos y familia de productos.

(Hosseini-Nasab et al., 2018) publican un estudio de clasificación y revisión del problema de distribución de las instalaciones (FLP). Hace más de 60 años que Koopmans y Beckmann publicaron el primer artículo fundamental sobre el modelado del FLP como un problema de asignación cuadrática QAP. Desde entonces ha habido mejoras al planteamiento original de los autores. Sin embargo, aún se tiene aspectos del FLP que se pueden mejorar o ser susceptibles de mejora en cuanto a los planteamientos de solución, lo que hace interesante trabajar en este campo. Los autores, realizan una revisión de la literatura publicada acerca del FLP a través de las formulaciones y planteamientos de solución y las metodologías realizadas y tendencias futuras de investigación sobre el campo del FLP.

(Peng et al., 2018) El artículo trata el problema de distribución dinámica estocástica de las instalaciones bajo la incertidumbre de la demanda en términos de flujo de materiales entre las instalaciones. El enfoque aplica la simulación Montecarlo para generar diferentes escenarios de forma aleatoria. El modelo matemático se establece para teniendo en cuenta la asignación del dispositivo de transporte. Como procedimiento de solución para el modelo propuesto se desarrolla un algoritmo genético adaptativo mejorado con estrategia de inicialización de la población para reducir el espacio de búsqueda y mejorar la eficiencia de resolución. Se comparan instancias de diferentes tamaños con el algoritmo de optimización enjambre de partículas (Particle Swarm Optimization - PSO) para verificar la efectividad del algoritmo genético propuesto. Los resultados experimentales muestran un buen desempeño del diseño planteado con relación al diseño esperado.

(Sun et al., 2018) El artículo trata el UA-FLP donde las instalaciones no son idénticas y propone un algoritmo genético (GA) basado en un modelo de isla llamado IMGA. Dado que los algoritmos evolutivos (EA) todavía requieren mucho tiempo, se tienen esfuerzos dedicados a paralelizar varios EA, incluido el IMGA para aplicarlo al diseño de CPU's (Central Process Units) y GPU (Graphic Process Unit). En el artículo se propone algoritmos paralelos para cada paso individual en el IMGA al resolver el problema UA-FLP.

(Amaral, 2017) El artículo considera el problema del UA-FLP con dimensiones fijas. Propone una formulación de programación entera mixta para encontrar soluciones óptimas al problema. Las pruebas computacionales otorgan buenas soluciones para problemas entre 5, 8, 11 y 13 departamentos considerando restricciones prácticas para estos.

(Anjos & Vieira, 2017) publican una revisión de las clases de problemas de diseño de plantas FLP: (a) diseño de layout por filas, (b) diseño de layout para áreas desiguales, y (c) diseño de layout para varios pisos. Para cada uno de estos se tienen planteamientos de optimización matemática, optimización lineal, entera, mixta y cónica. Estos enfoques se complementan con la aplicación de metaheurísticas tales como el recocido simulado, algoritmos genéticos, colonia de hormigas, búsqueda tabú. Enfoques aplicados en las dos últimas décadas y que aún permanecen abiertas para futuras investigaciones.

(Fowosere, 2017) en su tesis de maestría explora dos variaciones del problema de distribución de instalaciones: (a) el problema de distribución dinámica de instalaciones de áreas iguales (EA-DFLP) y (b) el problema de distribución dinámica de instalaciones de áreas desiguales (UA-FLP). La similitud en ambos problemas es que se debe encontrar la mejor disposición que minimice la suma del costo de manipulación y reordenamiento de materiales donde en el primer caso se tienen departamentos iguales y en el segundo caso la disposición de los departamentos debe hacerse sin violar las restricciones de forma. La tesis propone un algoritmo genético elitista

para resolver el EA-DFLP y adicionalmente presenta un nuevo enfoque de modelado llamado Modelado Progresivo (PM) y lo aplica para resolver el problema del UA-FLP. El algoritmo genético se aplica al EA-DLP representando la solución mediante un árbol binario, en tanto que el algoritmo de modelado progresivo se utiliza para resolver el UA-FLP, lo novedoso de la técnica demuestra cómo se controla y gestiona el proceso de búsqueda mientras se realizan búsquedas optimas o casi óptimas. Se prueba que tanto el algoritmo genético como el de modelado progresivo obtiene buenas soluciones frente a problemas reportados en la literatura científica.

(Hasda, 2017) en su tesis doctoral plantea que el diseño de la distribución de las instalaciones es uno de los problemas más importantes en los sectores de fabricación. Este es un problema cuya naturaleza NP-difícil que puede modelarse como uno de enteros mixtos y de búsqueda local con miras a su optimización. Para resolver el problema de disposición de instalaciones con departamentos de área desigual cuyo objetivo es minimizar la suma del costo de manipulación se plantea dos enfoques: un enfoque híbrido constructivo mediante un algoritmo genético, y un modelo avanzado de mejora de búsqueda local basado en algoritmos golosos. La mejora propuesta es un algoritmo híbrido donde el operador de cruce y mutación está diseñado para manejar la representación de la solución usando un modelo constructivo. El segundo enfoque complementario; es un modelo de búsqueda local y global combinado que utiliza un operador de intercambio y rotación para reducir significativamente el número de variables y evitar la formulación de enteros mixtos del problema. Finalmente se prueba la bondad de la propuesta seleccionando problemas de la literatura y mostrando resultados mejores que los algoritmos existentes los cuales tienen un potencial clave para los problemas de campo.

(Hasda et al., 2017) El autor destaca que el problema de distribución de las instalaciones en los sectores de fabricación es un problema común y por su naturaleza mixta y combinatoria es un problema NP-difícil, debido a la naturaleza de enteros mixtos del problema es difícil resolverlos mediante

técnicas de optimización clásicas. Estas técnicas clásicas son buenas para la búsqueda local de la solución óptima, sin embargo; estas técnicas no son eficientes cuando existen múltiples soluciones y alternativas óptimas. En el artículo se propone un nuevo algoritmo de búsqueda local, evolutivo interactivo para resolver problemas de disposición de instalaciones estáticas con áreas desiguales. El algoritmo evolutivo crea nuevas soluciones para que el algoritmo de búsqueda local obtenga una solución óptima. Lo destacado es que el diseñador puede interactuar entre estos procesos para obtener la mejor solución posible al problema. La función objetivo es minimizar la suma del costo de manipulación del material. Se aplican los operadores genéticos de cruce mutación y elitismo, añadiendo operadores de intercambio y rotación. El intercambio y rotación se utiliza para evitar la formulación de números enteros mixtos del problema y disminuir el número de variables.

(Kulturel-Konak, 2017) realiza el estudio para el problema del FLP dinámico (DFLP) donde los flujos de material cambian en el horizonte de planificación de varios períodos debido a cambios en las demandas entre periodo y periodo. Ese enfoque implica el diseño de las instalaciones y la logística lo cual lo hace un problema de optimización no lineal muy desafiante. La propuesta de solución es un diseño de bloques basado en zonas flexibles que incluyen un pasillo donde las variables de decisión y los departamentos, se pueden adaptar fácilmente de diferentes sistemas de manipulación de materiales. El enfoque combina concepto de la búsqueda Tabú (TS) partiendo de un posicionamiento pre estructurado como solución inicial. Los resultados numéricos son prometedores para los problemas clásicos de la literatura.

(Paes et al., 2017) Abordan el problema UA-FLP cuyo objetivo el dimensionar y ubicar las instalaciones rectangulares en un espacio limitado, sin superponer entre instalaciones y minimizando la suma de distancias entre instalaciones por el manejo de materiales. La propuesta aborda el problema mediante un algoritmo genético básico y un algoritmo genético combinado con una estrategia de descomposición mediante

deconstrucciones y reconstrucciones de soluciones parciales. Para descomponer el problema se impone una estructura de solución donde ninguna instalación debe cruzar el eje X o Y. Aunque esta restricción posiblemente puede deteriorar el valor de una mejor solución alcanzable, también mejora grandemente las capacidades de búsqueda para problemas medianos y grandes. Para la mayoría de estos casos, los métodos exactos son impracticables. Los resultados de los experimentos producen soluciones de alta calidad para dos conjuntos de datos clásicos de la literatura y obtiene una mejora en seis de las ocho soluciones conocidas para el primer conjunto de datos con hasta 125 instalaciones. Para el segundo grupo de instancias con 90 o 100 instalaciones, se tiene una mejora promedio de solución que llega a un 6 o 7 por ciento en comparación con algoritmos anteriores, en menos tiempo de uso de CPU.

(Riffi et al., 2017) El algoritmo bat (murciélagos) es uno de los algoritmos recientes inspirados en la naturaleza, que ha surgido como un método de búsqueda poderoso para resolver problemas de optimización discretos o continuos. El algoritmo propuesto se evalúa con un conjunto de instancias de la biblioteca QAPLIB y se comparan los resultados experimentales con otros algoritmos y se obtienen resultados prometedores.

(Sharma & Singhal, 2017) Proponen una metodología integrada para manejar el problema FLP. Se adopta el proceso analítico jerárquico para evaluar las medidas de desempeño cualitativas. Se utiliza ProModel con fines de simulación para analizar los datos cuantitativos. Se implementa el método del índice de selección de preferencias para manejar los datos cualitativos y cuantitativos simultáneamente para clasificar las alternativas. Los resultados ilustran la adaptabilidad del enfoque sugerido frente a otras metodologías que justifican su efectividad y aceptabilidad.

(Y. Xiao et al., 2017) presentan un modelo de programación lineal de enteros mixtos (MILP) para resolver el problema de disposición dinámica de instalaciones. Los autores proponen un nuevo marco metaheurístico evolutivo denominado Algoritmo de Problemas Evolutivos (PEA) como un

enfoque general para los FLP. Los experimentos computacionales muestran que la PEA combinada con la programación lineal (LP) conocida como PEA-LP funciona bien en varios tipos de FLP. Se propone un nuevo método de aproximación interna poliédrica basado en líneas secantes para la linealización de la restricción no lineal para los requisitos del área del departamento. El nuevo método garantiza que el área real del departamento sea siempre mayor o igual al área requerida dentro de un error de desviación máximo dado.

(Zha et al., 2017) En el artículo se aborda el DFLP para afrontar el problema de la distribución dinámica de las instalaciones causado por la incertidumbre de la demanda del producto. En el artículo se presenta una nueva fórmula continua de distribución basado en la lógica difusa aleatoria. Las demandas se representan mediante variables aleatorias difusas. El algoritmo propuesto de optimización del enjambre de partículas flexibles basado en la posición para obtener soluciones óptimas viables.

(Atencio & Rodado, 2016) consideran el problema de asignación cuadrática (QAP) como uno de los problemas más importantes de optimización que es ampliamente estudiado en la literatura científica y los enfoques heurísticos y metaheurísticos se utilizan para optimizar uno o más objetivos; con el cuestionamiento que estos no se aplican a situaciones reales. La propuesta de los autores usa el método de Sule y algoritmos genéticos para resolver un QAP en una instalación real de Colombia, tal que permite minimizar el costo de mover el material requerido entre las instalaciones. La bondad de la propuesta radica en que el uso del método de Sule y algoritmos genéticos se propone para un problema de optimización combinatoria y es aplicado a un problema real. Así mismo; utilizan conjuntos de problemas tomados del QAP Library para analizar la eficiencia de la metodología propuesta.

(Jadid & Firouz, Mohammad; Snyder, 2016) presentan un nuevo método para resolver problemas de diseño de instalaciones dinámicas (DFLP - Dynamic Facility Layout Problem). Para obtener cada diseño se aplica el

método de árbol de corte integrado a un algoritmo genético para obtener soluciones iniciales prometedoras. Luego se agregan nuevos departamentos al diseño considerando flujos estocásticos. Complementan el método aplicando simulación para modelar la complejidad uniéndolo al algoritmo genético logrando una mejora en los resultados. Los resultados se obtienen para los problemas reportados en la literatura académica que muestra la eficiencia del algoritmo propuesto.

(Jerin Leno et al., 2016) proponen un enfoque integrado para el FLP, estableciendo el diseño entre las celdas y el diseño de la distribución de la ruta del flujo del sistema de materiales (MHS) simultáneamente. La calidad del diseño obtenido se evalúa minimizando el costo total de manipulación del flujo de materiales. Para la codificación del diseño se utiliza la representación de pares de secuencias (SP). La traducción de SP a diseño se realiza de manera eficiente mediante la secuencia común más larga (LCS). Se implementa y prueba un algoritmo genético de estrategia elitista que utiliza un algoritmo de recocido simulado (E-GASAA) este último como mecanismo de búsqueda local y se prueban cuatro casos de problemas de prueba disponibles en la literatura. Con la estrategia elitista se consigue mejorar la característica de convergencia del algoritmo propuesto. Los resultados del E-GASAA propuesto muestran que es capaz de obtener las mejores soluciones para la instancia de problemas de prueba de diferentes tamaños dentro de un esfuerzo computacional aceptable, logrando reducir la carga computacional con la ayuda de la metodología de cálculo LCS, consiguiendo una buena mejora.

Dado que los circuitos integrados actualmente tienen una demanda incremental en todo tipo de electrodomésticos y otros artefactos, (Kumar Perumalla, 2016) en su tesis de maestría propone un algoritmo genético para el diseño y planificación de un circuito integrado (Floorplanning IC's) con el propósito de optimizar el tiempo de diseño y la utilización del área del circuito integrado en un solo chip mediante la metodología SoC (System-on-Chip) para la fabricación de circuitos integrados (IC) cada vez más densos, siendo los tiempos de diseño y el área aspectos críticos a considerar. El

algoritmo propuesto es escrito en lenguaje de programación C++ y probado en la plataforma Linux obteniendo buenos resultados frente a un software comercial que realiza idéntica tarea.

(Masel & Marincheck, 2016) aplican el método de bahías flexibles para crear un diseño de instalaciones cuyos pasillos no son ortogonales; es decir, por lo general los pasillos interdepartamentales son paralelos a las paredes externas de la instalación, la propuesta es crear pasillos en ángulo con las paredes exteriores, creando rutas más directas entre departamentos, consiguiendo la reducción de las distancias de viaje. La propuesta es probada utilizando casos conocidos en la literatura.

(Niebles et al., 2016) en este artículo se considera el problema de la localización de las instalaciones FLP, en la fabricación de productos eléctricos de telecomunicaciones y de construcción. El método propuesto utiliza el método de Sule y algoritmos genéticos para el diseño de las instalaciones en una planta industrial real de Colombia, de manera tal que minimice el costo total de mover el material requerido entre las instalaciones. Se realizan experimentos computacionales y se compara el enfoque propuesto con la formulación del QAP con datos bien conocidos en la literatura académica para asegurar la eficiencia de la propuesta.

(Papadaki & Chassiakos, 2016) plantean que para un proyecto de construcción civil la planificación eficiente del sitio de construcción es fundamental para el éxito del proyecto, pues mejora tanto la productividad como la seguridad de los sitios de construcción para las obras civiles. Esta tarea consiste generalmente en identificar las instalaciones temporales necesarias para apoyar las operaciones de construcción, determinando su tamaño, su forma y colocación de manera óptima dentro de las áreas desocupadas y dentro de los límites del terreno donde se desarrolla el proyecto. Por su naturaleza, este es un problema de optimización combinatoria complejo que involucra múltiples objetivos, cuya complejidad crece a medida que aumenta el número de instalaciones y limitaciones. El objetivo del estudio es desarrollar soluciones de diseño de sitio factibles y

eficientes, que logran una representación realista que tiene en cuenta no solo la distancia total recorrida, sino también los parámetros de costo y de seguridad. El modelo de optimización multi objetivo minimiza la función de costo generalizado que resulta del costo de construcción de una instalación ubicada en ubicaciones alternativas, el costo de transporte entre ubicaciones y el problema de seguridad en cuanto a cercanía o lejanía preferida de instalaciones particulares, a otras instalaciones o áreas de trabajo. Para ello se emplea algoritmos genéticos (GA). La evaluación del modelo propuesto proporciona soluciones eficaces y racionales, en respuesta a los parámetros de decisión y las limitaciones o restricciones del problema, y obtiene como resultado una planificación de diseño de las instalaciones más sólida que otros métodos tanto cualitativa como cuantitativamente.

(Chen, Yanru;Jiang, Yangsheng;Wahab, M. I.M.;Long, 2015) proponen una solución al FLP en parques logísticos no rectangulares con líneas divisorias (FLP – LP), que poseen un gran espacio y permiten gestionar de manera eficiente y efectiva recibir y enviar bienes. Este tipo de problema difiere de los FLP tradicionales pues tienen líneas divisorias que pueden ser carreteras, pistas o ferrovías que pueden cruzar el parque logístico y dividirlo en varias partes. Así mismo, los parques logísticos suelen tener una forma irregular en lugar de formas rectangulares. Esto hace que, para los parques logísticos, se requiera de modelos matemáticos explícitos. De acuerdo con esto, los autores proponen dos modelos de programación matemática para resolver este tipo de problemas. El primer modelo implica asignar las áreas funcionales en diferentes partes resultantes de las líneas de divisiones dadas y el segundo modelo implica el uso de la técnica del árbol de estructuras de corte SST, para determinar el diseño final de las áreas funcionales. Dado que el diseño de instalaciones de un parque logístico FLP-LP, es un NP-completo, los autores proponen un enfoque heurístico que combina la metodología genética adaptativa mejorada, con un algoritmo de búsqueda con dispersión.

(Sghir et al., 2015) proponen un sistema inteligente multi-agente basado en optimización aplicado al problema de asignación cuadrática

(MAOM-QAP). Este sistema este compuesto por varios agentes: (a) agente decisor, (b) agente de búsquedas locales, (c) agentes de cruce, y (d) agentes de perturbación, estos están diseñados con el propósito realizar actividades de búsqueda intensificadas y diversificadas. Con la ayuda de un mecanismo de aprendizaje reforzado, MAOM-QAP, decide dinámicamente, cual es el agente más adecuado para activar, según el estado, el proceso de búsqueda. Bajo la coordinación del agente decisor, los demás agentes realizan tareas de búsqueda específicas. Este enfoque propuesto evalúa el conjunto de instancias de referencia de los QAP más avanzados según la literatura. Aunque estas ideas son generales pueden adaptarse a otras tareas de optimización, abriendo el camino para diseñar nuevos sistemas inteligentes distribuidos que permitan abordar otros problemas NP-hard de búsqueda complejos.

(Saraswat et al., 2015) proponen un marco (framework) multi-objetivo para el diseño de las instalaciones FLP. A partir de la revisión de la literatura de planificación de las instalaciones proponen generar bloques de diseño basados en tres objetivos: (a) flujo-distancia, (b) trabajo promedio en proceso, y (c) número de dispositivos de manejo de materiales requeridos. En el estudio plantean experimentos numéricos sobre una serie de problemas FLP estándar, y su cumplimiento con los diferentes objetivos, los cuales se deben tener en cuenta para la implementación real del diseño de las instalaciones.

(Caputo et al., 2015) publican el artículo “Disposición de planta de proceso basada en la seguridad mediante un algoritmo genético”. La ubicación relativa de las unidades de proceso principales se determina para minimizar una función de costo anual que incluye el costo de transferencia de material entre las unidades de proceso (incluye costos de tubería y bombeo), el costo de la tierra y la pérdida anual esperada del daño a cada unidad secundaria causada por accidentes primarios que ocurren en unidades de proceso cercanas. El método es una mejora con respecto a intentos anteriores que utilizan algoritmos genéticos o técnicas de programación matemática para optimizar el diseño de la planta, que no

toman en cuenta los costos de bombeo ni incluyen los problemas de seguridad al conectar entre las instalaciones. La bondad de la propuesta radica en que se incluyen costos operativos de la transferencia de material entre las instalaciones teniendo en cuenta también la probabilidad de accidentes; el resultado es que se proporciona buenas soluciones optimas practicas aplicando algoritmos genéticos incorporando funciones, restricciones y costos más realistas. Que ponen a prueba la metodología propuesta.

(Gonçalves & Resende, 2015) en el artículo: “Un algoritmo genético de clave aleatoria sesgada (BRKGA) para el problema de distribución de instalaciones de área desigual (UA-FLP)” el objetivo es encontrar la colocación y las dimensiones de las instalaciones de manera que se minimice la suma de las distancias ponderadas entre los centroides de las instalaciones. El articulo desarrolla un enfoque híbrido novedoso que combina un BRKGA para determinar el orden de ubicación y las dimensiones de cada instalación con un modelo de programación lineal para afinar las soluciones. El enfoque propuesto se prueba en 100 conjuntos de datos aleatorios y 28 conjuntos de datos de referencia. La calidad del enfoque fue validada por la mejora de las soluciones más conocidas de 19 de las 28 soluciones de referencia ampliamente estudiada en trabajos previos.

En el artículo “Un nuevo enfoque evolutivo híbrido para capturar el conocimiento de los tomadores de decisiones en el problema de distribución de instalaciones de áreas desiguales” (García-Hernández et al., 2015) proponen la introducción de conocimientos expertos en algoritmos genéticos para proporcionar mejores soluciones al FLP que aquellas soluciones matemáticamente optimas, al considerar aspectos cualitativos en el diseño. Este enfoque requiere intervención directa del diseñador (llamado el tomador de decisiones) en el algoritmo evolutivo que guía el proceso de búsqueda para ajustarlo a sus preferencias. Para ello, el diseñador puntuá cada uno de los diseños más representativos de la población. Este novedoso sistema híbrido propuesto en este estudio consiste en un algoritmo genético

interactivo que se combina con dos métodos de niching diferentes para permitir interacciones entre el algoritmo y el diseñador experto. La introducción de técnicas de niching en este enfoque permite la preservación de la diversidad, lo cual permite evitar presentar soluciones similares a las del diseñador en la misma iteración del algoritmo. El enfoque propuesto se probó utilizando dos estudios de caso de diseños de distribución de instalaciones cuyos resultados experimentales validan con éxito el enfoque propuesto.

(Allahyari & Azab, 2015) proponen un modelo para el problema de distribución de las instalaciones para los sistemas de fabricación celular (CMS) desarrollando una nueva formulación continua para el problema de modelar talleres de fabricación con pasillos verticales y horizontales y eliminar cualquier posible superposición entre maquinas herramientas y entre celdas. Se utiliza un estudio de caso de la industria de mecanizado para verificar el modelo.

(Azarbonyad & Babazadeh, 2015) afrontan el problema de asignación cuadrática (QAP) como un modelo utilizado para el problema de distribución de filas múltiples con instalaciones de igual área. -Para cada par de ubicaciones, se especifica una distancia y para cada par de ubicaciones se le asigna un peso o flujo (por ejemplo, la cantidad de materiales o suministros transportados entre estas dos instalaciones). El problema consiste en es asignar todas las instalaciones a diferentes ubicaciones con el objetivo de minimizar la suma de las distancias multiplicadas por los caudales correspondientes. Tal como se ha expresado anteriormente el QAP es un problema de optimización combinatoria NP-hard que se encuentra entre los más difíciles de resolver. El trabajo de los autores presenta un algoritmo genético (GA) eficiente que resuelve el problema en un tiempo razonable.

(Troncoso, 2015) propone en su tesis un procedimiento para resolver el problema del diseño de plantas en instalaciones industriales de manera tal que las instalaciones adyacentes estén enlazadas por pasillos. El modelo

propuesto considera el método multivariante y propone tres etapas: (a) generar una estructura de árbol de corte para situar las instalaciones tal que se mantengan más próximas aquellas que poseen mayor flujo entre sí. (b) utilizar un algoritmo genético para obtener un árbol que minimice el costo de transporte entre instalaciones y maximice la razón de forma de estas, y (c) a partir de la instalación obtenida en las dos fases anteriores se plantean los ajustes necesarios para introducir pasillos de manera tal que conecten instalaciones no adyacentes, manteniendo la ratio de transponte lo menor posible. Finalmente se analiza y discute la mejora de los resultados obtenidos frente a otras propuestas.

(Chakraborty, 2015) en su tesis de maestría aborda el problema NP-hard del diseño estático de instalaciones de área desigual (UA-SFLP) con el fin de minimizar la suma de los costos de manejo de materiales aplicando una nueva estrategia de optimización heurística denominada “estrategia de colocación basada en el centro” CBPS integrada al algoritmo de búsqueda local. El algoritmo establece la primera colocación en el centro del área destinada a las instalaciones, el orden de las siguientes instalaciones es aleatorio (y también su orientación). Las instancias de los problemas se toman de la literatura UA-FLP y aplica el método mediante la técnica de optimización de enjambre de partículas aplicadas a este problema particular. Esta estrategia es comparada con los métodos de gradiente y algoritmos genéticos. Los resultados reportados muestran ser bastante efectivos y reportan menos tiempo de cálculo comparado con los otros métodos.

(Giussepe Aiello et al., 2013) plantean un ranking no dominado como un MOGA y el método electre para resolver el problema del diseño de las instalaciones de planta de departamentos de áreas desiguales (UA-FLP).

(Giuseppe Aiello et al., 2012) proponen un MOGA (Multi Objetive Genetic Algorithm) para resolver el FLP en áreas desiguales basándose en una estructura SST donde las colocaciones relativas de las instalaciones en el terreno son representadas mediante una matriz de colocaciones codificada en dos cromosomas.

(Nawaz-Ripon et al., 2011) plantean un enfoque evolutivo para resolver el FLP de áreas desiguales con un enfoque multi objetivo aplicando como variable de búsqueda la del vecino más cercano VNS (Variable Neighborhood Search) que plantea un enfoque adaptativo que obtiene los layout finales como un conjunto de soluciones Pareto-optimas. Es necesario destacar que el VNS es un método exploratorio de búsqueda local cuya estrategia es el cambio de la vecindad precisamente en ese proceso de búsqueda.

(Jaafari et al., 2009) enfocan el FLP mediante el modelado matemático de PEM (Programación entera mixta) tomando en cuenta dos objetivos (1) maximizar la ratio de cercanía entre los departamentos y (2) minimizar el costo de manipulación de materiales entre departamentos; por lo general estos dos objetivos son contrapuestos, de allí la bondad de ese enfoque.

(Drira et al., 2007) realizan un interesante estudio de revisión y clasificación de los problemas FLP reportando los diferentes enfoques de formulación modelamiento y técnicas de resolución con los que la comunidad académica enfrenta este tipo de problemas.

Adicionalmente, (Diego-Más, 2006) en su tesis doctoral propone un indicador que mide la capacidad de un determinado árbol de corte para generar soluciones geométricamente aceptables aplicando la técnica de los algoritmos genéticos para escoger el mejor árbol a partir de él procede a buscar la mejor solución al FLP.

Por otro lado (Tam, 1992a), (Tam, 1992b) , (Tam & Li, 1991), (Tam & Chan, 1998) proponen la utilización de la estructura de árboles de corte SST(Slicing Structure Tree) y algoritmos genéticos para obtener soluciones a problemas clásicos FLP de áreas rectangulares y desiguales; pero con una geometría flexible, estableciendo que el ratio largo/ancho puede variar dentro de ciertos márgenes establecidos. Mediante este enfoque obtienen buenas soluciones; es decir, soluciones optimas.

Según (Armour y Buffa, 1963); los sistemas de manufactura tienen departamentos de áreas desiguales y fueron los primeros en plantear un método de intercambio de parejas para los FLP de área desigual. Por otro lado (Tong, X.,1991) propone el concepto de bahía para la ubicación de los departamentos y aplica el concepto de bahía flexible logrando una representación continua que permite que los departamentos se ubiquen en bahías paralelas con diferentes anchos. (Hernández Gress et al., 2011) proponen un algoritmo genético para al menos 9 departamentos de área desigual.

Los primeros en modelar el FLP fueron (Koopmans & Beckman, 1957) definiéndolo como un problema cuadrático de asignación QAP (Quadratic Assignment Problem) para el que se minimizan los costos del flujo de materiales, resultantes de colocar cada máquina en cada una de las localizaciones posibles. Este trabajo sin duda fue el punto de partida y un referente para numerosos trabajos e investigadores que continúan explorando este tema.

2.2.1 *Metodologías empleadas para resolver problemas de optimización*

Como se ha visto el problema de la distribución en planta conocido también como el problema de la distribución de las instalaciones FLP, es un problema combinatorio de optimización difícil o NP-Hard por su gran complejidad computacional. Para proponer una solución en las últimas décadas se han propuesto técnicas o metodologías metaheurísticas.

Es necesario dejar claro que un algoritmo metaheurístico es un algoritmo aproximado de optimización y búsqueda de propósito general. Los algoritmos metaheurísticos son procedimientos iterativos que se encargan de guiar una heurística combinándola con otros conceptos para explorar y

explorar de manera adecuada el espacio de búsqueda para encontrar una solución aproximada.

Respecto a los algoritmos metaheurísticos se tiene ventajas y desventajas que se presenta a continuación.

Ventajas:

- Son algoritmos de propósito general.
- Tienen gran éxito en términos prácticos.
- Se pueden expresar en un algoritmo e implementar mediante un lenguaje de programación.
- Son paralelizables, lo que significa que se pueden implementar en paralelo debido a la programación concurrente.

Desventajas o inconvenientes:

- Son algoritmos no exactos; es decir son aproximados.
- Son probabilísticos; es decir no determinísticos.
- La base teórica que los sustenta está en construcción.

Los algoritmos metaheurísticos se vuelven una opción cuando no se tiene un método exacto de resolución, o su implementación se traduce en un modelo matemático complejo que requiere mucho proceso, tiempo de cálculo, y computacionalmente demanda gran cantidad de memoria, lo cual lo hace ineficiente.

Para que las metaheurísticas sean aceptables requieren poseer dos características contrapuestas en el proceso de búsqueda:

1. *Intensificación*.- Se define por la cantidad de esfuerzo empleado en la búsqueda en la región actual; esto implica la explotación de dicho espacio.

2. *Diversificación.* - Se define por la cantidad de esfuerzo empleado en la búsqueda de regiones distantes del espacio actual de búsqueda; esto implica la exploración del espacio de búsqueda.

Para obtener un buen funcionamiento de los algoritmos metaheurísticos se debe lograr un equilibrio entre intensificación y diversificación cuya tarea es:

- Identificar de manera rápida aquellas regiones prometedoras; es decir aquellas que conduzcan a soluciones de buena calidad.
- No invertir mucho tiempo en aquellas regiones del espacio no prometedoras o que ya fueron exploradas. Esto implica que deben ser capaces de abandonar rápidamente estas regiones.

1.2.2 Clasificación de las metaheurísticas

Según (Moreno Vega et al., 2003) las metaheurísticas se clasifican en cuatro grupos. Ver la tabla 1.

En lo que respecta al problema FLP, dada su naturaleza de ser un problema de optimización combinatoria, con alta complejidad computacional, es que pertenece a la clase de problemas NP-difíciles. Este problema tiene similitud al problema del “VLSI Layout” (Diseño de circuitos integrados de muy alta escala). Para ambos problemas se proponen diferentes metaheurísticas que afrontan la optimización combinatoria. Según (Ghosal et al., 2005) estas técnicas proponen una nueva clase de algoritmos metaheurísticos tales como: Enfriamiento Simulado (Simulated Annealing – SA), Búsqueda Tabú (Tabu Search - TS), Búsqueda Local Iterada (Iterated Local Search - ILS), Computación Evolutiva (Evolutionary Computation EC) que incluye Algoritmos Genéticos (Genetic Algorithms - GA), Optimización de Colonia de Hormigas (Ant Colony Optimization - ACO), y Procedimientos

Codiciosos de Búsqueda Adaptativa Aleatoria (Greedy Random Adaptive Search Procedures – GRASP).

Tabla 1

Clasificación de las metaheurísticas

Tipo	Descripción
1. Metaheurísticas de relajación	Son procedimientos de resolución de problemas que aplican relajaciones al modelo original, de manera que convierten el problema original en uno equivalente y más fácil de resolver, lo cual facilita la solución del problema original.
2. Metaheurísticas constructivas	Aquellas que aplican procedimientos que pretenden obtener una solución a partir de analizar, seleccionar e incorporar paulatinamente las componentes que lo forman con miras a obtener una solución.
3. Metaheurísticas de búsqueda	Aquellas que aplican procedimientos que utilizan transformaciones o movimientos que posibilitan recorrer el espacio de soluciones alternativas, buscando la mejor solución.
4. Metaheurísticas evolutivas	Aquellas que están enfocadas a procedimientos basados en conjunto de soluciones que aplican el concepto de evolución sobre el espacio de soluciones, estableciendo un conjunto de soluciones (la población) en la búsqueda de nuevas soluciones.

Nota: (Moreno Vega et al., 2003)

De la revisión de la literatura se tiene una amplia aplicación de metaheurísticas evolutivas al problema del FLP con resultados buenos y eficientes por lo que se decide para el presente trabajo de investigación utilizar estas metaheurísticas, específicamente los algoritmos genéticos aplicados a las poblaciones (conjunto de soluciones) para hacerlas evolucionar y obtener mejores soluciones aplicando fundamentalmente procedimientos aleatorios. Ver más adelante 2.3.1.

2.3 Metodología de los algoritmos evolutivos (EAs) y algoritmos genéticos (AGs)

La teoría de evolución de las especies y la selección natural (modelo de evolución natural) propuesta por Charles Darwin (Darwin C., 1859) es la fuente de inspiración para una técnica de resolución de problemas de búsqueda y optimización, conocida hoy como algoritmos evolutivos. La característica de búsqueda aleatoria y búsqueda dirigida de estos algoritmos proviene del mecanismo de selección de los individuos más adaptados. Ambas características permiten abordar los problemas de manera muy particular, permitiendo acceder a cualquier región del espacio de búsqueda (característica que no poseen otros algoritmos de búsqueda exhaustiva) y explorar el espacio de búsqueda de manera más eficiente que los métodos meramente aleatorios.

Es muy importante tener en cuenta que aplicar un algoritmo evolutivo no garantiza obtener una solución exacta al problema planteado, sino una aproximación a la solución, cuya calidad depende de los recursos empleados en la búsqueda; es decir, tiempo y memoria (por supuesto, también del diseño de los componentes del algoritmo). Lo positivo de esta característica es que los algoritmos evolutivos se pueden aplicar a problemas de alta complejidad computacional, proporcionando una solución aproximada que en estos casos es suficiente para las necesidades del usuario y en otros casos es lo único que puede procurarse.

Los algoritmos genéticos son una metodología planteada por primera vez por Holland en el año 1975. En 1989 el profesor David E. Goldberg de la Universidad de Alabama publicó el primer libro que enseña como implementar o programar algoritmos genéticos para funciones de valor real, el mismo que se ha convertido en un clásico sobre esta temática (Goldberg, 1989). El esquema básico común de los algoritmos evolutivos que se pueden formular comparte las siguientes propiedades:

1. Paralelización. - Tener capacidad de procesar, no una solución al problema, sino un conjunto de ellas. Estos algoritmos establecen una representación de soluciones potenciales al problema. Las cuales se nombran *individuos*. El conjunto de individuos pasa a formar lo que se conoce como *población*, que es donde trabaja el algoritmo.
2. Generaciones. - A lo largo de las iteraciones, la composición de la población se va modificando; a esto se conoce como generaciones. Entre generación y generación varía el número de copias de un mismo individuo en la población, y se permite también la aparición de nuevos individuos que son generados mediante operaciones de transformación sobre individuos de la población anterior. Este conjunto de operaciones, se establecen mediante operadores genéticos, denominados como cruce y mutación.
3. Selección. - Este proceso se da en cada generación y otorga mayor probabilidad de permanecer en la población y permite participar en operaciones de reproducción a individuos catalogados como los mejores (esto se conoce como elitismo). Se considera mejores individuos a aquellos que obtienen los mejores valores (máximos o mínimos) dada la función de adaptación del algoritmo. Para el buen funcionamiento del algoritmo evolutivo es esencial que el proceso de selección tenga una componente aleatoria, lo cual asegura que aquellos individuos con baja adaptación también tendrán oportunidad de sobrevivir en la siguiente generación. Esta capacidad permite que los algoritmos evolutivos puedan escapar de óptimos locales y les permite explorar distintas zonas del espacio de búsqueda.

El seudocódigo para un posible esquema general de un algoritmo evolutivo se presenta en la figura 6.

Figura 6*Seudocódigo para un algoritmo evolutivo*

```

Begin AlgoritmoEvolutivo()
    pob := GenerarPoblacionInicial() // Al azar
    s := MejorIndividuo(pob)
    While (Not CriterioDeParada())
        pob' := Seleccionar(pob)
        pob'' := Cruzar(pob')
        pob''' := Mutar(pob'')
        s' := MejorIndividuo(pob''')
        if (f(s') < f(s)) then
            s := s'
        endif
        pob := NuevaPoblacion(pob'''')
    endwhile
    return s
End

```

*Fuente: Adaptado de (Michalewicz, 1997)***2.3.1 Algoritmos genéticos y distribución de plantas**

Los autores (Kundu, A.;Dan, 2010), publican “El alcance de los algoritmos genéticos para el tratamiento de problemas de diseño de instalaciones”; en el artículo, se estudian las diversas formulaciones para la optimización del FLP y en el destacan seis objetivos principales:

- A. Minimizar el costo total o costo del flujo de materiales.
- B. Minimizar el tamaño del diseño o maximizar el área utilizada.
- C. Generar un diseño flexible.
- D. Minimizar el costo del manejo de materiales entre celdas o el movimiento entre celdas o departamentos.
- E. Minimizar la distancia rectilínea total del recorrido de materiales.
- F. Optimizar la estructura de los pasillos.

La tabla 2 presenta los resultados del estudio en cuanto a la aplicación de los algoritmos genéticos al FLP.

De acuerdo con la tabla 2, los modelos QAP (Quadratic Assignment Problem) que incluye el UA-FLP (Unequal Area-FLP) es el más ampliamente usado, luego se tiene los modelos MIP (Mixed Integer Programming). Por otro lado, el objetivo más utilizado es el de tipo A. Para el presente trabajo de investigación se propone un algoritmo genético que utiliza los operadores de cruce y mutación aplicada a la representación de la estructura de datos conocida como árbol de cortes (Slicing Tree - ST) con el objetivo de representar soluciones al FLP.

Tabla 2*Aplicaciones y técnicas usadas por los GA en FLP (1/2)*

Referencias	Técnicas de modelación	Objetivos					
		A	B	C	D	E	F
Aiello et al. (2006)	MIP	✓				✓	
Aiello et al. (2012)	Slicing Tree	✓		✓			
Aiello et al. (2013)	QAP		✓				
Atencio & Rodado (2016)	QAP		✓				
Azarbonyad and Babazadeh (2015)	QAP		✓				
Caputo et al. (2015)	MIP		✓				
Castillo & Weterlund (2005)	MIP				✓		
Chen et al. (2015)	Slicing Tree		✓				
Delmaire et al. (1997)	LP		✓				
Diego-Más et al. (2009)	Slicing Tree		✓		✓		
Dunker et al. (2005)	DP			✓			
Eklund et al. (2006)	MIP		✓			✓	
El-Baz (2004)	QAP			✓			
Erfani et al. (2020)	DP			✓			
Fowosere (2017)	DP			✓			
Gau & Meller (1999)	MIP			✓			
Gonçalves and Resende (2015)	LP			✓			

Aplicaciones y técnicas usadas por los GA en FLP (2/2)

Referencias	Técnicas de modelación	Objetivos					
		A	B	C	D	E	F
Hasda et al. (2017)	MIP	✓					
Hicks (2004)	Agrupación aglomerativa					✓	
Hu & Wang (2004)	QAP	✓	✓				
Hochard & Heragu (1999)	MIP	✓					
Jadid et al. (2016)	DP	✓					
Jankovits et al. (2011)	LP	✓					
Kulkarni & Shanker (2007)	QAP	✓			✓		
Kulturel-Konad & Konad (2013)	LP	✓					
Kumar Perumalla (2016)	Slicing Tree	✓			✓		
Lee & Lee 2002	QAP	✓	✓				
Liu & Li 2006	MIP	✓					
Longo et al. 2005	QAP	✓					
Niebles et al. (2016)	QAP	✓					
Osman et al. 2003	QAP	✓					
Paes et al. (2017)	QAP	✓					
Papadaki and Chassiakos (2016)	QAP	✓	✓				✓
Rajasekharan et al. 1998	MIP	✓					
Rankumar et al. 2009	QAP	✓					
Sun et al. (2018)	QAP	✓					
Tam & Gong 1991	Agrupación aglomerativa	✓					
Tam 1992	Slicing Tree	✓					
Tam & Chan 1998	Slicing Tree	✓					
Wang et al. 2008	Simulación	✓					
Wang et al. 2008	Simulación y realidad virtual	✓					
Wu & Appleton 2002	QAP	✓					✓
Wu et al. 2007	MIP	✓				✓	
Xiu et al. (2017)	MIP	✓					

Nota: Actualizado e inspirado en (Kundu, A.; Dan 2010)

2.4 El árbol de cortes

El primero en emplear algoritmos genéticos para el FLP fue Kar Yan Tam de la universidad de Hong Kong (Tam, 1992b) quien presenta el artículo “Genetic algorithms, function optimization and facility layout design” donde las distribuciones de planta son representadas mediante una estructura de cortes, cada corte corresponde al espacio de cada departamento. La estructura de cortes se representa de manera equivalente mediante un árbol de cortes.

El árbol de cortes (Slicing Tree) es una estructura de datos que puede aplicarse al problema de optimización del plano de planta (Floorplan o floor planning). Para entender esta estructura se proponen las siguientes definiciones (Chang, 2019):

Definición 1.- Disección rectangular (Rectangular dissection RD): subdivisión de un rectángulo dado por un número finito de segmentos de línea horizontal y vertical en un número finito de rectángulos no superpuestos.

Definición 2.- Estructura de corte (Slicing Structure - SS): una disección rectangular que se obtiene de subdividir repetitivamente rectángulos horizontal o verticalmente.

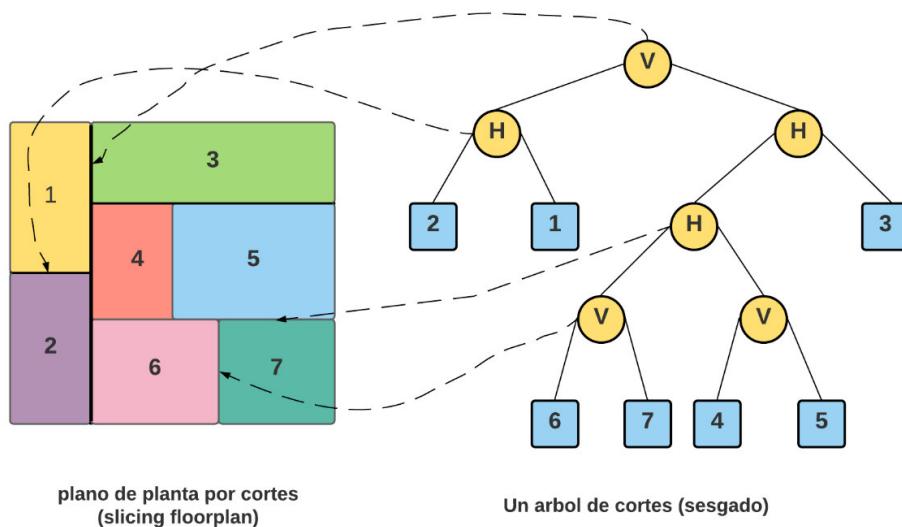
Definición 3.- Árbol de corte (Slicing Tree - ST): un árbol binario, donde cada nodo interno representa una línea de corte vertical o línea de corte horizontal, y cada hoja un rectángulo básico o atómico.

Definición 4.- árbol de cortes sesgado (Skewed Slicing Tree SST) uno en el que ningún nodo y su hijo derecho son los mismos.

Estas ideas se representan en la figura 7 que presenta un árbol de cortes sesgado donde H significa corte horizontal y V corte vertical.

Figura 7

Floorplan y su representación mediante un árbol de cortes



Fuente: Tomado de (Chang, 2019)

2.4.1 Determinación del árbol de cortes

Para crear la estructura de árbol de cortes se utiliza técnicas numéricas conocidas como clustering aglomerativo (que utiliza el método de vinculación promedio). Estas técnicas de agrupamiento realizan un análisis de afinidad entre actividades evaluando la distancia entre ellas y las agrupa en función de dichas distancias. Esto significa que el criterio de agrupamiento entre departamentos toma como único criterio la proximidad entre las actividades y el tráfico de materiales entre estos.

La propuesta de Tam considera la distancia como una función inversa de la intensidad relacional; esto quiere decir que la distancia es menor cuando mayor sea la intensidad relacional. La fórmula para el cálculo de las distancias entre dos actividades i y j se presenta en la ecuación 1:

$$d_{ij} = \frac{1}{1 + w_{ij} + w_{ji}} \quad (1)$$

En la fórmula anterior w_{ij} y w_{ji} representan el flujo de materiales entre las actividades i, j. Con estas distancias se construye la matriz de distancias D, para representar las distancias entre cada par de actividades para el layout. Una vez obtenida la matriz D se realiza el agrupamiento. Este es un proceso iterativo, en el cual se agrupan inicialmente las dos actividades más cercanas entre sí. Este grupo formado pasa a ser considerado como una actividad y se recalcula su distancia con cada una de las actividades restantes, con lo cual se modifica la matriz D inicial. Este proceso continúa agrupando nuevamente las actividades y/o grupos más cercanos entre sí.

Puesto que para el problema se tiene **n** actividades; entonces se realizan ($n - 1$) agrupamientos. El recálculo de las distancias se realiza cada vez que se tenga un nuevo grupo. Tam, emplea el promedio del agrupamiento entre una actividad no agrupada, **a** y un grupo, **g** resultante de la unión de dos elementos *i* y *j* que a su vez pueden ser actividades o agrupamientos ya formados. La fórmula para el cálculo de la nueva distancia se presenta en la ecuación 2:

$$d_{a(i,j)}^2 = \frac{n_i}{n_i + n_j} d_{ai}^2 + \frac{n_j}{n_i + n_j} d_{aj}^2 \quad (2)$$

donde:

n_i número de actividades del grupo *i*

n_j número de actividades del grupo *j*

d_{ai} distancia entre actividad **a** y actividad (o grupo de actividades *i*)
antes de la fusión.

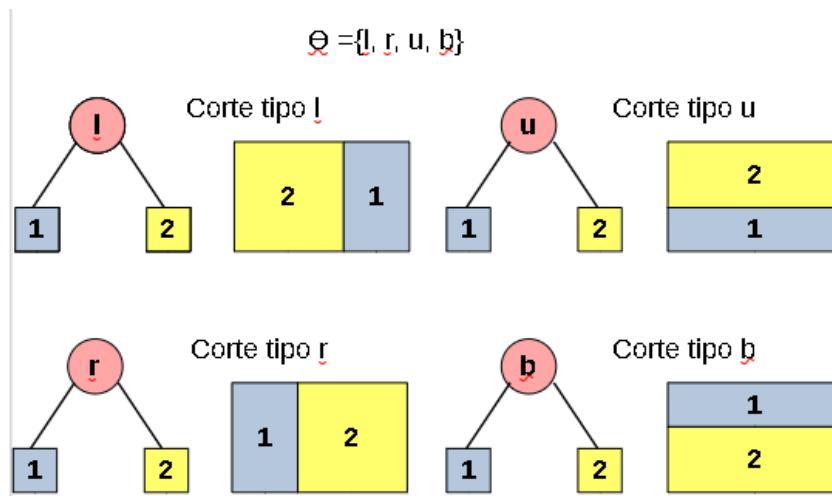
d_{aj} distancia entre actividad **a** y actividad (o grupo de actividades *j*)
antes de la fusión.

Según Tam, cada nodo interno del árbol representa la manera en la que se realiza el corte. Establece operadores: **u** = upper (superior), **b** = bottom (inferior), **l** = left (izquierdo), **r** = right (derecho). Los operadores **u** y **b** aplican corte horizontal. El operador **u** sitúa las actividades que penden de la rama izquierda del nodo en la parte superior del corte y las que penden de la rama derecha en la parte inferior del corte. El operador **b** ubica las

actividades que penden de la rama izquierda del nodo en la parte inferior del corte y las que penden de la rama derecha en la parte superior. De otro lado, los operadores **I** y **r** aplican cortes verticales; donde **I** sitúa actividades de la rama izquierda en la parte izquierda del corte y a la derecha las de la rama derecha, en tanto el operador **r**, actúa de manera inversa. La figura 8 resume estas líneas.

Figura 8

Tipos de corte para los nodos de un árbol



Fuente: (Tam, 1992a)

A partir de un árbol de cortes se puede obtener una variabilidad considerable de distribuciones. Estas se consiguen al variar los operadores de cortes. La fórmula para estimar el número de configuraciones a partir de un árbol de cortes de n actividades se presenta en la ecuación 3.

$$N = \left(\frac{p}{2}\right)^{n-1} \cdot n! (n-1)! \quad (3)$$

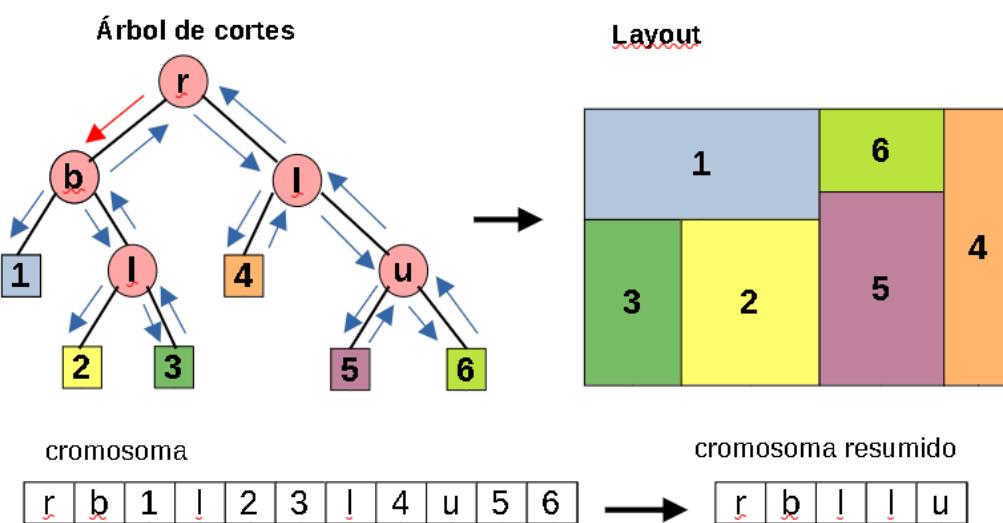
Siendo p la cardinalidad del conjunto de operadores de corte. A modo de ejemplo, para la distribución de 5 actividades, empleando los 4 operadores de corte habituales, se tiene $N = \left(\frac{4}{2}\right)^{n-1} \cdot 5! (5-1)! = 46,080$ configuraciones distintas obtenidas a partir de un mismo árbol de cortes.

2.4.2 Determinando la distribución layout optima

En la búsqueda de soluciones al problema, para aplicar un algoritmo genético, según Tam se debe codificar las distribuciones mediante una cadena finita. Una vez establecidos los tipos de corte en cada nodo, se establece el recorrido del árbol de cortes en preorden; es decir se visita primero el nodo raíz y se visita primero la rama izquierda de cada nodo (ver la flecha roja que inicia las visitas). La figura 9 ilustra el recorrido y secuencia de visitas que conforman la cadena cromosómica.

Figura 9

Codificación de la distribución de un árbol de cortes



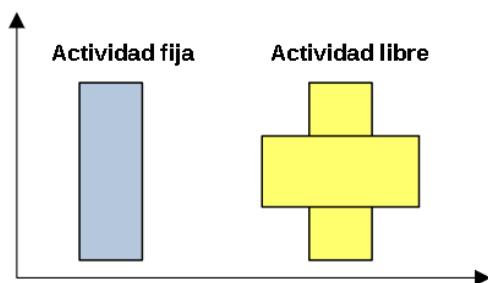
Fuente: (Tam, 1992b)

Para establecer una solución el supuesto es que la planta es una región rectangular (o cuadrada) y cada una de las actividades es también rectangular con un tamaño fijo y posee una ratio alto-ancho dentro de un intervalo prefijado (admisible). Cada actividad está definida por su tamaño y su ratio alto-ancho, el área que estas ocuparan se caracteriza por su

orientación; esta orientación puede ser fija o libre. Establecido un punto de referencia, se dice que una actividad es libre cuando puede colocarse de manera vertical u horizontal, sin que su desarrollo como actividad, se vea afectado. En el caso de aquella actividad cuya colocación u orientación esté definida para ser necesariamente vertical o bien horizontal; se dice entonces, que esta es una actividad fija (ver figura 10).

Figura 10

Actividades según su orientación fija y libre



Fuente: Diego-Más, 2006. p177

El objetivo es asignar espacio a las instalaciones de tal forma que aquellas con grandes volúmenes de tráfico colocados en las proximidades sin dejar las limitaciones de área y forma de las instalaciones individuales. La formulación o modelo matemático y la función objetivo para el problema tiene el siguiente planteamiento.

Dado un árbol de corte $s \in S$, el problema de asignación de espacio se formula como se presenta en las ecuaciones 4 y 5:

$$\text{Min } F = \sum_{i=1}^n \sum_{j=1}^n w_{ij} d_{ij} \quad (4)$$

Sujeto a:

$$r_i^{\min} \leq r_i \leq r_i^{\max}, 0 \leq o_i \leq o_i^{\max}; i, j = 1, 2, \dots, n \quad (5)$$

donde:

w_{ij} volumen de tráfico (costo) asociado al movimiento entre las instalaciones i, j.

d_{ij} distancia rectilínea entre los centroides de las particiones asignadas a las instalaciones i y j.

r_i relación de aspecto (ratio) alto-ancho del espacio asignado a la actividad i.

r_i^{max} valor máximo (límite superior) de la actividad i.

r_i^{min} valor mínimo (límite inferior) de la actividad i.

o_i relación de aspecto del espacio asignada a la actividad i.

o_i^{max} límite superior de o_i .

Si la actividad es libre se considera la ecuación 6:

$$r_i^{min} = \min\left\{r_i^{min}, \frac{1}{r_i^{max}}\right\}; r_i^{max} = \max\left\{r_i^{max}, \frac{1}{r_i^{min}}\right\} \quad (6)$$

Los algoritmos genéticos están diseñados para resolver problemas de optimización complejos. Las restricciones anteriores se convierten en una función de penalización. El problema se reformula como un problema de optimización sin restricciones expresado en la ecuación 7 como sigue:

$$\text{Min } F = \sum_{i=1}^n \sum_{j=1}^n w_{ij} d_{ij} + \mu \sum_{i=1}^n l_i \quad (7)$$

donde:

μ coeficiente que pondera la importancia relativa del costo del incumplimiento de las restricciones formales del problema, frente al costo del flujo de materiales entre actividades.

l_i indicador de incumplimiento de restricciones geométricas de la actividad i.

Para el caso de una actividad libre ($l_{i_{lib}}$) se utiliza la ecuación 8, en una actividad fija (l_{i_f}) se utiliza la ecuación 9; el incumplimiento formal (l_i) se calcula de manera diferente.

$$l_{i_{lib}} = \max \left\{ 0, \max \left\{ \left(r_i - \max \left\{ r_i^{\max}, \frac{1}{r_i^{\min}} \right\} \right) \left(\min \left\{ r_i^{\min}, \frac{1}{r_i^{\max}} \right\} - r_i \right) \right\} \right\} \quad (8)$$

$$l_{i_f} = \left\{ 0, \max \{ r_i - r_i^{\max}, r_i - r_i^{\min} \} \right\} \quad (9)$$

2.4.3 Los operadores genéticos

Una vez definida la manera de construir y representar (codificar) las soluciones y evaluar la aptitud de cada individuo, queda definir los operadores genéticos que permitan introducir variabilidad a la población. En los AG se tienen tres operadores clásicos: selección, cruce y mutación.

- a) La selección. – Según (Tam, 1992) consiste en decidir los supervivientes y los reproductores para ello se establece un mecanismo conocido como ruleta que establece las probabilidades de selección en términos de la aptitud de los individuos. Para calcular la probabilidad de selección de un individuo mediante su adaptación respecto a los otros individuos de la población. Para un individuo x de una población g , con fenotipo f ; la adaptación se calcula con la ecuación 10:

$$\mu(f) = costo_{\max} - costo(x) \quad (10)$$

donde:

$\mu(f)$ adaptación al medio del individuo x (expresado en el fenotipo f).

$costo_{\max}$ costo del individuo peor adaptado de la población (el de mayor costo).

$costo(x)$ costo de la solución x medido con la función evaluadora.

De lo anterior la probabilidad de selección de un individuo x se calcula con la ecuación 11:

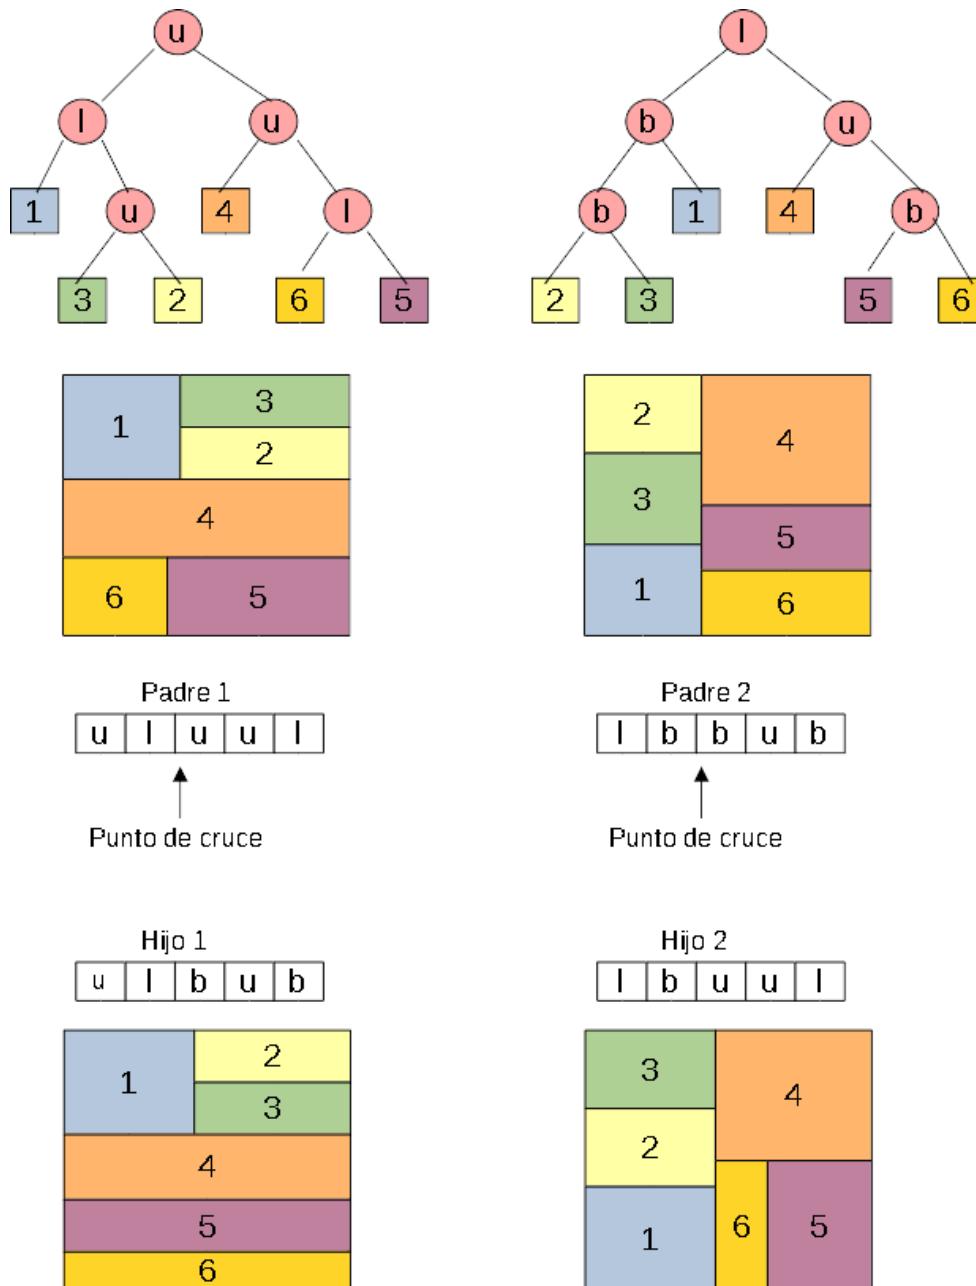
$$P(x, g) = \frac{\mu(f)}{\sum_{\forall f} \mu(f)} \quad (11)$$

Calculadas y conocidas las probabilidades de los individuos, se procede a ordenarlas de manera descendente. Luego se calcula las probabilidades acumuladas de cada individuo, obtenido de la probabilidad propia y la de todos los que le preceden según la ordenación. La fórmula por utilizar se presenta en la ecuación 12:

$$P_{acum}(x_i) = \sum_j^i P(x_j) \quad (12)$$

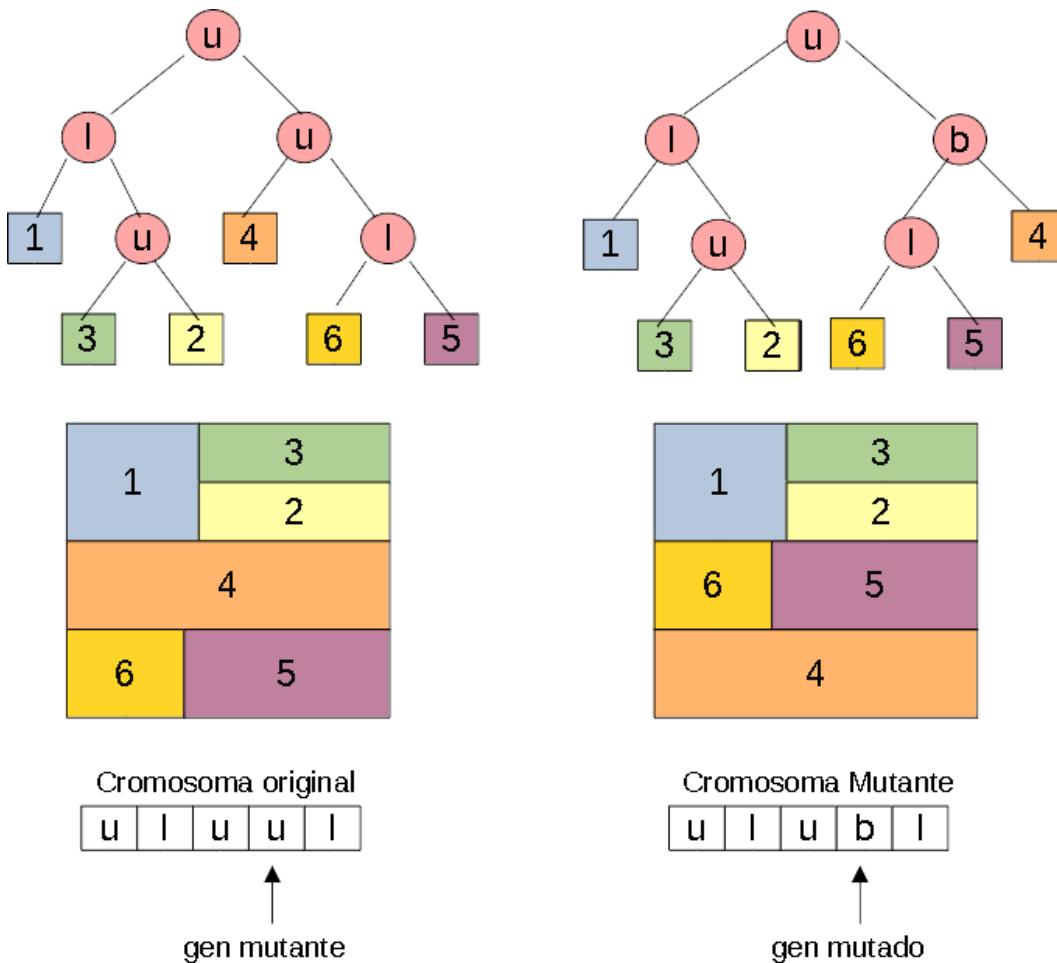
- b) El cruce en (Tam, 1992) es monopunto y se realiza de manera aleatoria eligiendo un punto de cruce. A partir de este punto, se intercambia el código de los progenitores que queda a ambos lados del punto de cruce. La figura 11 presenta este proceso.

Figura 11
Cruce en un único punto



Fuente: (Tam, 1992b)

- c) La mutación toma aleatoriamente un gen de la cadena que representa un individuo y lo cambia aleatoriamente obteniendo un cambio en dicho alelo (ver figura 12).

Figura 12*Mutación*

Fuente: (Tam, 1992b)

2.4.4 *La nueva propuesta de Tam*

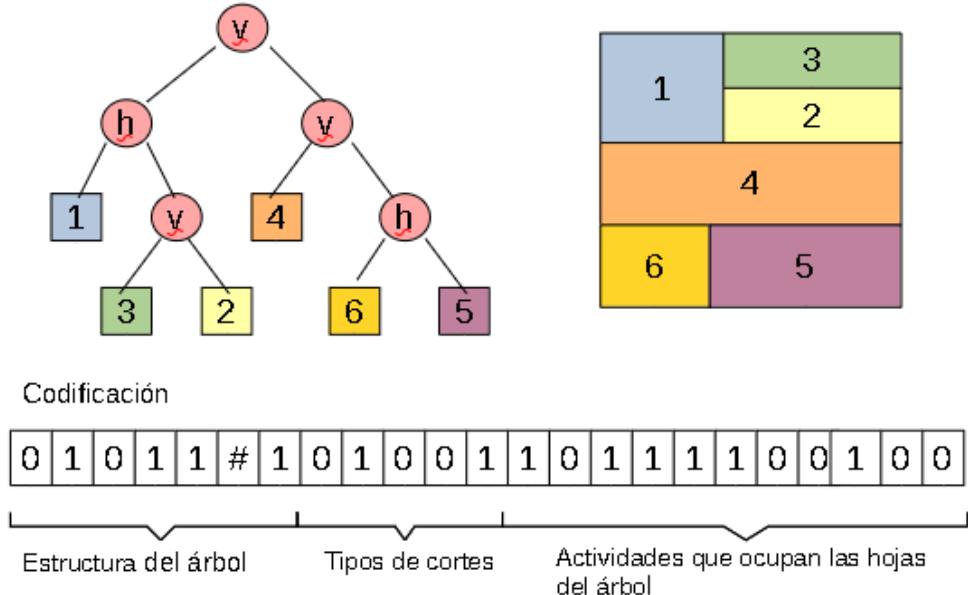
La propuesta de (Tam, 1992b) obtiene un único árbol de cortes, lo cual implica que excluye en la búsqueda otros arboles del espacio de solución. Este procedimiento fue mejorado por el mismo en (Tam & Chan, 1998). Lo resaltante de esta nueva propuesta es que realiza la búsqueda en todo el espacio de soluciones.

Este nuevo esquema presentado por Tam para el árbol de cortes y las instalaciones se codifica en una cadena con tres partes: la estructura del árbol, los nodos internos y las hojas externas.

Para representar una estructura de árbol como una cadena se usa '0' y '1' para denotar las hojas internas y externas respectivamente. La estructura del árbol se codifica utilizando el método "Gambler's ruin" que es un caso especial de representación en preorden de un árbol binario. Esta aplicación tiene las características siguientes:

- (1) El primer elemento de la ruina debe ser '0' (nodo interno) y los dos últimos elementos ruina, deben ser '1' (hoja externa).
- (2) El número total de '0' es $N_{fac} - 1$ y el número total de '1' es N_{fac} , donde N_{fac} es el número de instalaciones (o hojas externas); y
- (3) En cualquier posición P de la ruina, el número de '0' que aparecen antes de P debe ser \geq que el número de '1' que aparecen antes de P .

Tomando estas características, no es necesario especificar la ruina completa pues algunos elementos de la ruina pueden ser determinados por otros elementos conocidos. En ese sentido, la estructura de un árbol de corte está representada por un esquema, en lugar de una cadena binaria exacta. Por ejemplo (según Tam, 1998), la estructura de árbol de la figura 13 está representada por el esquema '#01011###'. Los nodos internos definen el tipo de corte en cada nodo. '1' un corte horizontal, '0' indica un corte vertical. Si el corte es vertical las actividades que penden del ramal izquierdo del nodo se colocan en la parte superior del corte, y en la inferior las restantes. Por otro lado, si el corte es horizontal, las actividades que penden del ramal izquierdo del nodo se ubican en la parte izquierda del corte, y en la derecha las restantes.

Figura 13*Codificación de un individuo**Fuente: (Tam & Chan, 1998)*

2.4.5 **Formulación del modelo**

El objetivo del diseño de la distribución de planta es asignar espacio a las instalaciones tal que las instalaciones con grandes valores de tráfico se colocan muy cerca sin dejar de satisfacer las limitaciones de área y forma de las instalaciones individuales. A partir de esta formulación, para cualquier árbol de corte $s \in S$, el problema de asignación de espacio se expresa en las ecuaciones 13 y 14:

$$\text{Min}_{s \in S} F = \sum_{i=1}^n \sum_{j=1}^n w_{ij} d_{ij} \quad (13)$$

Sujeto a:

$$r_i^{\min} \leq r_i \leq r_i^{\max}; i, j = 1, 2, \dots, n \quad (14)$$

donde:

w_{ij} volumen de tráfico (costo) asociado al movimiento entre las instalaciones i, j.

d_{ij} distancia rectilínea entre los centroides de las particiones asignadas a las instalaciones i y j.

r_i relación de aspecto alto-ancho del espacio asignado a la actividad i.

r_i^{max} valor máximo (límite superior) de la actividad i.

r_i^{min} valor mínimo (límite inferior) de la actividad i.

Según Tam, el problema se reformula como un problema de optimización sin restricciones expresado como sigue (ver ecuaciones 15 y 16):

$$\text{Min}_{s \in S} F = \sum_{i=1}^n \sum_{j=1}^n v_{ij} d_{ij} + \sum_{i=1}^n w_i^\alpha r_i \quad (15)$$

donde:

$$\begin{aligned} r_i &= \max \left\{ 0, \left[(r_i - r_i^{max}), (r_i^{min} - r_i), \left(r_i - \frac{1}{r_i^{min}} \right), \left(\frac{1}{r_i^{max}} - r_i \right) \right] \right\} \\ w_i^\alpha &\geq 0, \quad i, j = 1, 2, \dots, n \end{aligned} \quad (16)$$

El primer término de F mide la capacidad de tráfico. Se define como el producto de la distancia rectilínea d_{ij} entre dos instalaciones y su volumen de tráfico v_{ij} . El segundo término representa una función de penalización por restricciones geométricas. En cuanto a la función de penalización el primer término mide el grado en que se violan las restricciones de relación de aspecto. Dado que cada instalación tiene un nivel de tolerancia único para violar esta restricción r_i , se multiplica por un factor de peso $w_i^\alpha \geq 0$.

2.5 Glosario

ALELO: Valor que puede adoptar un gen.

CONTROLAR: Acto de medir y registrar los resultados alcanzados por un agente del sistema organizacional en un tiempo y espacio determinados.

EFFECTIVIDAD: Cumplimiento al ciento por ciento de los objetivos planteados.

EFICIENCIA: Uso racional de los medios con que se cuenta para alcanzar un objetivo predeterminado; es el requisito para evitar o cancelar dispendios y errores.

ESPACIO DE SOLUCIONES: Conjunto de todas las posibles soluciones a un problema determinado que es posible alcanzar con el sistema de resolución empleado. Equivale a espacio de individuos.

EXPERIMENTACIÓN: Observación provocada.

FENOTIPO: Características físicas de un individuo determinadas por su genotipo y las condiciones del medio externo.

GEN: Analogía natural de cada uno de los elementos que conforman la cadena o cromosoma que se necesita para representar un individuo.

GENERACIÓN: Proceso de creación de nuevos individuos. También se emplea como sinónimo de población.

GENOTIPO: Se empleará para denotar el contenido genético de un individuo, es decir, el cromosoma que lo codifica.

INDIVIDUO: Equivalente analógicamente a solución o alternativa de solución.

MEDIO EXTERNO: Entorno en el que se desarrollan y compiten los individuos. En el presente trabajo será análogo al dominio de ubicación o colocación de las actividades.

PROCESO: Un conjunto de acciones integradas y dirigidas hacia un fin. Una acción continua u operación o serie de cambios o tareas que ocurren de manera definida.

SOLUCION: Configuración compatible con las restricciones del problema y que le da la solución.

SOLUCIÓN ÓPTIMA: Solución $s \in S$, tal que la función objetivo $f(s)$ sea óptima. Analógicamente, en algoritmos genéticos es el individuo mejor adaptado a su entorno.

SOLUCIÓN SUB ÓPTIMA: Solución de calidad cercana a la de la solución óptima, o bien de calidad aceptable para las condiciones del problema planteado.

CAPITULO 3: METODOLOGIA

En este capítulo antes de presentar el algoritmo genético propuesto, se describe primero la hipótesis general, las hipótesis específicas, la identificación de variables y su operacionalización, la matriz de consistencia de la investigación se presenta en el anexo I.

3.1 Hipótesis general

HG: Utilizando el Algoritmo Genético de operadores de cruce y mutación ALGOCYM se optimiza La distribución en planta en las organizaciones de manufactura.

3.1.1 *Hipótesis específicas*

HE1: La aplicación del árbol de cortes por algoritmos genéticos permite optimizar el área de la distribución en planta.

HE2: La elaboración del algoritmo genético ALGOCYN permite alcanzar una solución óptima al problema de distribución en planta.

HE3: Los experimentos numéricos permiten cuantificar los resultados del algoritmo genético ALGOCYM.

HE4: El diseño e implementación de la aplicación informática permite probar la bondad del algoritmo genético ALGOCYM.

3.2 Identificación de variables

Para el desarrollo de la tesis propuesta se ha identificado las siguientes variables:

3.2.1 ***Variables dependientes***

VD: Optimización de la distribución en planta.

VD1: Optimización del área de la distribución en planta.

VD2: Solución óptima al problema de la distribución en planta.

VD3: Resultados del algoritmo genético ALGOCYM.

VD4: Bondad del algoritmo genético ALGOCYM.

3.2.2 ***Variables independientes***

VI: Algoritmo genético de operadores de cruce y mutación

VI1: Árbol de cortes por algoritmos genéticos.

VI2: Algoritmo genético ALGOCYM.

VI3: Niveles de cruce y mutación para el algoritmo genético ALGOCYM.

VI4: Diseño e Implementación de la aplicación informática del algoritmo ALGOCYM.

3.3 Operacionalización de variables

En la tabla 3 se presenta la identificación de variables. Las dimensiones e indicadores de estas variables se presentan en el anexo 1.

Tabla 3

Identificación de variables

HIPOTESIS GENERAL	VARIABLE INDEPENDIENTE	VARIABLE DEPENDIENTE
Utilizando el Algoritmo Genético de operadores de cruce y mutación ALGOCYM se optimiza La distribución en planta en las organizaciones de manufactura.	VI: Algoritmo genético de operadores de cruce y mutación	VD: Optimización de la distribución en planta.
HIPOTESIS ESPECIFICA	VARIABLE INDEPENDIENTE	VARIABLE DEPENDIENTE
HE1: La aplicación del árbol de cortes por algoritmos genéticos permite optimizar el área de la distribución en planta.	VI1: Árbol de cortes por algoritmos genéticos.	VD1: Optimización del área de la distribución en planta.
HE2: La elaboración del algoritmo genético (ALGOCYN) permite alcanzar una solución óptima al problema de distribución en planta	VI2: Algoritmo genético ALGOCYM.	VD2: Solución óptima al problema de la distribución en planta.
HE3: Los experimentos numéricos, permiten cuantificar los resultados del algoritmo genético ALGOCYM.	VI3: Niveles de cruce y mutación para el algoritmo genético ALGOCYM.	VD3: Resultados del algoritmo genético ALGOCYM.
HE4: El diseño e implementación de la aplicación informática permite probar la bondad del algoritmo genético ALGOCYM.	VI4: Diseño e Implementación de la aplicación informática del algoritmo ALGOCYM.	VD4: Bondad del algoritmo genético ALGOCYM.

Fuente: elaboración propia

3.4 Tipo y diseño de investigación

Cuando se clasifican las investigaciones tomando como criterio el papel que ejerce el investigador sobre los factores o características que son objeto de estudio, la investigación puede ser clasificada como experimental o no-experimental. Es experimental, cuando el investigador no solo identifica las características que se estudian, sino que las controla, las altera o manipula con el fin de observar los resultados al tiempo que procura evitar que otros factores intervengan en la observación (Hernández-Sampieri & Mendoza, 2018).

La presente investigación es del tipo experimental mediante simulación. Tomando en cuenta que el FLP es tratado generalmente como un conjunto de departamentos de áreas desiguales, el problema consiste en una región rectangular con dimensiones H (Height, alto) y W (Width, ancho), una secuencia de departamentos de 1 hasta n cuyas áreas están preestablecidas, el flujo y costo de materiales que viajan entre estos, y restricciones como la secuencia y las formas que estos departamentos pueden o deben tener. El objetivo es obtener el layout tal que minimice el costo total del flujo de materiales entre los departamentos (Shebanie II, 2004). Adicionalmente se aclara que en la formulación del problema y la solución planteada por el algoritmo propuesto no se considera los pasillos en la distribución de planta.

La expresión gráfica del diseño experimental es la siguiente:

$$G: AXO_1$$

donde:

G : Grupo experimental

A : Aleatorio

X : Variable independiente

O_i : Observación

Este diseño se aplicará a cada uno de los cuatro problemas FLP que se indican más adelante en 3.7.

3.5 El algoritmo propuesto

Para mostrar la funcionalidad del algoritmo genético propuesto (ALGOCYD) se toma como datos de entrada una formulación FLP para 5 departamentos tomada de (Tam & Li, 1991). La tabla 4 presenta la matriz de flujos del problema¹, nótese que al no existir flujo consigo mismo esto se representa con el valor cero. La tabla 5 presenta las áreas y las ratios de aspecto de cada departamento.

Tabla 4

Matriz de flujos para 5 departamentos (Tam5)

Dept.	1	2	3	4	5
1	0	5	2	4	1
2		0	3	0	2
3			0	0	0
4				0	5
5					0

Fuente: (Tam & Li, 1991)

Tabla 5

Departamentos y ratios de aspecto (Tam5)

Dept.	Área	Ratio lower	Ratio upper
1	24.00	0.80	1.00
2	16.00	0.75	1.15
3	36.00	0.60	1.85
4	8.00	0.30	1.10
5	21.00	0.90	1.18

Fuente: (Tam & Li, 1991)

¹ Nótese que la matriz de flujos es una matriz simétrica.

El método LAYAGEN fue propuesto por Santamarina en 1995 para resolver el problema de la distribución en planta aplicando algoritmos genéticos en dos pasos. El algoritmo propuesto ALGOCYM está inspirado en LAYAGEN por lo que consta en dos partes: la primera mediante algoritmos genéticos realiza la búsqueda del árbol que tenga el mayor potencial geométrico y relacional para a partir de él encontrar las mejores soluciones. La segunda parte consiste en tomar este árbol y mediante algoritmos genéticos aplicar los cortes para obtener la mejor solución al FLP.

Resumiendo, el párrafo anterior se tiene:

Paso 1: Buscar el árbol con el mejor potencial geométrico y relacional.

Paso 2: Al árbol encontrado en el paso 1, aplicar los cortes de manera tal que represente el layout óptimo.

3.5.1 ***Paso 1: Buscar el árbol con el mejor potencial geométrico***

De acuerdo con (Santamarina, 1995) en el paso 1, es posible obtener el mejor árbol de cortes óptimo determinando la estructura del árbol (ramas y nodos que indican los cortes), las posiciones de las n actividades se ubican en las hojas del árbol. Esto genera diferentes individuos de dicha especie; es decir las diferentes soluciones que genera un árbol, el cual se determina en el paso 2.

Según Santamarina, la ecuación 17 permite determinar el número de posibles árboles de corte (especies) con n instalaciones o actividades:

$$\frac{1}{2^{n-1}} \prod_{i=0}^{n-2} (n-i)(n-i-1) \quad (17)$$

Tomando la formula anterior se obtiene la tabla 6 que resume el número de árboles que se obtienen dadas n instalaciones o actividades. En la figura 14 se observa que el crecimiento en cuanto al número de árboles de cortes se da exponencialmente.

Tabla 6

Número de árboles de corte para n instalaciones

Numero de Instalaciones	Número de áboles de corte
1	1
2	1
3	3
4	18
5	180
6	2700
7	56700
8	1.5876e+06
9	6.82195e+06

Fuente: elaboración propia

Figura 14

Número de instalaciones versus número de árboles de corte



Fuente: elaboración propia

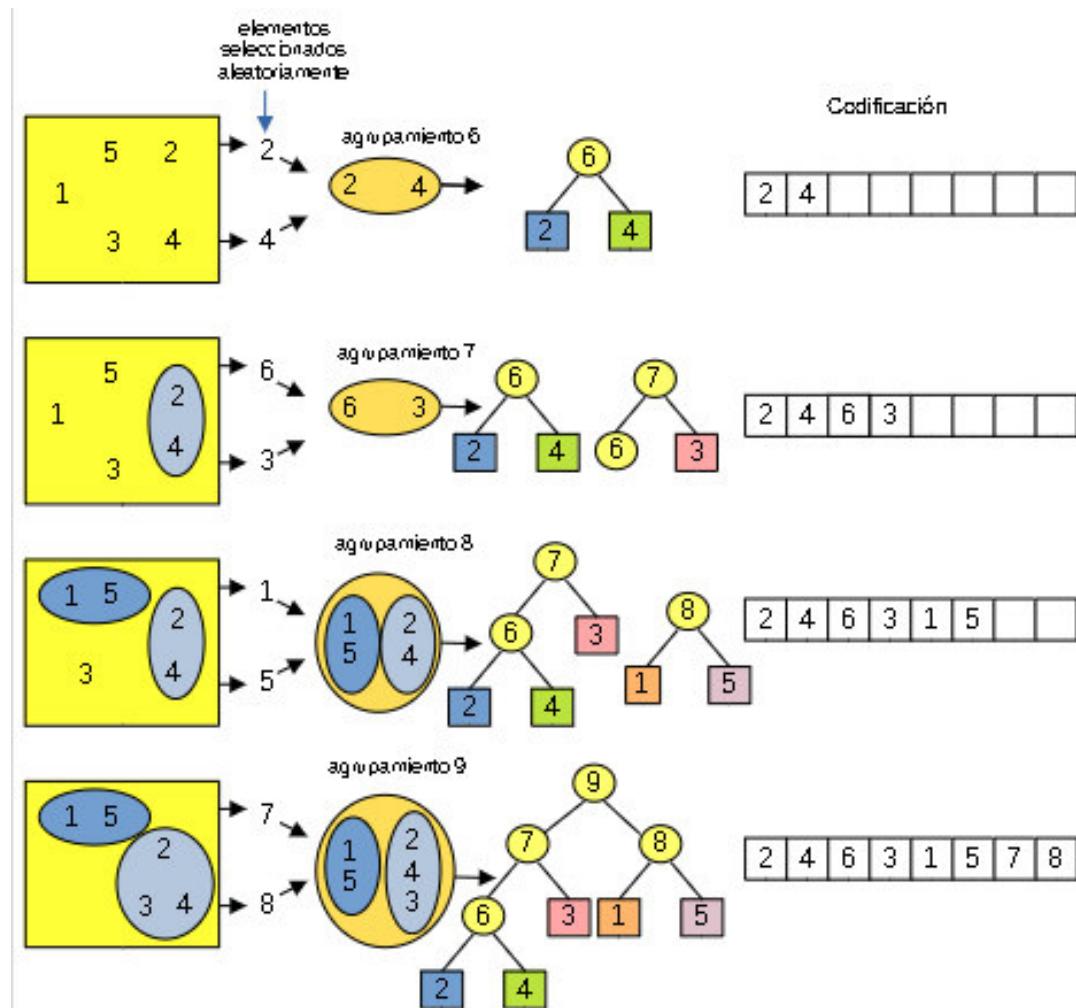
3.5.1.1 **Codificación y decodificación de los árboles de corte.** Según la tabla 6, el número posible de árboles de corte se incrementa de manera exponencial para $n = 5$ se tiene que codificar 180 árboles distintos, para $n = 6$ se tiene que codificar 2700 árboles distintos; por tanto, surge la necesidad de plantear un mecanismo de codificación-decodificación. Santamarina propone cadenas que representan a cada árbol, donde la codificación emplea la formación de clústeres (en adelante se llamará agrupamientos).

Para el caso de $n = 5$ instalaciones se tienen $\{1,2,3,4,5\}$. El primer agrupamiento se forma eligiendo aleatoriamente dos instalaciones; a este agrupamiento se denomina $(n + 1) = 6$. Las dos instalaciones seleccionadas, constituyen los dos primeros elementos de la cadena; por ejemplo, 2 y 4. Este proceso es de selección aleatoria conformando nuevos agrupamientos, tomando dos elementos del conjunto que no forman parte de ningún agrupamiento y los agrupamientos ya formados. Los dos números que representan las instalaciones o agrupamientos seleccionados se agregan a la cadena que representará el árbol. Este procedimiento es iterativo y se da hasta que no quede ninguna instalación por seleccionar (ver figura 15).

Examinando la figura 14 se tiene que las cadenas (cromosomas) formadas tendrán una longitud de $(2 * n - 2)$ elementos; es decir 8 genes en el ejemplo, de los que $(n - 2) = (5 - 2) = 3$ son valores mayores que $n = 5$; lo cual significa que estos agrupamientos son $\{6, 7, 8\}$. Resumiendo, los genes toman valores cuyo conjunto de alelos es $\theta = \{1,2,3,\dots,2n - 2\}$.

Figura 15

Obtención de árboles de corte y codificación de cadenas en ALGOCYMY para el caso Tam5



Fuente: Preparado de acuerdo con (Santamarina, M.C., 1995)

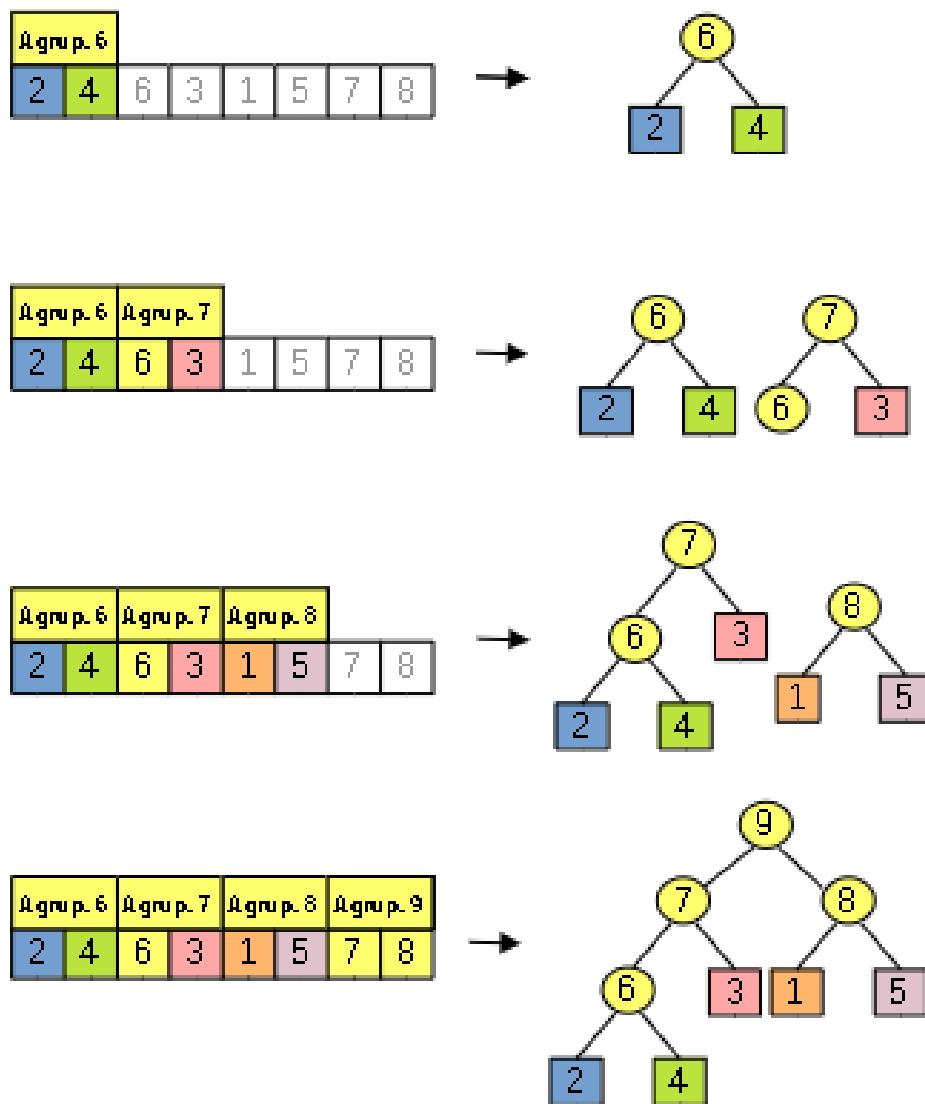
Para realizar el proceso de decodificación de las cadenas se analizan los genes que la forman por parejas. En ese orden de ideas, el número de parejas será $(n - 2)$. Así el primer par de genes representa las dos primeras actividades que conforman el primer agrupamiento; el $(n + 1) = 6$, los cuales penden de un mismo nodo. El segundo par de genes representa las instalaciones (agrupamiento o instalación) contenidas en el agrupamiento $(n + 2) = 7$, y así sucesivamente, ver la figura 16.

Es necesario notar que el último de los agrupamientos denotado por $(2n - 1) = (2 * 5 - 1) = 9$ en la figura 15, no se representa en la cadena o cromosoma por considerarse que es información no necesaria o irrelevante; puesto que es el nodo raíz del árbol.

Figura 16

Decodificación de cadenas (cromosomas) según ALGOCYMY para obtener el árbol de cortes que representan para Tam5

Decodificación



Fuente: Preparado de acuerdo con (Santamarina, M.C., 1995)

3.5.1.2 **Cálculo del potencial del árbol de cortes.** Para explicar cómo se realiza el cálculo del potencial suponga que se tiene un árbol con dos nodos (actividades) 1 y 2, cuyas áreas (para cada actividad) son A₁ y A₂. Para estas actividades se tiene las ratios de aspecto mínimos y máximos establecidos para cada actividad r_{1min} , r_{1max} y r_{2min} , r_{2max} . La figura 17 presenta el dominio de colocación mediante un corte único que puede ser vertical u horizontal lo cual genera las distribuciones del árbol. En la figura 17 el área de colocación A es la suma de las áreas A₁ y A₂, la ratio R representa alto-ancho del dominio de colocación. Dependiendo del corte vertical u horizontal se tendrá todas las posibles configuraciones que variaran entre R_{min} y R_{max} . Esto constituye dos subdominios cuyas relaciones entre la ratio de las actividades se plantean como se muestra en las ecuaciones 18 y 19:

Caso I: Corte vertical

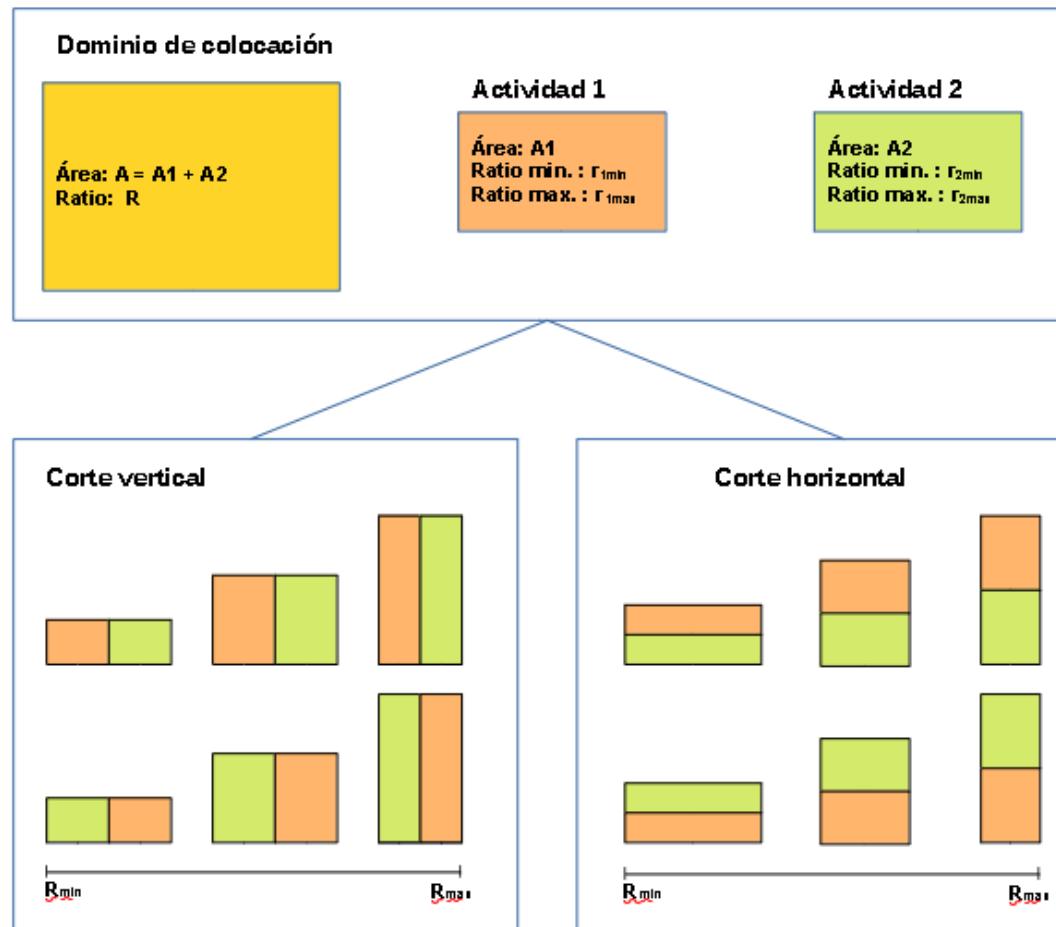
$$r_1 = \frac{A_1 + A_2}{A_1} R = \frac{A}{A_1} R \quad r_2 = \frac{A_1 + A_2}{A_2} R = \frac{A}{A_2} R \quad (18)$$

Caso II: Corte horizontal

$$r_1 = \frac{A_1}{A_1 + A_2} R = \frac{A_1}{A} R \quad r_2 = \frac{A_2}{A_1 + A_2} R = \frac{A_2}{A} R \quad (19)$$

Figura 17

Configuraciones posibles al aplicar un corte en un árbol de cortes

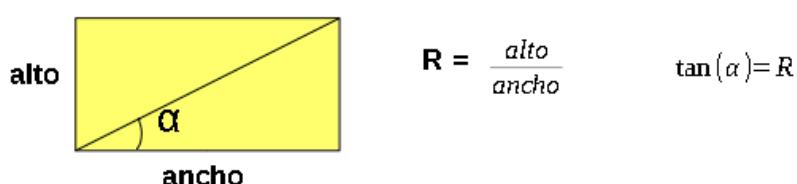


Fuente: Modificado de (Diego-Más, 2006)

El cociente alto - ancho expresa la ratio del dominio a considerar y tomará valores comprendidos entre $0, \infty$, así se tiene que cuando el dominio es cuadrado entonces el valor de la ratio es 1 (ver figura 18).

Figura 18

Dominio mediante ratio alto-ancho y mediante ángulo



Fuente: (Diego-Más, 2006)

Para medir la geometría de la zona donde se colocará una actividad, de la figura 18, tomando el ángulo α se tiene que R es el cociente entre el cateto opuesto al ángulo y el cateto adyacente; por ello se plantea la siguiente transformación, ver ecuaciones 20 y 21:

Caso I: Corte vertical

$$\alpha_1 = \arctan\left(\frac{A}{A_1} \tan \alpha\right) \quad \alpha_2 = \arctan\left(\frac{A}{A_2} \tan \alpha\right) \quad (20)$$

Caso II: Corte horizontal

$$\alpha_1 = \arctan\left(\frac{A_1}{A} \tan \alpha\right) \quad \alpha_2 = \arctan\left(\frac{A_2}{A} \tan \alpha\right) \quad (21)$$

Nota: En términos de programación para la implementación informática de ALGOCYMY se utiliza las ecuaciones 20 y 21.

3.5.1.3 ***Cálculo del incumplimiento de las instalaciones.***

Conocidos los ratios mínimos y máximos de cada instalación, el ángulo permisible para cada instalación, el corte a aplicarse; se puede valorar el grado de cumplimiento de las restricciones en función a la ratio inicial. El siguiente punto por considerar es establecer la diferencia entre orientación libre o fija con respecto a las actividades y la manera en que estas serán codificadas. Dado un sistema de referencia una instalación se considera libre cuando puede ser colocada vertical u horizontal de manera indistinta, sin que esto afecte su normal desempeño. Una instalación se considera fija en caso contrario. Si es posible calcular el grado de cumplimiento; entonces, también es posible calcular el grado de incumplimiento de una determinada instalación.

Para el caso de **instalaciones de orientación libre** el cálculo del incumplimiento de restricciones geométricas se realiza calculando la distancia entre la ratio de la instalación y el extremo del intervalo válido más cercano. Sea I el incumplimiento y α_i la ratio de la instalación (ver ecuación 22).

$$I_{lib_i} = \begin{cases} \alpha_{imin} - \alpha_i; & \alpha_i < \alpha_{imin} \\ \alpha_i - \alpha_{imax}; & \alpha_{imax} < \alpha_i \leq 45^\circ \\ 90^\circ - \alpha_{imax} - \alpha_i; & 45^\circ < \alpha_i < 90^\circ - \alpha_{imax} \\ \alpha_i - 90^\circ + \alpha_{imin}; & \alpha_i > 90^\circ - \alpha_{imin} \\ 0; & \text{en cualquier otro caso} \end{cases} \quad (22)$$

Dado que el ángulo varía de 0° a 90° , cuando este es 45° aplicando simetría, la expresión anterior se puede simplificar al aplicar una traslación del origen a dicho punto, para dar lugar al cálculo del incumplimiento mediante la ecuación 23, siguiente:

$$I_{lib} = \left| |\alpha_i - 45^\circ| - \left[45^\circ - \frac{\alpha_{imin} + a}{2} \right] \right| - \frac{a - \alpha_{imin}}{2} \quad (23)$$

Nota. - Tener en cuenta que α toma el valor α_{imax} si el ángulo es menor que 45° ; en otro caso toma el valor 45° .

Para el caso de **instalaciones de orientación fija** el cálculo del incumplimiento de las restricciones geométricas es parecido, teniendo en cuenta si se trata de una instalación de orientación vertical α_{imin} y α_{imax} son sustituidos por $90^\circ - \alpha_{imax}$ y $90^\circ - \alpha_{imin}$ respectivamente, y el reciproco de α_i es $90^\circ - \alpha_i$, (Ver la ecuación 24).

$$I_{fij_i} = \begin{cases} \alpha_{imin} - \alpha_i; & \alpha_i < \alpha_{imin} \\ \alpha_i - \alpha_{imax}; & \alpha_i < \alpha_{imax} \\ 0; & \alpha_{imin} \geq \alpha_i \geq \alpha_{imax} \end{cases} \quad (24)$$

Trasladando el origen de ángulos al centro del intervalo y aplicando simetría respecto al origen, se tiene la ecuación 25:

$$I_{fib_i} = \left| \alpha_i - \frac{\alpha_{imin} + \alpha_{imax}}{2} \right| - \frac{\alpha_{imax} - \alpha_{imin}}{2} \quad (25)$$

Para valorar el incumplimiento geométrico de una instalación de ratio α_i sabidos las ratios máximas y mínimos permitidos para dicha instalación, se tiene las ecuaciones (24) y (25). Relacionándolas con la ecuación (23) es posible formular el incumplimiento formal de las instalaciones obtenidas por un corte (vertical u horizontal) en función del dominio inicial de partida de la manera presentada en la ecuación 26:

$$I_{lib_i}(\alpha) = \left| \arctan(K \tan(\alpha)) - 45^\circ \right| - \left[45^\circ - \frac{\alpha_{imin} + a}{2} \right] - \frac{a - \alpha_{imin}}{2} \quad (26)$$

$$I_{fib_i}(\alpha) = \left| \arctan(K \tan(\alpha)) - \frac{\alpha_{imin} + \alpha_{imax}}{2} \right| - \frac{\alpha_{imax} - \alpha_{imin}}{2}$$

En las ecuaciones (26) se debe tener en cuenta que $a = \alpha_{imax}$ si es menor de 45° ; en otro caso su valor es 45° , K denota el cociente del área de instalación y el área del dominio de partida, si el corte es vertical. En caso de que el corte es horizontal, se toma el inverso de este valor. Si bien es cierto en las fórmulas presentadas, el ángulo se expresa en grados sexagesimales, no obstante, para la implementación informática este ángulo se expresa en radianes, siendo su intervalo entre 0 y $\pi/2$.

Finalmente es deseable que el valor del incumplimiento geométrico de cada instalación asignada sea 0 para garantizar que el árbol evaluado que representa la solución el mejor y permitirá alcanzar el óptimo buscado.

3.5.1.4 Función evaluadora para el paso 1. Tal como lo indica (Santamarina, M.C. 1995) la función objetivo tiene una naturaleza multicriterio que en si es una medida de la adaptación de un árbol (especie) al medio (población) donde se encuentra. Esta función busca aquel árbol de cortes con el mayor potencial (denotado por $P(AC)$), lo que implica el árbol con el menor costo relacional. Esta función tiene la forma presentada en la ecuación 27:

$$P(AC) = \sum_{i=1}^n \sum_{j=1}^n P(ij) - \left[\pm \sum_{u=1}^k \alpha_u - f_{u,ij} + \sum_{v=1}^{k'} \beta_v t_{v,ij} \right] \quad (27)$$

donde:

β_v , α_u coeficientes de ponderación entre factores relativa cualitativa y cuantitativa respectivamente.

$f_{u,ij}$ intensidad relacional entre instalaciones i , j tomando criterio cuantitativo.

$t_{v,ij}$ intensidad relacional entre instalaciones i , j tomando criterio cualitativo.

k número de criterios cuantitativos.

k' número de criterios cualitativos.

$P(ij)$ potencial de adyacencia entre instalaciones i , j del árbol de cortes.

Para el cálculo del potencial de adyacencia del árbol de cortes entre dos actividades i y j , se utiliza $P(ij) = P(i)*P(j)$, la cual se expresa en la ecuación 28.

$$P(ij) = \left(\frac{3}{4}\right)^{s+s'-2} \quad (28)$$

donde:

- s número de nodos a recorrer en dirección ascendente desde el nodo i , hasta hallar el primer nodo común con similar recorrido partiendo de la actividad j .
- s' número de nodos a recorrer en dirección ascendente desde el nodo j , hasta hallar el primer nodo común con similar recorrido partiendo de la actividad i .

Santamarina propone el estimador dado por la ecuación (28) mide la capacidad de dos instalaciones de mantener adyacencia en las diferentes conformaciones que se pueden generar a partir de un árbol de cortes, lo cual implica la profundidad relativa de las instalaciones en dicho árbol.

Resumiendo, el potencial geométrico de un árbol de cortes se evalúa con la ecuación 29:

$$P_{gac} = \min(P_{gac}(\alpha)); \quad \alpha_{\min} \geq \alpha \geq \alpha_{\max} \quad (29)$$

A partir de las ecuaciones (28) y (29) (Diego-Más, 2006) propone utilizar la ecuación 30, para definir el potencial del árbol de cortes P_{ac} tal como sigue:

$$P_{ac} = C_g * P_{gac} + \frac{C_r}{1 + P_{rac}} \quad (30)$$

donde

P_{gac} potencial geométrico del árbol de cortes definido en (29).

P_{rac} potencial relacional del árbol de cortes definido en (28).

C_g coeficiente de ponderación geométrica.

C_r coeficiente de ponderación relacional.

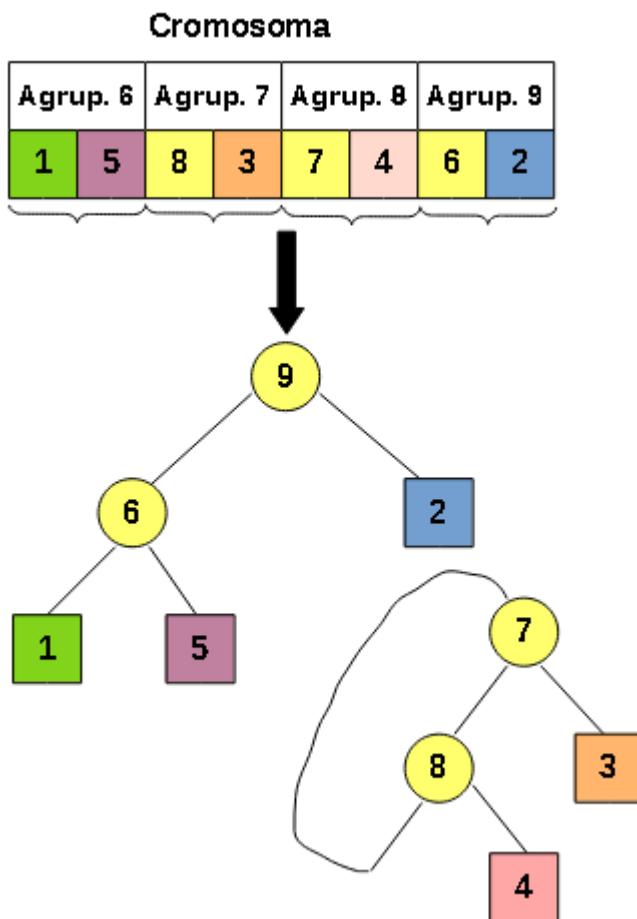
Respecto a la ecuación (30) la función evaluadora incrementa el tiempo computacional dado que requiere un elevado número de cálculos para evaluar cada árbol generado.

3.5.1.5 **Operadores genéticos.** Según los evolucionistas pequeños cambios hacen grandes diferencias. Esto es potencialmente cierto en la aplicación de algoritmos genéticos. La naturaleza de ALGOCYM permite examinar una cantidad considerable de posibles soluciones dentro del espacio de búsqueda lo cual conlleva a encontrar más de un óptimo local. En la codificación de una solución (cromosoma) al cual se le aplique una pequeña modificación se espera que conlleve a un pequeño cambio en la solución por otro lado grandes cambios en la codificación deben producir grandes cambios en la solución; esto se conoce como proporcionalidad entre las variaciones de la codificación y las variaciones entre los individuos que las representan. Así es posible que el individuo que represente una cadena sea inviable; es decir un individuo no viable.

Según (Diego Más, 2006) cuando una codificación representa un individuo no viable, se dice que no posee coherencia. Para ilustrar la representación de un individuo no viable suponga que se tiene $n = 5$ instalaciones, para que un elemento mayor que n aparezca en la cadena el agrupamiento que lo representa debe estar situado en las posiciones precedentes. Esto significa que un elemento $x > n$ no debe aparecer en la cadena en posiciones inferiores a $2(x - n) + 1$, esto implica colocar un nodo del cual aún no se han determinado sus ramas. En la figura 19 se tiene un cromosoma del cual el agrupamiento 8 ocupa los genes 5 y 6, aun así, el número 8 aparece en el tercer gen. Según esta conformación, al momento de decodificar se tiene que situar un agrupamiento aun no formado. Por otro lado, en el cromosoma de la figura se tiene que el agrupamiento 7 contiene al 8 y el 8 a su vez contiene al 7, esto hace que se tiene individuo no viable el cual generaría un árbol de cortes sin sentido.

Figura 19

Cromosoma que representa un individuo no viable



Fuente: Adaptado de (*Diego-Más, 2006*)

3.5.1.6 Operador de cruce. El operador de cruce en ALGOCYM es mono punto y toma al azahar un punto del cromosoma estableciendo el cruce entre dos cromosomas (papá y mamá). Para ilustrar su aplicación se utiliza Tam 5; cuyos datos del problema se proponen en las tablas 4 y 5. Se tienen los cromosomas representados como un arreglo:

Cromosoma papá:

gen	5	3	2	4	1	7	8	6
índice	0	1	2	3	4	5	6	7

Cromosoma mamá:

gen	1	2	4	5	7	3	8	6
índice	0	1	2	3	4	5	6	7

Tomando el índice 4 como un punto de cruce se tiene los siguientes hijos.

Cromosoma hijo 1 (inviable):

gen	5	3	2	4	7	3	8	6
índice	0	1	2	3	4	5	6	7

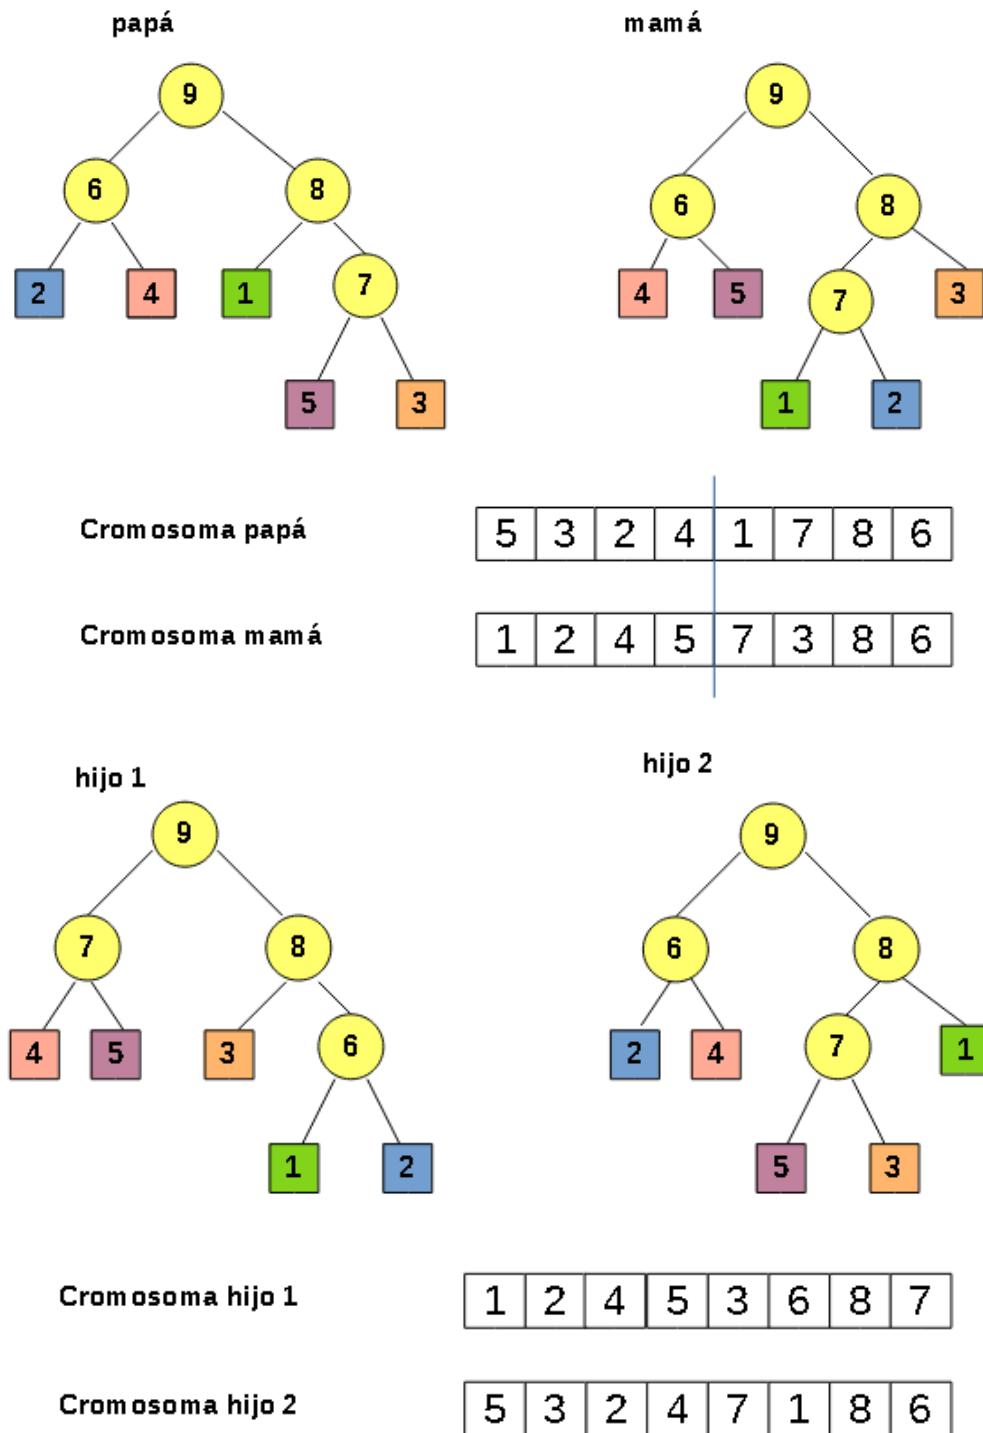
Cromosoma hijo 2 (inviable):

gen	1	2	4	5	1	7	8	6
índice	0	1	2	3	4	5	6	7

Para resolver el problema el algoritmo reacomoda los genes para conseguir un hijo viable (Ver figura 20).

Figura 20

Operador de cruce en ALGOCYMY para Tam 5

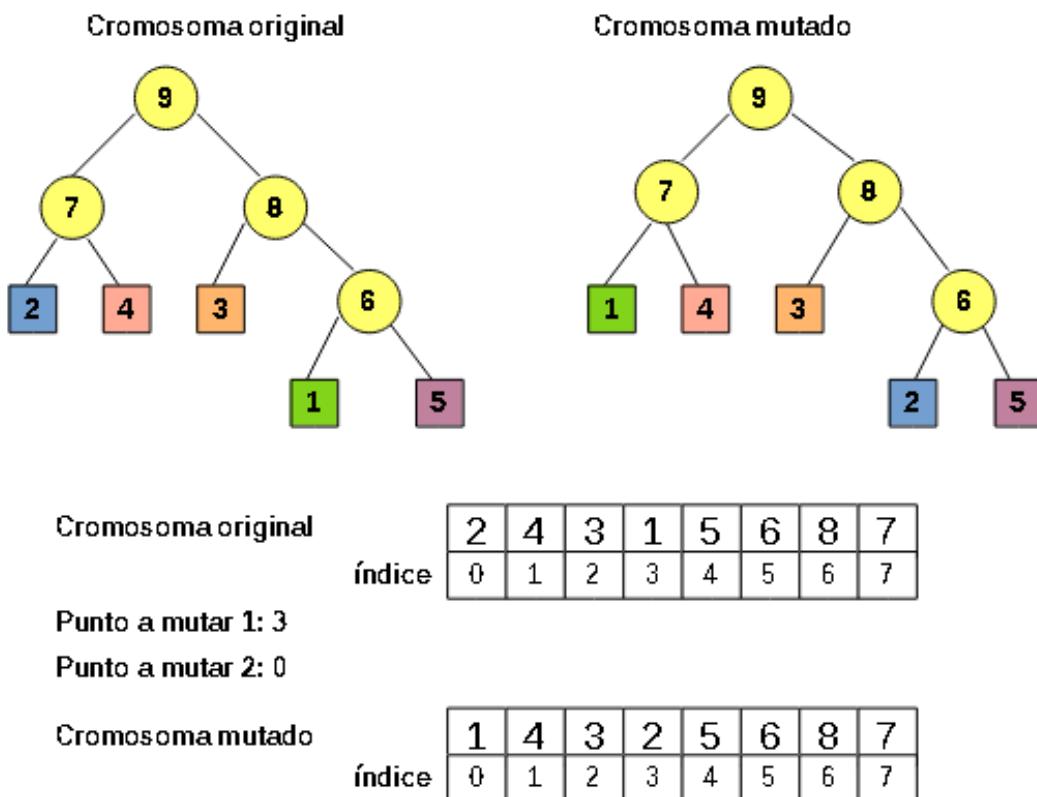


Fuente: Adaptado de (Diego Más, 2006)

3.5.1.7 Operador de mutación. El operador de mutación en ALGOCYMY consiste en intercambiar los alelos en determinadas posiciones las cuales son escogidas al azahar. Esta operación se ilustra en la figura 21 para Tam 5; donde dado un cromosoma, los puntos a mutar constan de los índices 3 y 0 del cromosoma original respectivamente, lo cual produce el cromosoma mutado como se aprecia en la figura. Al igual que en la operación de cruce el algoritmo verifica si el individuo es o no viable.

Figura 21

Operador de mutación en ALGOCYMY para Tam 5



Fuente: Adaptado de (Diego Más, 2006)

3.5.1.8 Operadores de selección, reemplazo y elitismo en ALGOCYM.

En algoritmos genéticos los operadores de cruce, selección y elitismo son clásicos. Cuando una generación ha sido evaluada, se debe decidir qué individuos pasaran a la siguiente generación, para ello a cada individuo se le asigna una probabilidad de selección en función a su aptitud para adaptarse (sobrevivir) en el medio, esta asignación incluye también a los individuos menos aptos. Así los individuos más adaptados tienen mayor probabilidad de pasar a la siguiente generación. Adicionalmente se debe establecer el criterio de reemplazo lo que implica la manera como los individuos de la nueva generación sustituyen a la anterior.

La selección. – Para aplicar la selección se emplea el mecanismo de la ruleta donde dado un individuo y su probabilidad asociada, le corresponde una porción de la ruleta asociada de manera proporcional. La sumatoria de las probabilidades de los individuos de la población es 1.

Dada una población de m individuos y x_i un individuo de dicha población. Se denota por $\mu(x_i)$ la aptitud de x_i obtenida del potencial del árbol de cortes que representa. El individuo peor adaptado es aquel que tiene el valor del potencial más alto, esto es $\mu_{max} = \max\{\mu(x_i)\}_{i=1\dots m}$

Encontrado el valor μ_{max} es posible aplicar la transformación presentada en la ecuación 31:

$$\mu(x_i) = \mu_{max} - \mu(x_i) \quad (31)$$

Ahora todos los valores $\mu(x_i)$ son mas altos para los individuos mejor adaptados y mas bajos para los menos adaptados; así se tiene que el individuo peor adaptado tendrá un valor 0. Ahora es posible expresar las probabilidades de selección de cada individuo tal como se presenta en la ecuación 32:

$$P(x_i) = \frac{\mu(x_i)}{\sum_{j=1}^m \mu(x_j)} \quad (32)$$

Una vez obtenidas las probabilidades de cada individuo, estas se colocan en una tabla y luego se ordenan según su probabilidad de mayor a menor. Ahora se realiza el cálculo de las probabilidades acumuladas para cada individuo tal como se presenta en la ecuación 33:

$$P_{acum}(x_i) = \sum_{j=1}^i P(x_j) \quad (33)$$

La tabla 7 presenta los cálculos para 6 individuos en Tam 5 aplicando ALGOCYM. Los valores de la función $f(x_i)$ se calculan con la ecuación 32 y los de $\mu(x_i)$ con la ecuación 31, el $P_{acum}(x_i)$ se calcula con la ecuación 33.

Tabla 7

Selección por ruleta para Tam 5 aplicando ALGOCYM

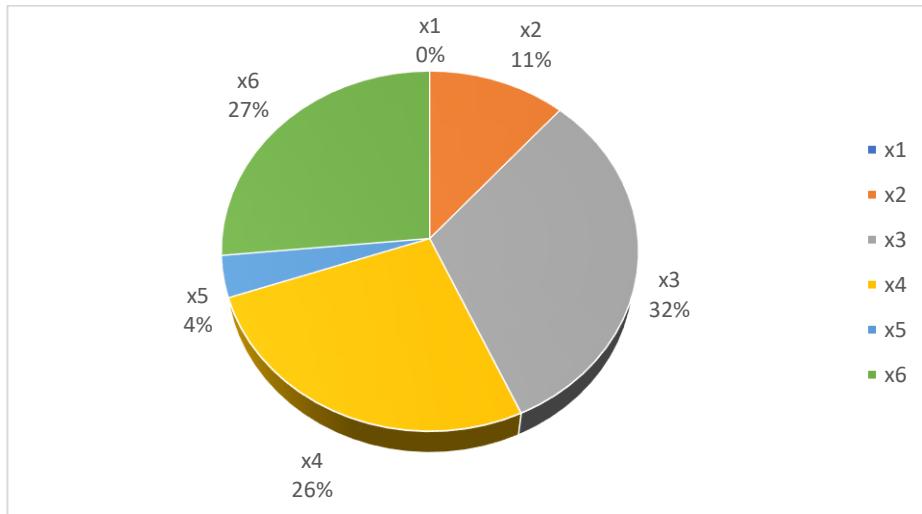
Cromosoma	Valor de la función		
	$f(x_i)$	$\mu(x_i)$	$P_{acum}(x_i)$
$x_1 = [15423687]$	58,638.16	0.00	0.0
$x_2 = [51724386]$	51,336.46	7,301.70	0.114158771
$x_3 = [15427386]$	38,269.84	20,368.32	0.318449453
$x_4 = [54126387]$	41,690.84	16,947.32	0.264963668
$x_5 = [12456387]$	56,241.91	2396.25	0.037464283
$x_6 = [45123678]$	41,690.83	16,947.33	0.264963825
$\sum f(x_i) = 287,868.04$		$\sum \mu_i = 63,960.92$	1.0

Fuente: elaboración propia

Los datos de la tabla 7 se presentan en la figura 22 para ilustrar la analogía de la ruleta aplicada a 6 individuos en Tam 5.

Figura 22

Selección por la ruleta para 6 individuos en Tam 5 aplicando ALGOCYM



Fuente: elaboración propia

El reemplazo. – En ALGOCYM el reemplazo de individuos de una generación para la siguiente se realiza de manera directa. La regla para la población futura es la siguiente ($n * pC$) donde n es el número de individuos de la población y pC es la probabilidad de cruce. El operador de selección trabaja con $n * (1 - pC) - I_{e_1}$ veces a fin de seleccionar los individuos que sobreviven y pasan a la siguiente generación. Esta selección se aplica a toda la población actual a fin de determinar los individuos de la generación siguiente.

El elitismo. - En ALGOCYM la intensidad del elitismo se denota como I_{e_1} representando a los individuos destacados por su gran aptitud (son la elite) para merecer su inclusión directa en la siguiente generación. Así, la nueva generación de n individuos se produce mediante $n = ([n * pC] + [n * (1 - pC) - I_{e_1}] + [I_{e_1}])$. Aun identificando un individuo como perteneciente a la elite, siendo el algoritmo genético de comportamiento probabilista, no garantiza en sí mismo que ese individuo pase directamente a la siguiente generación, por ello se establece la técnica de un buffer (almacén) como un parámetro adicional al algoritmo que inicialmente está vacío, al final de la

primera generación el individuo elite ocupa la primera posición del buffer y pasará directamente a la siguiente generación. Hay que notar que si en una determinada generación se encuentra un individuo superior al del buffer; este será reemplazado en la primera posición y el que estaba allí pasa a la segunda posición. Este proceso se repite sucesivamente hasta llenar el buffer. La gestión del buffer de la elite se hace mediante un algoritmo del tipo pila es decir es PEPS (Primero en Entrar Primero en Salir).

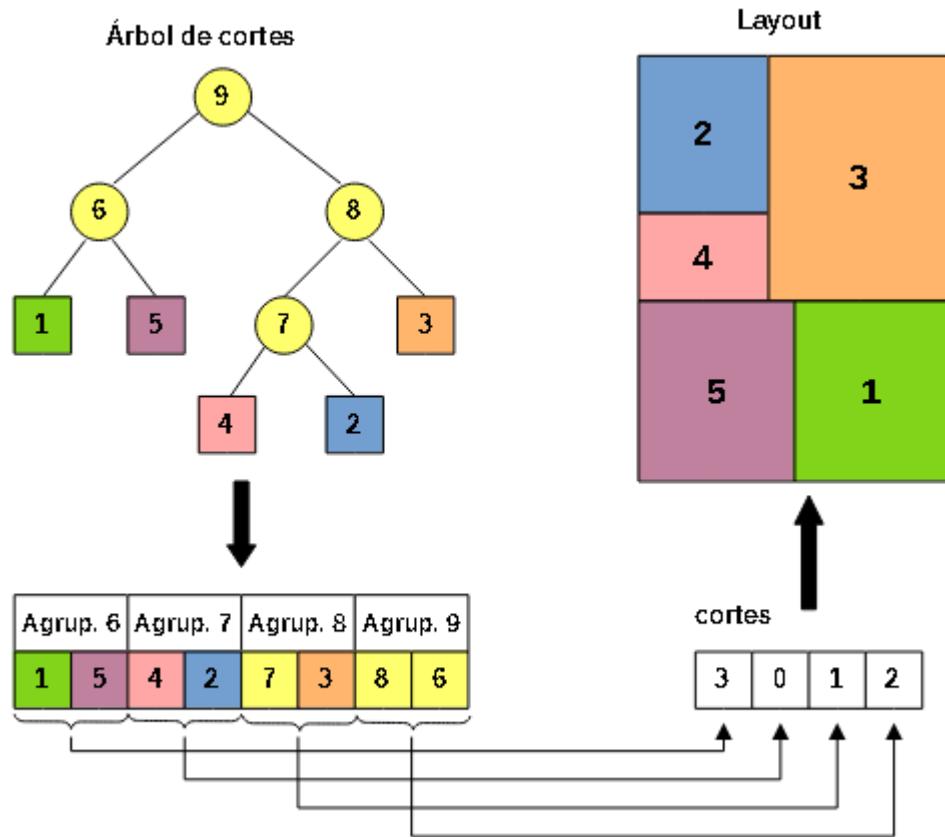
3.5.2 *Paso 2: Buscar el árbol de cortes que represente la mejor solución*

Una vez encontrado el árbol de cortes con el mejor potencial geométrico aplicado el paso 1, se da inicio al paso 2. En este paso los operadores de selección, cruce, mutación y elitismo son similares al paso 1; la diferencia está en la aplicación de los tipos de corte que se aplicarán a este árbol. Al respecto se establecen cuatro tipos de cortes según lo siguiente: el corte (0 = Horizontal Arriba, 1 = Vertical Izquierda, 2 = Horizontal abajo, 3 = Vertical derecha) y que instalación está a la izquierda o a la derecha.

Una vez establecido los cortes de un determinado árbol, la siguiente decisión es establecer un mecanismo de codificación de dicho árbol de cortes. Como se puede observar el recorrido de un árbol de cortes en ALGOCYM es del tipo preorden en cuanto a la visita de sus nodos y ramas, teniendo en cuenta los agrupamientos que los componen. La figura 23 presenta una solución obtenida por ALGOCYM para el caso de Tam 5.

Figura 23

Codificación del paso 2 en ALGOCYM que obtiene el layout óptimo para Tam 5



Fuente: Adaptado de (Diego Más, 2006)

3.5.2.1 La función de aptitud para el paso 2. Tal como se vio en la tabla 6, el número de árboles posibles de ser solución para $n = 5$, es de 180 árboles. Se debe plantear una fórmula que evalúe cada cromosoma que representa una solución. En este punto el algoritmo propuesto toma la ecuación 34 presentada en (Diego-Más, 2006).

$$F = C_r \sum_{i=1}^n \sum_{j=1}^n d_{ij} * [\pm \sum_{u=1}^k \alpha_u * f_{u,ij}] + \frac{C_g}{g_c+1} * \sum_{i=1}^n (u_i * l_i + 1)^p \quad (34)$$

donde:

C_r y C_g se definieron anteriormente.

d_{ij} representa la distancia entre los equicentros o centros de gravedad de las instalaciones i y j.

k es el número de criterios relacionales que se aplica.

$f_{u,ij}$ valor de intensidad relacional de las instalaciones i y j, dado el criterio u.

l_i penalización por incumplimiento de la instalación i.

P exponente de penalización geométrica.

g_c número de actividades en la distribución actual que cumplen con las restricciones geométricas del problema.

α_u importancia relativa del u_ésimo criterio respecto al resto de criterios relacionales.

En Algocym se plantea la opción de utilizar a decisión del usuario dos maneras de calcular la distancia del centro de gravedad entre dos instalaciones i y j, estas son: (a) Distancia de Euclides, y (b) distanciade Manhattan (ver ecuaciones 35, 36 y la figura 24).

Distancia de Euclides

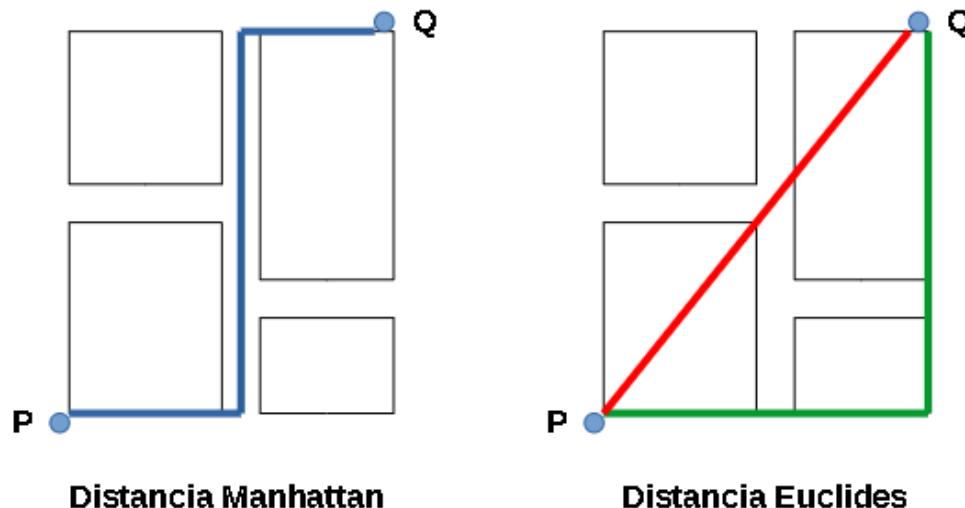
$$d_{Euclides} = \sqrt{\sum_{i=1}^k (x_i - y_i)^2} \quad (35)$$

Distancia de Manhattan

$$d_{Manhattan} = \sum_{i=1}^k |x_i - y_i| \quad (36)$$

Figura 24

Representación de las distancias euclídea y manhattan entre dos puntos P y Q



Fuente: elaboración propia

3.6 Unidad de análisis

La unidad de muestreo/análisis puede ser individuos, organizaciones, períodos, comunidades, situaciones, piezas producidas, eventos, etc.(Hernández-Sampieri & Mendoza, 2018).

En la presente investigación se plantea un AG de operadores de cruce, mutación para la optimización de la distribución en planta en organizaciones de manufactura. Como unidad de análisis se tiene cuatro casos provistos por la literatura especializada en el tema del layout de planta.

Para validar el algoritmo genético propuesto se tomará como conjunto de prueba 4 formulaciones del FLP conocidas y reportadas en la literatura: (Tam & Li, 1991) para 8 departamentos, (van Camp et al., 1992) para 10 departamentos (Bazaraa, 1975) para 14, y (Armour & Buffa, 1963) para 20 departamentos. Estos problemas son tradicionalmente estudiados en

investigaciones del FLP y brindan una robusta oportunidad de análisis a los investigadores.

Tal como se menciona en el párrafo anterior, los cuatro problemas son utilizados con fines de aplicación y prueba de algoritmos que resuelven problemas FLP. Cada problema posee: un área total, dimensiones largo y ancho (ver tabla 12), un número predefinido de departamentos, dimensiones rectangulares de cada instalación o actividad, el área de cada departamento, la ratio mínima (ver tabla 13) y la matriz del flujo valorizado entre los departamentos, adicionalmente de manera opcional se puede incluir las relaciones de precedencia o importancia entre los departamentos. Las tablas 8, 9, 10 y 11 muestran la matriz de flujos de cada problema. Donde se asume que cada departamento no tiene flujo consigo mismo; por lo cual los elementos de la diagonal principal de la matriz de flujos son iguales a cero. Es necesario aclarar que los valores dentro de la matriz de flujos pueden ser distancias entre departamentos, costos o unidades (materiales) entre uno y otro departamento.

Tabla 8

Matriz de flujos para Tam de 8 departamentos (Tam8)

Dept.	1	2	3	4	5	6	7	8
1	-	5	2	4	1	0	0	6
2		-	3	0	2	2	2	0
3			-	0	0	0	0	5
4				-	5	2	2	10
5					-	0	0	0
6						-	5	1
7							-	10
8								-

Fuente: (Tam & Li, 1991)

Tabla 9
Matriz de flujos para van Camp de 10 departamentos (vC10)

Dept.	1	2	3	4	5	6	7	8	9	10
1	-	0	0	0	0	218	0	0	0	0
2		-	0	0	0	148	0	0	296	0
3			-	28	70	0	0	0	0	0
4				-	0	28	70	140	0	0
5					-	0	0	210	0	0
6						-	0	0	0	0
7							-	0	0	28
8								-	0	888
9									-	59.2
10										-

Fuente: (Shebanie, 2004)

Tabla 10
Matriz de flujos para Bazaraa de 14 departamentos (B14)

Dept.	1	2	3	4	5	6	7	8	9	10	11	12	13	14
1	-	72	162	90	108	27	0	0	18	27	18	0	0	0
2		-	72	80	0	48	0	48	32	0	16	8	0	0
3			-	45	54	27	27	27	0	27	0	9	18	0
4				-	30	0	30	30	20	0	20	10	10	0
5					-	18	0	18	12	18	24	0	0	0
6						-	9	9	0	0	6	6	6	0
7							-	9	12	9	6	3	0	0
8								-	6	9	0	3	0	0
9									-	6	4	6	2	0
10										-	6	3	6	0
11											-	2	0	0
12												-	4	0
13													-	0
14														-

Fuente: (Shebanie, 2004)

Tabla 11*Matriz de flujos para Armour y Buffa de 20 departamentos (AB20)*

Dept.	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
1	-	1.8	1.2	0	0	0	0	0	0	1.04	1.12	0	0	1.2	0	0	0	0	0	
2	-	0.96	24.45	0.78	0	13.95	0	1.2	1.35	0	0	0	0	0	0	0	0	6.9	0	
3	-	0	0	0.21	0	0	3.15	3.9	0	0	0	13.05	0	0	0	0	0	13.65	0	
4	-	1.08	5.7	7.5	0	2.34	0	0	1.4	0	0	0	0	0	0	0	1.5	15.75	0	
5	-	0	2.25	1.35	0	1.56	0	0	0	0	0	1.35	0	0	0	0	0	0	0	
6	-	6.15	0	0	0	0	0.45	0	0	0	0	0	0	0	0	1.05	0	0		
7	-	24	0	1.87	0	0	0	0.96	0	0	0	0	1.65	0	0	3.75	0	0		
8	-	0	0	0	0	0.6	0	0	0	0	0	0	0	0	0	0	7.5	33.4 5		
9	-	0	0	0	0	0	7.5	0	0	0	0	7.5	0	0	0	0	0	0		
10	-	0.36	12	0	18.6	1.92	0	0	0	0	0	0	0	0	0	5.25	0			
11	-	2.25	0	3	0.96	22.5	0	0	0	0	0	0	0	0	0	0	0	0		
12	-	0	0	1.65	0	15	0	0	0	0	0	0	0	0	0	8.4	0			
13	-	8	1.04	6	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
14	-	9.75	0	0	0.9	0	0	0	0	0	0	0	0	0	0	0	0	0		
15	-	0	5.25	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
16	-	12	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
17	-	0	7.5	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
18	-	0	4.65	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
19	-	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		
20	-	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0		

Fuente: (Shebanie, 2004)

La tabla 12 muestra el número de departamentos, la altura y el ancho para el layout de cada uno de los cuatro problemas.

Tabla 12*Parámetros Layout I*

Problema	# de Departamentos	Alto del Layout	Ancho del Layout
Armour and Buffa	20	20	30
Bazaraa14	14	7	9
Van Camp	10	25	51
Tam8	8	9.7	14.57

Fuente: (Tam & Li, 1991) y (Shebanie, 2004)

La tabla 13 detalla las áreas y los requerimientos de lado mínimos de las longitudes de cada departamento para los cuatro problemas.

Tabla 13

Parámetros Layout II

Dept.	Armour y Buffa AB20		Bazaraa14		van Camp vC10		Tam8	
	Área	Min Side	Área	Min Side	Área	Min Side	Área	Min Side
1	0.27	0.15	9	1	238	5	24	4.38
2	0.18	0.15	8	1	112	5	16	3.46
3	0.27	0.15	9	1	160	5	36	4.65
4	0.18	0.15	10	1	80	5	8	1.55
5	0.18	0.15	6	1	120	5	21	4.35
6	0.18	0.15	3	1	80	5	17.5	2.96
7	0.09	0.15	3	1	60	5	3.6	1.04
8	0.09	0.15	3	1	85	5	15.4	3.040
9	0.09	0.15	2	1	221	5		
10	0.24	0.15	3	1	119	5		
11	0.60	0.25	2	1				
12	0.42	0.20	1	1				
13	0.18	0.15	1	1				
14	0.24	0.15	3	0				
15	0.27	0.15						
16	0.75	0.30						
17	0.64	0.25						
18	0.41	0.20						
19	0.27	0.15						
20	0.45	0.20						

Fuente: (Tam, 1992b) y (Shebanie, 2004).

En 3.6.1, 3.6.2, 3.6.3, y 3.6.4, se presentan los datos de entrada y los resultados de la aplicación informática del algoritmo propuesto. Para cada caso se presenta la mejor solución obtenida luego de 10 ejecuciones del

paso 1, y de 14 ejecuciones del paso 2. Los detalles de la implementación informática del algoritmo se presentan en 3.11.

3.6.1 **Caso I: Tam 8 (T8)**

La tabla 14 presenta los parámetros de entrada para el paso 1.

Tabla 14

Caso I: Tam8 - Paso 1 – Datos de entrada

Parámetro	Valor
Matriz de flujos	Tabla 8
Área Total	Tabla 12
Área de cada departamento	Tabla 13
Número de ejecuciones:	Ne 10
Criterio geométrico:	Cg 100,000
Criterio relacional:	Cr 500,000
Tamaño de la muestra(individuos) ² :	n 30
Porcentaje de cruce:	pC 0.6
Porcentaje de mutación:	pM 0.05
Número de generaciones:	Ng 500
Número generaciones a mutar:	Ngm 1
Intensidad de elitismo:	le 1

Fuente: elaboración propia

Datos de salida (output)

Árbol [7, 4, 5, 2, 6, 14, 11, 10, 1, 3, 13, 8, 9, 12]

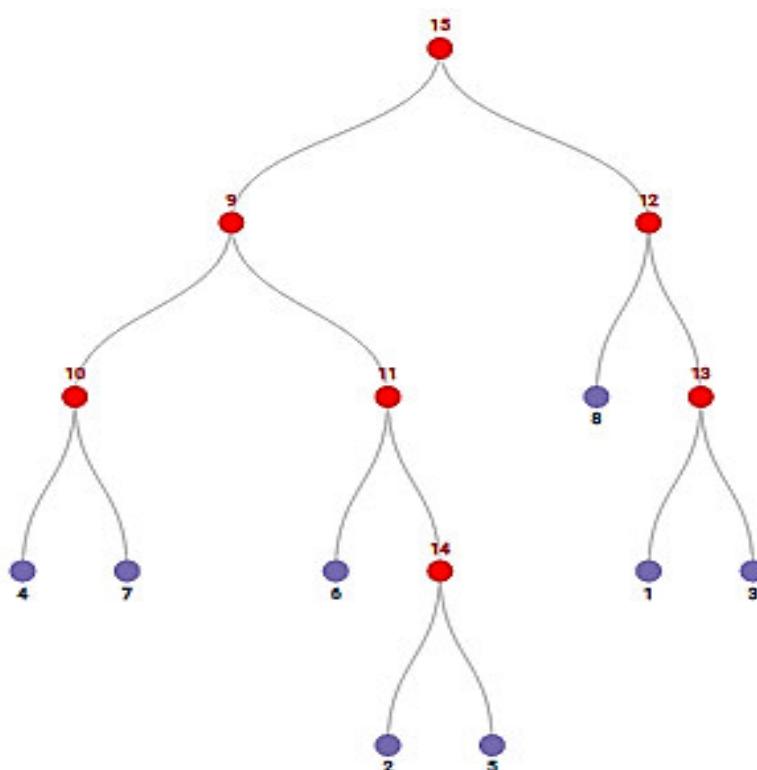
Función de Adaptación: 9,710.026741

El valor de la función de aptitud o de adaptación (fitness function) es el mejor valor encontrado por el algoritmo genético en la búsqueda del valor óptimo².

La figura 25 presenta el árbol de cortes obtenido en el paso 1. La figura 26 presenta la evolución o comportamiento de la población(muestra) para el número de generaciones establecido en la tabla 14.

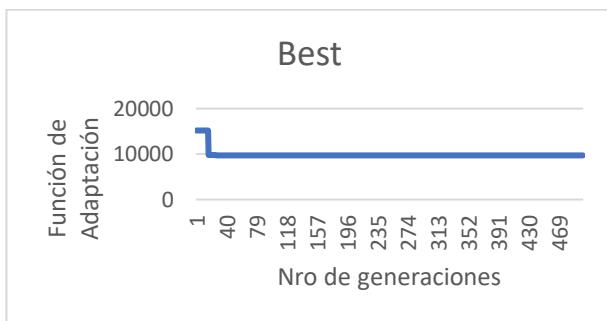
Figura 25

Árbol de cortes obtenido por Algocym para Tam8 en el paso 1



Fuente: elaboración propia

² En adelante fitness function, función de adaptación, costo de la función de adaptación se utilizarán como sinónimos.

Figura 26*Evolución de las generaciones para Tam8 – Paso 1**Fuente: elaboración propia*

Para cada unidad de análisis se establece un tamaño de muestra de $n = 30$ individuos, donde cada individuo es una solución al problema. En términos de algoritmos genéticos el tamaño de la muestra se conoce como población; es a esta población a la que se aplican los operadores de cruce y mutación con miras a que evolucionen en la búsqueda de obtener mejores soluciones. La tabla 15 presenta los parámetros de entrada para el paso 2. El layout óptimo se presenta en la figura 27.

Tabla 15*Caso I: Tam 8 - Paso 2 – Datos de entrada*

Parámetro	Valor	
Árbol de cortes		Obtenido en el paso 1
Número de ejecuciones:	Ne	14
Criterio geométrico:	Cg	100,000
Criterio relacional:	Cr	0.10
Tamaño de la muestra(individuos):	n	30
Porcentaje de cruce:	pC	0.9
Porcentaje de mutación:	pM	0.10
Número de generaciones:	Ng	50
Número generaciones a mutar:	Ngm	1
Métrica de distancia	d	Manhattan
Intensidad de elitismo:	le	1

Fuente: elaboración propia

Datos de salida (output)

Árbol [7, 4, 5, 2, 6, 14, 11, 10, 1, 3, 13, 8, 9, 12]

Tipo de cortes [0, 1, 2, 0, 2, 2, 3]

Función de Adaptación: 88,975194778

Detalles del árbol que representa el layout optimo

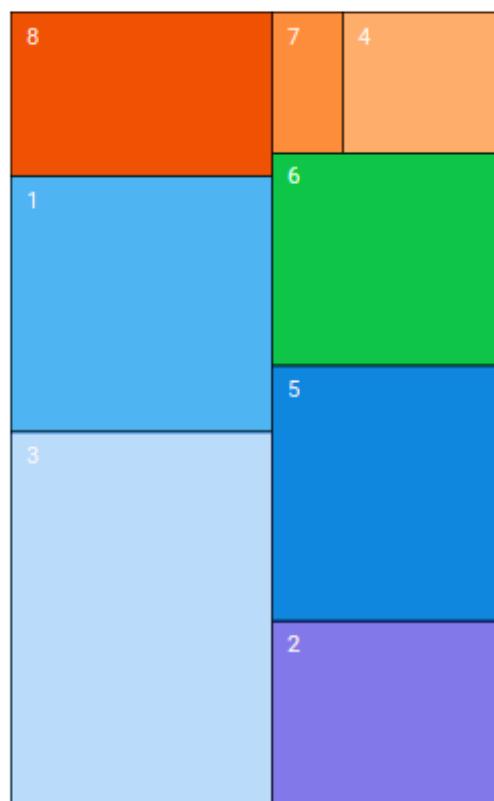
```
[{'cluster': 1, 'estado': 0, 'altura': 3, 'rmin': 0.8, 'rmax': 1.0, 'area': 24.000000000000007, 'esquinas': [0.0, 3.0731770849504656], 'incum': 0, 'lados': [5.011100751536477, 4.7893668856371026], 'puntos': [2.5055503757682387, 5.467860527769017]}, {'cluster': 2, 'estado': 0, 'altura': 4, 'rmin': 0.75, 'rmax': 1.15, 'area': 16.000000000000004, 'esquinas': [5.011100751536477, 11.40445347022792], 'incum': 0, 'lados': [4.393020685365536, 3.642140828815303], 'puntos': [7.207611094219246, 13.225523884635571]}, {'cluster': 3, 'estado': 0, 'altura': 3, 'rmin': 0.6, 'rmax': 1.850000000000001, 'area': 36.000000000000001, 'esquinas': [0.0, 7.862543970587568], 'incum': 0, 'lados': [5.011100751536477, 7.184050328455655], 'puntos': [2.5055503757682387, 11.454569134815396]}, {'cluster': 4, 'estado': 0, 'altura': 3, 'rmin': 0.3, 'rmax': 1.1, 'area': 8.000000000000002, 'esquinas': [6.374451998718886, 0.0], 'incum': 0, 'lados': [3.029669438183127, 2.640552100891096], 'puntos': [7.8892867178104495, 1.320276050445548]}, {'cluster': 5, 'estado': 0, 'altura': 4, 'rmin': 0.9, 'rmax': 1.18, 'area': 21.000000000000007, 'esquinas': [5.011100751536477, 6.624143632407834], 'incum': 0, 'lados': [4.393020685365536, 4.780309837820087], 'puntos': [7.207611094219246, 9.014298551317877]}, {'cluster': 6, 'estado': 0, 'altura': 3, 'rmin': 0.5, 'rmax': 1.0, 'area': 17.500000000000004, 'esquinas': [5.011100751536477, 2.640552100891096], 'incum': 0, 'lados': [4.393020685365536, 3.983591531516737], 'puntos': [7.207611094219246, 4.632347866649464]}, {'cluster': 7, 'estado': 0, 'altura': 3, 'rmin': 0.3, 'rmax': 1.4, 'area': 3.600000000000001, 'esquinas': [5.0111007515364765, 0.0], 'incum': 0, 'lados': [1.363351247182409, 2.640552100891096], 'puntos': [5.692776375127681, 1.320276050445548]}, {'cluster': 8, 'estado': 0, 'altura': 2, 'rmin': 0.6, 'rmax': 1.25, 'area': 15.400000000000006, 'esquinas': [0.0, 0.0], 'incum': 0, 'lados': [5.011100751536477, 3.0731770849504656], 'puntos': [2.5055503757682387, 1.5365885424752328]}, {'cluster': 9, 'estado': 1, 'altura': 1, 'incum': 0.0, 'corte': 0, 'izq': 11, 'der': 10, 'area': 66.10000000000002}, {'cluster': 10, 'estado': 1, 'altura': 2, 'incum': 0.0, 'corte': 1, 'izq': 7, 'der': 4, 'area': 11.600000000000003}, {'cluster': 11, 'estado': 1, 'altura': 2, 'incum': 0.0, 'corte': 2, 'izq': 6, 'der': 14, 'area': 54.50000000000014}, {'cluster': 12, 'estado': 1, 'altura': 1, 'incum': 0.0, 'corte': 0, 'izq': 13, 'der': 8, 'area': 75.40000000000002}, {'cluster': 13, 'estado': 1, 'altura': 2, 'incum': 0.0, 'corte': 2, 'izq': 1, 'der': 3, 'area': 60.00000000000014}, {'cluster': 14, 'estado': 1, 'altura': 3, 'incum': 0.0, 'corte': 2, 'izq': 5, 'der': 2, 'area': 37.00000000000014}, {'cluster': 15, 'estado': 1, 'altura': 0, 'incum': 0, 'corte': 3, 'izq': 9, 'der': 12, 'area': 141.50000000000006}]
```

En cuanto a los detalles del árbol que representa el layout óptimo se tiene una lista que contiene los agrupamientos o clusters; estos se presentan y explican en 3.5.1.1 y complementan con las figuras 15 y 16. El estado del

agrupamiento {0 si es nodo, 1 si es instalación), las ratios rmin y rmax de la instalación, el área asignada, coordenadas esquinas, el valor del incumplimiento (calculado según las ecuaciones 22, 23 y 24) presentadas en 3.5.1.3. Cuando se trata de una instalación se tiene además del número de agrupamiento, el estado (1), el incumplimiento, el corte (0 = Horizontal Arriba, 1 = Vertical Izquierda, 2 = Horizontal abajo, 3 = Vertical derecha) y que instalación está a la izquierda o a la derecha, finalmente el área asignada a la instalación. Es pertinente indicar que cuando el valor del incumplimiento geométrico es 0, se tiene en contrapartida un cumplimiento del 100% de las restricciones geométricas impuestas por el problema.

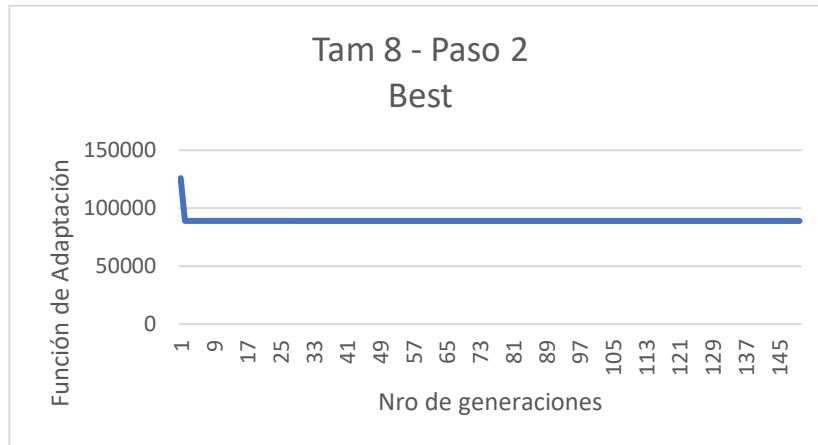
Figura 27

Layout óptimo para Tam 8 – Paso 2



Fuente: obtenido de Algocym

La figura 28 presenta la evolución de las generaciones para el paso 2.

Figura 28*Evolución de las generaciones para Tam 8 – Paso 2**Fuente: elaboración propia.*

3.6.2 Caso II: Van Camp (vC10)

La tabla 16 presenta los parámetros de entrada para el paso 1.

Tabla 16*Caso II: van Camp vC10 - Paso 1 – Datos de entrada*

Parámetro	Valor
Matriz de flujos	Tabla 9
Área Total	Tabla 12
Área de cada departamento	Tabla 13
Número de ejecuciones:	Ne 10
Criterio geométrico:	Cg 100,000
Criterio relacional:	Cr 500,000
Tamaño de la muestra (individuos):	n 30
Porcentaje de cruce:	pC 0.8
Porcentaje de mutación:	pM 0.1
Número de generaciones:	Ng 2000
Número generaciones a mutar:	Ngm 1
Intensidad de elitismo:	le 1

Fuente: elaboración propia

Datos de salida (output)

Árbol [3, 7, 1, 12, 11, 4, 5, 6, 9, 14, 2, 13, 10, 17, 15, 8, 18, 16]

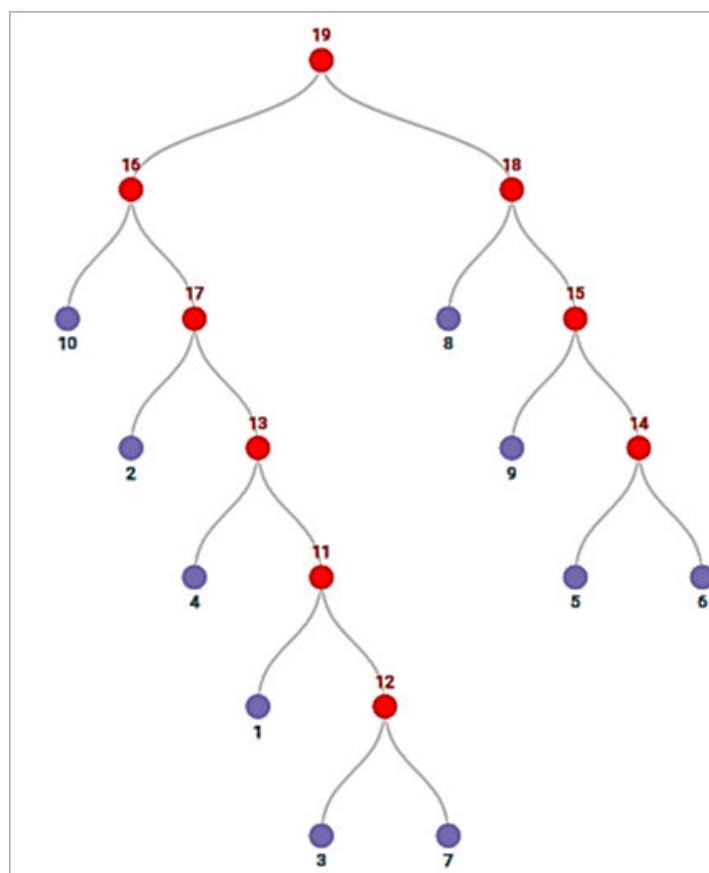
Función de Adaptación: 304.736909

La figura 29 presenta el árbol de cortes obtenido en el paso 1.

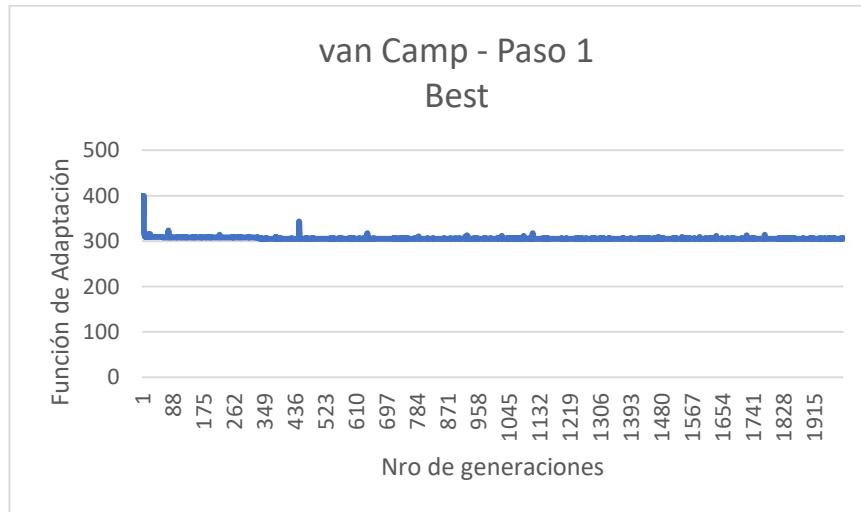
La figura 30 presenta la evolución o comportamiento de la población para el número de generaciones en el paso 1.

Figura 29

Árbol de cortes obtenido por Algocym para vC10 en el paso 1



Fuente: obtenido de Algocym

Figura 30*Evolución de las generaciones para vC 10 – Paso 1**Fuente: elaboración propia*

La tabla 17 presenta los parámetros de entrada para el paso 2. El layout óptimo se presenta en la figura 31.

Tabla 17*Caso II: van Camp vC10 - Paso 2 – Datos de entrada*

Parámetro	Valor
Árbol de cortes	Obtenido en el paso 1
Número de ejecuciones:	Ne 14
Criterio geométrico:	Cg 100,000
Criterio relacional:	Cr 0.10
Tamaño de la muestra (individuos):	n 30
Porcentaje de cruce:	pC 0.9
Porcentaje de mutación:	pM 0.7
Número de generaciones:	Ng 1000
Número generaciones a mutar:	Ngm 1
Métrica de distancia	d Manhattan
Intensidad de elitismo:	le 1

Fuente: elaboración propia

Datos de salida (output)

Árbol[3, 7, 1, 12, 11, 4, 5, 6, 9, 14, 2, 13, 10, 17, 15, 8, 18, 16]

Tipo de cortes [0, 1, 1, 3, 1, 3, 1, 1, 0]

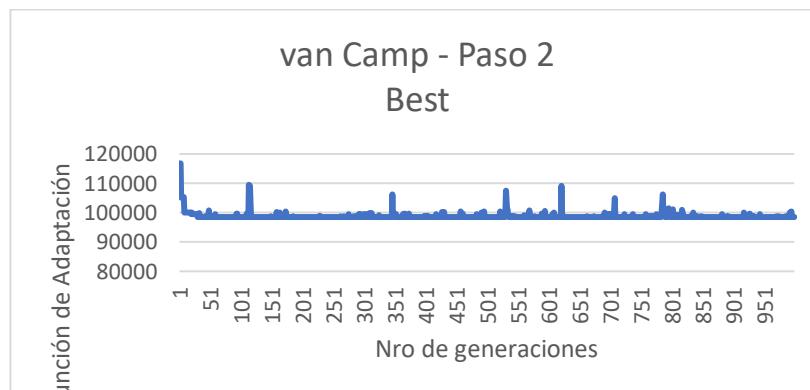
Función de Adaptación: 98,509.570454

Detalles del árbol que representa el layout óptimo

```
[{'cluster': 1, 'estado': 0, 'altura': 5, 'rmin': 0.105042, 'rmax': 9.52, 'area': 238.0, 'esquinas': [7.427828348504555, 7.242914633102148], 'incum': 0, 'lados': [30.37451235370611, 7.835516739446871], 'puntos': [22.61508452535761, 11.160673002825584]}, {'cluster': 2, 'estado': 0, 'altura': 3, 'rmin': 0.223214, 'rmax': 4.48, 'area': 112.0, 'esquinas': [0.0, 0.0], 'incum': 0, 'lados': [7.427828348504555, 15.07843137254902], 'puntos': [3.7139141742522774, 7.53921568627451]}, {'cluster': 3, 'estado': 0, 'altura': 6, 'rmin': 0.15625, 'rmax': 6.4, 'area': 160.0, 'esquinas': [7.427828348504555, 0.0], 'incum': 0, 'lados': [22.090554439058987, 7.242914633102148], 'puntos': [18.47310556803405, 3.621457316551074]}, {'cluster': 4, 'estado': 0, 'altura': 4, 'rmin': 0.3125, 'rmax': 3.2, 'area': 80.0, 'esquinas': [37.802340702210664, 0.0], 'incum': 0, 'lados': [5.3055916775032514, 15.07843137254902], 'puntos': [40.455136540962286, 7.53921568627451]}, {'cluster': 5, 'estado': 0, 'altura': 4, 'rmin': 0.208333, 'rmax': 4.8, 'area': 120.0, 'esquinas': [30.33794466403162, 15.07843137254902], 'incum': 0, 'lados': [12.09486166007905, 9.92156862745098], 'puntos': [36.38537549407115, 20.03921568627451]}, {'cluster': 6, 'estado': 0, 'altura': 4, 'rmin': 0.3125, 'rmax': 3.2, 'area': 80.0, 'esquinas': [22.274703557312254, 15.07843137254902], 'incum': 0, 'lados': [8.063241106719367, 9.92156862745098], 'puntos': [26.306324110671937, 20.03921568627451]}, {'cluster': 7, 'estado': 0, 'altura': 6, 'rmin': 0.416667, 'rmax': 2.4, 'area': 60.0, 'esquinas': [29.518382787563542, 0.0], 'incum': 0, 'lados': [8.283957914647122, 7.242914633102148], 'puntos': [33.660361744887105, 3.621457316551074]}, {'cluster': 8, 'estado': 0, 'altura': 2, 'rmin': 0.294118, 'rmax': 3.4, 'area': 85.0, 'esquinas': [42.43280632411067, 15.07843137254902], 'incum': 0, 'lados': [8.567193675889328, 9.92156862745098], 'puntos': [46.716403162055336, 20.03921568627451]}, {'cluster': 9, 'estado': 0, 'altura': 3, 'rmin': 0.113122, 'rmax': 8.84, 'area': 221.0, 'esquinas': [0.0, 15.07843137254902], 'incum': 0, 'lados': [22.274703557312254, 9.92156862745098], 'puntos': [11.137351778656127, 20.03921568627451]}, {'cluster': 10, 'estado': 0, 'altura': 2, 'rmin': 0.210084, 'rmax': 4.76, 'area': 119.0, 'esquinas': [43.107932379713915, 0.0], 'incum': 0, 'lados': [7.8920676202860855, 15.07843137254902], 'puntos': [47.05396618985696, 7.53921568627451]}, {'cluster': 11, 'estado': 1, 'altura': 4, 'incum': 0.0, 'corte': 0, 'izq': 1, 'der': 12, 'area': 458.0}, {'cluster': 12, 'estado': 1, 'altura': 5, 'incum': 0.0, 'corte': 1, 'izq': 3, 'der': 7, 'area': 220.0}, {'cluster': 13, 'estado': 1, 'altura': 3, 'incum': 0.0, 'corte': 1, 'izq': 11, 'der': 4, 'area': 538.0}, {'cluster': 14, 'estado': 1, 'altura': 3, 'incum': 0.0, 'corte': 3, 'izq': 5, 'der': 6, 'area': 200.0}, {'cluster': 15, 'estado': 1, 'altura': 2, 'incum': 0.0, 'corte': 1, 'izq': 9, 'der': 14, 'area': 421.0}, {'cluster': 16, 'estado': 1, 'altura': 1, 'incum': 0.0, 'corte': 3, 'izq': 10, 'der': 17, 'area': 769.0}, {'cluster': 17, 'estado': 1, 'altura': 2, 'incum': 0.0, 'corte': 1, 'izq': 2, 'der': 13, 'area': 650.0}, {'cluster': 18, 'estado': 1, 'altura': 1, 'incum': 0.0, 'corte': 1, 'izq': 15, 'der': 8, 'area': 506.0}, {'cluster': 19, 'estado': 1, 'altura': 0, 'incum': 0, 'corte': 0, 'izq': 18, 'der': 16, 'area': 1275.0}]
```

Figura 31*Layout óptimo para vC10 – Paso 2**Fuente: obtenido de ALGOCYD*

La figura 32 presenta la evolución o comportamiento de la población para el número de generaciones.

Figura 32*Evolución de las generaciones para vC 10 – Paso 2**Fuente: elaboración propia*

3.6.3 Caso III: Bazaraa 14 (B14)

La tabla 18 presenta los parámetros de entrada para el paso 1.

Tabla 18

Caso III: Bazaraa 14 - Paso 1 – Datos de entrada

Parámetro	Valor
Matriz de flujos	Tabla 10
Área Total	Tabla 12
Área de cada departamento	Tabla 13
Número de ejecuciones:	Ne 10
Criterio geométrico:	Cg 100,000
Criterio relacional:	Cr 500,000
Tamaño de la muestra (individuos):	n 30
Porcentaje de cruce:	pC 0.8
Porcentaje de mutación:	pM 0.7
Número de generaciones:	Ng 3000
Número generaciones a mutar:	Ngm 1
Intensidad de elitismo:	le 2

Fuente: elaboración propia.

Datos de salida (output)

Árbol:

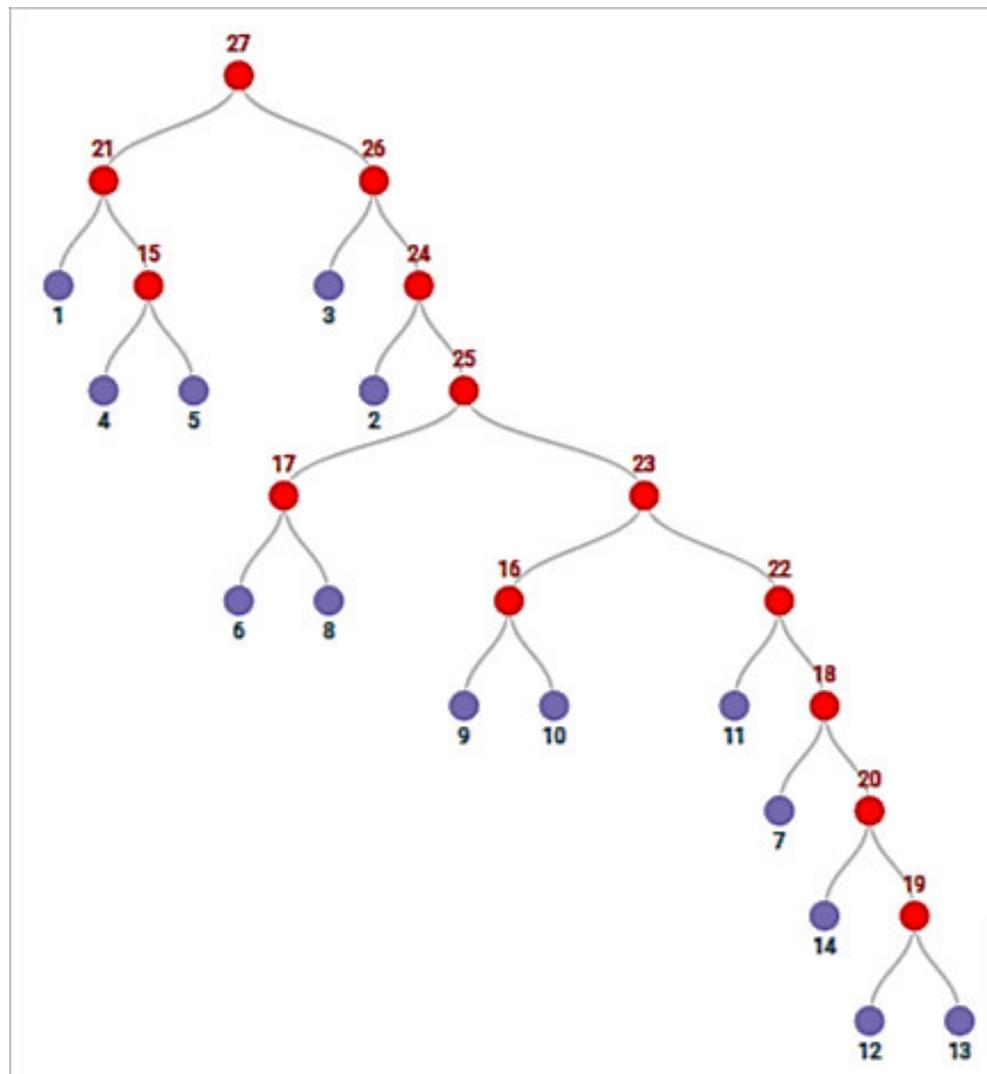
[4,5,10,9,6,8,13,12,19,14,20,7,15,1,18,11,16,22,17,23,2,25,24,3,26,21]

Función de Adaptación: 606,401753

La figura 33 presenta el árbol de cortes obtenido en el paso 1.

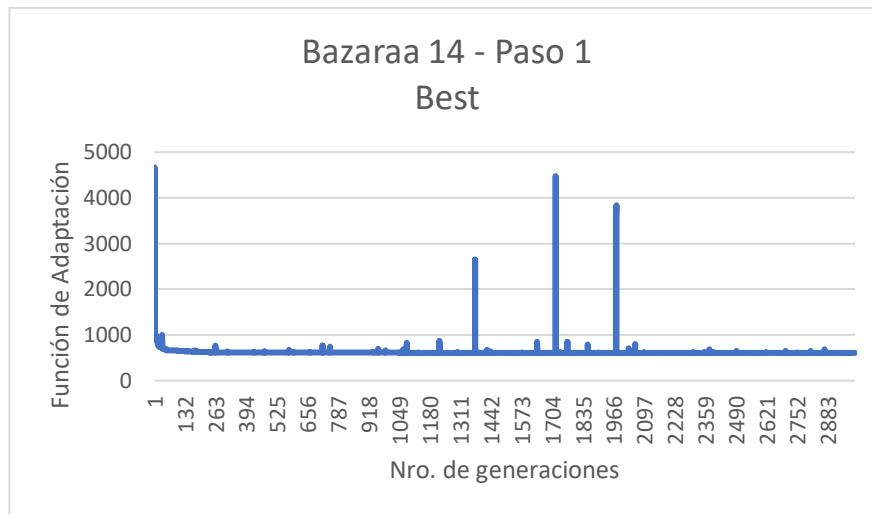
Figura 33

Árbol de cortes obtenido por Algocym para B14 en el paso 1



Fuente: obtenido de Algocym.

La figura 34 presenta la evolución o comportamiento de la población para el número de generaciones del paso 1.

Figura 34*Evolución de las generaciones para B14 – Paso 1**Fuente: elaboración propia*

La tabla 19 presenta los parámetros de entrada para el paso 2. El layout óptimo se presenta en la figura 35.

Tabla 19*Caso III: Bazaraa 14 - Paso 2 – Datos de entrada*

Parámetro	Valor
Árbol de cortes	Obtenido en el paso 1
Número de ejecuciones:	Ne 14
Criterio geométrico:	Cg 1000,000
Criterio relacional:	Cr 0.10
Tamaño de la muestra (individuos):	n 30
Porcentaje de cruce:	pC 0.9
Porcentaje de mutación:	pM 0.2
Número de generaciones:	Ng 1500
Número generaciones a mutar:	Ngm 1
Métrica de distancia	d Manhattan
Intensidad de elitismo:	le 2

Fuente: elaboración propia.

Datos de salida (output)

Árbol

[4,5,10,9,6,8,13,12,19,14,20,7,15,1,18,11,16,22,17,23,2,25,24,3,26,21]

Tipo de cortes [0, 2, 1, 0, 1, 2, 3, 0, 3, 3, 2, 1, 1]

Función de Adaptación 11,213.901786

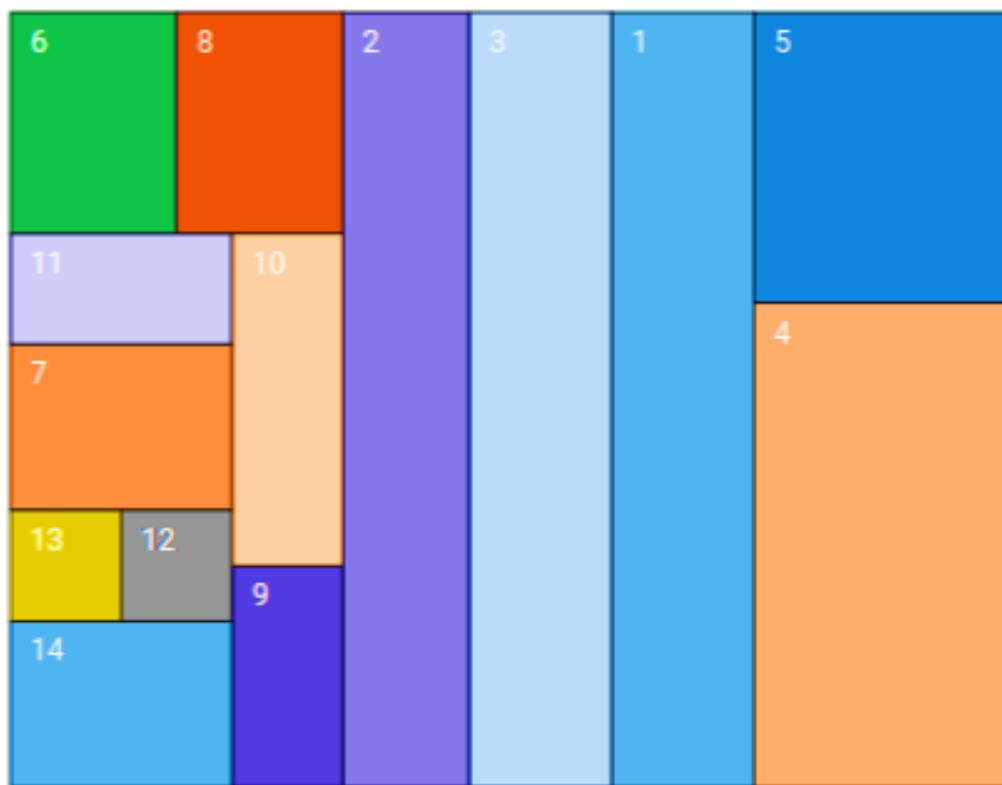
Detalles del árbol que representa el layout óptimo

```
[{'cluster': 1, 'estado': 0, 'altura': 2, 'rmin': 0.111111, 'rmax': 9.0, 'area': 9.0, 'esquinas': [5.428571428571429, 0.0], 'incum': 0, 'lados': [1.285714285714286, 7.0], 'puntos': [6.071428571428571, 3.5]}, {'cluster': 2, 'estado': 0, 'altura': 3, 'rmin': 0.125, 'rmax': 8.0, 'area': 8.0, 'esquinas': [3.0000000000000004, 0.0], 'incum': 0, 'lados': [1.1428571428571428, 7.0], 'puntos': [3.571428571428572, 3.5]}, {'cluster': 3, 'estado': 0, 'altura': 2, 'rmin': 0.111111, 'rmax': 9.0, 'area': 9.0, 'esquinas': [4.142857142857143, 0.0], 'incum': 0, 'lados': [1.2857142857142858, 7.0], 'puntos': [4.785714285714286, 3.5]}, {'cluster': 4, 'estado': 0, 'altura': 3, 'rmin': 0.1, 'rmax': 10.0, 'area': 10.0, 'esquinas': [6.714285714285714, 2.625], 'incum': 0, 'lados': [2.2857142857142856, 4.375], 'puntos': [7.857142857142858, 4.8125]}, {'cluster': 5, 'estado': 0, 'altura': 3, 'rmin': 0.166667, 'rmax': 6.0, 'area': 6.0, 'esquinas': [6.714285714285714, 0.0], 'incum': 0, 'lados': [2.2857142857142856, 2.625], 'puntos': [7.857142857142858, 1.3125]}, {'cluster': 6, 'estado': 0, 'altura': 5, 'rmin': 0.333333, 'rmax': 3.0, 'area': 3.0, 'esquinas': [0.0, 0.0], 'incum': 0, 'lados': [1.5000000000000001, 2.0000000000000001], 'puntos': [0.7500000000000006, 1.0000000000000004]}, {'cluster': 7, 'estado': 0, 'altura': 7, 'rmin': 0.333333, 'rmax': 3.0, 'area': 3.0, 'esquinas': [0.0, 3.0], 'incum': 0, 'lados': [2.0, 1.5], 'puntos': [1.0, 3.75]}, {'cluster': 8, 'estado': 0, 'altura': 5, 'rmin': 0.333333, 'rmax': 3.0, 'area': 3.0, 'esquinas': [1.5000000000000001, 0.0], 'incum': 0, 'lados': [1.4999999999999993, 2.0000000000000001], 'puntos': [2.2500000000000001, 1.0000000000000004]}, {'cluster': 9, 'estado': 0, 'altura': 6, 'rmin': 0.5, 'rmax': 2.0, 'area': 2.0, 'esquinas': [2.0, 5.0], 'incum': 0, 'lados': [1.0000000000000002, 1.9999999999999996], 'puntos': [2.5000000000000004, 6.0]}, {'cluster': 10, 'estado': 0, 'altura': 6, 'rmin': 0.333333, 'rmax': 3.0, 'area': 3.0, 'esquinas': [2.0, 2.0000000000000004], 'incum': 0, 'lados': [1.0000000000000002, 2.9999999999999996], 'puntos': [2.5000000000000004, 3.5]}, {'cluster': 11, 'estado': 0, 'altura': 6, 'rmin': 0.5, 'rmax': 2.0, 'area': 2.0, 'esquinas': [0.0, 2.0000000000000001], 'incum': 2.7755575615628914e-17, 'lados': [2.0, 0.9999999999999991], 'puntos': [1.0, 2.5000000000000004]}, {'cluster': 12, 'estado': 0, 'altura': 9, 'rmin': 1.0, 'rmax': 1.0, 'area': 1.0, 'esquinas': [1.0, 4.5], 'incum': 0.0, 'lados': [1.0, 1.0], 'puntos': [1.5, 5.0]}, {'cluster': 13, 'estado': 0, 'altura': 9, 'rmin': 1.0, 'rmax': 1.0, 'area': 1.0, 'esquinas': [0.0, 4.5], 'incum': 0.0, 'lados': [1.0, 1.0], 'puntos': [0.5, 5.0]}, {'cluster': 14, 'estado': 0, 'altura': 8, 'rmin': 0.0, 'rmax': 0.0, 'area': 3.0, 'esquinas': [0.0, 5.5], 'incum': 0, 'lados': [2.0, 1.5], 'puntos': [1.0, 6.25]}, {'cluster': 15, 'estado': 1, 'altura': 2, 'incum': 0.0, 'corte': 0, 'izq': 4, 'der': 5, 'area': 16.0}, {'cluster': 16, 'estado': 1, 'altura': 5, 'incum': 0.0, 'corte': 2, 'izq': 10, 'der': 9, 'area': 5.0}, {'cluster': 17, 'estado': 1, 'altura': 4, 'incum': 0.0, 'corte': 1, 'izq': 6, 'der': 8, 'area': 6.0}, {'cluster': 18, 'estado': 1, 'altura': 6, 'incum': 0.0, 'corte': 0, 'izq': 20, 'der': 7, 'area': 8.0}, {'cluster': 19, 'estado': 1, 'altura': 8, 'incum': 0.0, 'corte': 1, 'izq': 13, 'der': 12, 'area': 2.0}, {'cluster': 20, 'estado': 1, 'altura': 7, 'incum': 0.0, 'corte': 2, 'izq': 19, 'der': 14, 'area': 5.0}, {'cluster': 21, 'estado': 1, 'altura': 1, 'incum': 0.0, 'corte': 3, 'izq': 15, 'der': 16}]]
```

```
'der': 1, 'area': 25.0}, {'cluster': 22, 'estado': 1, 'altura': 5, 'incum': 0.0, 'corte': 0, 'izq': 18, 'der': 11, 'area': 10.0}, {'cluster': 23, 'estado': 1, 'altura': 4, 'incum': 0.0, 'corte': 3, 'izq': 16, 'der': 22, 'area': 15.0}, {'cluster': 24, 'estado': 1, 'altura': 2, 'incum': 0.0, 'corte': 3, 'izq': 2, 'der': 25, 'area': 29.0}, {'cluster': 25, 'estado': 1, 'altura': 3, 'incum': 0.0, 'corte': 2, 'izq': 17, 'der': 23, 'area': 21.0}, {'cluster': 26, 'estado': 1, 'altura': 1, 'incum': 0.0, 'corte': 1, 'izq': 24, 'der': 3, 'area': 38.0}, {'cluster': 27, 'estado': 1, 'altura': 0, 'incum': 2.7755575615628914e-17, 'corte': 1, 'izq': 26, 'der': 21, 'area': 63.0}]
```

Figura 35

Layout óptimo para B14 – Paso 2



Fuente: obtenido de Algocym.

La figura 36 presenta la evolución o comportamiento de la población para un número de mil quinientas generaciones.

|Figura 36*Evolución de las generaciones para B14 – Paso 2**Fuente: elaboración propia*

3.6.4 **Caso IV: Armour y Buffa 20 (AB20)**

La tabla 20 presenta los parámetros para el paso 1.

Tabla 20*Caso IV: Armour & Buffa AB20 - Paso 1 – Datos de entrada*

Parámetro	Valor
Matriz de flujos	Tabla 10
Área Total	Tabla 11
Área de cada departamento	Tabla 12
Número de ejecuciones:	Ne 10
Criterio geométrico:	Cg 100,000
Criterio relacional:	Cr 500,000
Tamaño de la muestra (individuos):	n 30
Porcentaje de cruce:	pC 0.6
Porcentaje de mutación:	pM 0.7
Número de generaciones:	Ng 3500
Número generaciones a mutar:	Ngm 1
Intensidad de elitismo:	le 2

Fuente: elaboración propia

Datos de salida (output)

Árbol

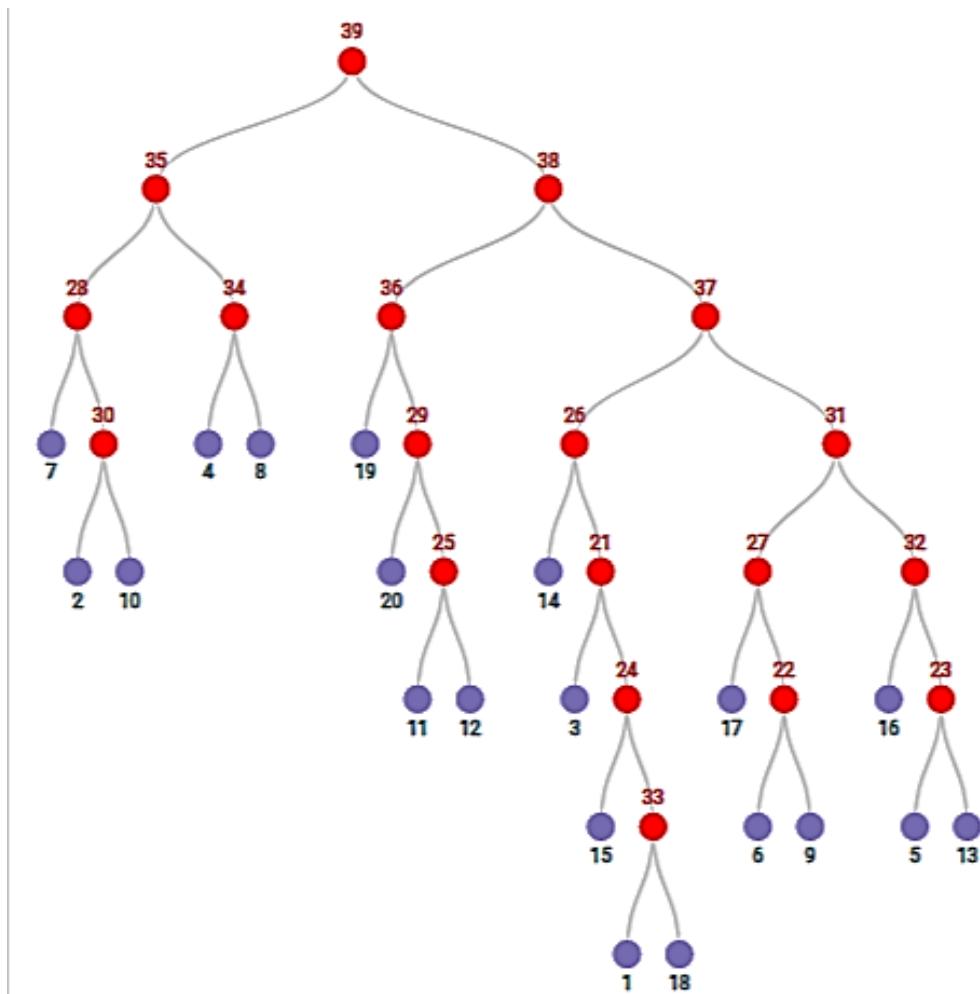
[18,1,33,15,24,3,9,6,5,13,12,11,14,21,22,17,2,10,7,30,25,20,16,23,32,27,4,8,28,34,29,19,26,31,37,36,38,35]

Función de Adaptación 3730.011470

La figura 37 presenta el árbol de cortes obtenido en el paso 1.

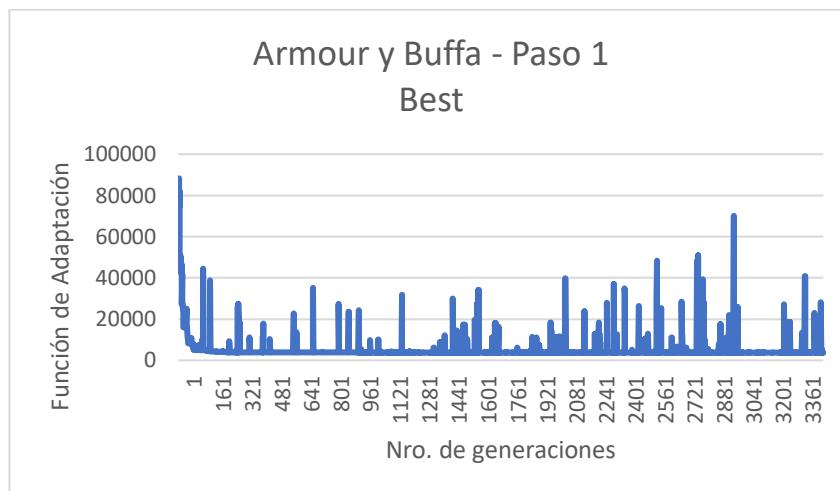
Figura 37

Árbol de cortes obtenido por Algocym para AB20 en el paso 1



Fuente: obtenido de ALGOCYM

La figura 38 presenta la evolución de las generaciones en el paso 1.

Figura 38*Evolución de las generaciones para AB20 – Paso 1**Fuente: elaboración propia*

La tabla 21 presenta los parámetros de entrada para el paso 2.

Tabla 21*Caso IV: Armour & Buffa AB20 - Paso 2 – Datos de entrada*

Parámetro	Valor
Árbol de cortes	Obtenido en el paso 1
Número de ejecuciones:	Ne 14
Criterio geométrico:	Cg 10000.00
Criterio relacional:	Cr 0.10
Tamaño de la muestra (individuos):	n 30
Porcentaje de cruce:	pC 0.9
Porcentaje de mutación:	pM 0.3
Número de generaciones:	Ng 2000
Número generaciones a mutar:	Ngm 1
Métrica de distancia	d Manhattan
Intensidad de elitismo:	le 4

Fuente: elaboración propia

Datos de salida (output)

Árbol

[18,1,33,15,24,3,9,6,5,13,12,11,14,21,22,17,2,10,7,30,25,20,16,23,32,27,4,8,28,34,29,19,26,31,37,36,38,35]

Tipo de cortes [3, 0, 2, 3, 1, 1, 1, 2, 3, 2, 3, 3, 1, 2, 0, 3, 0, 0, 3]

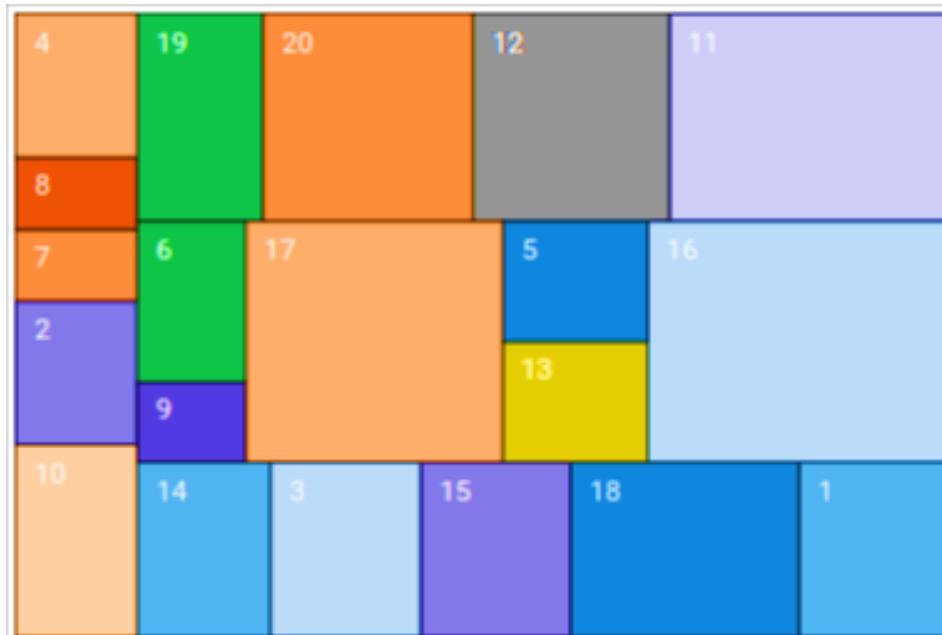
Función de Adaptación 10,347.871967

Detalles del árbol que representa el layout óptimo

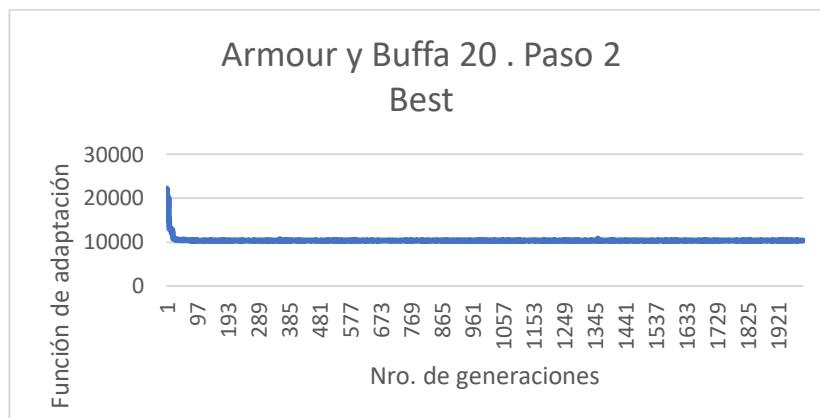
```
[{'cluster': 1, 'estado': 0, 'altura': 7, 'rmin': 0.59, 'rmax': 1.700000000000001, 'area': 27.000000000000007, 'esquinas': [25.17328767123289, 14.406130268199242], 'incum': 0, 'lados': [4.8267123287671225, 5.593869731800768], 'puntos': [27.586643835616453, 17.203065134099628]}, {'cluster': 2, 'estado': 0, 'altura': 4, 'rmin': 0.59, 'rmax': 1.700000000000001, 'area': 18.000000000000007, 'esquinas': [0.0, 9.230769230769283], 'incum': 0, 'lados': [3.9000000000000163, 4.615384615384596], 'puntos': [1.9500000000000082, 11.538461538461581]}, {'cluster': 3, 'estado': 0, 'altura': 5, 'rmin': 0.59, 'rmax': 1.700000000000001, 'area': 27.000000000000007, 'esquinas': [8.190410958904128, 14.406130268199242], 'incum': 0, 'lados': [4.826712328767119, 5.593869731800768], 'puntos': [10.603767123287687, 17.203065134099628]}, {'cluster': 4, 'estado': 0, 'altura': 3, 'rmin': 0.59, 'rmax': 1.700000000000001, 'area': 18.000000000000007, 'esquinas': [0.0, 0.0], 'incum': 0, 'lados': [3.9000000000000163, 4.615384615384686], 'puntos': [1.9500000000000082, 2.307692307692343]}, {'cluster': 5, 'estado': 0, 'altura': 6, 'rmin': 0.59, 'rmax': 1.700000000000001, 'area': 18.000000000000007, 'esquinas': [15.657920792079224, 6.666666666666705], 'incum': 0, 'lados': [4.65148514851, 3.869731800766286], 'puntos': [17.98366336633665, 8.601532567049814]}, {'cluster': 6, 'estado': 0, 'altura': 6, 'rmin': 0.59, 'rmax': 1.700000000000001, 'area': 18.000000000000007, 'esquinas': [3.9000000000000163, 6.6666666666667], 'incum': 0, 'lados': [3.4886138613861366, 5.1596424010217135], 'puntos': [5.644306930693085, 9.246487867177526]}, {'cluster': 7, 'estado': 0, 'altura': 3, 'rmin': 0.59, 'rmax': 1.700000000000001, 'area': 9.000000000000004, 'esquinas': [0.0, 6.9230769230769855], 'incum': 0, 'lados': [3.9000000000000163, 2.3076923076922977], 'puntos': [1.9500000000000082, 8.076923076923133]}, {'cluster': 8, 'estado': 0, 'altura': 3, 'rmin': 0.59, 'rmax': 1.700000000000001, 'area': 9.000000000000004, 'esquinas': [0.0, 4.615384615384686], 'incum': 0, 'lados': [3.9000000000000163, 2.307692307692299], 'puntos': [1.9500000000000082, 5.769230769230836]}, {'cluster': 9, 'estado': 0, 'altura': 6, 'rmin': 0.59, 'rmax': 1.700000000000001, 'area': 9.000000000000004, 'esquinas': [3.9000000000000163, 11.826309067688383], 'incum': 0, 'lados': [3.4886138613861366, 2.579821200510858], 'puntos': [5.644306930693085, 13.116219667943813]}, {'cluster': 10, 'estado': 0, 'altura': 4, 'rmin': 0.59, 'rmax': 1.700000000000001, 'area': 24.000000000000001, 'esquinas': [0.0, 13.846153846153879], 'incum': 0, 'lados': [3.9000000000000163, 6.153846153846131], 'puntos': [1.9500000000000082, 16.923076923076945]}, {'cluster': 11, 'estado': 0, 'altura': 5, 'rmin': 0.59, 'rmax': 1.700000000000001, 'area': 60.000000000000003, 'esquinas': [21.000000000000014, 0.0], 'incum': 0, 'lados': [8.99999999999998, 6.66666666666671], 'puntos': [25.500000000000014, 3.333333333333357]}, {'cluster': 12, 'estado': 0, 'altura': 5, 'rmin': 0.59, 'rmax': 1.700000000000001, 'area': 42.000000000000002, 'esquinas': [14.700000000000015, 0.0], 'incum': 0, 'lados': [6.299999999999999, 6.66666666666671], 'puntos': [17.850000000000016, 3.333333333333357]}, {'cluster': 13, 'estado': 0, 'altura': 6, 'rmin': 0.59, 'rmax': 1.700000000000001, 'area': 18.000000000000007, 'esquinas': [15.657920792079224, 10.536398467432956],
```

```
'incum': 0, 'lados': [4.651485148514851, 3.869731800766285], 'puntos':
[17.98366336633665, 12.471264367816099]}, {'cluster': 14, 'estado': 0, 'altura': 4,
'rmin': 0.59, 'rmax': 1.7000000000000001, 'area': 24.000000000000001, 'esquinas':
[3.9000000000000163, 14.406130268199242], 'incum': 0, 'lados':
[4.290410958904111, 5.593869731800768], 'puntos': [6.045205479452072,
17.203065134099628]}, {'cluster': 15, 'estado': 0, 'altura': 6, 'rmin': 0.59, 'rmax':
1.7000000000000001, 'area': 27.000000000000007, 'esquinas':
[13.017123287671247, 14.406130268199242], 'incum': 0, 'lados':
[4.8267123287671225, 5.593869731800768], 'puntos': [15.430479452054808,
17.203065134099628]}, {'cluster': 16, 'estado': 0, 'altura': 5, 'rmin': 0.59, 'rmax':
1.7000000000000001, 'area': 75.000000000000004, 'esquinas':
[20.309405940594075, 6.666666666666705], 'incum': 0, 'lados':
[9.69059405940594, 7.739463601532571], 'puntos': [25.154702970297045,
10.536398467432956]}, {'cluster': 17, 'estado': 0, 'altura': 5, 'rmin': 0.59, 'rmax':
1.7000000000000001, 'area': 64.00000000000003, 'esquinas': [7.388613861386153,
6.666666666666705], 'incum': 0, 'lados': [8.26930693069307,
7.739463601532571], 'puntos': [11.523267326732688, 10.536398467432956]},
{'cluster': 18, 'estado': 0, 'altura': 7, 'rmin': 0.59, 'rmax': 1.7000000000000001, 'area':
41.00000000000002, 'esquinas': [17.84383561643837, 14.406130268199242], 'in-
cum': 0, 'lados': [7.3294520547945226, 5.593869731800768], 'puntos':
[21.50856164383563, 17.203065134099628]}, {'cluster': 19, 'estado': 0, 'altura': 3,
'rmin': 0.59, 'rmax': 1.7000000000000001, 'area': 27.000000000000007, 'esquinas':
[3.9000000000000163, 0.0], 'incum': 0, 'lados': [4.0500000000000001,
6.66666666666671], 'puntos': [5.9250000000000017, 3.3333333333333357]},
{'cluster': 20, 'estado': 0, 'altura': 4, 'rmin': 0.59, 'rmax': 1.7000000000000001, 'area':
45.00000000000002, 'esquinas': [7.950000000000017, 0.0], 'incum': 0, 'lados':
[6.75, 6.66666666666671], 'puntos': [11.3250000000000017,
3.333333333333357]}, {'cluster': 21, 'estado': 1, 'altura': 4, 'incum': 0.0, 'corte': 3,
'izq': 24, 'der': 3, 'area': 122.00000000000003}, {'cluster': 22, 'estado': 1, 'altura': 5,
'incum': 0.0, 'corte': 0, 'izq': 9, 'der': 6, 'area': 27.00000000000001}, {'cluster': 23,
'estado': 1, 'altura': 5, 'incum': 0.0, 'corte': 2, 'izq': 5, 'der': 13, 'area':
36.000000000000014}, {'cluster': 24, 'estado': 1, 'altura': 5, 'incum': 0.0, 'corte': 3,
'izq': 33, 'der': 15, 'area': 95.00000000000003}, {'cluster': 25, 'estado': 1, 'altura': 4,
'incum': 0.0, 'corte': 1, 'izq': 12, 'der': 11, 'area': 102.00000000000006}, {'cluster': 26,
'estado': 1, 'altura': 3, 'incum': 0.0, 'corte': 1, 'izq': 14, 'der': 21, 'area':
146.00000000000003}, {'cluster': 27, 'estado': 1, 'altura': 4, 'incum': 0.0, 'corte': 1,
'izq': 22, 'der': 17, 'area': 91.00000000000004}, {'cluster': 28, 'estado': 1, 'altura': 2,
'incum': 0.0, 'corte': 2, 'izq': 7, 'der': 30, 'area': 51.00000000000014}, {'cluster': 29,
'estado': 1, 'altura': 3, 'incum': 0.0, 'corte': 3, 'izq': 25, 'der': 20, 'area':
147.00000000000009}, {'cluster': 30, 'estado': 1, 'altura': 3, 'incum': 0.0, 'corte': 2,
'izq': 2, 'der': 10, 'area': 42.00000000000014}, {'cluster': 31, 'estado': 1, 'altura': 3,
'incum': 0.0, 'corte': 3, 'izq': 32, 'der': 27, 'area': 202.0000000000001}, {'cluster': 32,
'estado': 1, 'altura': 4, 'incum': 0.0, 'corte': 3, 'izq': 16, 'der': 23, 'area':
111.00000000000006}, {'cluster': 33, 'estado': 1, 'altura': 6, 'incum': 0.0, 'corte': 1,
'izq': 18, 'der': 1, 'area': 68.0000000000003}, {'cluster': 34, 'estado': 1, 'altura': 2,
'incum': 0.0, 'corte': 2, 'izq': 4, 'der': 8, 'area': 27.0000000000001}, {'cluster': 35,
'estado': 1, 'altura': 1, 'incum': 0.0, 'corte': 0, 'izq': 28, 'der': 34, 'area':
78.0000000000003}, {'cluster': 36, 'estado': 1, 'altura': 2, 'incum': 0.0, 'corte': 3, 'izq':
29, 'der': 19, 'area': 174.0000000000009}, {'cluster': 37, 'estado': 1, 'altura': 2, 'in-
cum': 0.0, 'corte': 0, 'izq': 26, 'der': 31, 'area': 348.0000000000001}, {'cluster': 38,
'estado': 1, 'altura': 1, 'incum': 0.0, 'corte': 0, 'izq': 37, 'der': 36, 'area':
522.0000000000002}, {'cluster': 39, 'estado': 1, 'altura': 0, 'incum': 0, 'corte': 3, 'izq':
38, 'der': 35, 'area': 600.0000000000002}]
```

La figura 39 presenta el Layout resultante para AB20.

Figura 39*Layout óptimo para AB20 – Paso 2**Fuente: obtenido de ALGOCYM*

La figura 40 presenta la evolución de las generaciones para AB20 al aplicar el paso 2.

Figura 40*Evolución de las generaciones para AB20 – Paso 2**Fuente: elaboración propia*

3.7 Población de estudio

Entiéndase por población todo el espacio finito de soluciones que son calculadas por la cantidad de posibles árboles de corte proporcionado por la ecuación 17 (ver 3.5.1).

Las técnicas metaheurísticas tienen una naturaleza no determinista, por ello en la literatura se encuentra que cada experimento se realiza un número de veces (replicas), a partir de los resultados; las conclusiones se toman de los valores medios y así se evita que estas conclusiones obedezcan a los resultados muy buenos o malos. Según (Diego-Más, 2006), esta decisión permite aumentar la fiabilidad de los resultados, aunque eventualmente puede aumentar el costo global en tiempo y almacenamiento de cómputo requerido.

En el caso de la presente investigación, se procederá de manera semejante a lo planteado por (Diego-Más, 2006) estableciendo:

- a) **Parametrización del algoritmo propuesto.** - Un primer conjunto de experimentos dirigidos a establecer los valores de los parámetros más adecuados que consigan optimizar los resultados del algoritmo propuesto.
- b) **Funcionalidades del algoritmo propuesto.** - Un segundo conjunto de experimentos que permitan determinar las funcionalidades del algoritmo propuesto en cuanto a los tiempos de ejecución de este.
- c) **Prueba del algoritmo propuesto.** - Una vez obtenidos los dos puntos anteriores, se toma como conjunto de prueba las 4 formulaciones FLP conocidos y reportados en la literatura tales como (Tam & Li, 1991) para 8 departamentos, (van Camp et al., 1992) para 10 departamentos, (Bazaraa, 1975) para 14 departamentos, y (Armour & Buffa, 1963) para 20 departamentos.

3.8 Tamaño de la muestra

Para determinar el tamaño de la muestra se propone un conjunto de experimentos iniciales (ver tabla 26) donde se establecen: tamaño chico de 30 individuos, mediano de 60 individuos y grande de 100 individuos. Realizados los experimentos y hecho el análisis ANOVA en cada caso se encuentra que un tamaño de 30 individuos es significativo (ver capítulo 4). Por ello se establece que para todas las unidades de análisis se aplicara un tamaño de muestra de 30 individuos.

Para cada uno de los problemas planteados en 3.6.1, 3.6.2, 3.6.3, 3.6.4, se propone en cada paso:

Paso 1. - Resolverlos diez veces teniendo cuidado de mantener siempre las mismas condiciones de ejecución, de número de individuos y combinaciones de tipo de parámetros.

Paso 2. - Resolverlos catorce veces teniendo cuidado de mantener siempre las mismas condiciones de ejecución, de número de individuos y combinaciones de tipo de parámetros.

En todos los casos se espera obtener resultados cuyos valores pueden ser medios, máximos y mínimos de cada grupo de experimentos en cada paso y aquellas variables que se ha planteado medir para la presente tesis.

3.9 Selección de la muestra

El rendimiento de los algoritmos genéticos está en función de los parámetros establecidos para él, midiendo el rendimiento en la optimización de cuatro problemas tomados de la literatura del FLP, variando el tamaño de la muestra (población de individuos o soluciones), el modo de realizar el reemplazo, la probabilidad de cruce y de mutación, el tipo de selección, etc. (Digalakis & Margaritis, 2001).

De la revisión de la aplicación de algoritmos genéticos a problemas de optimización se encuentra dos enfoques en cuanto a la selección de parámetros comunes a estos algoritmos: probabilidad de cruce, de mutación y tamaño de población³ que se somete a evolución. El primer enfoque fue propuesto por D. Jong y Spears (De Jong & Spears, 1991) que recomienda emplear tamaños de población grandes (100 o más individuos) y probabilidades de cruce y mutación relativamente bajas, ($P_c = 0,6$, $P_m = 0,001$). El segundo enfoque fue propuesto por (Grefenstette, 1986) que indica tamaños de población menores (30 individuos) y una actividad mayor de los operadores genéticos ($P_c = 0,9$, $P_m = 0,01$). De ambas propuestas se puede inferir que la primera disminuye la actuación de los operadores genéticos dada una población alta (lo cual garantiza la diversidad). En la segunda propone una mayor intensidad de los operadores genéticos y una población pequeña a fin de evitar la convergencia prematura del algoritmo hacia un óptimo local. En este punto (Diego-Más, 2006), propone que el operador de cruce debe tener mayor preponderancia que el de mutación.

En la presente tesis para el algoritmo ALGOCYM propuesto, se opta por el segundo enfoque que plantea una menor población⁴, pero una gran actividad de los operadores genéticos de cruce y mutación. Esto significa que el tamaño de la muestra (individuos) se establece de tamaño 30.

Es pertinente aclarar que al ser el FLP un problema de naturaleza combinatoria para él se tiene un espacio muy grande de posibles soluciones (población total). En programación genética el espacio total de soluciones debe ser explorado en la búsqueda de una solución óptima, por ello es importante determinar el tamaño de la muestra adecuado que permita encontrar la solución óptima para los casos en estudio.

³ Para los experimentos y las pruebas estadísticas se aclara en este punto que el “tamaño de la población”, es en realidad la muestra.

⁴ La decisión acerca del tamaño de la muestra(población que evolucionara) se discute en 4.1.1

3.10 Técnicas de recolección de datos

Tal como se expuso en el inciso 3.6, primero se establecerán los parámetros adecuados para el algoritmo genético Algocym tal que contribuyan a encontrar una solución del problema del FLP.

Según lo indicado en el inciso 3.6, se toman cuatro casos para poner a prueba el algoritmo y mostrar su funcionalidad. Resumiendo, estos casos son:

- a) Caso I: Tam (T8) para 8 departamentos.
- b) Caso II: van Camp (vC10) para 10 departamentos.
- c) Caso III: Bazaraa 14 (B14) para 14 departamentos.
- d) Caso IV: Armour y Buffa 20 (AB20) para 20 departamentos.

Para cada caso se establecen cuatro grupos experimentales. En el paso 1, para cada grupo se realizan 10 ejecuciones del algoritmo, donde la variable dependiente VD es el Costo de la función objetivo (adaptación), la variable independiente VI es la probabilidad de cruce que será de $pc = \{0.6, 0.7, 0.8, 0.9\}$, la probabilidad de mutación es de $pm = \{0.05, 0.08, 0.1, 0.2, 0.3, 0.4, 0.5\}$, manteniendo constante la población (tamaño de la muestra) $n = 30$ individuos, el número de generaciones Ng permanece en cada grupo experimental. Al respecto ver 3.6.1, 3.6.2, 3.6.3, 3.6.4.

Dado que se tienen casos entre 8, 10, 14, y 20 departamentos; en esta parte del presente documento, se considera presentar el cuarto caso (AB20) por ser el de mayor tamaño. Para este caso se muestran los resultados de los cuatro grupos experimentales tomando para el paso 1: 10 ejecuciones cada uno (ver tabla 22), y para el paso 2: se realizaron 14 ejecuciones, según los parámetros indicados (ver tabla 23). Las tablas de resultados experimentales de los casos I, II y III se presentan en los anexos 3, 4 y 5.

En la tabla 22 se tiene como mejor valor para la función de adaptación⁵ 3,730.011470 (este valor se muestra con color resaltado), siendo el árbol de cortes el de la figura 37. Este valor se obtuvo en la ejecución 7 de la fila solución P1AB20_1D. Tal como se ha planteado para Algocym; el mejor árbol de cortes del paso 1, es tomado para desarrollar el paso 2. En la tabla 23 se presenta los resultados experimentales del paso 2, en cada fila experimental se realizaron 14 ejecuciones, se puede notar que de estas; entre 6 y 11 ejecuciones consiguieron el valor óptimo buscado. El Layout resultante se presenta en la figura 39.

⁵ Fitness function = Función de adaptación = Costo de la función de adaptación.

Tabla 22*Experimentos Caso IV AB20 – Paso 1*

Tamaño de población			30	Costo de la función de adaptación										Costo Minimo	Aciertos
Número de generaciones			3500	Ejec 1	Ejec 2	Ejec 3	Ejec 4	Ejec 5	Ejec 6	Ejec 7	Ejec 8	Ejec 9	Ejec 10		
Nº	Solución	pc	pm	Ejec 1	Ejec 2	Ejec 3	Ejec 4	Ejec 5	Ejec 6	Ejec 7	Ejec 8	Ejec 9	Ejec 10		
1	P1AB20_1A1	0.6	0.05	3,990.448648	3,959.195228	4,073.159668	4,153.673447	4,174.023073	4,056.932634	4,035.842677	4,056.288291	4,075.293551	4,094.397803	3,959.195228	0
2	P1AB20_1B1	0.6	0.1	4,031.442332	3,995.442304	3,776.262552	3,904.121405	4,035.055292	3,779.187310	4,034.691893	3,970.653324	3,994.685209	4,137.164562	3,776.262552	0
3	P1AB20_1C1	0.6	0.2	3,785.203459	3,847.193657	4,184.143726	3,995.961440	3,857.474157	4,091.821429	3,990.418093	4,086.326980	4,128.895179	3,890.109128	3,785.203459	0
4	P1AB20_1D1	0.6	0.3	4,128.260320	5,254.770692	3,795.188243	3,879.390040	3,948.833265	4,022.612165	4,013.784492	3,774.104271	3,947.501296	4,171.212945	3,774.104271	0
5	P1AB20_1A	0.6	0.4	4,007.646151	3,905.533302	3,897.358719	4,052.480724	3,971.656375	3,972.295674	3,806.716832	3,890.236084	3,874.580851	3,947.162161	3,806.716832	0
6	P1AB20_1B	0.6	0.5	3,946.904672	3,861.591300	3,978.250530	3,755.969827	3,906.264156	3,937.671749	3,937.671749	4,035.042010	3,914.773644	4,164.589911	3,755.969827	0
7	P1AB20_1C	0.6	0.6	4,193.223336	3,912.531042	3,941.651320	3,748.833522	4,115.545921	4,053.352901	4,060.756677	4,040.686810	3,968.524080	3,866.148447	3,748.833522	0
8	P1AB20_1D	0.6	0.7	4,027.131548	4,136.606149	3,901.296122	4,016.343673	3,925.524255	3,983.034226	3,730.011470	3,999.013493	3,747.771436	3,983.476191	3,730.011470	1
9	P1AB20_1E	0.6	0.8	3,868.267184	4,084.815135	4,181.210689	4,118.389097	4,030.910134	4,220.182847	3,939.801819	3,923.851124	4,219.467125	3,937.671749	3,868.267184	0
10	P1AB20_2A1	0.7	0.05	4,221.703572	3,943.307813	3,990.914848	4,085.015019	4,187.856213	4,342.325750	3,885.881350	4,246.986144	4,038.690457	4,157.902256	3,885.881350	0
11	P1AB20_2B1	0.7	0.1	4,122.258573	4,127.977240	4,015.094739	3,993.681370	4,124.391873	4,212.407954	4,009.413277	3,803.402961	4,015.021852	4,028.204619	3,803.402961	0
12	P1AB20_2C1	0.7	0.2	4,023.605241	3,967.522400	3,829.563250	3,911.949481	4,247.668417	3,938.791000	4,031.442332	3,916.401923	3,833.040083	4,009.606856	3,829.563250	0
13	P1AB20_2D1	0.7	0.3	3,860.582009	4,058.920150	3,760.037699	3,942.607592	3,907.708567	3,966.258580	3,891.341756	4,061.941192	4,180.235004	4,093.156841	3,760.037699	0
14	P1AB20_2A	0.7	0.4	3,985.320261	3,965.112736	3,948.833265	4,022.492584	3,961.908475	3,981.498483	3,878.105370	3,880.022141	4,075.368065	4,136.573791	3,878.105370	0
15	P1AB20_2B	0.7	0.5	3,923.993708	3,973.154160	3,865.410780	3,953.705676	4,095.986342	3,826.384732	4,060.909385	3,928.418297	4,118.891964	3,951.868735	3,826.384732	0
16	P1AB20_2C	0.7	0.6	4,053.436362	3,979.072845	4,091.322358	3,996.381258	3,946.169647	4,111.365625	4,038.306450	4,003.600175	3,985.953887	4,046.237243	3,946.169647	0
17	P1AB20_2D	0.7	0.7	4,048.499184	3,890.972451	4,152.361579	4,119.714890	4,118.586738	3,794.326861	4,002.227001	3,765.895068	4,447.230232	4,059.441784	3,765.895068	0
18	P1AB20_2E	0.7	0.8	4,009.667810	3,967.348730	3,838.923216	4,175.559920	3,971.405686	3,905.751766	3,744.377452	4,011.681813	3,859.956666	4,030.338625	3,744.377452	0
19	P1AB20_3A1	0.8	0.05	4,595.699948	4,259.053827	4,152.989764	4,125.961592	4,601.602751	4,116.812422	3,904.176969	4,584.149070	3,864.541042	4,196.709135	3,864.541042	0
20	P1AB20_3B1	0.8	0.1	4,054.601523	3,920.969303	4,043.967983	3,900.400722	4,038.270925	4,230.933718	4,112.187095	3,854.188052	4,076.047283	3,947.688653	3,854.188052	0
21	P1AB20_3C1	0.8	0.2	3,937.478155	3,790.253645	3,991.003140	4,056.952213	3,993.196046	3,918.671589	3,996.211899	3,891.935845	4,141.770873	4,116.990065	3,790.253645	0
22	P1AB20_3D1	0.8	0.3	3,835.487125	4,165.409528	3,919.805451	3,991.190282	3,878.703190	4,177.486352	3,969.125651	3,928.559175	3,974.377720	3,835.487125	0	
23	P1AB20_3A	0.8	0.4	4,187.115009	3,988.605470	3,798.933209	4,010.478118	4,105.815655	3,978.485568	3,866.098429	4,111.687150	4,132.385331	4,031.714134	3,798.933209	0
24	P1AB20_3B	0.8	0.5	3,975.995896	4,049.877997	4,145.432091	3,935.475641	4,554.624948	3,922.101987	3,817.060511	3,828.819365	3,994.864054	4,116.878407	3,817.060511	0
25	P1AB20_3C	0.8	0.6	3,983.847781	4,130.355242	4,127.894630	4,059.482723	3,896.639920	3,781.478202	3,804.235703	3,835.230321	3,926.843719	4,207.269321	3,781.478202	0
26	P1AB20_3D	0.8	0.7	4,031.376044	4,103.427578	3,926.889460	4,132.195345	3,800.752152	3,867.846626	4,001.178594	3,883.926148	4,028.394752	3,888.007355	3,800.752152	0
27	P1AB20_3E	0.8	0.8	4,259.714416	3,979.380934	3,933.125814	4,051.509102	3,888.959187	3,960.727915	3,959.054578	3,987.298231	3,931.871342	3,893.477454	3,888.959187	0
28	P1AB20_4A1	0.9	0.05	4,122.007816	6,916.906982	5,979.517937	4,024.363693	3,913.045497	4,691.437271	4,134.970960	8,520.658949	4,322.140727	4,091.010810	3,913.045497	0
29	P1AB20_4B1	0.9	0.1	4,034.768137	3,807.425697	4,011.656303	4,004.169625	4,087.041534	3,930.266251	4,086.769923	3,759.252685	4,075.965506	4,098.765173	3,759.252685	0
30	P1AB20_4C1	0.9	0.2	4,117.737661	3,947.513574	4,149.406201	3,884.561056	4,001.477017	4,015.685849	3,769.722779	4,152.018933	3,935.917165	3,944.866161	3,769.722779	0
31	P1AB20_4D1	0.9	0.3	3,888.628355	3,957.028465	3,988.577266	4,193.131533	3,973.753477	3,959.147568	4,005.335628	4,045.868186	4,131.556821	3,874.533537	3,874.533537	0
32	P1AB20_4A	0.9	0.4	3,946.298845	3,939.897253	3,993.204582	3,846.377627	3,818.073049	3,895.114370	3,952.322633	3,954.137640	4,177.572199	4,016.691210	3,818.073049	0
33	P1AB20_4B	0.9	0.5	3,937.671749	4,030.002799	3,922.803965	3,873.282224	3,851.372642	3,970.681969	3,942.091638	3,831.675512	3,829.288796	3,979.763360	3,829.288796	0
34	P1AB20_4C	0.9	0.6	3,930.044321	4,437.413465	4,142.941031	4,066.996476	4,015.682261	3,915.690722	4,069.034117	3,939.234994	3,901.946355	4,028.204619	3,901.946355	0
35	P1AB20_4D	0.9	0.7	3,948.390861	4,011.427024	3,906.605919	3,867.682309	3,866.098429	4,013.686192	4,060.216100	4,038.319753	4,000.903437	4,024.381258	3,866.098429	0
36	P1AB20_4E	0.9	0.8	4,109.412929	4,148.163593	4,077.825933	3,935.475641	4,288.778624	3,921.667807	3,855.362668	3,922.515842	4,053.352901	3,854.727083	3,854.727083	0

Nota: Se resalta con fondo amarillo la ejecución 7, donde se encuentra el óptimo en el experimento P1AB20_1D

Tabla 23*Experimentos Caso IV AB20 – Paso 2*

Tamaño de población				30		Costos de la función de adaptación														
Número de generaciones				2000																
Nº	Solución	pc	pm	Ejec 1	Ejec 2	Ejec 3	Ejec 4	Ejec 5	Ejec 6	Ejec 7	Ejec 8	Ejec 9	Ejec 10	Ejec 11	Ejec 12	Ejec 13	Ejec 14	Aciertos	%	
1	P1AB20_1D	0.6	0.2	10,347.871967	10,347.871967	10,347.871967	12,607.063404	12,607.618314	10,347.871967	10,347.871967	10,347.871967	12,635.888335	16,352.821282	10,347.871967	12,607.063404	10,347.871967	9	0.64		
2	P1AB20_1D	0.6	0.3	10,347.871967	12,635.888335	10,347.871967	10,347.871967	12,614.485375	12,635.888335	10,347.871967	10,347.871967	12,607.618314	16,374.710992	10,347.871967	10,347.871967	10,347.871967	10,347.871967	9	0.64	
3	P1AB20_1D	0.6	0.4	10,347.871967	12,635.888335	10,347.871967	10,347.871967	12,607.063404	10,347.871967	10,347.871967	10,347.871967	12,635.888335	12,635.888335	10,347.871967	12,607.063404	10,347.871967	10,347.871967	9	0.64	
4	P1AB20_1D	0.6	0.5	10,347.871967	12,614.485375	10,347.871967	10,347.871967	13,189.569338	10,347.871967	12,635.888335	10,347.871967	10,347.871967	10,347.871967	12,607.063404	10,347.871967	10,347.871967	12,607.063404	12,610.049794	12,610.049794	
5	P1AB20_1D	0.6	0.6	13,189.569338	10,347.871967	10,347.871967	10,347.871967	12,607.063404	10,347.871967	10,347.871967	10,347.871967	12,607.063404	10,347.871967	12,607.063404	10,347.871967	12,614.485375	10,347.871967	9	0.64	
6	P1AB20_1D	0.6	0.7	10,347.871967	12,607.618314	12,607.063404	10,347.871967	10,347.871967	10,347.871967	10,347.871967	12,607.618314	10,347.871967	10,347.871967	12,635.888335	12,635.888335	10,347.871967	10,347.871967	10,347.871967	9	0.64
7	P1AB20_1D	0.6	0.8	12,635.888335	12,607.063404	12,607.063404	10,347.871967	12,607.063404	10,347.871967	12,607.063404	12,607.618314	12,635.888335	12,635.888335	10,347.871967	10,347.871967	10,347.871967	10,347.871967	10,347.871967	6	0.43
8	P1AB20_1D	0.7	0.2	16,352.821282	12,614.485375	10,347.871967	10,347.871967	12,607.063404	12,607.063404	10,347.871967	10,347.871967	12,607.063404	12,607.063404	10,347.871967	10,347.871967	10,347.871967	12,635.888335	7	0.50	
9	P1AB20_1D	0.7	0.3	10,347.871967	10,347.871967	12,635.888335	10,347.871967	12,635.888335	12,607.063404	12,635.888335	12,635.888335	16,352.821282	10,347.871967	10,347.871967	12,635.888335	12,607.063404	10,347.871967	13,168.513444	6	0.43
10	P1AB20_1D	0.7	0.4	10,347.871967	10,347.871967	12,607.063404	10,347.871967	10,347.871967	12,635.888335	13,168.513444	12,607.063404	10,347.871967	12,607.063404	10,347.871967	16,352.821282	12,607.063404	10,347.871967	7	0.50	
11	P1AB20_1D	0.7	0.5	10,347.871967	10,347.871967	10,347.871967	10,347.871967	12,607.063404	10,347.871967	12,607.618314	10,347.871967	13,168.513444	13,168.513444	10,347.871967	12,607.063404	10,347.871967	10,347.871967	9	0.64	
12	P1AB20_1D	0.7	0.6	10,347.871967	10,347.871967	13,189.569338	10,347.871967	10,347.871967	12,607.063404	10,347.871967	12,614.485375	10,347.871967	12,607.618314	10,347.871967	10,347.871967	10,347.871967	13,168.513444	9	0.64	
13	P1AB20_1D	0.7	0.7	10,347.871967	10,347.871967	12,607.063404	12,614.485375	10,347.871967	10,347.871967	12,607.063404	12,635.888335	12,619.060784	10,347.871967	12,635.888335	13,189.569338	10,347.871967	12,635.888335	6	0.43	
14	P1AB20_1D	0.7	0.8	10,347.871967	10,347.871967	10,347.871967	12,607.618314	10,347.871967	10,347.871967	10,347.871967	12,638.835000	12,607.063404	12,607.618314	12,607.063404	12,635.888335	10,347.871967	10,347.871967	8	0.57	
15	P1AB20_1D	0.8	0.2	10,347.871967	12,607.618314	10,347.871967	10,347.871967	12,614.485375	12,614.485375	10,347.871967	10,347.871967	12,635.888335	16,352.821282	12,619.060784	12,635.888335	12,607.618314	10,347.871967	6	0.43	
16	P1AB20_1D	0.8	0.3	12,607.063404	10,347.871967	12,607.063404	10,347.871967	10,347.871967	12,635.888335	13,168.513444	12,607.618314	10,347.871967	13,168.513444	12,635.888335	13,189.569338	12,610.049794	12,607.063404	4	0.29	
17	P1AB20_1D	0.8	0.4	10,347.871967	12,635.888335	10,347.871967	12,614.485375	10,347.871967	12,607.063404	12,635.888335	13,189.569338	10,347.871967	10,347.871967	10,347.871967	10,347.871967	10,347.871967	10,347.871967	9	0.64	
18	P1AB20_1D	0.8	0.5	13,168.513444	10,347.871967	10,347.871967	12,635.888335	12,614.485375	10,347.871967	10,347.871967	13,168.513444	10,347.871967	12,607.063404	12,635.888335	12,607.063404	10,347.871967	10,347.871967	6	0.43	
19	P1AB20_1D	0.8	0.6	10,347.871967	10,347.871967	10,347.871967	10,347.871967	10,347.871967	10,347.871967	10,347.871967	13,189.569338	10,347.871967	10,347.871967	13,168.513444	10,347.871967	12,635.888335	10,347.871967	11	0.79	
20	P1AB20_1D	0.8	0.7	10,347.871967	12,607.063404	12,607.063404	10,347.871967	10,347.871967	10,347.871967	12,607.063404	12,607.063404	10,347.871967	10,347.871967	10,347.871967	10,347.871967	10,347.871967	16,352.821282	10,347.871967	9	0.64
21	P1AB20_1D	0.8	0.8	10,347.871967	10,347.871967	10,347.871967	10,347.871967	10,347.871967	10,347.871967	12,607.618314	12,635.888335	12,607.063404	12,607.063404	12,607.063404	10,347.871967	12,607.063404	10,347.871967	8	0.57	
22	P1AB20_1D	0.9	0.2	16,319.198064	10,347.871967	10,347.871967	12,607.063404	10,347.871967	12,614.485375	10,347.871967	10,347.871967	12,607.063404	12,607.618314	10,347.871967	10,347.871967	13,189.569338	10,347.871967	8	0.64	
23	P1AB20_1D	0.9	0.3	12,610.049794	10,347.871967	10,347.871967	10,347.871967	13,168.513444	12,635.888335	10,347.871967	10,347.871967	12,635.888335	16,352.821282	12,607.618314	12,635.888335	10,347.871967	10,347.871967	7	0.64	
24	P1AB20_1D	0.9	0.4	10,347.871967	13,168.513444	10,347.871967	16,364.899523	12,607.618314	13,168.513444	10,347.871967	10,347.871967	10,347.871967	10,347.871967	12,607.063404	10,347.871967	13,168.513444	12,607.063404	7	0.64	
25	P1AB20_1D	0.9	0.5	10,347.871967	12,607.063404	12,635.888335	10,347.871967	12,607.063404	10,347.871967	13,168.513444	12,635.888335	10,347.871967	10,347.871967	12,614.485375	10,347.871967	10,347.871967	12,607.618314	7	0.64	
26	P1AB20_1D	0.9	0.6	10,347.871967	12,635.888335	12,610.049794	12,635.888335	10,347.871967	10,347.871967	12,607.063404	10,347.871967	12,635.888335	10,347.871967	10,347.871967	12,607.063404	10,347.871967	10,347.871967	8	0.64	
27	P1AB20_1D	0.9	0.7	12,607.618314	10,347.871967	12,607.063404	10,347.871967	13,168.513444	12,614.485375	12,607.063404	10,347.871967	10,347.871967	10,347.871967	10,347.871967	13,189.569338	10,347.871967	13,189.569338	6	0.64	
28	P1AB20_1D	0.9	0.8	12,635.888335	10,347.871967	12,635.888335	12,638.835000	12,635.888335	12,607.063404	12,607.063404	10,347.871967	10,347.871967	10,347.871967	12,610.049794	10,347.871967	12,607.063404	10,347.871967	6	0.64	

Nota: Se resalta con fondo amarillo las ejecuciones que encuentran el óptimo para AB20.

3.11 El algoritmo ALGOCYM

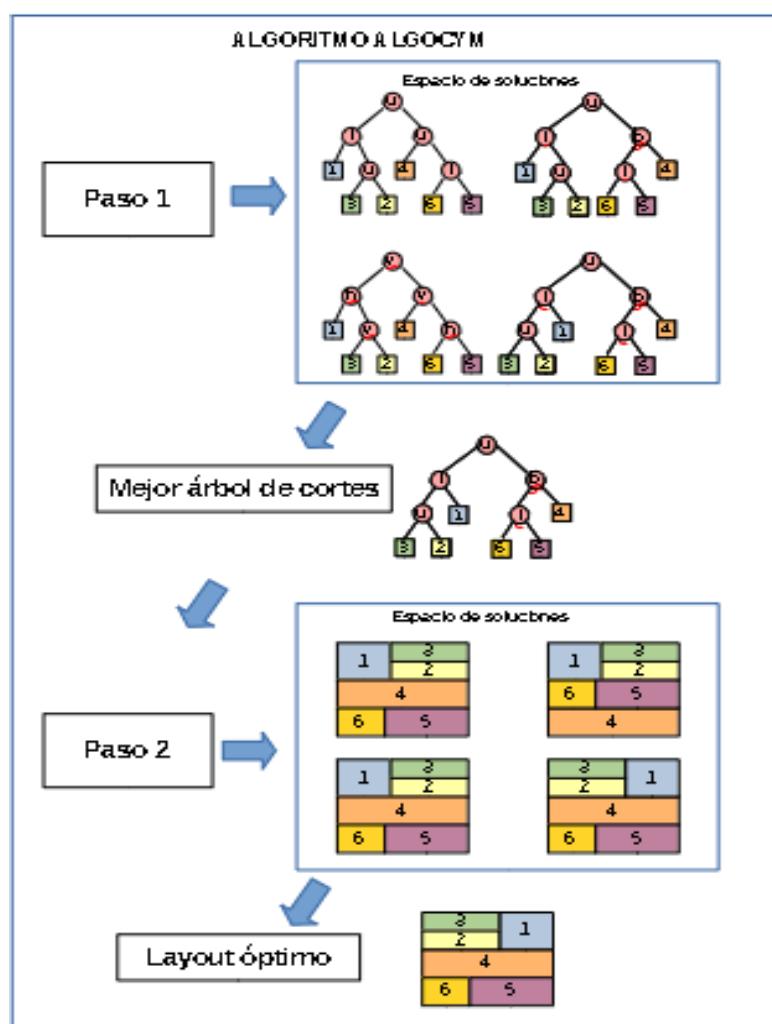
El algoritmo Algocym se implementa según lo expuesto en los acápite 3.5.1 y 3.5.2. A continuación se presentan los diagramas del algoritmo.

3.11.1 *Diagramas del algoritmo*

Para presentar el algoritmo Algocym se emplea como herramientas gráficas: diagramas de módulos, de flujo y pseudocódigo de los módulos principales. La figura 41 presenta el diagrama básico que representa el esquema abstracto de Algocym.

Figura 41

Abstracción básica de Algocym

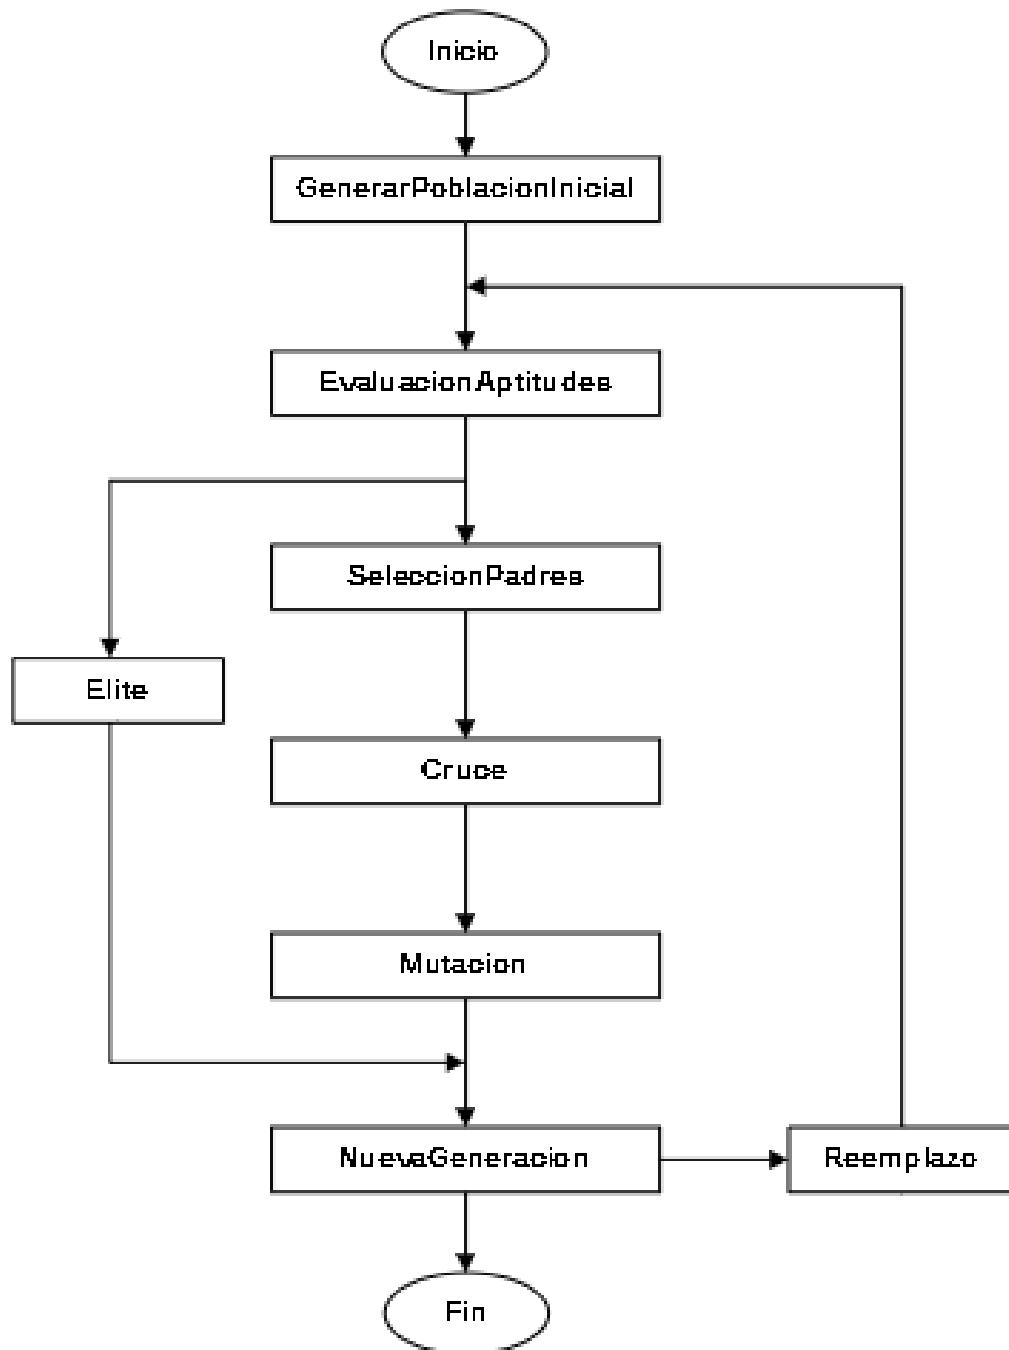


Fuente: elaboración propia

La figura 42 presenta el diagrama de flujo del paso 1 para Algocym. La explicación del paso 1 se presenta en 3.5.1

Figura 42

Diagrama de flujo del paso 1

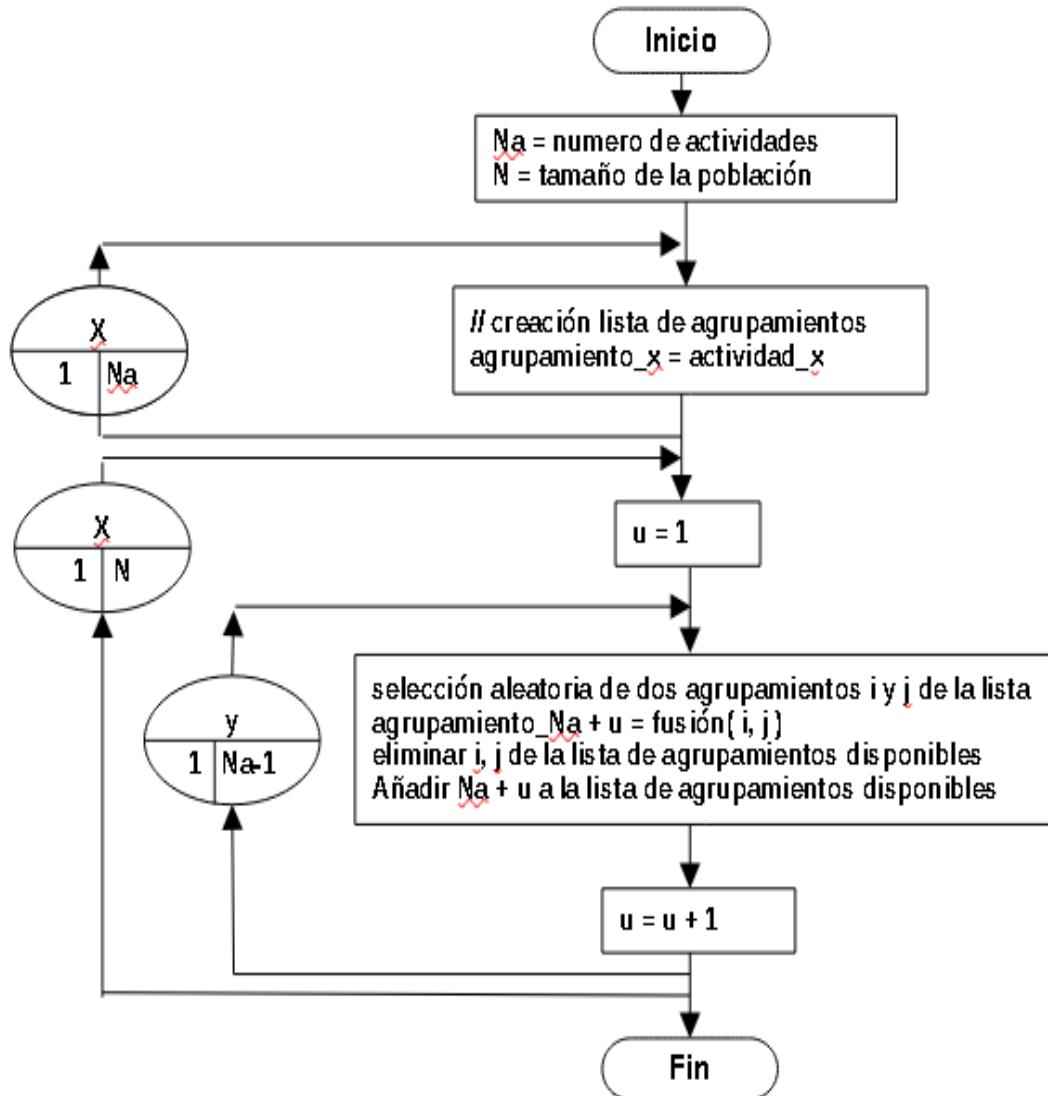


Fuente: elaboración propia

La figura 43 presenta el diagrama de flujo para el procedimiento de generar población inicial de soluciones o individuos factibles. Este proceso es aleatorio, La creación de los agrupamientos se presenta en la figura 15.

Figura 43

Procedimiento para generar población de árboles de corte de tamaño n

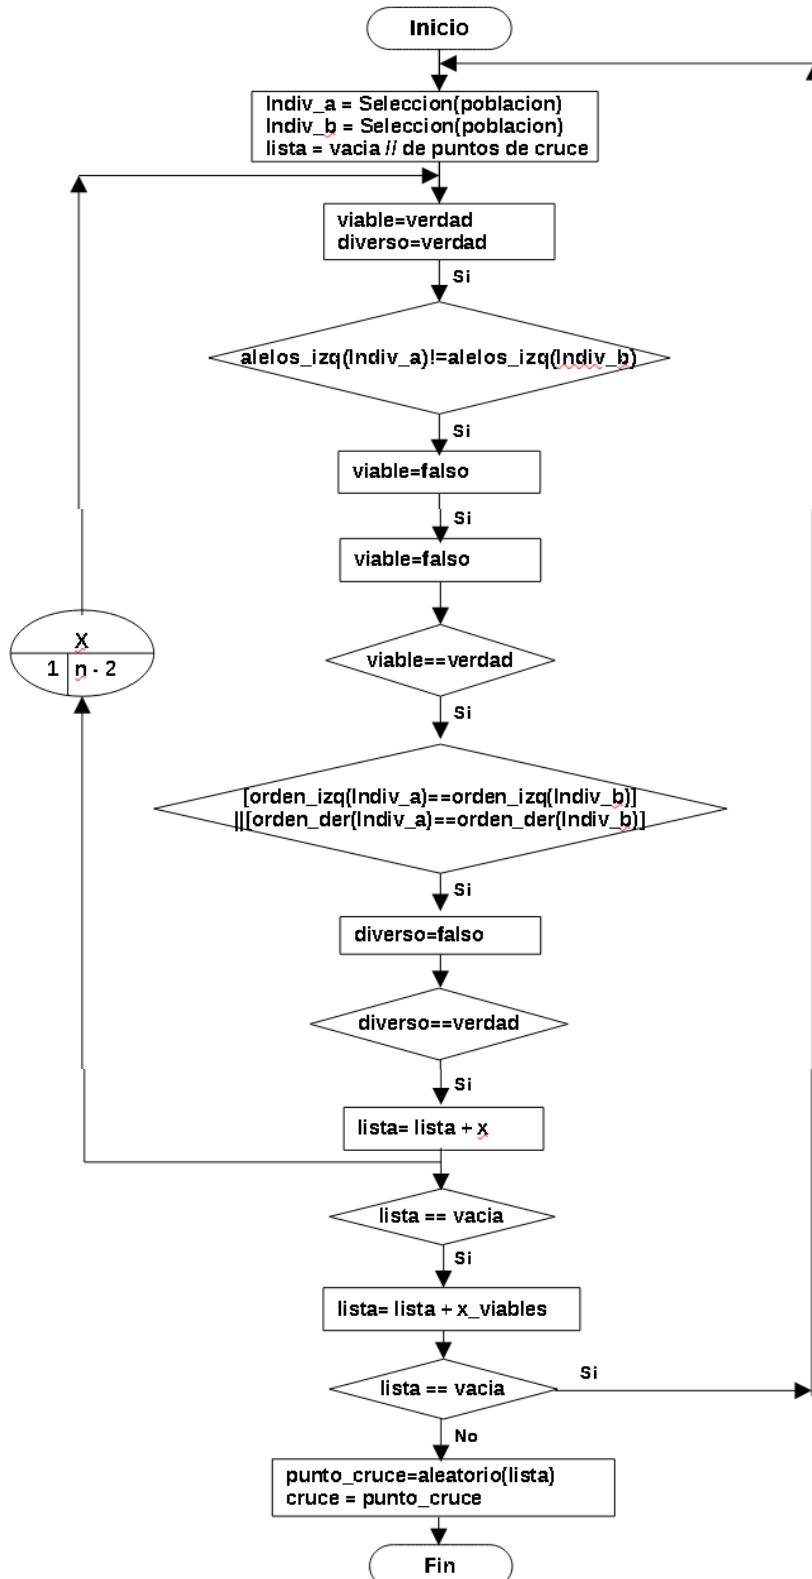


Fuente: Adaptado de (Santamarina, 95)

La figura 44 presenta el diagrama de flujo para el procedimiento que determina el punto de cruce. El proceso del cruce se expone en 3.5.1.6.

Figura 44

Procedimiento para determinar el punto de cruce - operador de cruce

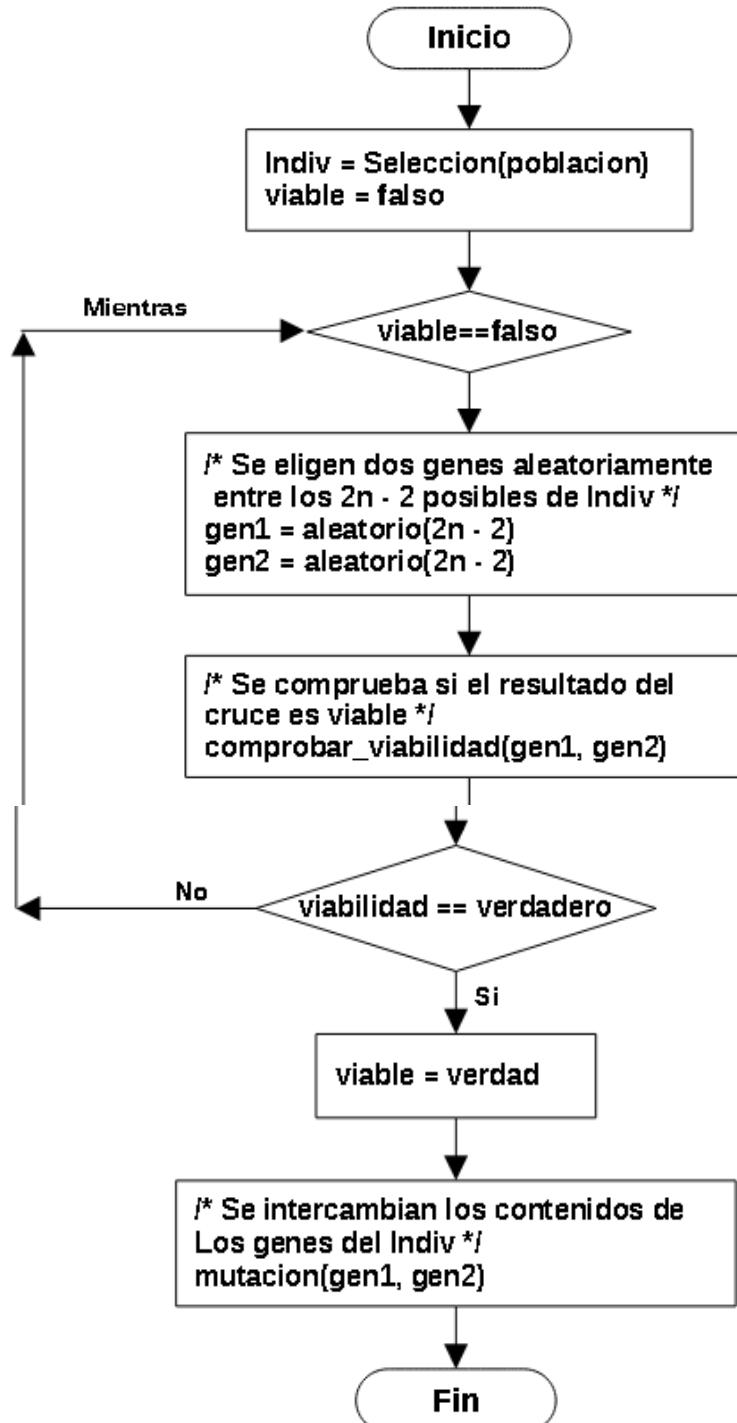


Fuente: Adaptado de (Diego-Más, 2006)

La figura 45 presenta el diagrama de flujo para el procedimiento de mutación. El proceso de la mutación se expone en 3.5.1.7.

Figura 45

Procedimiento para el operador de mutación



Fuente: Adaptado de (Santamarina, 95)

La figura 46 presenta el proceso para intensificar la búsqueda en la selección. En 3.5.1.8 se explica el proceso de selección.

Figura 46

Procedimiento para intensificar la búsqueda en la selección

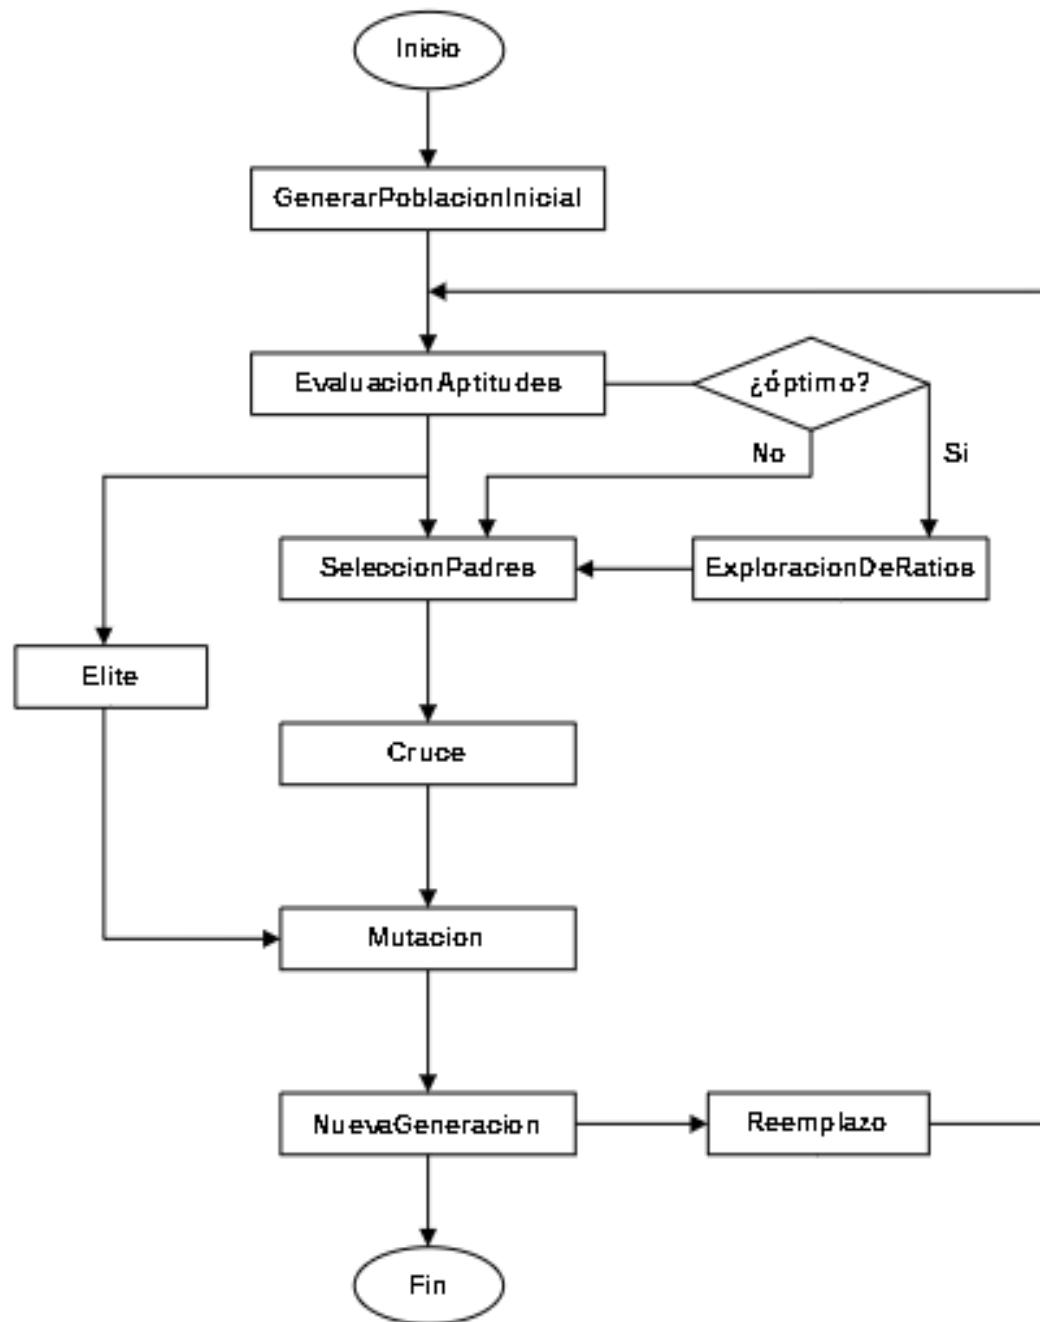
```

Procedimiento IntensificarBusquedaEnLaSeleccion()
    Lindiv // Lista de individuos
    Para x = 1 hasta Lindiv hacer
        seleccion( indiv )// elegir un individuo de la Lindiv aplicando operador de selección
        valor_indiv = evaluar( indiv )
        mejor_valor = valor_indiv
        cambio = falso
        Para y = 1 hasta (2n-3) hacer
            Para z = y + 1 hasta (2n - 2) hacer
                indiv' = Intercambiar_indiv( y, z ) // intercambiar genes de y en z de indiv
                valor_vecino = evalua( indiv' )
                Si valor_vecino < mejor_valor entonces
                    cambio = verdad
                    mejor_valor = valor_vecino
                    y' = y
                    z' = z
                FinSi
            FinPara
            Si cambio = verdad
                // reemplazar ind por el mejor vecino que lo supere si es que existe
                indiv' = intercambiar_indiv(y', z' )
            FinSi
        FinPara
    Fin

```

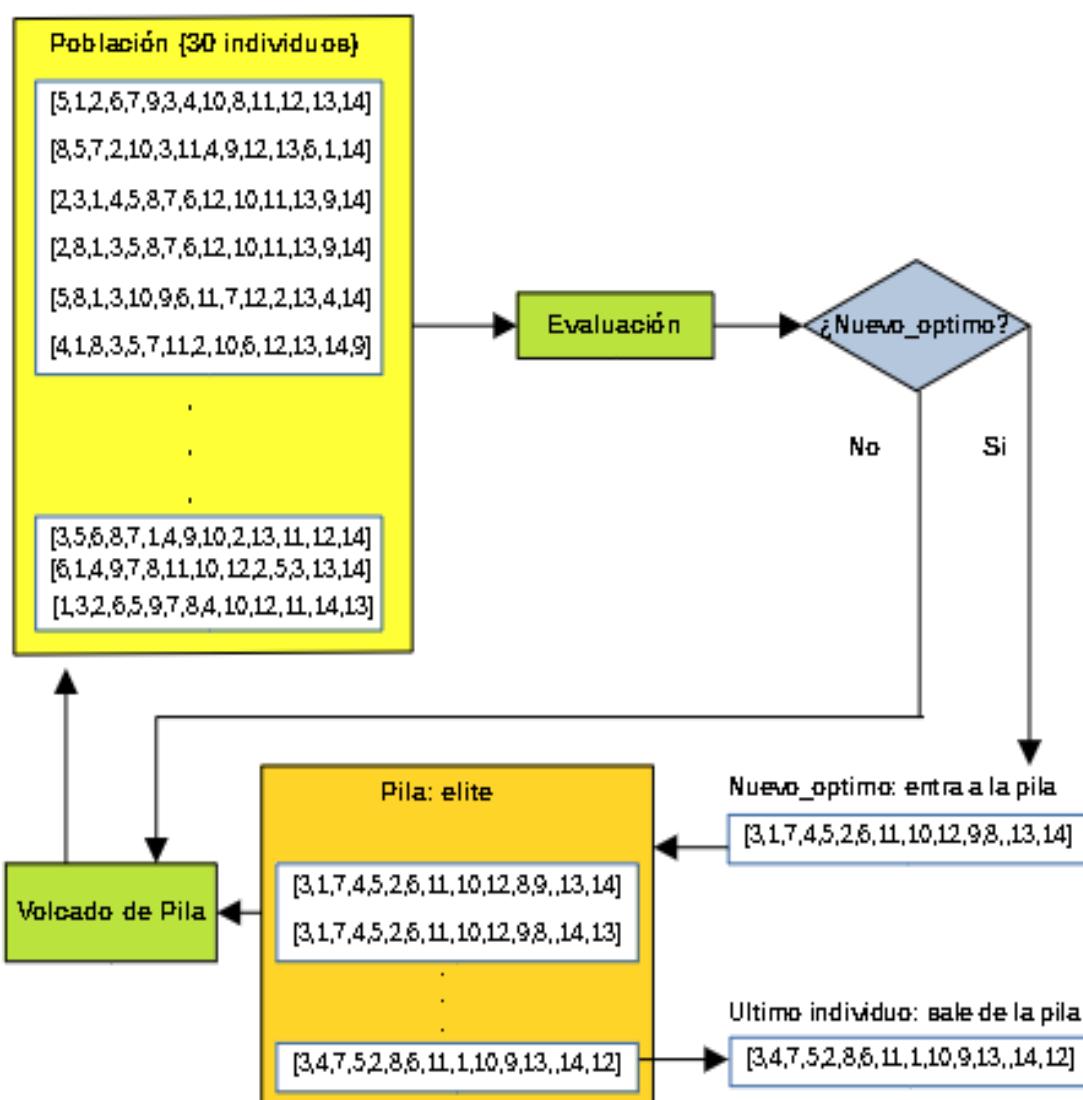
Fuente: Adaptado de (Diego-Más, 2006)

La figura 47 presenta el diagrama de flujo para los módulos del paso 2 en Algocym. La explicación del paso 2 se presenta en 3.5.2. Los procesos de evaluación, selección, cruce y mutación son similares al del paso 1.

Figura 47*Diagrama de flujo del paso 2**Fuente: elaboración propia*

La figura 48 presenta la abstracción para el procedimiento de elitismo. El proceso de elitismo se expone en 3.5.1.8.

Figura 48
Procedimiento para el elitismo



Fuente: Adaptado de (Diego-Más, 2006)

3.12 La implementación informática

La aplicación informática se ha desarrollado aplicando el paradigma orientado a objetos (POO) en lenguaje de programación Python y sobre el entorno del sistema operativo Linux 20.04.

3.12.1 *Objetivos del diseño de la aplicación*

1. Crear un software a medida tal que agrupe las tareas de resolución de un problema FLP mediante el algoritmo propuesto. Estas tareas son: Ingresar datos de entrada, introducir los parámetros, ejecutar los dos pasos del algoritmo, realizar la explotación de los resultados y visualizar el layout óptimo.
2. Implementar y ejecutar el software tal que permita la resolución de los casos aplicando programación concurrente y mediante servidores en cloud computing (computación en la nube).
3. Recoger, almacenar, explotar la información y resultados de los experimentos en una base de datos, tal que esté disponible para su uso posterior.

Para cumplir el objetivo 1, la implementación de la aplicación informática se realizó en Odoo que es un sistema de gestión ERP (Enterprise Resource Planning) de código abierto, modificable, extensible y sin costos de licenciamiento. Según (Odoo, 2021), Odoo es completo y ampliamente usado, posee una comunidad que supera los 2 millones de usuarios, más de 4600 desarrolladores y mensualmente se crean en promedio 312 aplicaciones por mes, ver figuras 49 y 50. Es así como la aplicación se implementa sobre el módulo de nombre Algocym, el cual se visualiza y ejecuta sobre el navegador Google Chrome.

Figura 49

Logotipo de Odoo ERP



Fuente: (Odoo, 2021)

Figura 50

Aplicaciones que pueden realizarse con Odoo

Una aplicación para cada necesidad

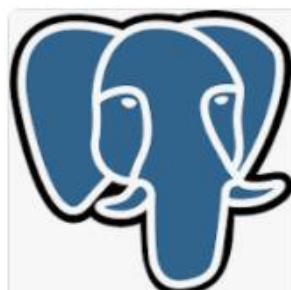


Fuente: https://www.odoo.com/es_ES/

Para dar cumplimiento de los objetivos en cuanto a la explotación de los resultados (objetivo 3) se utiliza PostgreSQL por ser un sistema gestor de base de datos relacionales y orientadas a objetos que es desarrollado por la comunidad de Software Libre, (PostgreSQL, 2021). Se decide por esta herramienta por ser especialmente eficiente en la gestión de base de datos medianas y grandes, la figura 51 presenta el logo de PostgreSQL.

Figura 51

Logotipo de PostgreSQL



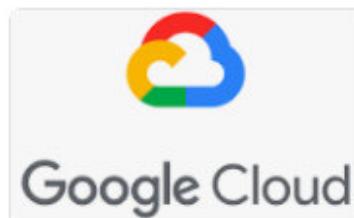
PostgreSQL

Fuente: <https://www.postgresql.org/>

En cumplimiento del objetivo 2, el desarrollo de la aplicación se realizó mediante el nuevo paradigma denominado cloud computing (computación en la nube), que permite contratar los servicios de hardware; específicamente se contrató los servicios de Google Cloud para ejecutar los casos realizados en la presente investigación («Google cloud», 2021). La figura 52 presenta el logotipo de los servicios de Google Cloud.

Figura 52

Logotipo de Google Cloud



Fuente: («Google cloud», 2021)

La ejecución de Algocym puede lanzarse en paralelo, esto significa que un problema se puede ejecutar un determinado número de veces. Es así como según la tabla 22; para el paso 1, cada fila (combinación de parámetros de cruce y mutación) se ejecutó 10 veces, y para el paso 2, cada fila se ejecutó 14 veces (tabla 23). Resumiendo, para ejecutar Algocym se utiliza el concepto de programación concurrente tal que, con una sola orden, se ejecuta el número de veces indicado para cada fila.

Uno de los servicios utilizado es el de *Compute Engine* que permite crear y ejecutar máquinas virtuales que configuran clusteres de procesamiento (incluso miles de CPU virtuales, memoria RAM y almacenamiento en disco) proporcionando un sistema de rendimiento seguro, coherente y rápido. *Compute Engine* permite ejecutar imágenes públicas de Linux, y Windows Server de manera predefinida o personalizada, según las necesidades de los clientes de Google. Para Algocym la configuración del servidor en la nube se realizó en el sistema operativo Linux

Ubuntu 20.04, cuya configuración se presenta en la tabla 24. La contratación del servicio fue de 600 dólares.

Tabla 24

Configuración del servidor en la nube

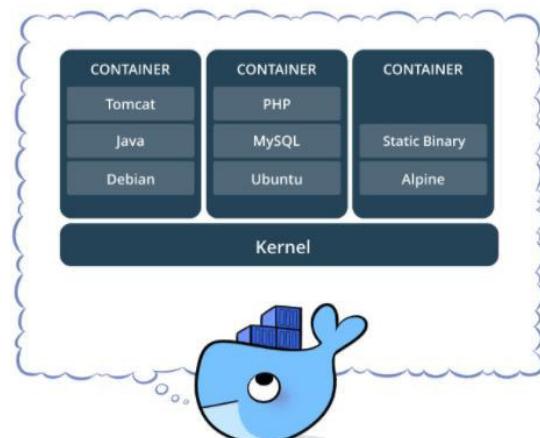
Descripción	Cantidad
CPU virtuales	96
Memoria RAM virtual	360 GB
Disco duro virtual	640 GB

Fuente: elaboración propia

Para que la configuración señalada pueda plasmarse correctamente en Linux fue necesario utilizar los servicios de Docker que es un software de código abierto que facilita la migración y garantiza el funcionamiento correcto en cuanto a dependencias entre las distintas versiones de software de los servidores (host) involucrados en el proyecto (Docker, 2021). La figura 53 ilustra de modo gráfico el concepto de Docker en el entorno Linux.

Figura 53

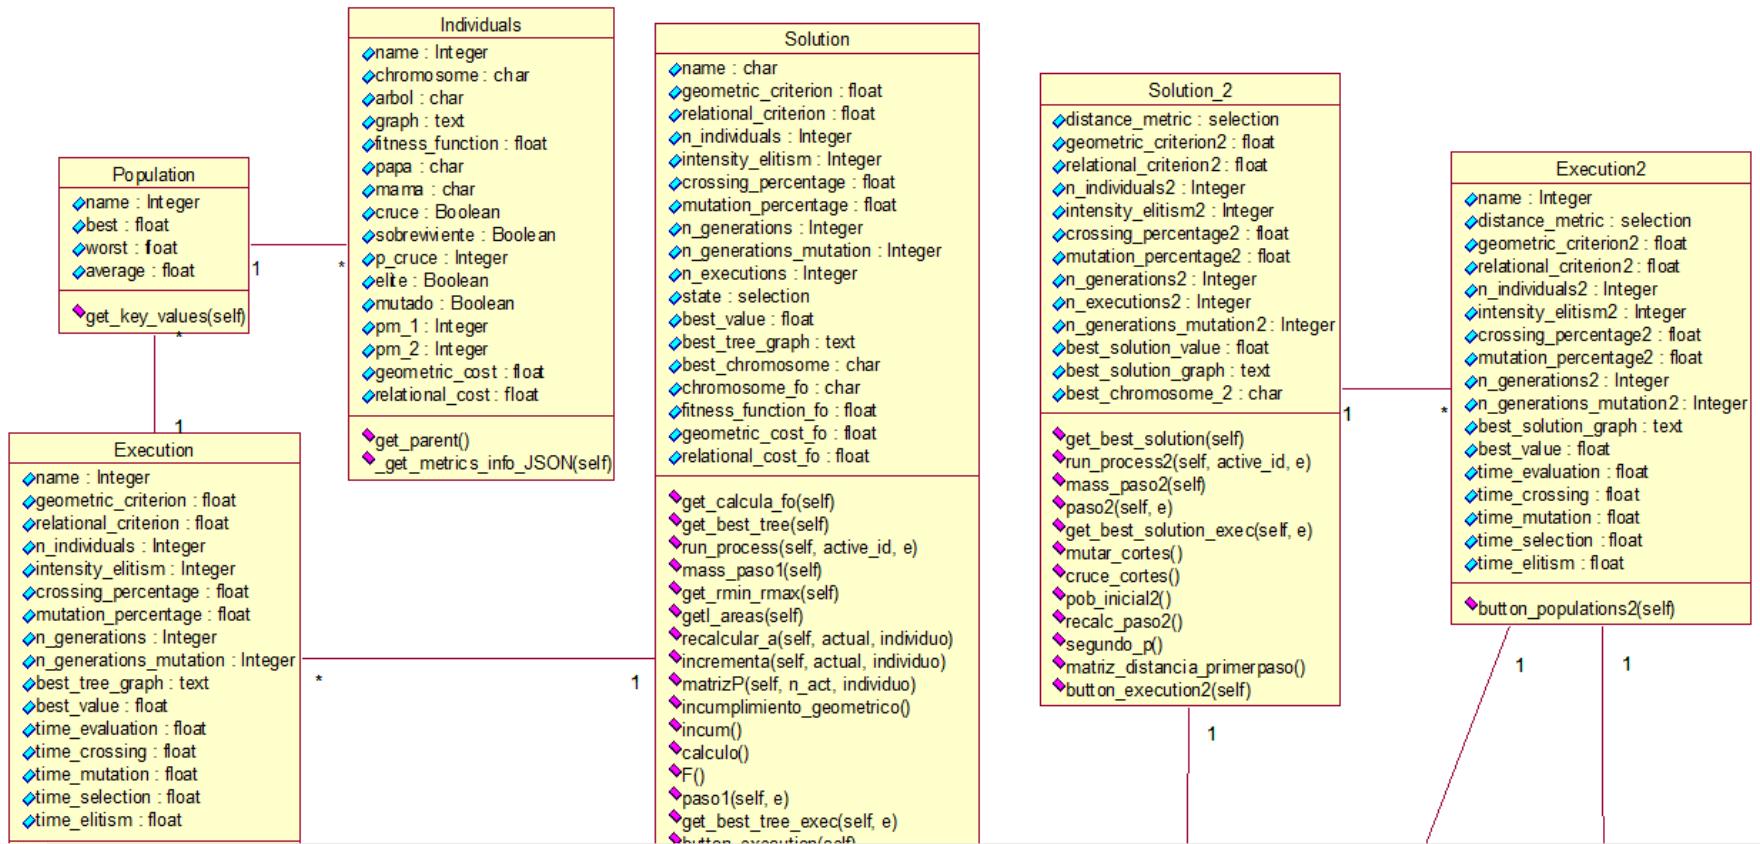
Modelo conceptual de los servicios Docker en Linux



Fuente: (Docker, 2021)

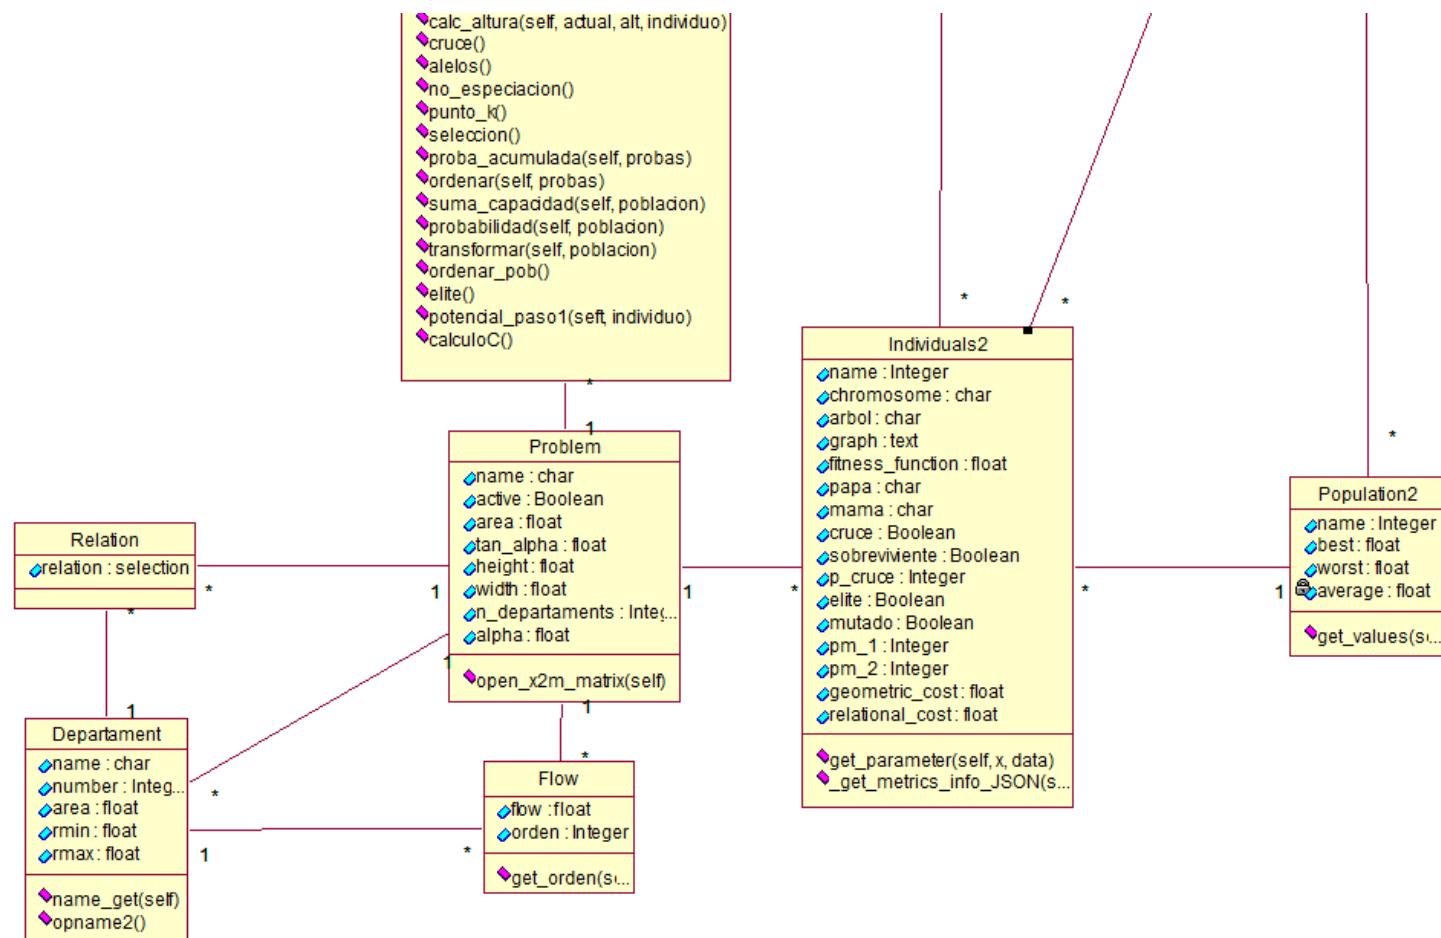
Adicionalmente con Docker se garantiza la portabilidad de la aplicación hacia el sistema operativo Windows, una vez completada la ejecución.

Para dar cumplimiento del objetivo 3 referido al diseño de la aplicación las figura 54 (parte 1 y parte 2) presenta el diagrama de clases UML creado para la implementación de Algocym. Es pertinente indicar que el diagrama de clases UML permite también representar la base de datos creada para Algocym.

Figura 54*Diagrama de clases UML para ALGOCYMYM (parte 1)*

Fuente: elaboración propia

Figura 54
Diagrama de clases UML para ALGOCYM (parte 2)



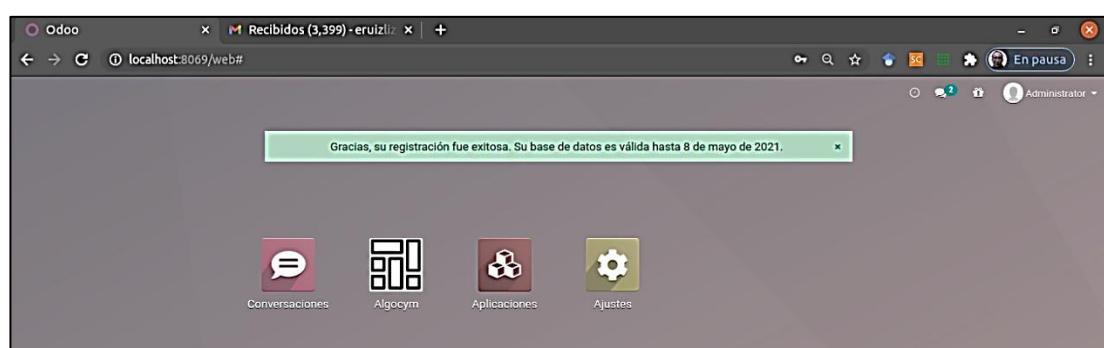
Fuente: elaboración propia

3.13 Detalles del uso de la aplicación

En las siguientes líneas se describe el uso de la aplicación informática denominada Algocym, explicando los pasos 1 y 2 para la ejecución. Al desplegar la aplicación en el navegador de Google; con el URL <http://localhost:8069/> que ha sido configurado para activar los servicios de Docker y correr Odoo en el servidor local (local host). Luego entonces, se activa la aplicación Algocym, tal como se puede apreciar en la figura 55.

Figura 55

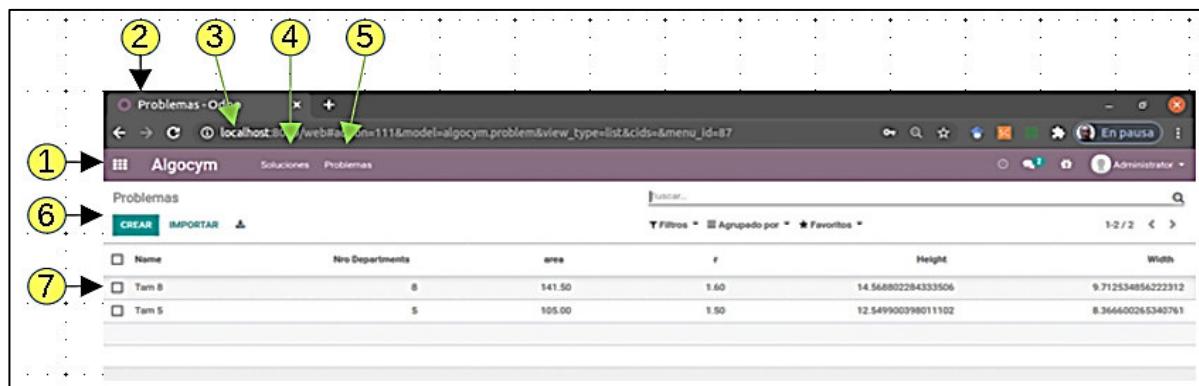
La aplicación Algocym



Fuente: elaboración propia sobre Odoo.

3.13.1 Ingreso de datos – Paso 1

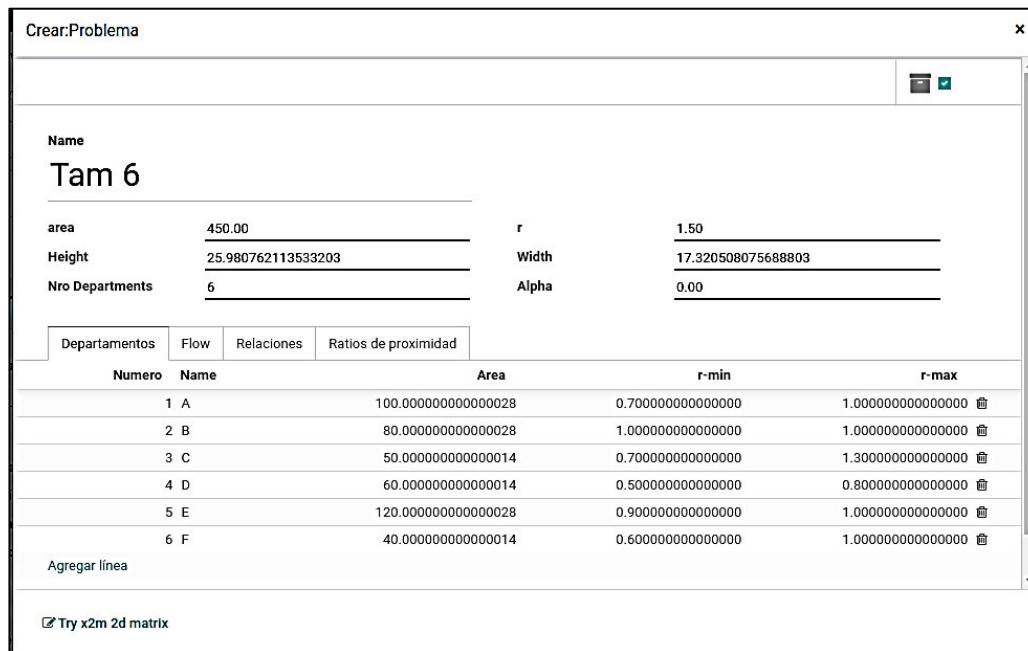
Para el diseño de la aplicación se considera que sea minimalista y sencilla; es decir que tenga lo necesario para dar funcionalidad a la aplicación. En la figura 56 se tiene los detalles iniciales. La leyenda describe sus componentes.

Figura 56*Detalles iniciales de la aplicación Algocym**Fuente: elaboración propia.*

Leyenda para la figura 56:

1. Ventana principal del módulo Algocym.
2. Applet donde se presenta el módulo para Odoo.
3. URL donde se ubica la página web para el módulo Algocym.
4. Pestaña de soluciones (se incrementa en tanto se define un problema).
5. Pestaña de problemas, aquí es donde se crea un problema o caso.
6. Botón crear, permite crear un nuevo problema.
7. Listado de problemas creados en el módulo.

Haciendo clic en el botón Crear se presenta un cuadro de dialogo que permite ingresar los datos básicos de un nuevo problema. Para el nuevo problema Ingresar: nombre, área total, ratio (alto/ancho), altura total, ancho total, número de instalaciones o departamentos, el valor de Alpha o ángulo de giro para los departamentos (0° a 90°) en caso de dejar en 0° se considera libre o flexible. Ver figura 57.

Figura 57*Caja de dialogo Crear Problema**Fuente: elaboración propia.*

Tal y como se observa en la figura 57, para la pestaña departamentos, se puede encontrar 5 columnas: Número, Nombre, Área, r-min, r-max. Estos datos se ingresan para cada instalación o departamento. Los valores de r-min y r-max; representan las ratios (alto/ancho) mínimo y máximo permitidos para cada instalación, estos datos son proporcionados en la definición de un problema FLP.

Una vez ingresados los datos de cada departamento, lo siguiente es realizar el ingreso de la matriz de flujos asociada entre departamentos. De manera similar al punto anterior, estos datos se ingresan línea a línea, ver la figura 58. Es pertinente recordar que no existe flujo así mismo en un departamento; en ese sentido la aplicación informática está codificada para aceptar el valor de 0 para un flujo inexistente y/o prohibitivo. Es necesario aclarar que se ingresan tanto el flujo desde la instalación y hacia la instalación j ; como el de la j hacia la i . En la parte inferior de la pestaña Flow se tiene el enlace a "Try x2m 2d matrix" que permite visualizar una caja de diálogo que facilita el ingreso de la matriz de flujos.

Figura 58

Ingresar matriz de flujos (pestana Flow)

The screenshot shows a software interface titled "Crear Problema" with a sub-tab "Flow". The problem is named "Tam 6". Parameters listed include:

- area: 450.00
- Height: 25.980762113533203
- Nro Departments: 6
- r: 1.50
- Width: 17.320508075688803
- Alpha: 0.00

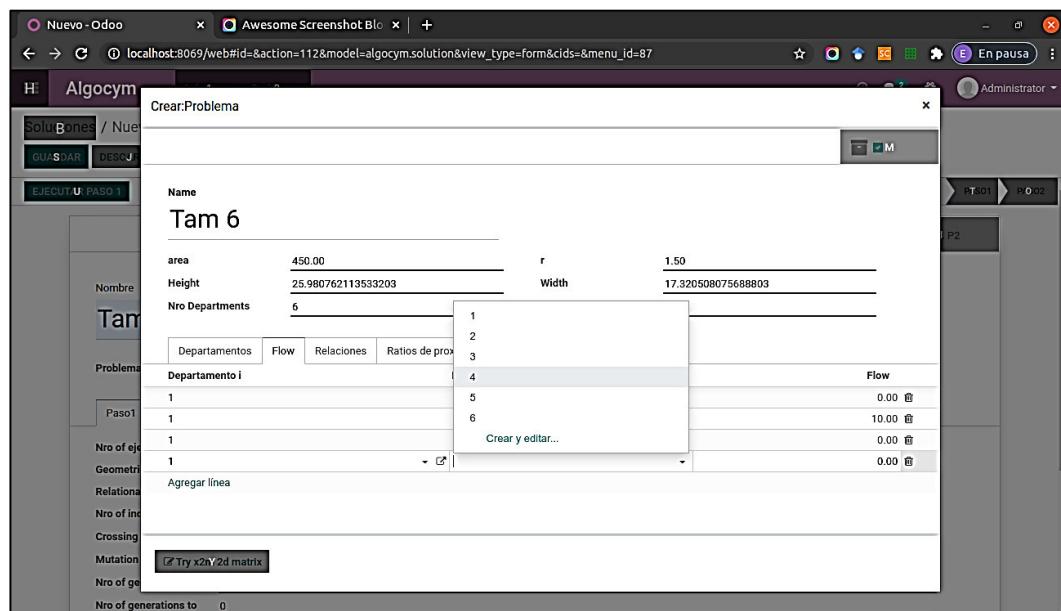
The "Flow" tab is selected, showing a table for entering flow values between departments. The table has "Departamento i" and "Departamento j" columns and a "Flow" column. Three rows are present:

Departamento i	Departamento j	Flow
1	1	0.00
1	2	10.00
1	3	0.00

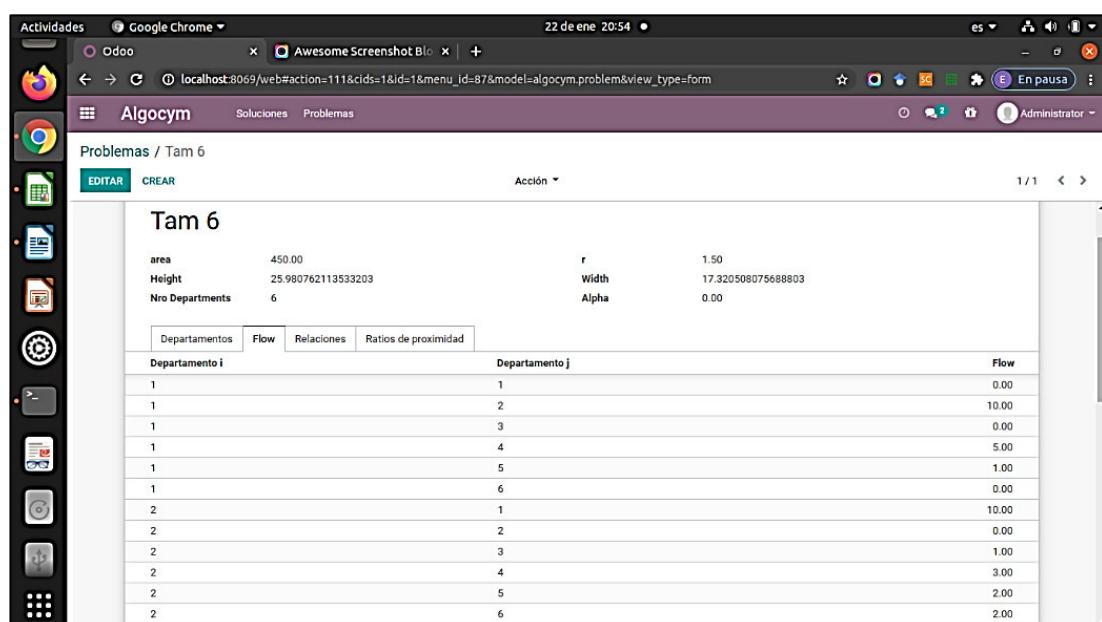
At the bottom left of the table area, there is a link "[?] Try x2m 2d matrix".

Fuente: elaboración propia.

Respecto al ingreso de la matriz de flujo; cada departamento i , y j , se selecciona de la caja de lista que se activa, puesto que estos departamentos se crearon en el paso anterior. Ver figura 59.

Figura 59*Clic en Agregar línea**Fuente: elaboración propia.*

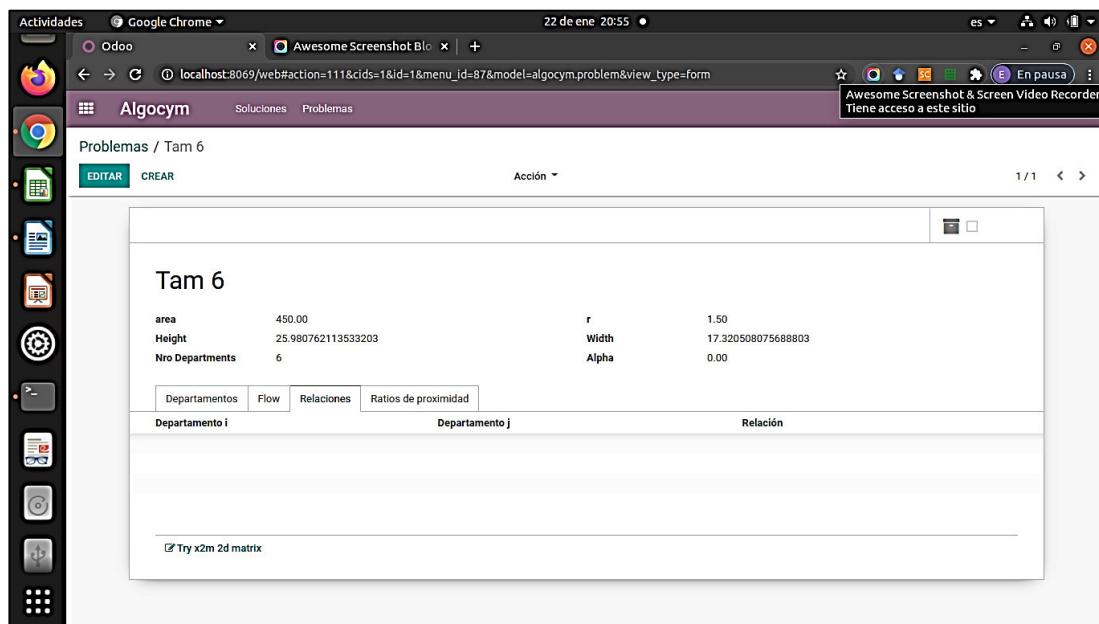
La figura 60 presenta los flujos adicionales conforme van ingresando.

Figura 60*Ingreso uno a uno en la matriz de flujos**Fuente: elaboración propia.*

La aplicación Algocym permite también el ingreso de la matriz de relaciones y/o precedencias si la formulación del problema lo requiere, ver la figura 61.

Figura 61

Pestaña establecer relaciones



Fuente: elaboración propia.

El método ALDEP (Automated Layout Design Program) establece una tabla relacional de actividades, la que a su vez ha sido obtenida del SLP (Systematic Layout Planning), esta permite establecer la cercanía (o lejanía) de una actividad con respecto a la anterior. En caso de no existir ninguno que cumpla el requisito, se selecciona la actividad o instalación siguiente de manera aleatoria. Los valores cualitativos constituyen el Total Closeness Rating (TCR). En el caso de Algocym son numéricos y se presentan en la tabla 25.

Tabla 25

Ratios de proximidad para Algocym

Nombre	Valor	Significado
A	640.0	Absolutamente necesario
E	160.0	Especialmente importante
I	40.0	Importante
O	2.0	Proximidad normal
U	0.0	Sin importancia
X	-1024.0	Indeseable

Fuente: Tomados y adaptados de (Diego-Mas, J. 2006)

La figura 62 presenta las ratios de proximidad que se utilizan en Algocym.

Figura 62

Ratios de proximidad en Algocym

The screenshot shows a Linux desktop environment with a terminal window open. The terminal window displays the command: `sudo apt-get update & sudo apt-get upgrade -y`. The background shows the Algocym application running in a browser window. The application interface includes a sidebar with icons for departments, flows, relations, and proximity ratios. The main area displays a table with departmental data and a proximity ratio table. The proximity ratio table is identical to the one shown in Table 25:

Nombre	Valor	Significado
A	640.0	Absolutamente necesario
E	160.0	Especialmente importante
I	40.0	Importante
O	2.0	Proximidad normal
U	0.0	Sin importancia
X	-1024.0	Indeseable

Fuente: Valores adaptados según (Diego-Más, J. 2006).

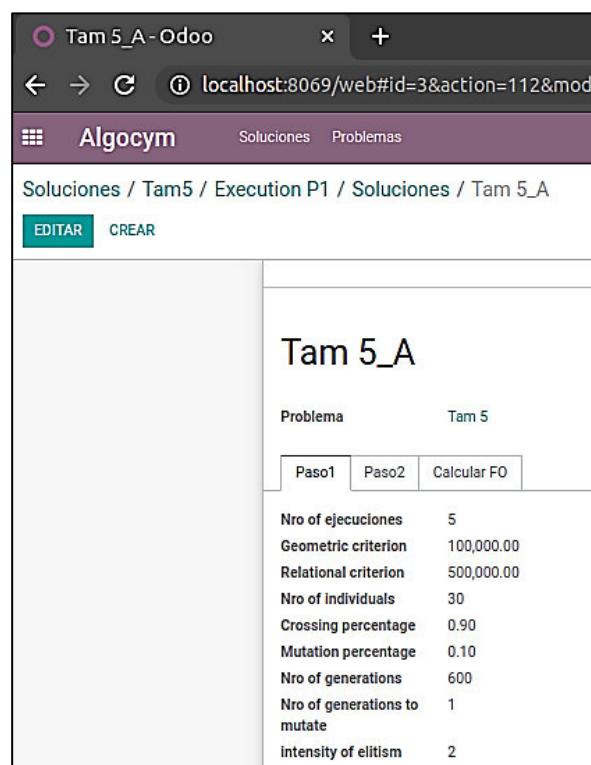
Una vez ingresados los datos de entrada, se guardan los datos del problema.

3.13.2 Ejecución de una solución

Una vez creado un problema se selecciona la opción soluciones, se elige el problema que se quiere solucionar. Haciendo clic en el botón Editar es posible activar la pestaña Paso1, que permite ingresar los datos de los parámetros requeridos para el paso 1 (ver figura 63).

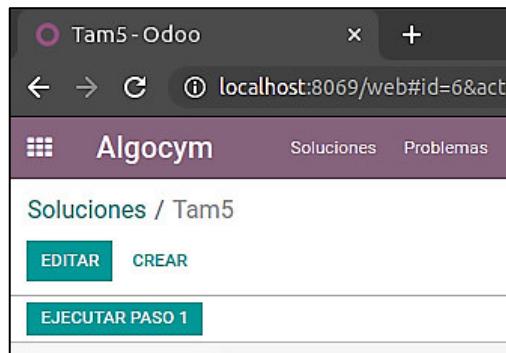
Figura 63

Ingreso de parámetros Paso 1

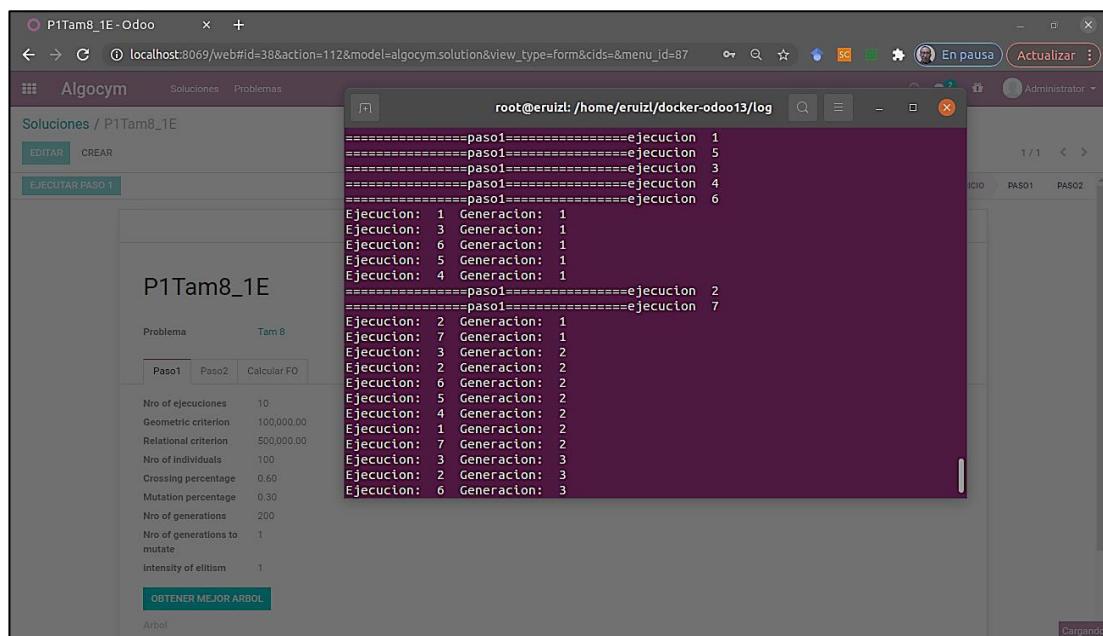


Fuente: elaboración propia.

Luego de realizar el ingreso de los parámetros del paso 1, ir al Botón Ejecutar paso 1, ver figura 64.

Figura 64*Botón Ejecutar Paso 1**Fuente: elaboración propia*

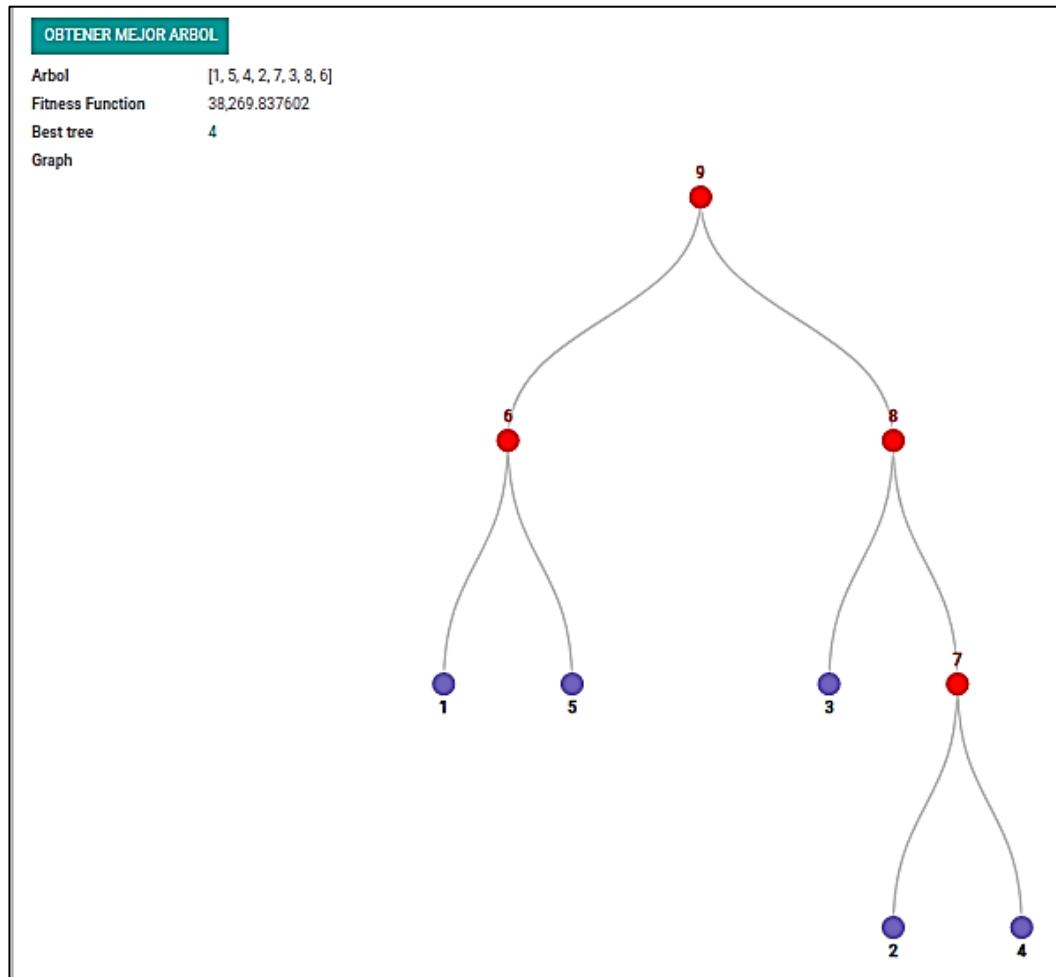
Como se puede apreciar en la figura 65, la ejecución de Algocym utiliza programación concurrente donde las corridas se realizan en paralelo; es decir varias a la vez.

Figura 65*Programación concurrente en Algocym**Fuente: elaboración propia*

Una vez terminada la ejecución del paso 1, se puede hacer clic en el botón obtener mejor árbol. La figura 66 presenta el mejor árbol para el cado de Tam con 5 departamentos.

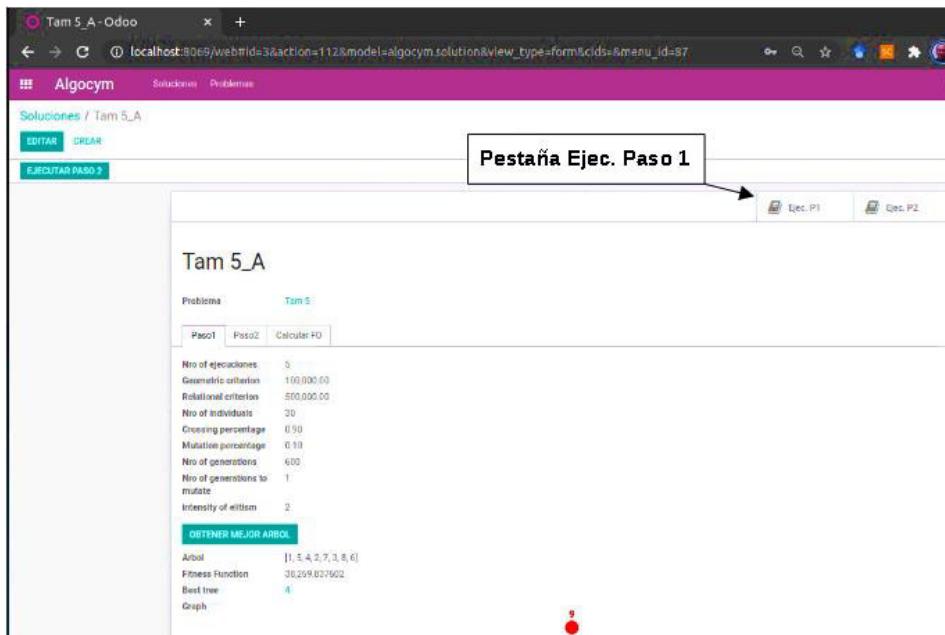
Figura 66

Botón Obtener mejor árbol



Fuente: Obtenido de Algocym

En la parte superior se encuentra las pestañas *Ejec. Paso 1* que permite examinar las ejecuciones del paso 1, ver figura 67.

Figura 67*Pestaña ejecuciones Paso 1**Fuente: elaboración propia.*

Tal como se aprecia en la figura 68, al seleccionar la pestaña Ejecuciones Paso 1, la base de datos presenta todas las ejecuciones realizadas por Algocym junto con su correspondiente porcentaje de cruce, de mutación y el valor de la función fitness encontrado por la aplicación. Por ser una base de datos las ejecuciones pueden ser ordenadas de acuerdo con el valor del Fitness function (Función de adaptación), de manera ascendente o descendente.

Figura 68*Vista de la base de datos de las ejecuciones del paso 1*

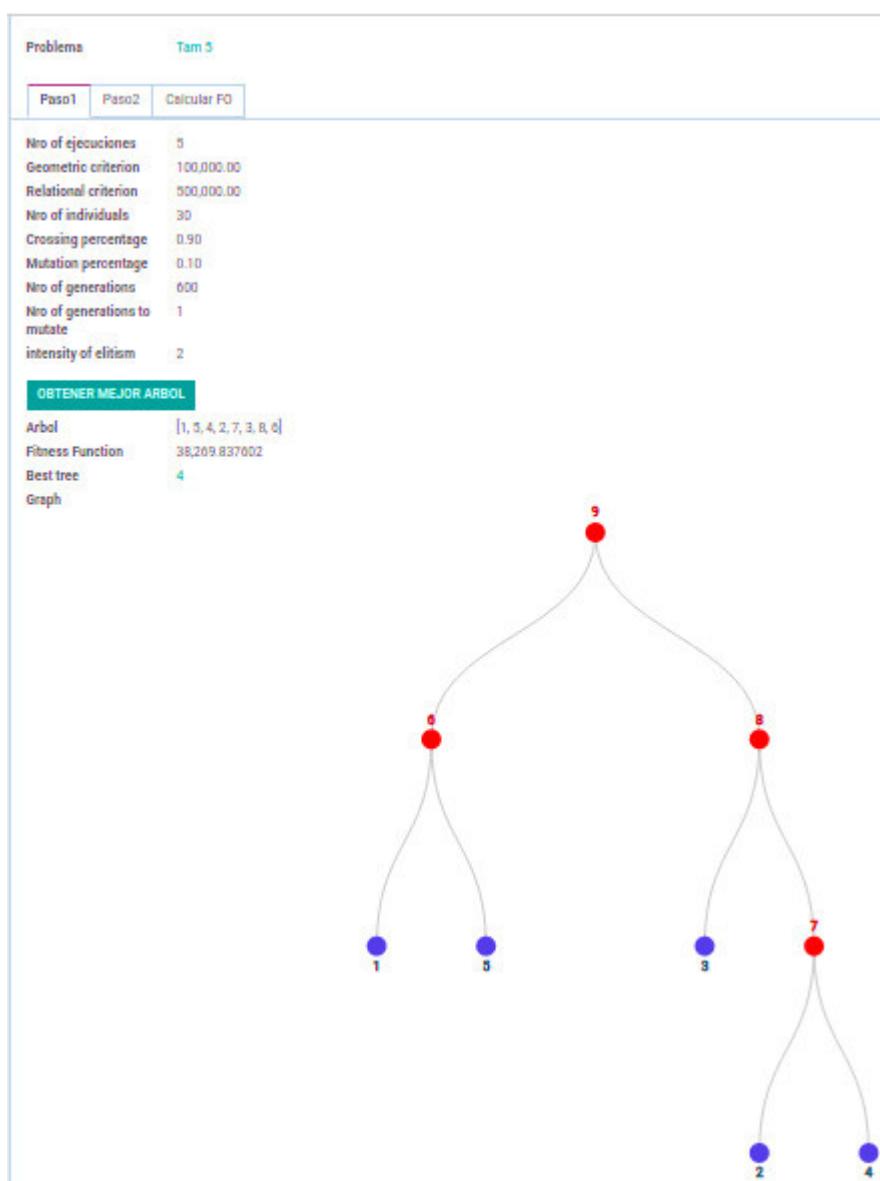
Número de Ejec.	Porcentaje de cruce	Porcentaje de mutación	Fitness function
5	0,90	0,10	38,299.837902
3	0,90	0,10	38,299.837902
2	0,90	0,10	38,299.837902
1	0,90	0,10	38,299.837902
4	0,90	0,10	38,299.837902

Fuente: obtenido por Algocym.

Haciendo clic en la primera fila de las ejecuciones del paso 1, que en este caso corresponde a la ejecución 5, se reportan los parámetros de entrada del problema, el mejor valor de la función de adaptación y los tiempos calculados con la ejecución del algoritmo. También en este caso se reporta que el mejor árbol corresponde a etiquetado, ver la figura 69.

Figura 69

Detalles de resultados de la ejecución del paso 1 para el mejor árbol

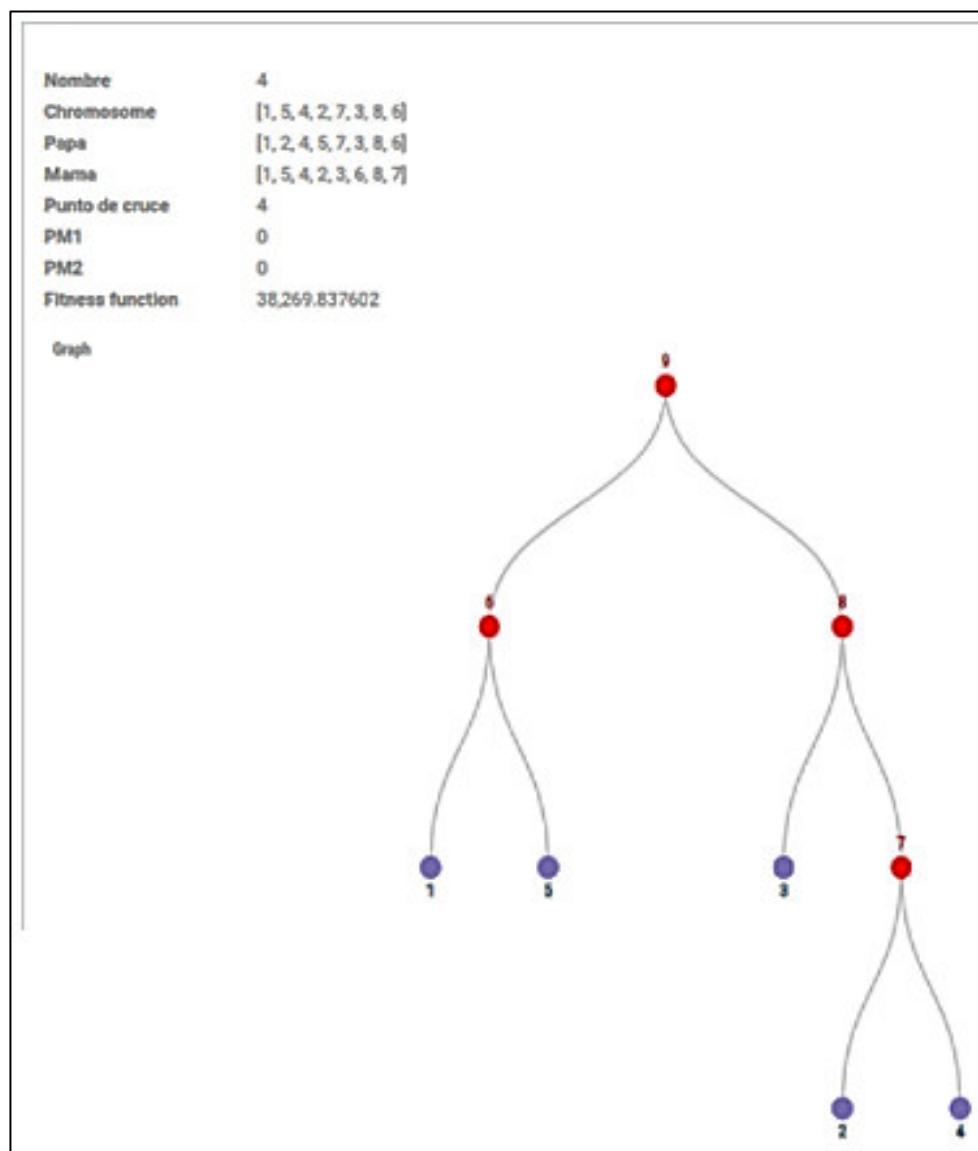


Fuente: obtenido de Algocym

El mejor árbol se etiqueta como número 4, haciendo clic en este número se obtiene los detalles del árbol. La figura 70 presenta el cromosoma que representa el árbol, el papá y la mamá que le dio origen, e punto de cruce, el punto mutado 1, punto mutado 2 (solo si existe), el valor de la función de adaptación(Fitness function) y el grafico que representa el árbol de cortes.

Figura 70

Conformación del mejor árbol de cortes



Fuente: obtenido de Algocym

Adicionalmente, tal como se puede apreciar en la figura 71, la aplicación creada también reporta los detalles del árbol y su conformación. Se presenta el detalle final del mejor árbol de cortes: El agrupamiento (clúster), el estado (0 para un nodo del tipo instalación o departamento, 1 para otro caso, la altura, dimensión mínima, área, coordenadas (x, y) de la esquina superior izquierda, el grado de incumplimiento (en el óptimo debe ser 0.0), el tipo de corte, el nodo que está a la izquierda y el de la derecha y el área asignada al departamento establecida en la definición del problema. Es pertinente indicar que estos valores se muestran de acuerdo con que el clúster se refiere a una instalación o a otro nodo.

Figura 71

Detalles finales del mejor árbol de cortes

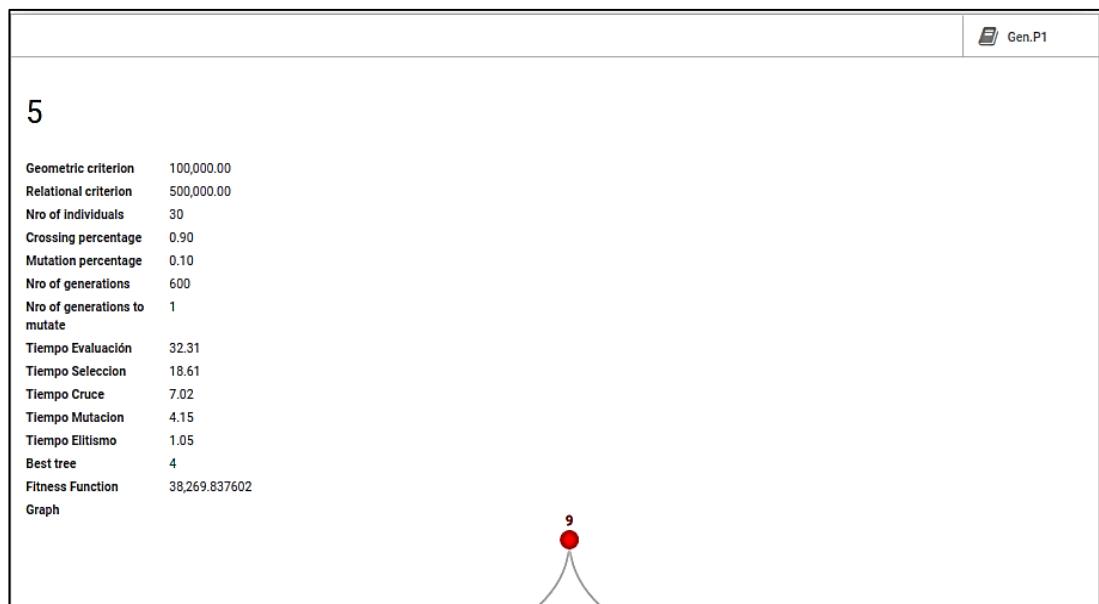
Árbol	<pre>[{"cluster": 1, "estado": 0, "altura": 2, "rmin": 0.8, "rmax": 1.0, "area": 24.000000000000007, "esquinas": [4.780914437337573, 5.856620185738529], "incum": 0.0, "lados": [3.5856858280031823, 6.693280212272604], "puntos": [6.5737573513391645, 9.20326029187483]}, {"cluster": 2, "estado": 0, "altura": 3, "rmin": 0.75, "rmax": 1.15, "area": 16.000000000000004, "esquinas": [1.5936381457791913, 7.5299402388066765], "incum": 0.0, "lados": [3.187276291558382, 5.019960159204456], "puntos": [3.1872762915583825, 10.039920318408905]}, {"cluster": 3, "estado": 0, "altura": 2, "rmin": 0.6, "rmax": 1.850000000000001, "area": 36.000000000000001, "esquinas": [0.0, 0.0], "incum": 0.0, "lados": [4.780914437337573, 7.5299402388066765], "puntos": [2.3904572186687867, 3.7649701194033383]}, {"cluster": 4, "estado": 0, "altura": 3, "rmin": 0.3, "rmax": 1.1, "area": 8.000000000000002, "esquinas": [0.0, 7.5299402388066765], "incum": 0.0, "lados": [1.5936381457791913, 5.019960159204456], "puntos": [0.7968190728895956, 10.039920318408905]}, {"cluster": 5, "estado": 0, "altura": 2, "rmin": 0.9, "rmax": 1.18, "area": 21.000000000000007, "esquinas": [4.780914437337573, 0.0], "incum": 0.0, "lados": [3.5856858280031823, 5.856620185738529], "puntos": [6.5737573513391645, 2.9283100928692645]}, {"cluster": 6, "estado": 1, "altura": 1, "incum": 0.0, "corte": 0, "izq": 1, "der": 5, "area": 45.00000000000014}, {"cluster": 7, "estado": 1, "altura": 2, "incum": 0.0, "corte": 1, "izq": 4, "der": 2, "area": 24.000000000000007}, {"cluster": 8, "estado": 1, "altura": 1, "incum": 0.0, "corte": 0, "izq": 7, "der": 3, "area": 60.00000000000014}, {"cluster": 9, "estado": 1, "altura": 0, "incum": 0.13767540511760695, "corte": 1, "izq": 8, "der": 6, "area": 105.000000000000003}]}</pre>
-------	---

Fuente: obtenido de Algocym

Tal como se puede ver en la figura 72, para la ejecución 5, mostrada en las figuras 69,70 y 71, se presenta la información completa la información relativa a los parámetros de entrada y los tiempos de ejecución: tiempo de evaluación de la función de adaptación, de selección, de cruce, mutación y elitismo. También se presenta el número que corresponde al mejor árbol, el valor del Función de Adaptación y el gráfico del árbol.

Figura 72

Parámetros de entrada y los tiempos del algoritmo en el paso 1



Fuente: obtenido de Algocym

Tal como se aprecia en la figura 73 se puede apreciar que en la esquina superior derecha se tiene acceso a ver y examinar todas las generaciones realizadas para esta ejecución.

En la figura 74 se muestran todas las generaciones realizadas por el algoritmo Algocym, en la ejecución número 5 (paso 1); la ejecución a la que corresponden, y los valores *Best* (Mejor), *Worst* (Peor) y *Average* (Promedio) de cada generación. Dado que estos resultados se guardan en una base de datos, cada una de estas tres últimas columnas pueden ordenarse.

Por tratarse de una base de datos es posible exportar los datos de cada ejecución a una hoja de cálculo de Excel, o Calc. Esto es especialmente importante para analizar la evolución de las generaciones en el momento que el analista así lo considere, ver la figura 75.

Figura 73

Vista de la base de datos de las ejecuciones en el paso 1

	Nro of Generation	Ejecucion	Best	Worst	Average
	1	5	39,244,864821	146,751,525461	80,045,230849
	2	5	39,244,864821	141,351,913141	62,105,258566
	3	5	39,244,864821	104,037,022760	53,871,296151
	4	5	38,269,837602	75,007,415239	46,419,828487
	5	5	38,269,837602	59,898,065515	46,333,747260
	6	5	38,269,837602	67,415,563878	43,026,035852
	7	5	38,269,837602	104,831,546828	45,502,464815
	8	5	38,269,837602	56,241,906017	42,933,625191
	9	5	38,269,837602	62,837,388869	42,201,592942
	10	5	38,269,837602	84,245,910947	43,465,727917
	11	5	38,269,837602	139,704,428122	46,046,358768
	12	5	38,269,837602	67,415,563878	40,478,622520
	13	5	38,269,837602	98,587,085832	41,538,601079
	14	5	38,269,837602	138,155,555093	43,035,705465
	15	5	38,269,837602	97,089,338522	41,487,455493
	16	5	38,269,837602	97,089,338522	43,333,489098
	17	5	38,269,837602	64,869,041047	40,398,123067
	18	5	38,269,837602	138,155,555093	42,928,543142
	19	5	38,269,837602	50,584,236383	40,445,479044
	20	5	38,269,837602	138,155,555093	43,361,510346
	21	5	38,269,837602	137,336,180650	43,564,556819

Fuente: obtenido de Alcocym.

Figura 74

Exportando los datos de una generación hacia una hoja de cálculo

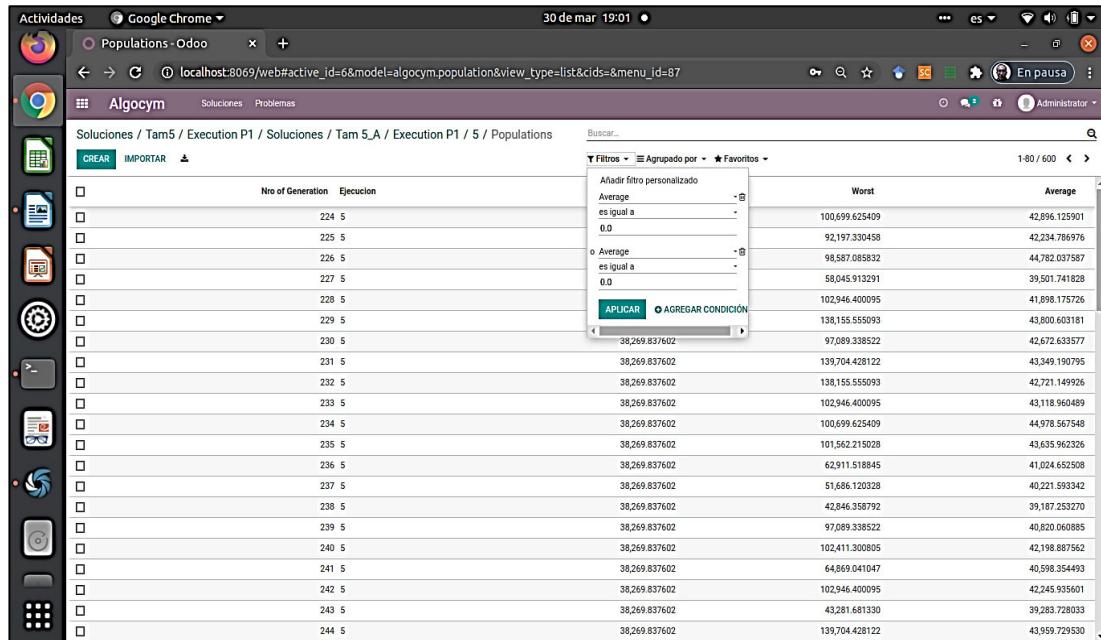
	Nro of Generation	Ejecucion	Best	Worst	Average
	224	5	38,269,837602	100,699,625409	42,896,125901
	225	5	38,269,837602	92,197,330458	42,234,786976
	226	5	38,269,837602	98,587,085832	44,782,037587
	227	5	38,269,837602	58,045,913291	39,501,741828
	228	5	38,269,837602	102,946,400095	41,898,175726
	229	5	38,269,837602	138,155,555093	43,800,603181
	230	5	38,269,837602	97,089,338522	42,672,633577
	231	5	38,269,837602	139,704,428122	43,349,190795
	232	5	38,269,837602	138,155,555093	42,721,149926
	233	5	38,269,837602	102,946,400095	43,118,960489
	234	5	38,269,837602	100,699,625409	44,978,567548
	235	5	38,269,837602	101,562,215028	43,635,962326
	236	5	38,269,837602	62,911,518845	41,024,652508
	237	5	38,269,837602	51,686,120328	40,221,593342
	238	5	38,269,837602	42,846,358792	39,187,253270
	239	5	38,269,837602	97,089,338522	40,820,060885
	240	5	38,269,837602	102,411,300805	42,198,887562
	241	5	38,269,837602	64,869,041047	40,598,354493
	242	5	38,269,837602	102,946,400095	42,245,935601
	243	5	38,269,837602	43,281,681330	39,283,728033
	244	5	38,269,837602	139,704,428122	43,959,729530

Fuente: obtenido de Algocym

La figura 76 y 77 muestra la posibilidad de aplicar filtros y agrupar los resultados de una generación.

Figura 75

Aplicando filtros para una determinada generación



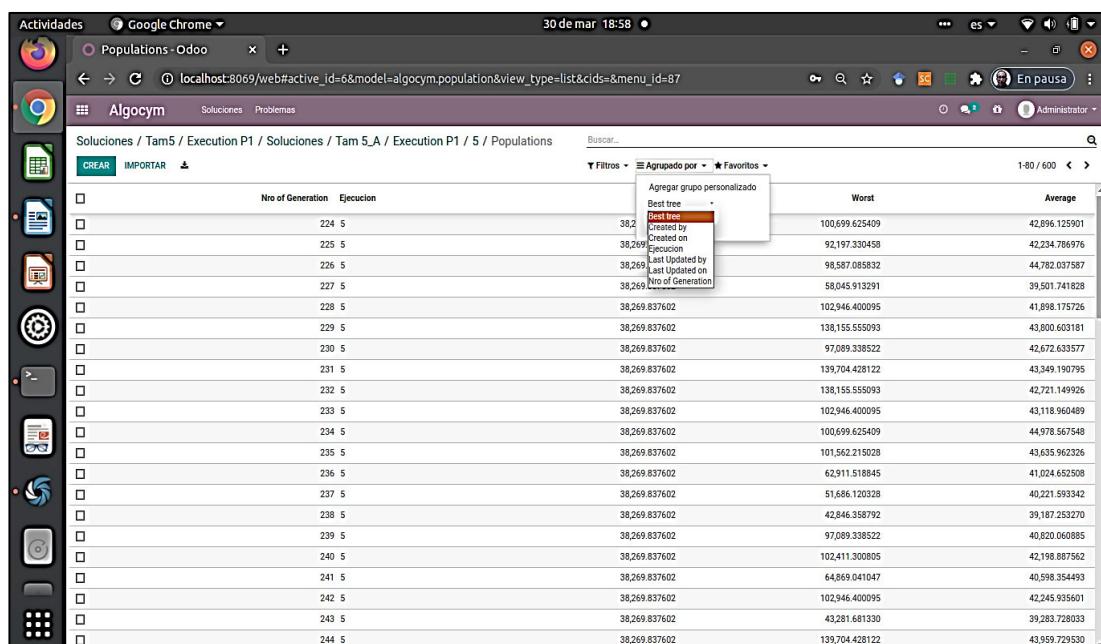
The screenshot shows a table of generation results. A filter dialog is open, showing two conditions: 'Average' and 'es igual a' (is equal to) '0.0'. The 'APLICAR' (Apply) button is highlighted. The table has columns 'Nro of Generation' and 'Ejecución'. The results are sorted by 'Worst' and 'Average'.

Nro of Generation	Ejecución	Worst	Average
224	5	100,699,625409	42,896,125901
225	5	92,197,330458	42,234,786976
226	5	98,587,085832	44,782,037587
227	5	58,045,913291	39,501,741828
228	5	102,946,400095	41,898,175726
229	5	138,155,555093	43,800,603181
230	5	97,089,338522	42,672,633577
231	5	139,704,428122	43,349,190795
232	5	138,155,555093	42,721,149926
233	5	102,946,400095	43,118,960489
234	5	100,699,625409	44,978,567548
235	5	101,562,215028	43,635,962326
236	5	62,911,518845	41,024,652508
237	5	51,686,120328	40,221,593342
238	5	42,846,358792	39,187,253270
239	5	97,089,338522	40,820,060885
240	5	102,411,300805	42,198,887562
241	5	64,869,041047	40,598,354493
242	5	102,946,400095	42,245,935601
243	5	43,281,681330	39,283,728033
244	5	139,704,428122	43,959,729530

Fuente: obtenido de Algocym

Figura 76

Agrupando los resultados de una generación



The screenshot shows a table of generation results. A group dialog is open, showing 'Best tree' selected. The table has columns 'Nro of Generation' and 'Ejecución'. The results are grouped by 'Best tree' and sorted by 'Worst' and 'Average'.

Nro of Generation	Ejecución	Best tree	Worst	Average
224	5	100,699,625409	42,896,125901	
225	5	92,197,330458	42,234,786976	
226	5	98,587,085832	44,782,037587	
227	5	58,045,913291	39,501,741828	
228	5	102,946,400095	41,898,175726	
229	5	138,155,555093	43,800,603181	
230	5	97,089,338522	42,672,633577	
231	5	139,704,428122	43,349,190795	
232	5	138,155,555093	42,721,149926	
233	5	102,946,400095	43,118,960489	
234	5	100,699,625409	44,978,567548	
235	5	101,562,215028	43,635,962326	
236	5	62,911,518845	41,024,652508	
237	5	51,686,120328	40,221,593342	
238	5	42,846,358792	39,187,253270	
239	5	97,089,338522	40,820,060885	
240	5	102,411,300805	42,198,887562	
241	5	64,869,041047	40,598,354493	
242	5	102,946,400095	42,245,935601	
243	5	43,281,681330	39,283,728033	
244	5	139,704,428122	43,959,729530	

Fuente: obtenido de Algocym

Respecto a la generación 222 (presentada en la figura 74) es posible mostrar y ordenar los individuos de esta generación. Las figuras 77, 78, y 79 se presentan estos resultados. Se puede analizar el detalle del comportamiento de los 30 individuos en esta generación.

Figura 77

Generación 222 del paso 1 (parte 1)

Nombre	Chromosome	Fitness function	Costo geométrico	Costo relacional	Elite	Cruce	Punto de cruce	Mutado	PM1	PM2
1 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	0 <input type="checkbox"/>	<input type="checkbox"/>	4	5
2 [1, 5, 4, 2, 7, 3, 8, 6]	38,269,837602	13,767,540512	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	0 <input type="checkbox"/>	<input type="checkbox"/>	0	0
3 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
4 [1, 5, 4, 2, 7, 3, 8, 6]	38,269,837602	13,767,540512	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
5 [1, 5, 4, 2, 7, 3, 8, 6]	38,269,837602	13,767,540512	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
6 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
7 [4, 1, 2, 5, 3, 7, 8, 6]	43,281,681330	19,275,679830	24,006,001500	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
8 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
9 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
10 [1, 5, 4, 2, 3, 7, 8, 6]	38,269,837602	13,767,540512	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
11 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	2 <input type="checkbox"/>	<input type="checkbox"/>	0	0
12 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	2 <input type="checkbox"/>	<input type="checkbox"/>	0	0
13 [1, 5, 4, 2, 3, 7, 8, 6]	38,269,837602	13,767,540512	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
14 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
15 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
16 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
17 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
18 [1, 5, 4, 2, 3, 7, 8, 6]	62,837,388669	39,914,752765	22,922,636103	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	3	5
19 [5, 3, 2, 1, 4, 7, 8, 6]	39,850,453176	14,742,567731	25,107,885445	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	2 <input type="checkbox"/>	<input type="checkbox"/>	4	3
20 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	2 <input type="checkbox"/>	<input type="checkbox"/>	0	0
21 [4, 1, 2, 5, 3, 7, 8, 6]	43,281,681330	19,275,679830	24,006,001500	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
22 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
23 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
24 [1, 5, 4, 2, 3, 7, 8, 6]	38,269,837602	13,767,540512	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
25 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
26 [4, 1, 2, 5, 3, 7, 8, 6]	43,281,681330	19,275,679830	24,006,001500	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
27 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	2 <input type="checkbox"/>	<input type="checkbox"/>	0	0
28 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	2 <input type="checkbox"/>	<input type="checkbox"/>	0	0
29 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	0 <input type="checkbox"/>	<input type="checkbox"/>	0	0
30 [4, 1, 2, 5, 3, 7, 8, 6]	43,281,681330	19,275,679830	24,006,001500	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	0 <input type="checkbox"/>	<input type="checkbox"/>	0	0

Fuente: obtenido de Algocym

Figura 78

Generación 222 del paso 1 (parte 2)

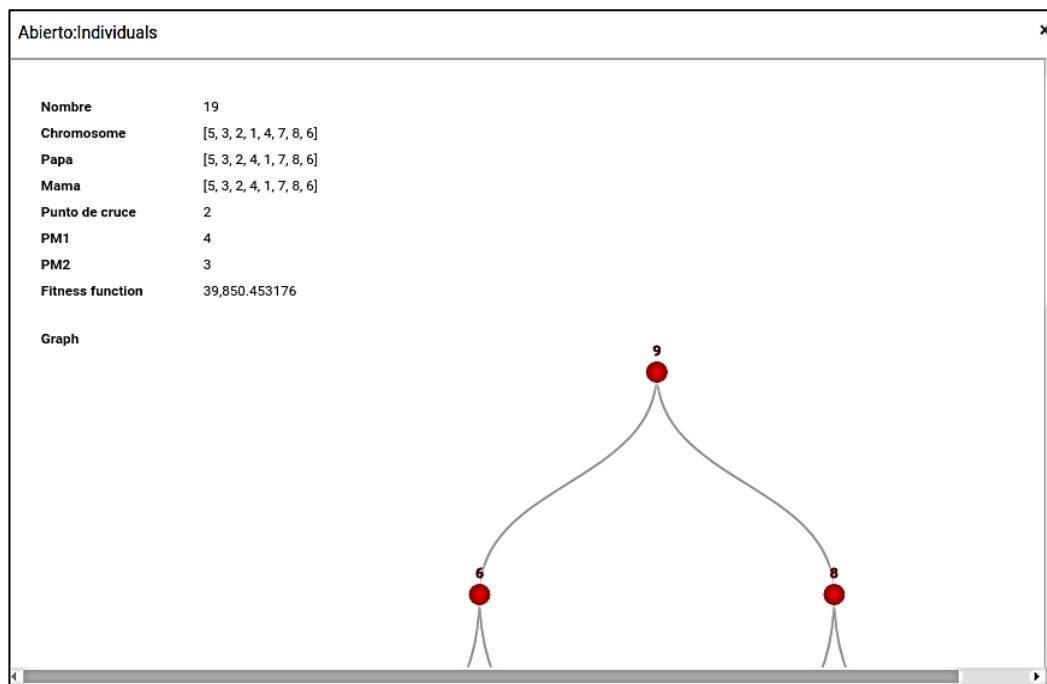
Nombre	Chromosome	Fitness function	Costo geométrico	Costo relacional	Elite	Cruce	Punto de cruce	Mutado	PM1	PM2
12 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	2 <input type="checkbox"/>	<input type="checkbox"/>	0	0
13 [1, 5, 4, 2, 3, 7, 8, 6]	38,269,837602	13,767,540512	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
14 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
15 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
16 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
17 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
18 [1, 5, 4, 2, 3, 7, 8, 6]	62,837,388669	39,914,752765	22,922,636103	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	3	5
19 [5, 3, 2, 1, 4, 7, 8, 6]	39,850,453176	14,742,567731	25,107,885445	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	2 <input type="checkbox"/>	<input type="checkbox"/>	4	3
20 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	2 <input type="checkbox"/>	<input type="checkbox"/>	0	0
21 [4, 1, 2, 5, 3, 7, 8, 6]	43,281,681330	19,275,679830	24,006,001500	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
22 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
23 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
24 [1, 5, 4, 2, 3, 7, 8, 6]	38,269,837602	13,767,540512	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
25 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
26 [4, 1, 2, 5, 3, 7, 8, 6]	43,281,681330	19,275,679830	24,006,001500	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	6 <input type="checkbox"/>	<input type="checkbox"/>	0	0
27 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	2 <input type="checkbox"/>	<input type="checkbox"/>	0	0
28 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	2 <input type="checkbox"/>	<input type="checkbox"/>	0	0
29 [5, 3, 2, 4, 1, 7, 8, 6]	39,244,864821	14,742,567731	24,502,297090	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	0 <input type="checkbox"/>	<input type="checkbox"/>	0	0
30 [4, 1, 2, 5, 3, 7, 8, 6]	43,281,681330	19,275,679830	24,006,001500	<input type="checkbox"/>	<input type="checkbox"/>	<input type="checkbox"/>	0 <input type="checkbox"/>	<input type="checkbox"/>	0	0

Fuente: obtenido de Algocym

Respecto a los resultados presentados en la figura 78, haciendo clic en uno de ellos por ejemplo el 19, nos presenta sus detalles. Ver la figura 80.

Figura 79

Detalles del individuo 19 de la generación 222



Fuente: obtenido de Algocym

3.13.3 Ingreso de datos – Paso 2

Tal como se presenta en la figura 80 al seleccionar la pestaña del Paso 2, luego ir al botón *Editar* para ingresar los parámetros del paso 2. Una vez ingresados los parámetros solicitados, ir al botón Guardar para salvar el paso 2.

Figura 80

Ingreso de parámetros del paso 2

The screenshot shows a web-based application window titled "Tam 5_A - Odoo". The URL is "localhost:8069/web#id=3&action=112&model=algoc". The header includes a back arrow, forward arrow, refresh button, and a help icon. Below the header is a navigation bar with "Algocym" and "Soluciones Problemas". The main content area shows the path "Soluciones / Tam5 / Execution P1 / Soluciones / Tam 5_A". There are two buttons at the top: "GUARDAR" and "DESCARTAR". A large green button labeled "EJECUTAR PASO 2" is prominently displayed. Below these buttons is a text input field containing the name "Tam 5_A". Underneath the name, there is a section for "Problema" with the value "Tam 5". A horizontal menu bar contains three items: "Paso1" (selected), "Paso2", and "Calcular FO". Below this menu is a table listing various parameters with their corresponding values:

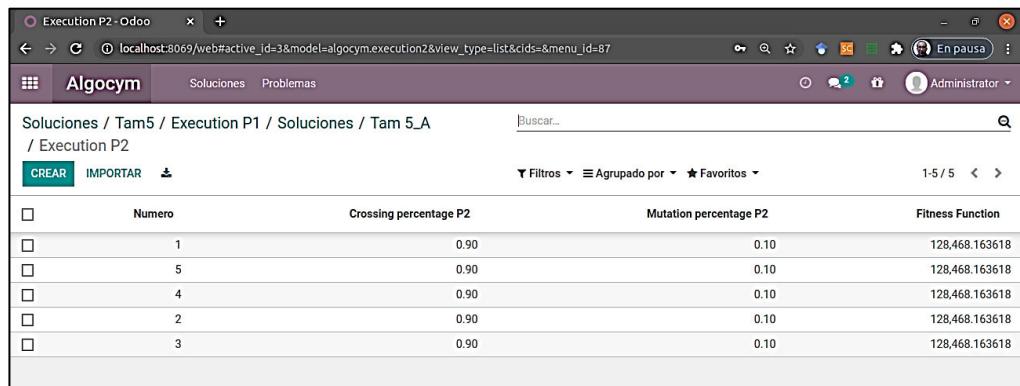
Nro of ejecuciones P2	5
Geometric criterion	100,000.00
Relational criterion	0.10
Nro of individuals P2	30
Crossing percentage P2	0.90
Mutation percentage P2	0.10
Nro of generations P2	300
Nro of generations to mutate P2	1
Distance metric	Euclides
Intensity of elitism P2	2

Fuente: obtenido de Algocym

Luego ir al botón *Ejecutar paso 2* (presentado en la figura 80). Una vez terminada la ejecución del paso 2. Como se puede apreciar en la figura 81 se presentan las ejecuciones realizadas en el paso 2.

Figura 81

Ejecuciones del paso 2



The screenshot shows a web-based application window titled "Execution P2 - Odoo". The URL is "localhost:8069/web#active_id=3&model=algocym.execution2&view_type=list&cids=&menu_id=87". The title bar includes icons for back, forward, search, and refresh, along with a status message "En pausa". The main header "Algocym" has tabs for "Soluciones" and "Problemas". Below the header is a breadcrumb navigation: "Soluciones / Tam5 / Execution P1 / Soluciones / Tam 5_A / Execution P2". A toolbar with buttons "CREAR", "IMPORTAR", and a plus sign is visible. To the right are filters, grouping, and favorite options, with a page number "1-5 / 5". The main content is a table with columns: "Número", "Crossing percentage P2", "Mutation percentage P2", and "Fitness Function". The data rows are:

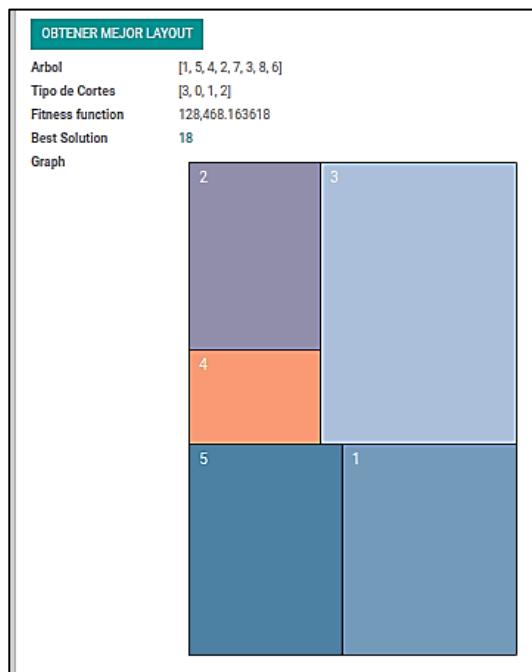
Número	Crossing percentage P2	Mutation percentage P2	Fitness Function
1	0.90	0.10	128,468.163618
5	0.90	0.10	128,468.163618
4	0.90	0.10	128,468.163618
2	0.90	0.10	128,468.163618
3	0.90	0.10	128,468.163618

Fuente: obtenido de Algocym

Seleccionando la ejecución número 1, se puede hacer clic en el botón *Obtener Mejor Layout*, (ver figura 82). Se presentará el mejor árbol, tipo de cortes para el layout, valor de la función de adaptación, la mejor solución encontrada y el grafico del layout óptimo.

Figura 82

Obteniendo el mejor layout en el paso 2

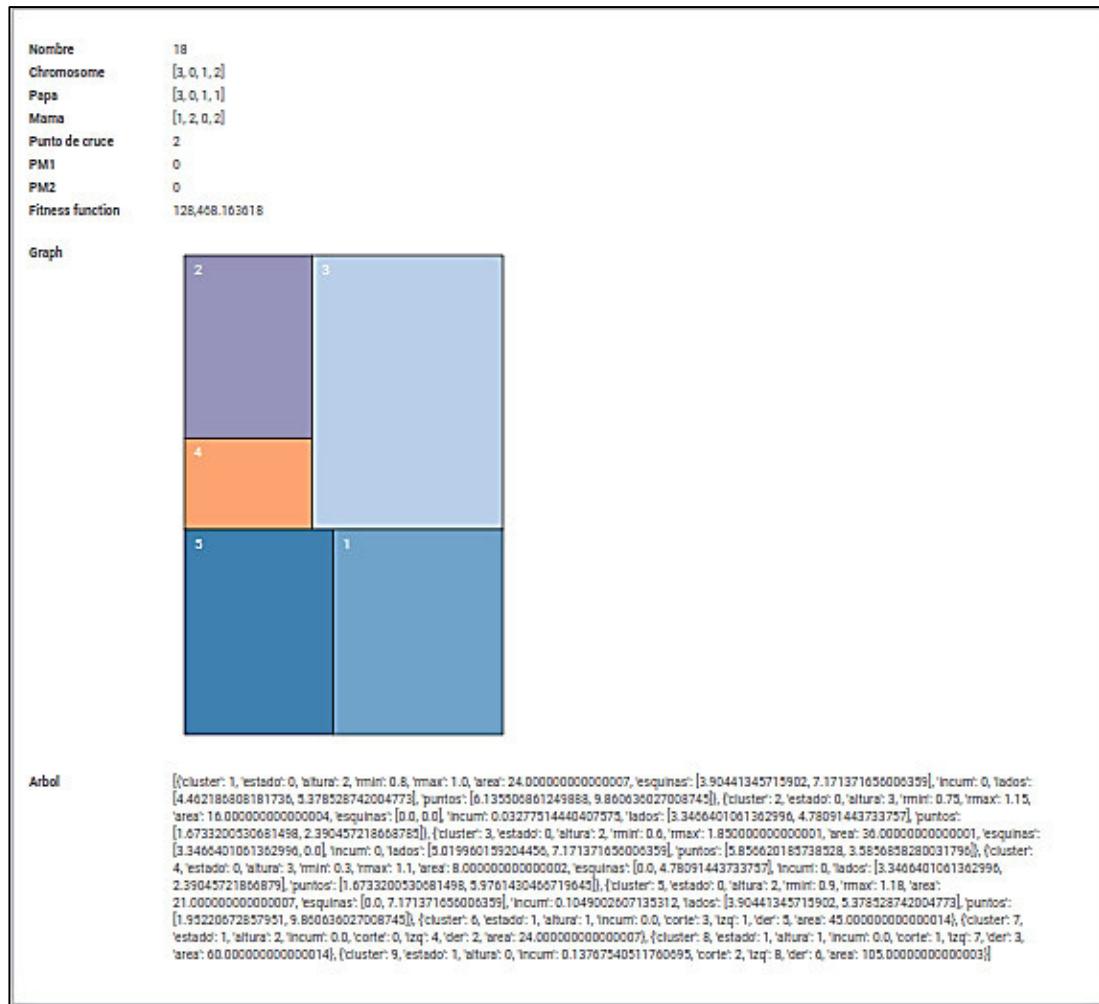


Fuente: Obtenido de Algocym.

Como se puede apreciar en la figura 83, el mejor layout es el número 18 y de manera similar al paso 1, haciendo clic en dicho número se tiene los detalles de la solución óptima: cromosoma que representa el layout, el padre y madre que le dio origen, los puntos de mutación 1 y 2, el valor de la función de adaptación, el grafico del layout óptimo y los detalles del árbol que representa el layout. Esto se presenta en la figura 84.

Figura 83

Detalles de la mejor solución del paso 2



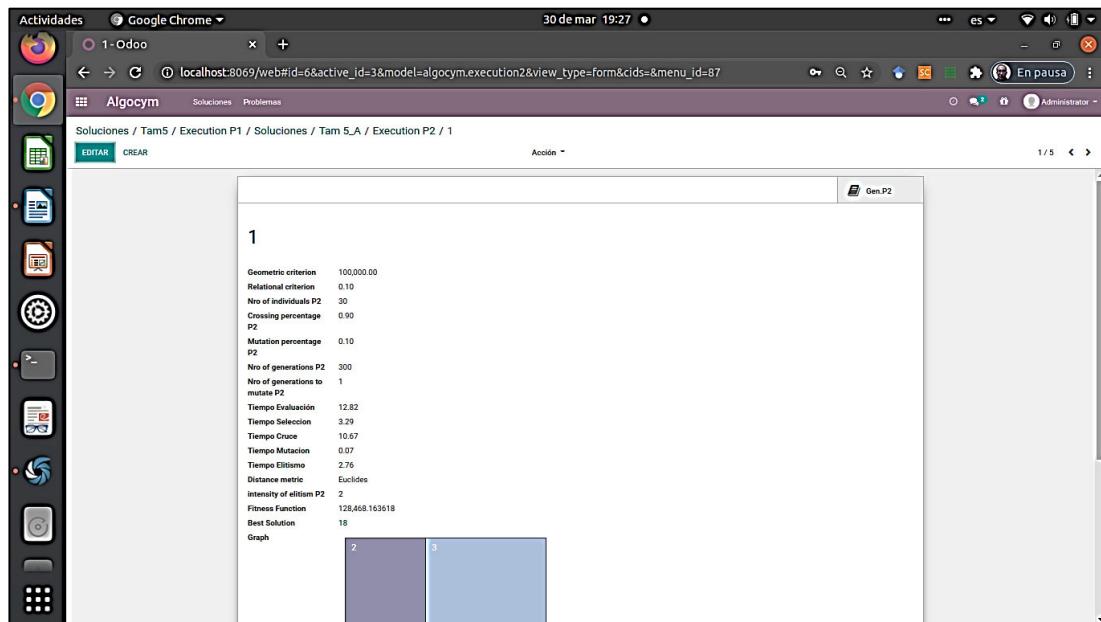
Fuente: obtenido de Algocym

Como se aprecia en la figura 84 de modo similar al paso 1, también se presenta los parámetros de entrada del paso 2, los tiempos de ejecución, selección, cruce, mutación, elitismo, la métrica utilizada (manhattan o

euclidian), intensidad de elitismo (tamaño de la elite), el valor de la función fitness, la generación donde se dio la mejor solución y el grafico del layout óptimo.

Figura 84

Resultados del paso 2



Fuente: obtenido de Algocym

En la figura 85 se muestras las generaciones del paso 2 se pueden examinar y procesar de manera similar a las del paso 1 vistas anteriormente.

En las figuras 86 y 87 se muestra que es posible ver y examinar el detalle de cada uno los 30 individuos (soluciones) encontradas por el algoritmo. Para cada individuo es posible examinar los puntos de cruce y mutación aplicados por el algoritmo. Esto puede ser especialmente útil con miras a realizar un mayor análisis y se ofrece en cumplimiento del cuarto objetivo de la presente tesis.

Figura 85

Generaciones del paso 2

Soluciones / Tam5 / Execution P1 / Soluciones / Tam 5_A / Execution P2 / 1 / Populations P2		Filtrar...			
	Nro de Generación	Solución	Best	Worst	Average
□	1	1	128,472,944939	722,259,339048	321,230,00105
□	2	1	128,468,163618	644,799,644475	237,486,614695
□	3	1	128,468,163618	342,939,389319	208,021,979173
□	4	1	128,468,163618	313,267,802229	185,944,151262
□	5	1	128,468,163618	644,798,114582	206,762,372558
□	6	1	128,468,163618	644,787,596570	203,698,284647
□	7	1	128,468,163618	722,259,339048	245,534,042944
□	8	1	128,468,163618	644,784,919258	206,404,252562
□	9	1	128,468,163618	342,938,327221	212,062,774387
□	10	1	128,468,163618	722,267,370984	184,094,937963
□	11	1	128,468,163618	342,932,044246	185,078,185123
□	12	1	128,468,163618	722,257,554173	184,499,876537
□	13	1	128,468,163618	644,784,919258	185,711,073700
□	14	1	128,468,163618	646,523,906351	166,558,668640
□	15	1	128,468,163618	644,784,919258	178,538,231325
□	16	1	128,468,163618	722,258,58165	183,020,183898
□	17	1	128,468,163618	342,939,389319	173,054,095762
□	18	1	128,468,163618	288,371,773289	149,527,986527
□	19	1	128,468,163618	193,977,025662	132,576,864847
□	20	1	128,468,163618	342,932,044246	137,541,213245
□	21	1	128,468,163618	193,083,226698	136,683,421786
□	22	1	128,468,163618	342,933,121722	195,725,425123

Fuente: obtenido de Algocym

Figura 86

Detalles de una generación en el paso 2

Soluciones / Tam5 / Execution P1 / Soluciones / Tam 5_A / Execution P2 / 1		/ Populations P2 / 8			
EDITAR		CREAR		Acción ▾	
12	[0, 0, 1]	179,999,679516	179,971,584255	28,095261	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
13	[3, 0, 0, 1]	205,244,397949	205,218,732199	25,665750	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
14	[1, 0, 3, 2]	128,468,163618	128,441,885128	26,278490	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
15	[1, 0, 0, 0]	288,371,773289	288,338,186622	33,586668	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
16	[5, 0, 3, 1]	342,933,121722	342,914,254690	18,867032	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
17	[1, 0, 3, 1]	342,932,042464	342,914,254690	17,789556	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
18	[3, 2, 1, 0]	128,468,163618	128,441,885128	26,278490	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
19	[1, 0, 3, 0]	128,473,108222	128,441,885128	31,223094	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
20	[1, 0, 1, 2]	288,357,963851	288,338,186622	19,777230	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
21	[3, 0, 1, 2]	128,468,163618	128,441,885128	26,278490	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
22	[1, 3, 3, 0]	166,159,249949	166,130,678060	28,571890	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
23	[1, 0, 0, 1]	205,243,431064	205,218,732199	24,698865	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
24	[3, 0, 0, 1]	205,244,397949	205,218,732199	25,665750	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
25	[1, 0, 0, 1]	205,243,431064	205,218,732199	24,698865	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
26	[0, 0, 3, 3]	305,072,272175	305,043,532774	28,739400	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
27	[1, 2, 1, 0]	128,468,529277	128,441,885128	26,644599	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
28	[1, 0, 3, 2]	128,468,163618	128,441,885128	26,278490	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
29	[1, 1, 3, 0]	186,159,459642	186,130,678060	28,781582	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>
30	[0, 0, 0, 1]	179,999,679516	179,971,584255	28,095261	<input type="checkbox"/> <input checked="" type="checkbox"/> <input type="checkbox"/>

Fuente: obtenido de *Algocym*

CAPITULO 4: RESULTADOS Y DISCUSION

4.1 Análisis y discusión de resultados

Para realizar el análisis, interpretación y discusión de resultados para cada uno de los cuatro casos estudiados se aplica un diseño experimental por bloques aleatorizado. El análisis de datos se realiza con el software Minitab® versión 18, y SPSS® versión 24, de la compañía IBM®. En cuanto a los tiempos de ejecución del algoritmo propuesto se analizan los resultados de cada caso en el acápite 4.2.

De acuerdo con (Montgomery, 2004) el experimento debe tener un mínimo de dos réplicas de modo tal que sea posible establecer el error “interno o puro”. En ese sentido teniendo en cuenta la aleatoriedad del algoritmo la cual debe estar relacionada con la obtención de la muestra inicial (población inicial) y los operadores genéticos que se aplican, se propone grupos experimentales a los cuales se aplicarán un mínimo de diez replicas.

4.1.1 Caso I: Tam 8 – T8

De acuerdo con lo planteado en 3.9 se debe determinar el parámetro “tamaño” adecuado de la muestra (población que será sometida al proceso evolutivo) se define un bloque experimental que considera tres tamaños de muestra: chico de 30, mediano de 60 y grande de 100 individuos. Manteniendo constante el porcentaje de cruce en 60 porciento, en tanto que

el porcentaje de mutación se establece en los siguientes valores $pm = \{0.05, 0.08, 0.10, 0.20, 0.30\}$. La tabla 26 presenta el esquema para este experimento, donde para cada renglón y columna se realizan 10 réplicas por muestra (población) en cada tamaño; lo cual hace 50 muestras para cada tamaño; totalizando se tiene 150 muestras, los datos se presentan en el anexo 3. El análisis estadístico permitirá determinar el tamaño adecuado para la muestra.

Tabla 26

Diseño de experimento para determinar el tamaño de la muestra

		A: Tamaño de la muestra		
		Chico pob = 30	Mediano pob = 60	Grande pob = 100
B: Porcentaje de mutación	0.05	x1, x2, ... ,x10	x1, x2, ... ,x10	x1, x2, ... ,x10
	0.08	x1, x2, ... ,x10	x1, x2, ... ,x10	x1, x2, ... ,x10
	0.10	x1, x2, ... ,x10	x1, x2, ... ,x10	x1, x2, ... ,x10
	0.20	x1, x2, ... ,x10	x1, x2, ... ,x10	x1, x2, ... ,x10
	0.30	x1, x2, ... ,x10	x1, x2, ... ,x10	x1, x2, ... ,x10

Fuente: elaboración propia

4.1.1.2 Análisis descriptivo

Se realiza el análisis descriptivo con la finalidad de determinar las diferencias existentes entre las medias del valor de la función de adaptación en los niveles del factor considerado. Los resultados se presentan en la tabla 27. Los datos experimentales se presentan en el anexo 3.

Tabla 27

Estadísticos descriptivos del tamaño de la muestra con relación al porcentaje de mutación

Muestra	pMutacion	Desviación es-		N
		Media	tándar	
fAdap_pob30	,05	10271,46484000	573,862215200	10
	,08	10207,43605000	505,744687400	10
	,10	9898,40750200	245,709655400	10
	,20	9744,52288900	109,086396900	10
	,30	9813,51518400	166,632223700	10
	Total	9987,06929400	414,747145000	50
fAdap_pob60	,05	9851,04119400	206,827796900	10
	,08	9923,84180500	239,555511900	10
	,10	9942,05876800	355,583280400	10
	,20	9943,30958200	247,469941800	10
	,30	9744,52288900	109,086396900	10
	Total	9880,95484700	246,915806900	50
fAdap_pob100	,05	10863,99922000	2023,116281000	10
	,08	9744,52288900	109,086396900	10
	,10	9838,70584000	201,439145700	10
	,20	9764,91974900	150,573237600	10
	,30	9761,65203800	150,560855900	10
	Total	9994,75994800	981,611579800	50

Fuente: Elaboración propia

Se aprecia que las medias para los factores tamaño de muestra (población) de 30 y 100 individuos no son homogéneas entre sí; en el caso de un porcentaje de mutación del 5%, por lo que se puede conjutar que el tamaño de la muestra puede ejercer algún efecto sobre la función de adaptación.

4.1.1.3 Análisis de varianzas

De acuerdo con (Perea González, 2015) en su tesis de Maestría , plantea un grupo inicial de experimentos (pp. 72 – 74) para determinar el

tamaño de la muestra entre 100 (bajo), 200 (medio) y 300 (alto) individuos con miras a decidir cuál de estos tamaños llevará a una mejor convergencia de su algoritmo genético. Hechas las pruebas y el análisis estadístico de las varianzas el autor llega a concluir que el mejor tamaño para su muestra es de 200 individuos.

En el caso de Algocym, con el fin de determinar si la diferencia del tamaño de la muestra es estadísticamente significativa, se realiza la prueba ANOVA, en cada grupo respecto a los valores de las réplicas en cuanto al valor de la función de adaptación⁶, (ver la tabla 28). La prueba de hipótesis es la siguiente.

Para el factor A tamaño de la muestra se tiene las siguientes hipótesis:

H_0 : Las medias de todas las muestras son iguales.

H_a : No todas las medias de las muestras son iguales.

Los resultados de la prueba ANOVA presentados en la tabla 28 muestran que los resultados del p-valor para tamaños de población de 30, 60 y 100 individuos son: 0.006, 0.321, y 0.035 respectivamente. Se observa que en los casos de poblaciones de tamaño 30 y 100 el p-valor es inferior al nivel de significancia establecido en 5% ($p < 0.05$). Con este resultado se concluye que el valor de la función de adaptación se encuentra influenciado por el factor considerado (tamaño de la muestra o población) y por tanto se rechaza la hipótesis nula y se acepta la hipótesis alterna.

⁶ Se recuerda que en el tema de algoritmos genéticos la función de adaptación equivale a la función óptima.

Tabla 28

Resultados de ANOVA para tamaño de la muestra con relación al porcentaje de mutación

			Suma de cuadra-dos	gl	Media cuadrá-tica	F	Sig.
fAdap_pob30 * pMutacion	Entre gru-pos	(Combinado)	2262530.370	4	565632.592	4.128	0.006
		Linealidad	1422638.872	1	1422638.872	10.382	0.002
		Desviación de la linealidad	839891.498	3	279963.833	2.043	0.121
	Dentro de grupos		6166214.151	45	137026.981		
	Total		8428744.520	49			
	Entre gru-pos	(Combinado)	289695.991	4	72423.998	1.208	0.321
		Linealidad	98461.611	1	98461.611	1.642	0.207
		Desviación de la linealidad	191234.380	3	63744.793	1.063	0.374
	Dentro de grupos		2697707.379	45	59949.053		
	Total		2987403.370	49			
fAdap_pob60 * pMutacion	Entre gru-pos	(Combinado)	9497142.036	4	2374285.509	2.833	0.035
		Linealidad	2759351.141	1	2759351.141	3.292	0.076
		Desviación de la linealidad	6737790.895	3	2245930.298	2.680	0.058
	Dentro de grupos		37717361.352	45	838163.586		
	Total		47214503.388	49			

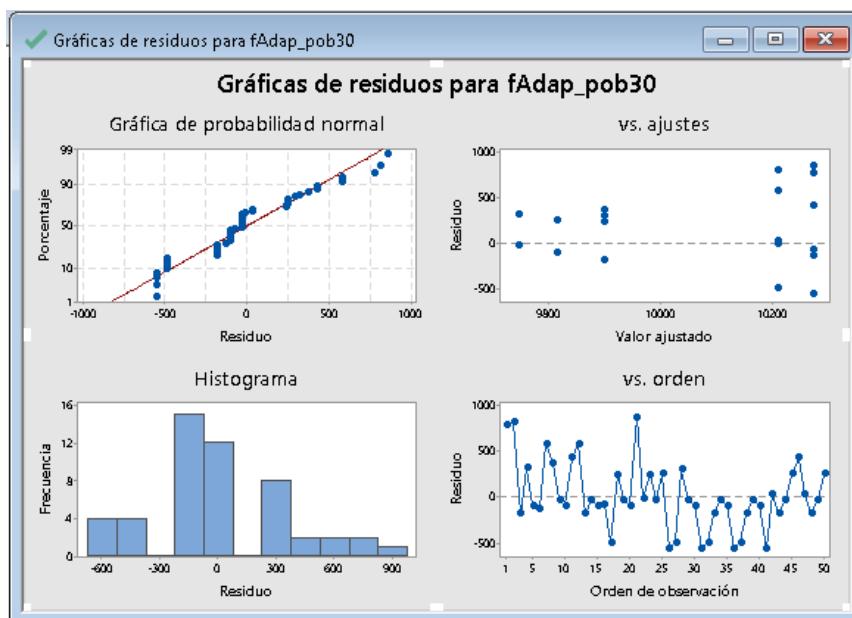
Fuente: elaboración propia

Según la prueba estadística realizada se tiene que para una muestra de 30 individuos el p-valor encontrado es de 0.006, valor establecido en un rango de $p < 0.01$, que es mucho menor que el valor de significancia donde $p\text{-valor} < 0.05$; entonces se puede establecer como conclusión que el tamaño óptimo para la muestra es de 30 individuos.

Las figuras 87, 88 y 89 presentan las gráficas de residuos de la función de adaptación para cada tamaño de muestra. Se comprueba visualmente que el mejor caso, se da para un tamaño de muestra de 30 individuos. De acuerdo con el análisis, se establece como tamaño de la muestra (población inicial) será de 30; con el cual se realizarán todas las corridas y pruebas experimentales para los cuatro casos de estudio establecidos.

Figura 87

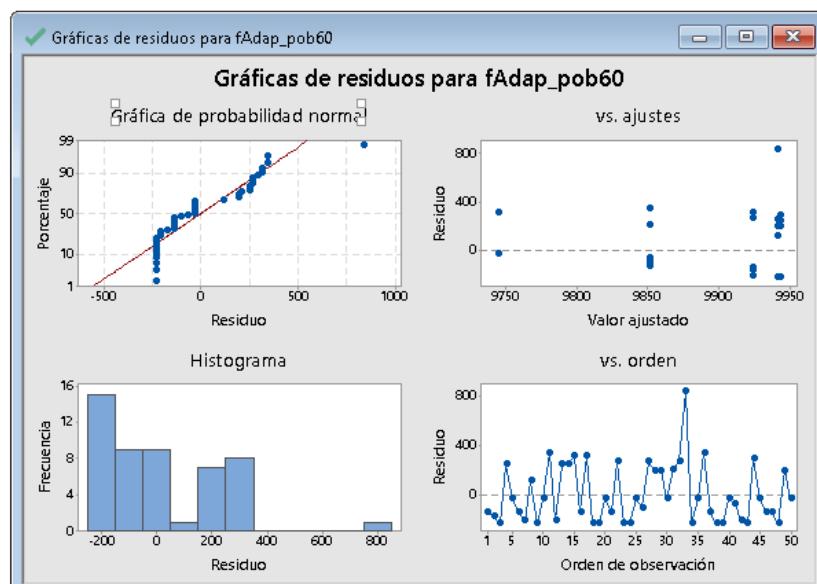
Grafica de residuos función de adaptación para un tamaño de muestra igual a 30



Fuente: elaboración propia

Figura 88

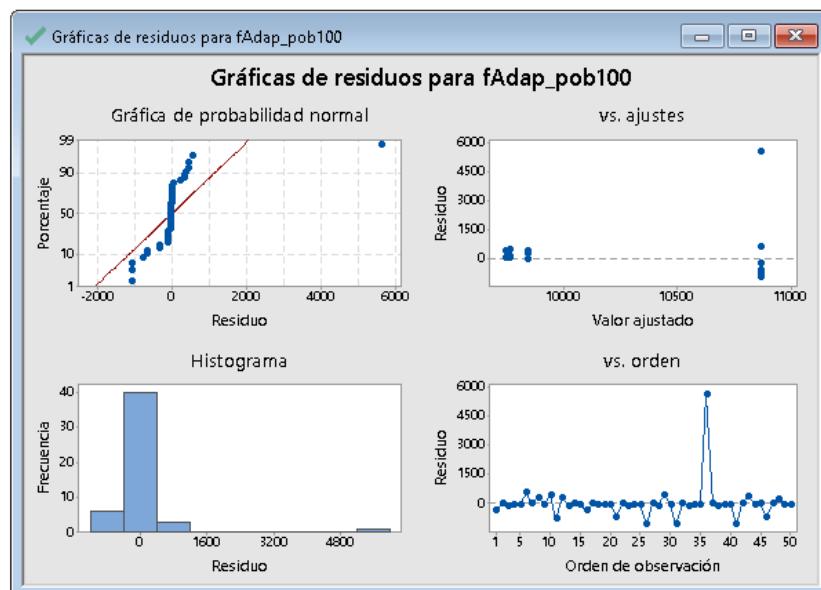
Grafica de residuos función de adaptación para un tamaño de muestra igual a 60



Fuente: elaboración propia

Figura 89

Grafica de residuos función de adaptación para un tamaño de muestra igual a 100



Fuente: elaboración propia

En las figuras 87, 88 y 89, se observa el grafico de probabilidad normal y se visualiza que en la en la figura 87 tiene mejor distribución normal a diferencia de las otras.

Tal como se establece en el presente capítulo, Algocym se implementa en dos pasos, por ello el análisis y prueba estadística de resultados se plantea para cada paso.

Paso 1: Búsqueda del mejor árbol de cortes

Según (Montgomery, 2004) “El diseño factorial de dos factores aleatorios se da cuando se tienen dos factores A y B y ambos tienen un gran número de niveles de interés”. Al respecto el autor recomienda escoger al azar niveles del factor A y b niveles del factor B , estos niveles de los factores se deben incluir en el diseño factorial experimental. Adicionalmente como se ha descrito anteriormente se recomienda n replicas (capítulo 12).

Definido el tamaño de la muestra y de acuerdo con lo propuesto por Montgomery, en la tabla 29 se presenta el diseño de experimentos para encontrar el mejor árbol de cortes en los pasos 1 y 2; donde se establece cuatro bloques para el factor A (porcentajes de cruce $pC = \{0.60, 0.70, 0.80, 0.90\}$ que se mantienen constante en cada bloque) y $b = 5$ niveles para el factor B (porcentaje de mutación que varía según $pM = \{0.05, 0.08, 0.10, 0.20, 0.30\}$); estos son los tratamientos y a cada uno se aplican 10 réplicas en el paso 1 y 14 réplicas en el paso 2. Los datos experimentales se presentan en el anexo 2.

Tabla 29*Diseño de experimentos para encontrar el mejor árbol de cortes*

Porcentaje de cruce	Porcentaje de mutación	Función de adaptación
0.60	0.05	x1, x2, x3, ..., x10
	0.08	x1, x2, x3, ..., x10
	0.10	x1, x2, x3, ..., x10
	0.20	x1, x2, x3, ..., x10
0.70	0.30	x1, x2, x3, ..., x10
	0.05	x1, x2, x3, ..., x10
	0.08	x1, x2, x3, ..., x10
	0.10	x1, x2, x3, ..., x10
0.80	0.20	x1, x2, x3, ..., x10
	0.30	x1, x2, x3, ..., x10
	0.05	x1, x2, x3, ..., x10
	0.08	x1, x2, x3, ..., x10
0.90	0.10	x1, x2, x3, ..., x10
	0.20	x1, x2, x3, ..., x10
	0.30	x1, x2, x3, ..., x10

Fuente: elaboración propia

Análisis descriptivo

Tanto para cruce y mutación se establecen las siguientes hipótesis.

Bloque = cruce

H_0 : Todos los bloques (cruce) son iguales.

H_a : Al menos uno de los bloques (cruce) es diferente.

Tratamiento = mutación

H_0 : Los tratamientos (mutación) son iguales.

H_a : Al menos uno de los tratamientos (mutación) es diferente.

Los resultados son presentados en las tablas 30 y 31.

Tabla 30

Prueba de igualdad de Levene de varianzas de error^a

Variable dependiente: función Adaptación			
F	df1	df2	Sig.
3,676	19	180	,000

Prueba la hipótesis nula que la varianza de error de la variable dependiente es igual entre grupos.

a. Diseño : Intersección + pCruce + pMutacion

Fuente: elaboración propia

De acuerdo con los resultados que se visualiza en la tabla 31, se puede observar con respecto a los bloques (Cruce): se acepta la hipótesis nula y se rechaza la hipótesis alterna, es decir que no existe diferencia significativa entre los bloques, porque el p-valor es mayor que 0.05. Sin embargo, con respecto a los tratamientos (Mutación) se puede apreciar que, si existe diferencia significativa, porque el p-valor es menor que el 0.05; esto quiere decir que se rechaza la Hipótesis Nula y se Acepta la Hipótesis Alterna, por consiguiente, existe evidencia estadística para afirmar, que al menos uno de los tratamientos (Mutación) es diferente. Esto se corrobora con las pruebas post hoc presentadas en la tabla 32, en donde se observa que el tratamiento (Mutación) con 0.05 es diferente es a los demás.

Tabla 31*Prueba ANOVA para el paso 1. Caso Tam 8*

Variable dependiente: f_Adaptación					
Origen	Tipo III de suma de cuadrados	gl	Media cuadrática	F	Sig.
Modelo corregido	29361496,380 ^a	19	1545341,915	3,865	,000
Intersección	20238288310,000	1	20238288310,000	50615,980	,000
pCruce	817385,007	3	272461,669	,681	,564
pMutacion	22623689,970	4	5655922,492	14,145	,000
pCruce * pMutacion	5920421,407	12	493368,451	1,234	,263
Error	71971181,070	180	399839,895		
Total	20339620990,000	200			
Total, corregido	101332677,500	199			

a. R al cuadrado = ,290 (R al cuadrado ajustada = ,215)

Fuente: elaboración propia

Como se observa en la tabla 31, se genera dos subconjuntos en el cual la mutación 0.05 es diferente a las demás por su diferencia de medias con respecto a las demás. Por lo tanto, se observa que es la más optima respecto a la función de adaptación y es la más alta. Con las demás no es significativo en cuanto a tener una mejora respecto al objetivo. La prueba de Tukey y la de Scheffe confirma el mismo resultado.

Tabla 32*Comparaciones múltiples*

	pMutacion	N	Subconjunto	
			1	2
HSD Tukey ^{a,b}	,20	40	9783,13400100	
	,30	40	9814,10532700	
	,10	40	9856,83225500	
	,08	40	10170,55422000	
	,05	40		10672,35262000
	Sig.		,052	1,000
Scheffe ^{a,b}	,20	40	9783,13400100	
	,30	40	9814,10532700	
	,10	40	9856,83225500	
	,08	40	10170,55422000	
	,05	40		10672,35262000
	Sig.		,116	1,000

Se visualizan las medias para los grupos en los subconjuntos homogéneos.

Se basa en las medias observadas.

El término de error es la media cuadrática(Error) = 399839,895.

a. Utiliza el tamaño de la muestra de la media armónica = 40,000.

b. Alfa = 0.05.

Fuente: elaboración propia

Paso 2: Búsqueda del mejor layout

Como se ha establecido en este capítulo; Algocym toma el mejor árbol de cortes obtenido en el paso1 y aplica los cortes establecidos para obtener el layout óptimo. Los datos experimentales se presentan en el anexo 3. En el presente caso se tiene 50 generaciones y aplicando 10 repeticiones para cada combinación de cruce y mutación, el algoritmo encuentra en todas las réplicas el valor de la función de adaptación(óptima); por lo que no procede realizar el análisis estadístico, ver tabla 60.

4.1.2 Caso II: van Camp – vC10

Los resultados experimentales se presentan en el anexo 4.

4.1.2.1 Análisis descriptivo

Paso 1: Búsqueda del mejor árbol de cortes

Tanto para cruce y mutación se establecen las siguientes hipótesis.

Bloque = cruce

H_0 : Todos los bloques (cruce) son iguales.

H_a : Al menos uno de los bloques (cruce) es diferente.

Tratamiento = mutación

H_0 : Los tratamientos (mutación) son iguales.

H_a : Al menos uno de los tratamientos (mutación) es diferente.

Los resultados presentados en la tabla 33 muestran que se acepta la hipótesis nula. La tabla 34 muestra un p-valor de 0.056 para cruce, 0.000 para mutación y 0.211, para la interacción de cruce y mutación con lo cual se acepta la hipótesis nula respecto a estos.

Tabla 33 Prueba de igualdad de Levene de varianzas de error^a

Variable dependiente: f_Adaptación			
F	df1	df2	Sig.
9,747	19	180	,000

Prueba la hipótesis nula que la varianza de error de la variable dependiente es igual entre grupos.

a. Diseño : Intersección + pCruce + pMutacion + pCruce * pMutacion

Fuente: elaboración propia

4.1.2.2 Análisis de varianzas

Tabla 34 Prueba ANOVA para el paso 1. Caso vC10

Pruebas de efectos inter-sujetos

Variable dependiente: f_Adaptación					
Origen	Tipo III de suma de cuadrados	gl	Media cuadrática	F	Sig.
Modelo corregido	92,659 ^a	19	4,877	4,307	,000
Intersección	18654732,160	1	18654732,160	16474446,580	,000
pCruce	8,702	3	2,901	2,562	,056
pMutacion	66,028	4	16,507	14,578	,000
pCruce * pMutacion	17,929	12	1,494	1,319	,211
Error	203,822	180	1,132		
Total	18655028,640	200			
Total corregido	296,481	199			

a. R al cuadrado = ,313 (R al cuadrado ajustada = ,240)

Fuente: elaboración propia

La tabla 35 presenta las comparaciones múltiples realizadas con pruebas de Tukey y Scheffe. En ambas pruebas se tiene con un porcentaje de mutación del 5% se obtiene un p-valor de 0.014 con Tukey, con Scheffe se obtiene un p-valor de 0.041, lo cual muestra que un porcentaje de 0.05 de mutación es significativo.

Tabla 35
Comparaciones múltiples

Variable dependiente: f_Adaptación									
		Diferencia de me-dias (I-J)		Error estándar	Sig.	Intervalo de confianza al 95%			
(I) pMutacion	HSD Tukey	,05	,10	,7600953*	,23794364	0.014	0.1044114	1.4157792	
		,20		1,2416056*	0.23794364	0.000	0.5859217	1.8972895	
		,30		1,6647544*	0.23794364	0.000	1.0090705	2.3204383	
		,40		1,3050187*	0.23794364	0.000	0.6493348	1.9607026	
		,10	,05	-,7600953*	0.23794364	0.014	-1.4157792	-0.1044114	
		,20		0.4815103	0.23794364	0.259	-0.1741736	1.1371942	
		,30		,9046591*	0.23794364	0.002	0.2489752	1.5603430	
		,40		0.5449234	0.23794364	0.153	-0.1107605	1.2006073	
		,20	,05	-1,2416056*	0.23794364	0.000	-1.8972895	-0.5859217	
		,10		-0.4815103	0.23794364	0.259	-1.1371942	0.1741736	
		,30		0.4231488	0.23794364	0.389	-0.2325351	1.0788327	
		,40		0.0634131	0.23794364	0.999	-0.5922708	0.7190970	
		,30	,05	-1,6647544*	0.23794364	0.000	-2.3204383	-1.0090705	
		,10		-,9046591*	0.23794364	0.002	-1.5603430	-0.2489752	
		,20		-0.4231488	0.23794364	0.389	-1.0788327	0.2325351	
		,40		-0.3597357	0.23794364	0.556	-1.0154196	0.2959482	
		,40	,05	-1,3050187*	0.23794364	0.000	-1.9607026	-0.6493348	
		,10		-0.5449234	0.23794364	0.153	-1.2006073	0.1107605	
		,20		-0.0634131	0.23794364	0.999	-0.7190970	0.5922708	
		,30		0.3597357	0.23794364	0.556	-0.2959482	1.0154196	
		Scheffe	,05	,10	,7600953*	0.23794364	0.041	0.0195066	1.5006840
			,20	1,2416056*	0.23794364	0.000	0.5010169	1.9821943	
			,30	1,6647544*	0.23794364	0.000	0.9241657	2.4053431	
			,40	1,3050187*	0.23794364	0.000	0.5644300	2.0456074	
			,10	,05	-,7600953*	0.23794364	0.041	-1.5006840	-0.0195066
			,20	0.4815103	0.23794364	0.396	-0.2590784	1.2220990	
			,30	,9046591*	0.23794364	0.007	0.1640704	1.6452478	
			,40	0.5449234	0.23794364	0.268	-0.1956653	1.2855121	
			,20	,05	-1,2416056*	0.23794364	0.000	-1.9821943	-0.5010169
			,10	-0.4815103	0.23794364	0.396	-1.2220990	0.2590784	
			,30	0.4231488	0.23794364	0.533	-0.3174399	1.1637375	
			,40	0.0634131	0.23794364	0.999	-0.6771756	0.8040018	
			,30	,05	-1,6647544*	0.23794364	0.000	-2.4053431	-0.9241657
			,10	-,9046591*	0.23794364	0.007	-1.6452478	-0.1640704	
			,20	-0.4231488	0.23794364	0.533	-1.1637375	0.3174399	
			,40	-0.3597357	0.23794364	0.684	-1.1003244	0.3808530	
			,40	,05	-1,3050187*	0.23794364	0.000	-2.0456074	-0.5644300
			,10	-0.5449234	0.23794364	0.268	-1.2855121	0.1956653	
			,20	-0.0634131	0.23794364	0.999	-0.8040018	0.6771756	
			,30	0.3597357	0.23794364	0.684	-0.3808530	1.1003244	

Se basa en las medias observadas.

El término de error es la media cuadrática(Error) = 1,132.

*. La diferencia de medias es significativa en el nivel .05.

Fuente: elaboración propia

La tabla 36 muestra que se generan tres subconjuntos, donde la mutación 0.05 es diferente a las demás por su diferencia de medias con respecto a las otras. Por lo tanto, se observa que es la más optima respecto a la función de adaptación y es la más alta.

Tabla 36*Subconjuntos homogéneos*

		f Adaptación		
		Subconjunto		
	pMutacion	N	1	2
HSD Tukey ^{a,b}	,30	40	304,7369090	
	,40	40	305,0966447	305,0966447
	,20	40	305,1600578	305,1600578
	,10	40		305,6415681
	,05	40		306,4016634
	Sig.		,389	,153
				1,000
Scheffe ^{a,b}	,30	40	304,7369090	
	,40	40	305,0966447	305,0966447
	,20	40	305,1600578	305,1600578
	,10	40		305,6415681
	,05	40		306,4016634
	Sig.		,533	,268
				1,000

Se visualizan las medias para los grupos en los subconjuntos homogéneos.

Se basa en las medias observadas.

El término de error es la media cuadrática(Error) = 1,132.

a. Utiliza el tamaño de la muestra de la media armónica = 40,000.

b. Alfa = .05.

Fuente: elaboración propia

Paso 2: Búsqueda del mejor layout

De modo similar al caso Tam 8, todas las repicas aplicadas en el paso 2 conducen al mismo resultado en cuanto a la función optima, por lo que no es necesario realizar el análisis estadístico, ver anexo 4.

4.1.3 Caso III: Bazaraa 14 – B14

Paso 1: Búsqueda del mejor árbol de cortes

4.1.3.1 Análisis descriptivo

Los resultados experimentales se presentan en el anexo 5.

Tanto para cruce y mutación se establecen las siguientes hipótesis.

Bloque = cruce

H_0 : Todos los bloques (cruce) son iguales.

H_a : Al menos uno de los bloques (cruce) es diferente.

Tratamiento = mutación

H_0 : Los tratamientos (mutación) son iguales.

H_a : Al menos uno de los tratamientos (mutación) es diferente.

Los resultados son presentados en las tablas 37 en cuanto al cruce conducen a aceptar la hipótesis nula.

Tabla 37

Prueba de igualdad de Levene de varianzas de error^a

Prueba de igualdad de Levene de varianzas de error^a

Variable dependiente: f_Optima

F	df1	df2	Sig.
6,432	19	180	,000

Prueba la hipótesis nula que la varianza de error de la variable dependiente es igual entre grupos.

a. Diseño : Intersección + pCruce + pMutacion + pCruce * pMutacion

Fuente: elaboración propia

La tabla 38 muestra un p-valor de 0.178 para cruce, 0.000 para mutación y 0.673, para la interacción de cruce y mutación con lo cual se acepta la hipótesis nula respecto a estos.

4.1.3.2 Análisis de varianzas

Tabla 38

Prueba ANOVA para el paso1. Caso Bazara 14

Variable dependiente: f_Adaptación					
Origen	Tipo III de suma de cuadrados	gl	Media cuadrática	F	Sig.
Modelo corregido	15804,485 ^a	19	831,815	3,008	,000
Intersección	75698814,030	1	75698814,030	273774,550	,000
pCruce	1373,598	3	457,866	1,656	,178
pMutacion	11849,311	4	2962,328	10,714	,000
pCruce * pMutacion	2581,576	12	215,131	,778	,673
Error	49770,099	180	276,501		
Total	75764388,620	200			
Total corregido	65574,584	199			

a. R al cuadrado = ,241 (R al cuadrado ajustada = ,161)

Aplicando el análisis post hoc la tabla 39 presenta que para Scheffe un porcentaje de mutación de 0.05% tiene un p-valor = 0.001 lo cual puede llevar a concluir que este porcentaje es significativo.

Tabla 39

Comparaciones múltiples

Variable dependiente: f_adaptación						Intervalo de confianza al 95%	
(I) pMutacion	Diferencia de medias (I-J)		Error estándar	Sig.	Límite inferior	Límite superior	
HSD Tukey	,05	,10	16,99824635*	3.718202195	0.000	6.75226802	27.24422468
		,20	19,35775002*	3.718202195	0.000	9.11177169	29.60372836
		,30	19,44860715*	3.718202195	0.000	9.20262882	29.69458548
		,40	20,36013328*	3.718202195	0.000	10.11415494	30.60611161
	,10	,05	-16,99824635*	3.718202195	0.000	-27.24422468	-6.75226802
		,20	2.35950368	3.718202195	0.969	-7.88647466	12.60548201
		,30	2.45036080	3.718202195	0.965	-7.79561753	12.69633913
		,40	3.36188693	3.718202195	0.895	-6.88409141	13.60786526
	,20	,05	-19,35775002*	3.718202195	0.000	-29.60372836	-9.11177169
		,10	-2.35950368	3.718202195	0.969	-12.60548201	7.88647466
		,30	0.09085713	3.718202195	1.000	-10.15512121	10.33683546

	,40	1.00238325	3.718202195	0.999	-9.24359508	11.24836158
	,30 ,05	-19,44860715*	3.718202195	0.000	-29.69458548	-9.20262882
	,10	-2.45036080	3.718202195	0.965	-12.69633913	7.79561753
	,20	-0.09085713	3.718202195	1.000	-10.33683546	10.15512121
	,40	0.91152613	3.718202195	0.999	-9.33445221	11.15750446
	,40 ,05	-20,36013328*	3.718202195	0.000	-30.60611161	-10.11415494
	,10	-3.36188693	3.718202195	0.895	-13.60786526	6.88409141
	,20	-1.00238325	3.718202195	0.999	-11.24836158	9.24359508
	,30	-0.91152613	3.718202195	0.999	-11.15750446	9.33445221
Scheffe	,05 ,10	16,99824635*	3.718202195	0.001	5.42551157	28.57098113
	,20	19,35775002*	3.718202195	0.000	7.78501525	30.93048480
	,30	19,44860715*	3.718202195	0.000	7.87587237	31.02134193
	,40	20,36013328*	3.718202195	0.000	8.78739850	31.93286805
	,10 ,05	-16,99824635*	3.718202195	0.001	-28.57098113	-5.42551157
	,20	2.35950368	3.718202195	0.982	-9.21323110	13.93223845
	,30	2.45036080	3.718202195	0.979	-9.12237398	14.02309558
	,40	3.36188693	3.718202195	0.936	-8.21084785	14.93462170
	,20 ,05	-19,35775002*	3.718202195	0.000	-30.93048480	-7.78501525
	,10	-2.35950368	3.718202195	0.982	-13.93223845	9.21323110
	,30	0.09085713	3.718202195	1.000	-11.48187765	11.66359190
	,40	1.00238325	3.718202195	0.999	-10.57035153	12.57511803
	,30 ,05	-19,44860715*	3.718202195	0.000	-31.02134193	-7.87587237
	,10	-2.45036080	3.718202195	0.979	-14.02309558	9.12237398
	,20	-0.09085713	3.718202195	1.000	-11.66359190	11.48187765
	,40	0.91152613	3.718202195	1.000	-10.66120865	12.48426090
	,40 ,05	-20,36013328*	3.718202195	0.000	-31.93286805	-8.78739850
	,10	-3.36188693	3.718202195	0.936	-14.93462170	8.21084785
	,20	-1.00238325	3.718202195	0.999	-12.57511803	10.57035153
	,30	-0.91152613	3.718202195	1.000	-12.48426090	10.66120865

Se basa en las medias observadas.

El término de error es la media cuadrática(Error) = 276,501.

*. La diferencia de medias es significativa en el nivel .05.

En la tabla 40 se comprueba que un porcentaje de mutación del 0.05% confirma la hipótesis alterna que al menos uno de los tratamientos de mutación es diferente.

Tabla 40*Subconjuntos homogéneos*

	pMutacion	N	Subconjunto	
			1	2
HSD Tukey ^{a,b}	,40	40	610,09153140	
	,30	40	611,00305760	
	,20	40	611,09391470	
	,10	40	613,45341840	
	,05	40		630,45166470
	Sig.		,895	1,000
Scheffe ^{a,b}	,40	40	610,09153140	
	,30	40	611,00305760	
	,20	40	611,09391470	
	,10	40	613,45341840	
	,05	40		630,45166470
	Sig.		,936	1,000

Se visualizan las medias para los grupos en los subconjuntos homogéneos.

Se basa en las medias observadas.

El término de error es la media cuadrática(Error) = 276,501.

a. Utiliza el tamaño de la muestra de la media armónica = 40,000.

b. Alfa = .05.

Paso 2: Búsqueda del mejor layout

Análisis descriptivo

Tanto para cruce y mutación se establecen las siguientes hipótesis.

Bloque = cruce

H_0 : Todos los bloques (cruce) son iguales.

H_a : Al menos uno de los bloques (cruce) es diferente.

Tratamiento = mutación

H_0 : Los tratamientos (mutación) son iguales.

H_a : Al menos uno de los tratamientos (mutación) es diferente.

Los resultados son presentados en la tabla 41 que prueba la hipótesis nula. La tabla 42 muestra que la interacción entre cruce y mutación tiene un p-valor de 0.019.

Tabla 41*Prueba de igualdad de Levene de varianzas de error^{as}*

Variable dependiente: f_Adaptación

F	df1	df2	Sig.
1,708	19	260	,035

Prueba la hipótesis nula que la varianza de error de la variable dependiente es igual entre grupos.

a. Diseño : Intersección + pCruce + pMutacion + pCruce * pMutacion

Tabla 42*Pruebas de efectos inter-sujetos*

Variable dependiente: f_Adaptación

Origen	cuadrados	Tipo III de suma de		F	Sig.
		gl	Media cuadrática		
Modelo corregido	36266601,540 ^a	19	1908768,502	2,332	,002
Intersección	41299280270,000	1	41299280270,000	50457,532	,000
pCruce	2200517,219	3	733505,740	,896	,444
pMutacion	13751666,970	4	3437916,743	4,200	,003
pCruce * pMutacion	20314417,350	12	1692868,113	2,068	,019
Error	212808918,700	260	818495,841		
Total	41548355790,000	280			
Total corregido	249075520,200	279			

a. R al cuadrado = ,146 (R al cuadrado ajustada = ,083)

Los resultados muestran que en el caso de los bloques (Cruce) se acepta la hipótesis nula. En cuanto a los tratamientos (mutación) al menos algún tratamiento es diferente, para los porcentajes de mutación de 10% y 20%, ver la tabla 42 y 43; en esta última se observa que se generan dos subconjuntos. Es importante mencionar que en este caso experimental no se realizó prueba para un porcentaje del 5%.

Tabla 43*Subconjuntos homogéneos*

	pMutacion	N	Subconjunto	
			1	2
HSD Tukey ^{a,b}	,50	56	11908,74916000000000	
	,40	56	11962,09276000000000	11962,09276000000000
	,30	56	12029,36106000000000	12029,36106000000000
	,20	56		12399,47202999999900
	,10	56		12424,58486999999900
	Sig.		,955	,056
Scheffe ^{a,b}	,50	56	11908,74916000000000	
	,40	56	11962,09276000000000	
	,30	56	12029,36106000000000	
	,20	56	12399,47202999999900	
	,10	56	12424,58486999999900	
	Sig.		,062	

Se visualizan las medias para los grupos en los subconjuntos homogéneos.

Se basa en las medias observadas.

El término de error es la media cuadrática(Error) = 818495,841.

a. Utiliza el tamaño de la muestra de la media armónica = 56,000.

b. Alfa = .05.

4.1.4 Caso IV: Armour & Buffa 20 – AB20

Paso 1: Búsqueda del mejor árbol de cortes

4.1.4.1 Análisis descriptivo

Tanto para cruce y mutación se establecen las siguientes hipótesis.

Bloque = cruce

H_0 : Todos los bloques (cruce) son iguales.

H_a : Al menos uno de los bloques (cruce) es diferente.

Tratamiento = mutación

H_0 : Los tratamientos (mutación) son iguales.

H_a : Al menos uno de los tratamientos (mutación) es diferente.

Los resultados para el cruce son presentados en la tabla 44 y 45 donde se acepta la hipótesis nula.

Tabla 44

Prueba de igualdad de Levene de varianzas de error^a

Variable dependiente: f_Adaptación

F	df1	df2	Sig.
14,347	19	180	,000

Prueba la hipótesis nula que la varianza de error de la variable dependiente es igual entre grupos.

a. Diseño : Intersección + pMutacion + pCruce + pMutacion * pCruce

Los resultados muestran que en el caso de los bloques (Cruce) se acepta la hipótesis nula.

4.1.4.2 Análisis de varianzas

En cuanto a los tratamientos (Mutación) al menos algún tratamiento es diferente, para los porcentajes de mutación de 5%, ver la tabla 46; en esta última se observa que se generan dos subconjuntos.

Tabla 45*Pruebas de efectos inter-sujetos*

Variable dependiente: f_Adaptación					
Origen	Tipo III de suma de cuadrados	gl	Media cuadrática	F	Sig.
Modelo corregido	11506647,820 ^a	19	605613,043	4,155	,000
Intersección	3310895412,000	1	3310895412,000	22715,549	,000
pMutacion	4643343,427	4	1160835,857	7,964	,000
pCruce	1222564,763	3	407521,588	2,796	,042
pMutacion * pCruce	5640739,633	12	470061,636	3,225	,000
Error	26235825,550	180	145754,586		
Total	3348637886,000	200			
Total corregido	37742473,370	199			

a. R al cuadrado = ,305 (R al cuadrado ajustada = ,231)

Tabla 46*Subconjuntos homogéneos*

	pMutacion	N	Subconjunto	
			1	2
HSD Tukey ^{a,b}	,40	40	3972,79773800	
	,20	40	3983,01270200	
	,10	40	4004,64741800	
	,30	40	4010,94894700	
	,05	40		4372,18989000
	Sig.		,992	1,000
Scheffe ^{a,b}	,40	40	3972,79773800	
	,20	40	3983,01270200	
	,10	40	4004,64741800	
	,30	40	4010,94894700	
	,05	40		4372,18989000
	Sig.		,995	1,000

Se visualizan las medias para los grupos en los subconjuntos homogéneos.

Se basa en las medias observadas.

El término de error es la media cuadrática(Error) = 145754,586.

a. Utiliza el tamaño de la muestra de la media armónica = 40,000.

b. Alfa = .05.

Paso 2: Búsqueda del mejor layout

Análisis descriptivo

Tanto para cruce y mutación se establecen las siguientes hipótesis.

Bloque = cruce

H_0 : Todos los bloques (cruce) son iguales.

H_a : Al menos uno de los bloques (cruce) es diferente.

Tratamiento = mutación

H_0 : Los tratamientos (mutación) son iguales.

H_a : Al menos uno de los tratamientos (mutación) es diferente.

Aquí la mutación fue de 0.20, 0.30, 0.40, 0.50 y 0.60.

Los resultados presentados en la tabla 47 y 48 muestran que para estos porcentajes de mutación no existe diferencias en los bloques, tratamientos, ni en la interacción de estos.

Tabla 47

Prueba de igualdad de Levene de varianzas de error^a

Variable dependiente: f_Adaptación

F	df1	df2	Sig.
,903	19	260	,580

Prueba la hipótesis nula que la varianza de error de la variable dependiente es igual entre grupos.

a. Diseño : Intersección + pMutacion + pCruce + pMutacion * pCruce

Tabla 48
Pruebas de efectos inter-sujetos

Variable dependiente: f_Adaptación

Origen	Tipo III de suma de cuadrados	gl	Media cuadrática	F	Sig.
Modelo corregido	27695029,760 ^a	19	1457633,145	,666	,851
Intersección	37191700220,000	1	37191700220,000	16993,388	,000
pMutacion	13415137,470	4	3353784,369	1,532	,193
pCruce	4260758,236	3	1420252,745	,649	,584
pMutacion * pCruce	10019134,050	12	834927,838	,381	,969
Error	569035559,700	260	2188598,307		
Total	37788430810,000	280			
Total corregido	596730589,500	279			

a. R al cuadrado = ,046 (R al cuadrado ajustada = -,023)

La tabla 49 muestra que para los porcentajes de mutación entre 0.20 a 0.60 son no significativos.

Tabla 49

Subconjuntos homogéneos

	pMutacion	N	Subconjunto
			1
HSD Tukey ^{a,b}	,60	56	11168,02804000
	,50	56	11460,92610000
	,40	56	11503,82591000
	,20	56	11676,98083000
	,30	56	11815,64601000
	Sig.		,143
Scheffe ^{a,b}	,60	56	11168,02804000
	,50	56	11460,92610000
	,40	56	11503,82591000
	,20	56	11676,98083000
	,30	56	11815,64601000
	Sig.		,255

Se visualizan las medias para los grupos en los subconjuntos homogéneos.

Se basa en las medias observadas.

El término de error es la media cuadrática(Error) = 2188598,307.

a. Utiliza el tamaño de la muestra de la media armónica = 56,000.

b. Alfa = .05.

4.2 Análisis y discusión de los tiempos de ejecución

En la discusión acerca de la bondad de un algoritmo un elemento crucial es el tiempo de ejecución. Respecto a los tiempos de ejecución para cada caso en 4.2.1, 4.2.2, 4.2.3, y 4.2.4 se presentan los tiempos promedios en cada paso y dentro de estos, para cada operación del algoritmo.

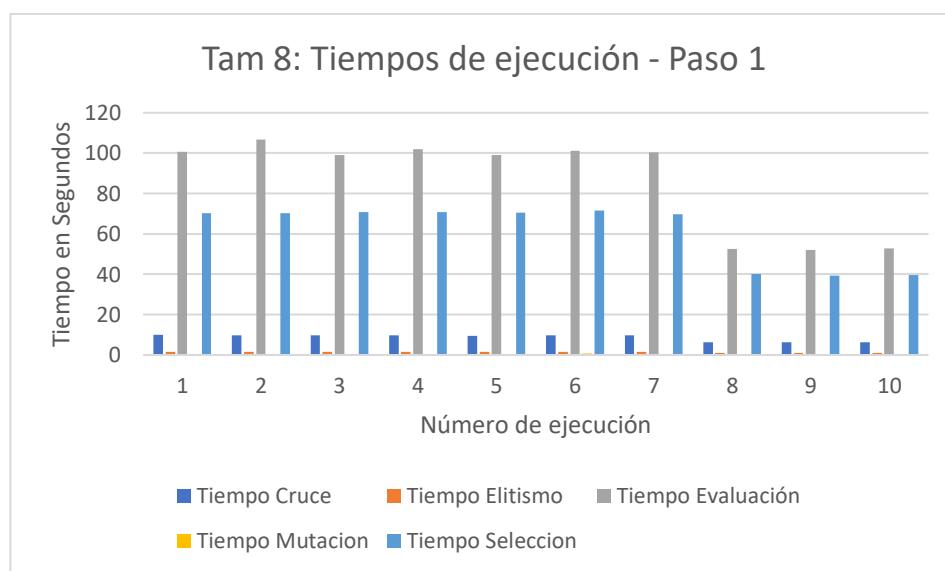
4.2.1 Caso I: Tam 8 – T8

Paso 1: Buscar el árbol con el mejor potencial geométrico

Tal como se ha establecido para cada combinación de cruce y mutación se aplican 10 réplicas, la figura 90 presenta el gráfico de barras para los tiempos, resultado de aplicar un $p_{Cruce} = 0.6$, y $p_{Mutación} = 0.05$.

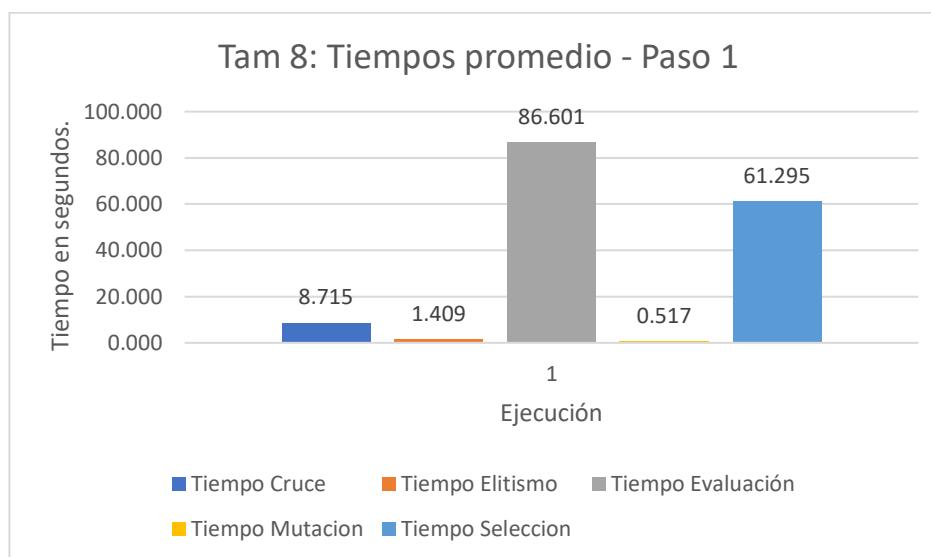
Figura 90

Tam 8: Tiempos de ejecución para 10 réplicas – Paso 1

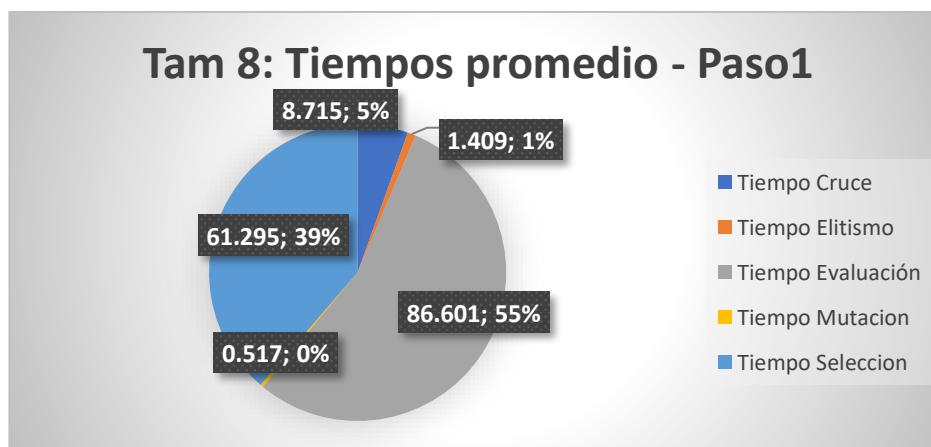


Fuente: elaboración propia

En la figura 91 se presenta el gráfico de barras con los tiempos promedios de 10 ejecuciones (según la figura 90).

Figura 91*Tam 8: Tiempos promedio – Paso 1**Fuente: elaboración propia*

En la figura 92 se observa que en promedio el tiempo de cruce fue del 5%, el de mutación 0.6%, el de elitismo del 1%, el de selección 39% y el de evaluación de la función de adaptación es del 55%.

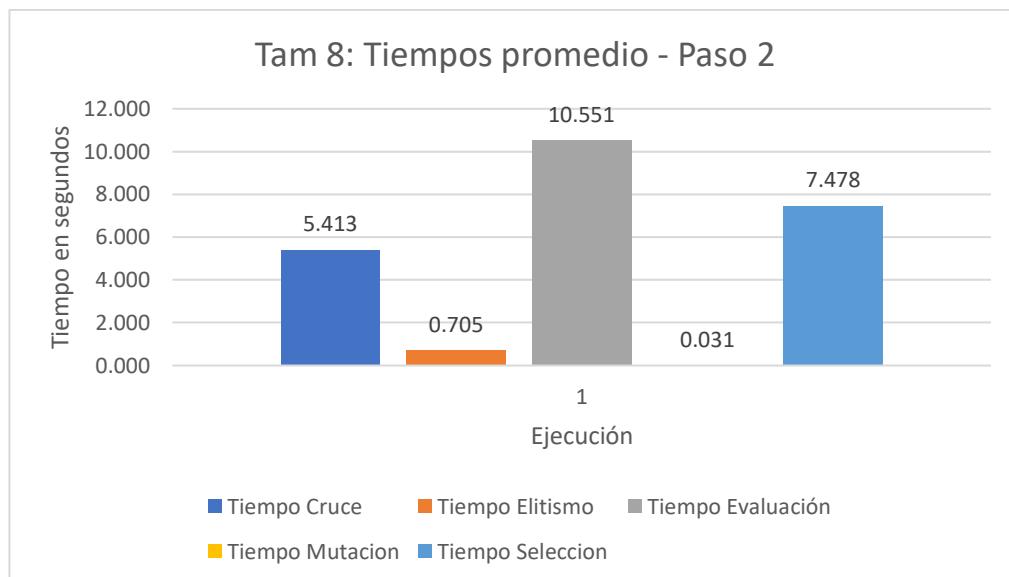
Figura 92*Tam 8: Tiempos promedio (porcentual) – Paso 1**Fuente: elaboración propia.*

Paso 2: Buscar el árbol de cortes que represente la mejor solución

En la figura 93 se presenta el gráfico de barras de los tiempos promedio en 10 ejecuciones del paso 2.

Figura 93

Tam 8: Tiempos promedio – Paso 2

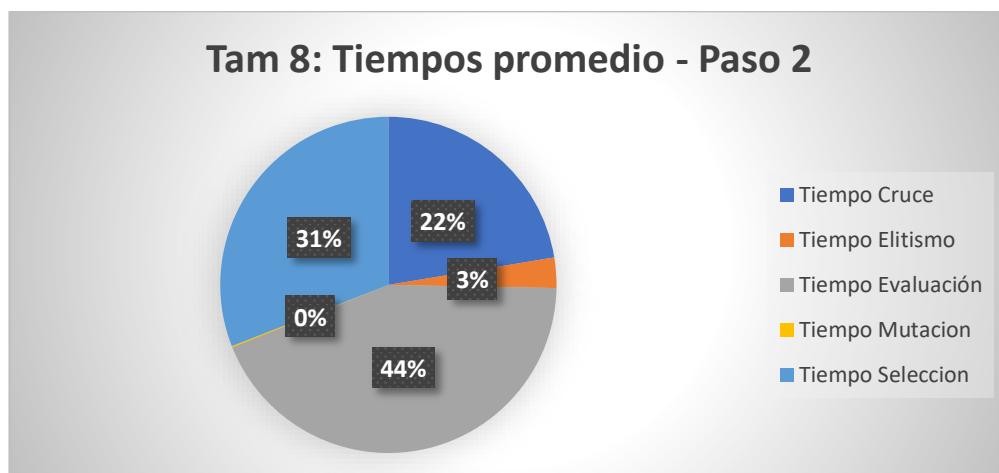


Fuente: elaboración propia.

En la figura 94 para el paso 2; se observa que en promedio el tiempo de cruce fue del 22%, el de mutación 0.13%, el de elitismo del 3%, el de selección 31% y el de evaluación de la función de adaptación es del 44%.

Figura 94

Tam 8: Tiempos promedio (porcentual) – paso 2



Fuente: elaboración propia.

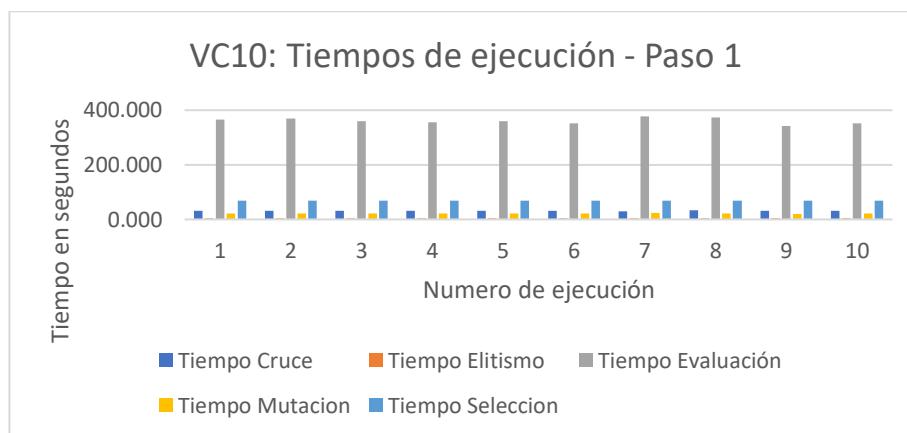
4.2.2 Caso II: van Camp – vC10

Paso 1: Buscar el árbol con el mejor potencial geométrico

En la figura 95 se presenta los resultados de una combinación de $p_{\text{Cruce}} = 0.8$, $p_{\text{Mutación}} = 0.5$; se aplican 10 réplicas.

Figura 95

vC10: Tiempos de ejecución para 10 réplicas – Paso 1

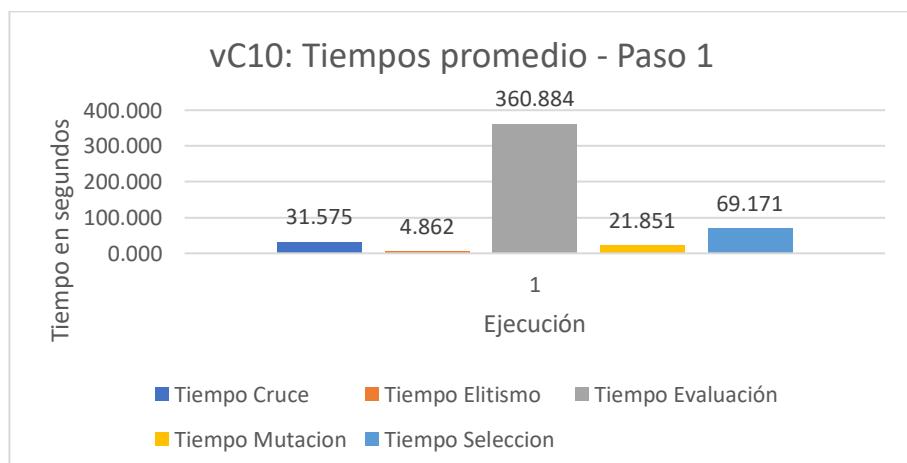


Fuente: elaboración propia

En la figura 96 presenta el gráfico de barrar con los tiempos promedios de 10 ejecuciones (según la figura 95).

Figura 96

vC10: Tiempos promedio – Paso 1

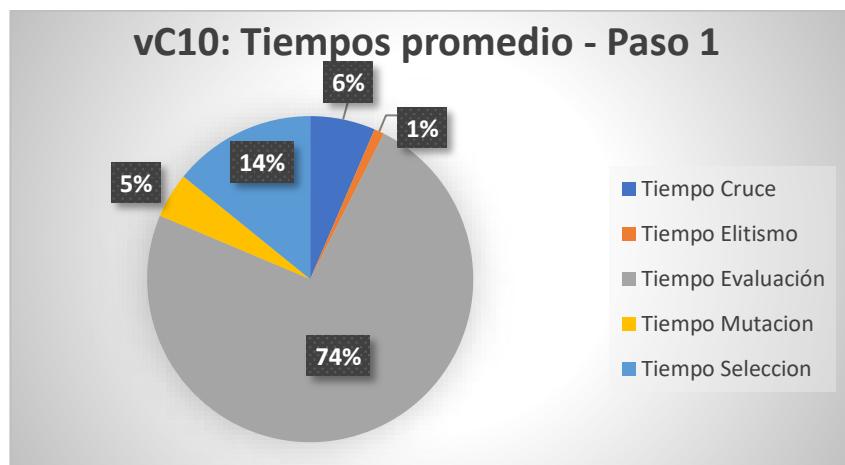


Fuente: elaboración propia

En la figura 97 se observa que en promedio el tiempo de cruce fue del 6%, el de mutación 5%, el de elitismo del 1%, el de selección 14% y el de evaluación de la función de adaptación es del 74%.

Figura 97

vC10: Tiempos promedio (porcentual) – Paso 1



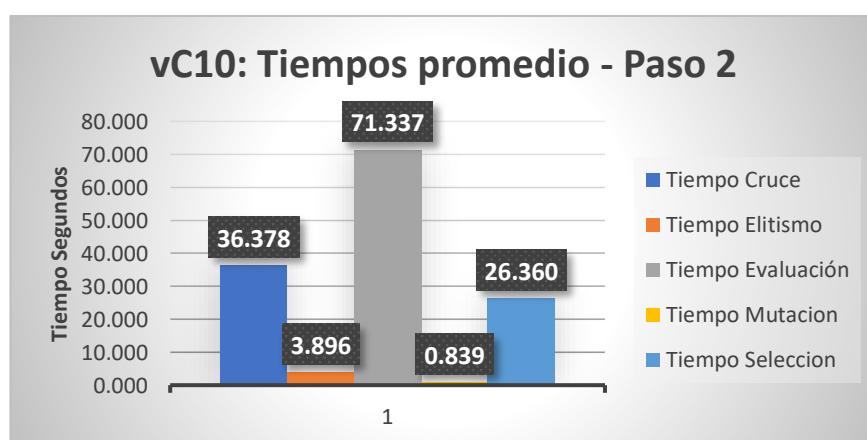
Fuente: elaboración propia

Paso 2: Buscar el árbol de cortes que represente la mejor solución

En la figura 98 se presenta el gráfico de barras de los tiempos promedio en 14 ejecuciones del paso 2.

Figura 98

vC10: Tiempos promedio – Paso 2

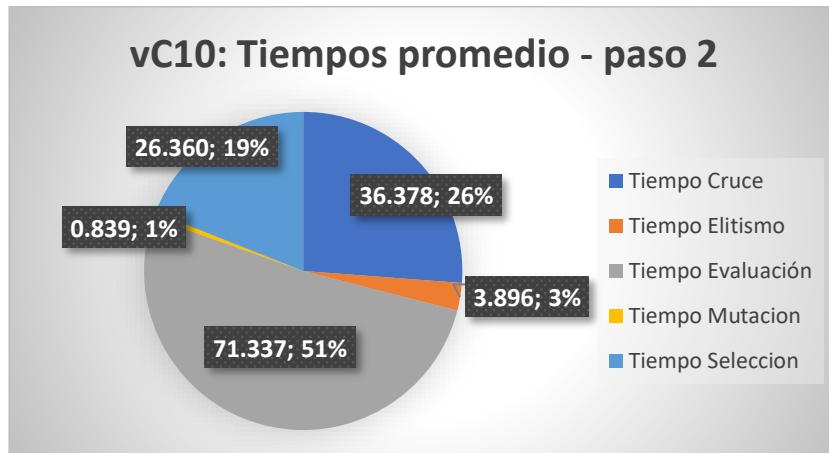


Fuente: elaboración propia

En la figura 99 para el paso 2; se observa que en promedio el tiempo de cruce fue del 26%, el de mutación 1%, el de elitismo del 3%, el de selección 19% y el de evaluación de la función de adaptación es del 51%.

Figura 99

vC10: Tiempos promedio (porcentual) – Paso 2



Fuente: elaboración propia

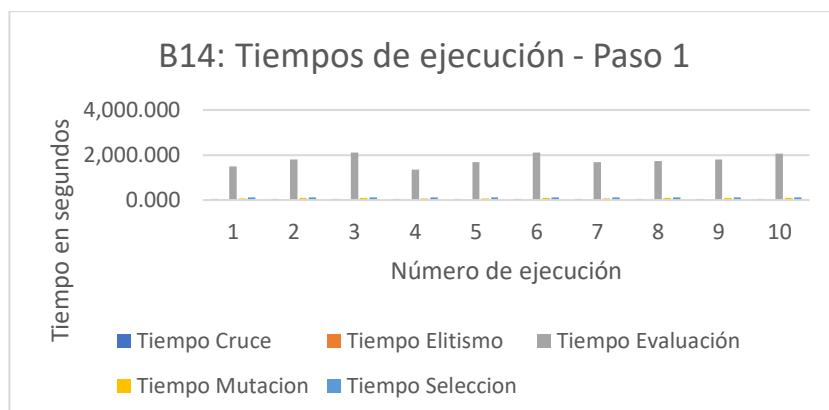
4.2.3 Caso III: Bazaraa 14 – B14

Paso 1: Buscar el árbol con el mejor potencial geométrico

En la figura 100 se presenta los resultados de una combinación de $p_{\text{Cruce}} = 0.8$, $p_{\text{Mutación}} = 0.5$; se aplican 10 réplicas.

Figura 100

B14: Tiempos de ejecución para 10 réplicas – Paso 1

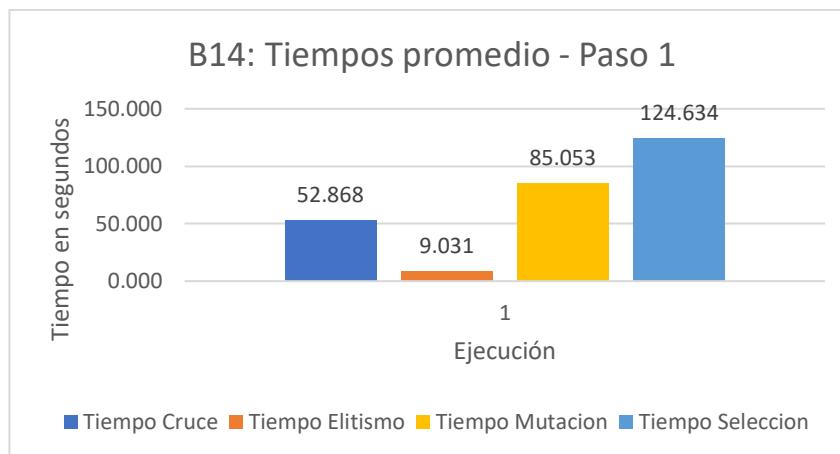


Fuente: elaboración propia

En la figura 101 presenta el gráfico de barras con los tiempos promedios de 10 ejecuciones (según la figura 100).

Figura 101

B14: Tiempos promedio – Paso 1

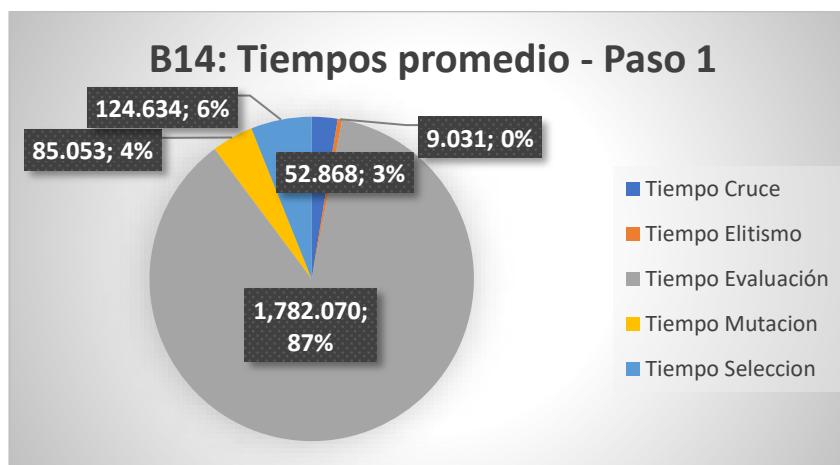


Fuente: elaboración propia

En la figura 102 se observa que en promedio el tiempo de cruce fue del 9%, el de mutación 4%, el de elitismo del 0.44%, el de selección 6% y el de evaluación de la función de adaptación es del 87%.

Figura 102

B14 Tiempos promedio (porcentual) – Paso 1



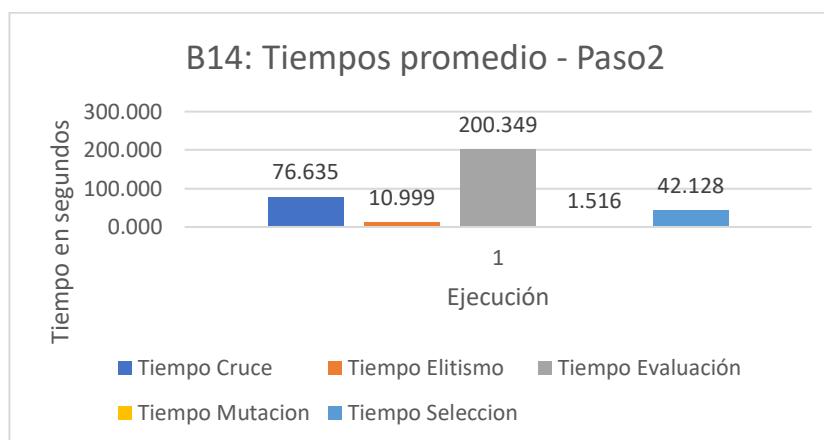
Fuente: elaboración propia

Paso 2: Buscar el árbol de cortes que represente la mejor solución

En la figura 103 se presenta el gráfico de barras de los tiempos promedio en 14 ejecuciones del paso 2.

Figura 103

B14: Tiempos promedio – Paso 2

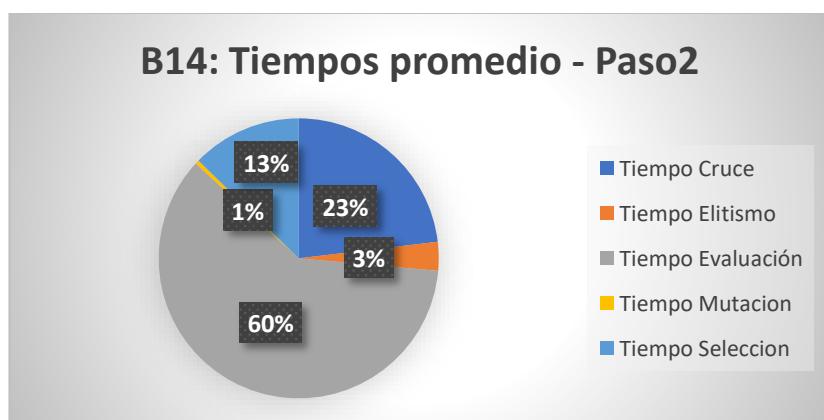


Fuente: elaboración propia

Para el paso 2, en la figura 104; se observa que en promedio el tiempo de cruce fue del 23%, el de mutación 1%, el de elitismo del 3%, el de selección 13% y el de evaluación de la función de adaptación es del 60%.

Figura 104

B14: Tiempos promedio (porcentual)– Paso 2



Fuente: elaboración propia

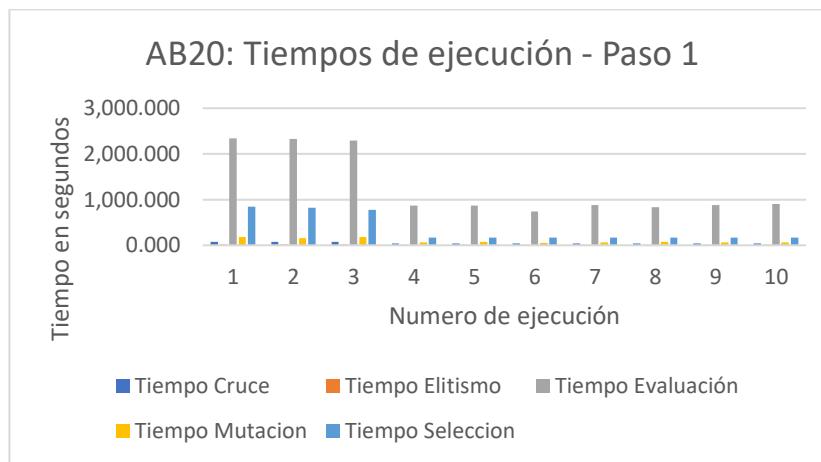
4.2.4 Caso IV: Armour y Buffa 20 – AB20

Paso 1: Buscar el árbol con el mejor potencial geométrico

En la figura 105 se presenta los resultados de una combinación de $p_{Cruce} = 0.6$, $p_{Mutación} = 0.7$; se aplican 10 réplicas.

Figura 105

AB20: Tiempos de ejecución para 10 réplicas – Paso 1

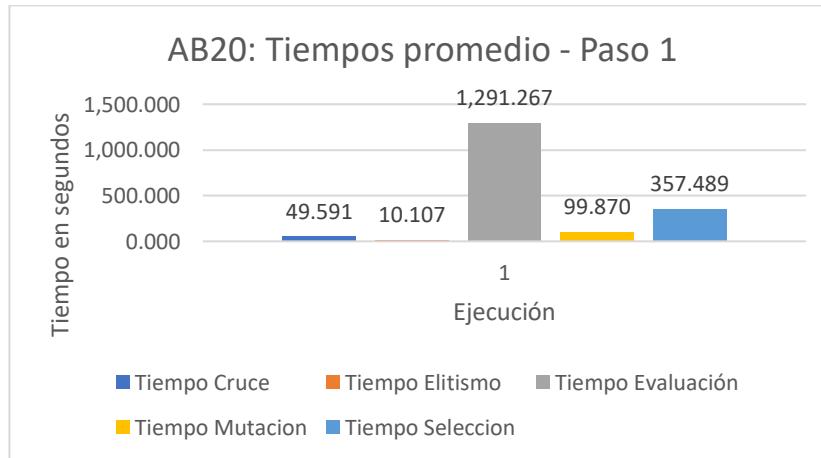


Fuente: elaboración propia

En la figura 106 presenta el gráfico de barras con los tiempos promedios de 10 ejecuciones (según la figura 105).

Figura 106

AB20: Tiempos promedio – Paso 1

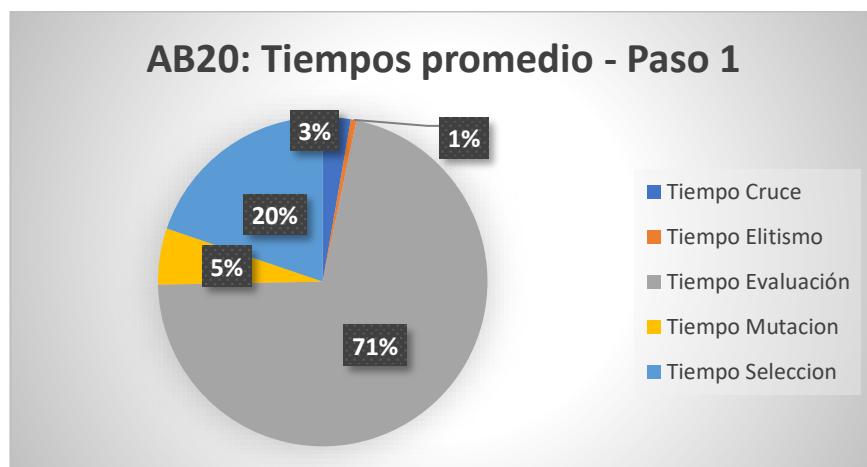


Fuente: elaboración propia

En la figura 107 se observa que en promedio el tiempo de cruce fue del 3%, el de mutación 5%, el de elitismo del 1%, el de selección 20% y el de evaluación de la función de adaptación es del 71%.

Figura 107

AB20: Tiempos promedio (porcentual) – Paso 1



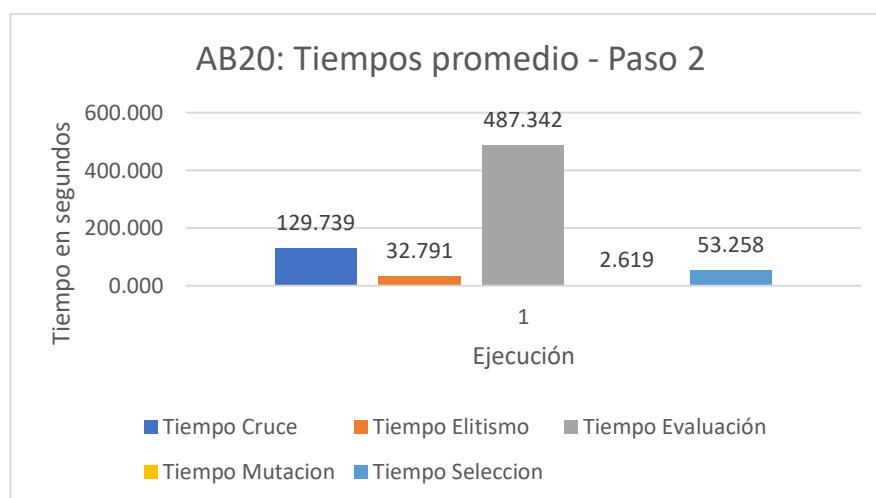
Fuente: elaboración propia

Paso 2: Buscar el árbol de cortes que represente la mejor solución

En la figura 108 se presenta el gráfico de barras de los tiempos promedio en 14 ejecuciones del paso 2.

Figura 108

AB20: Tiempos promedio – Paso 2

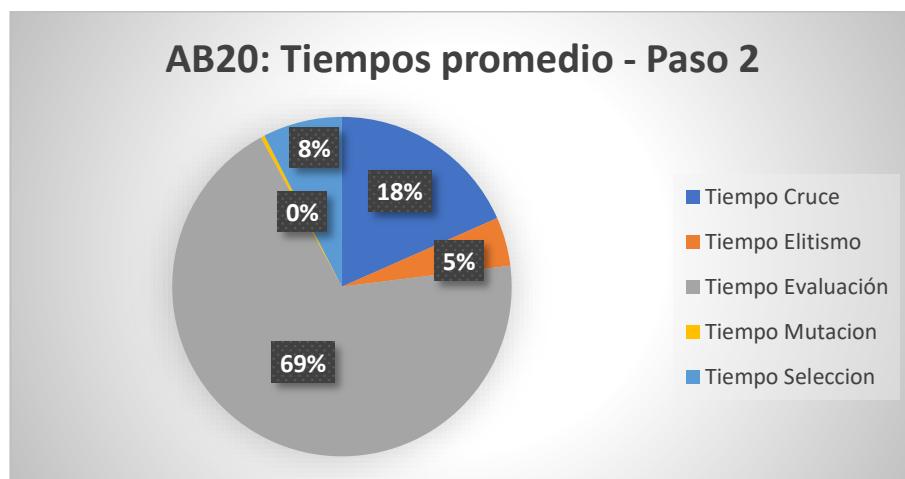


Fuente: elaboración propia

Para el paso 2, en la figura 109; se observa que en promedio el tiempo de cruce fue del 18%, el de mutación 0.37%, el de elitismo del 5%, el de selección 8% y el de evaluación de la función de adaptación es del 69%.

Figura 109

AB20: Tiempos promedio (porcentual) – Paso 2



Fuente: elaboración propia

4.2.5 Tiempos promedios totales

Conocidos los tiempos promedios en cada paso, es pertinente presentar los tiempos totales de Algocym. En la tabla 50 se presenta el resumen de los tiempos de las operaciones de cruce, elitismo, evaluación, mutación, selección y el tiempo total en cada caso para el paso 1.

Tabla 50

Tiempos promedio de ejecución de los cuatro casos – Paso 1

Caso	cruce	elitismo	evaluación	mutación	selección	Total
I. Tam 8	8.715	1.409	86.601	0.517	61.295	158.537
II. vCamp 10	31.775	4.862	360.884	21.851	69.771	489.143
III. Bazaraa 14	52.868	9.031	1,782.070	85.053	124.634	2,053.656
IV. Armour y Buffa 20	49.591	10.107	1,291.267	99.870	357.489	1,808.324

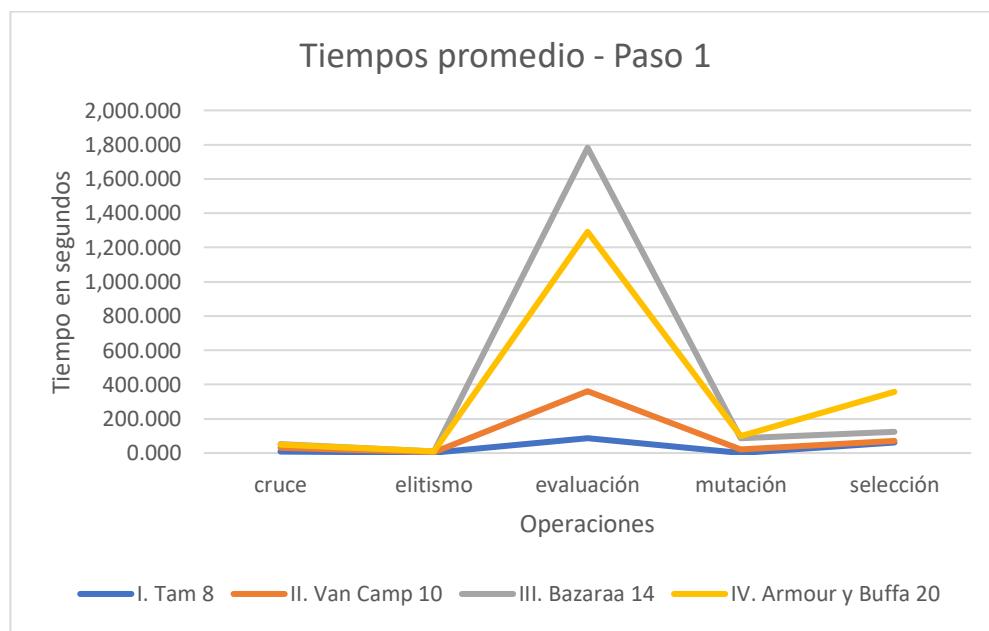
Fuente: elaboración propia

De acuerdo con la tabla 50, en los algoritmos genéticos de esperar que los procesos de evaluación y selección sean los que insumen más tiempo con respecto a los otros procesos.

De acuerdo con la figura 110 los procesos de evaluación y selección son los que insumen mayor tiempo en relación con el cruce, mutación y elitismo.

Figura 110

Gráfico lineal de tiempos promedio de los cuatro casos – Paso 1



Fuente: elaboración propia

Los tiempos promedios presentados para el paso 1 (tabla 50), permiten elaborar la tabla 51 donde se aprecia el equivalente en porcentajes del tiempo total para cada caso y los tiempos promedio generales para cada operación que realiza el algoritmo.

Tabla 51*Tiempos promedios de ejecución expresados en porcentajes – Paso 1*

Caso	cruce	elitismo	evaluación	mutación	selección	Total
I. Tam 8	4.80%	1.00%	54.80%	0.60%	38.80%	100.00%
II. Van Camp 10	6.00%	1.00%	74.00%	5.00%	14.00%	100.00%
III. Bazaraa 14	3.00%	0.44%	86.56%	4.00%	6.00%	100.00%
IV. Armour y Buffa 20	3.00%	1.00%	71.00%	5.00%	20.00%	100.00%
Porcentaje promedio	4.20%	0.86%	71.59%	3.65%	19.70%	100.00%

Fuente: elaboración propia

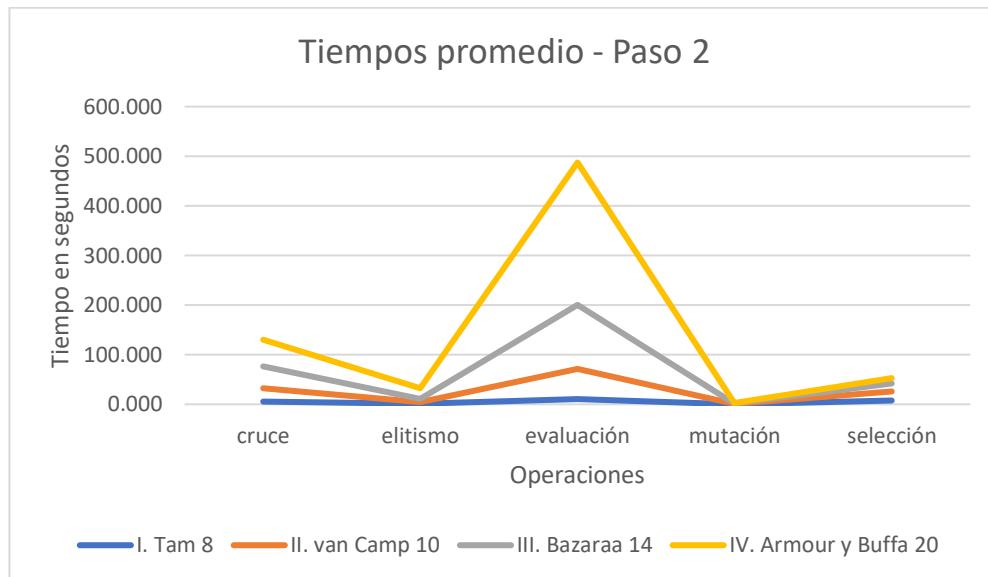
En la tabla 52 se presenta el resumen de los tiempos de las operaciones de cruce, elitismo, evaluación, mutación, selección y el tiempo total en cada caso para el paso 2.

Tabla 52*Tiempos promedio de ejecución de los cuatro casos – Paso 2*

Caso	cruce	elitismo	evaluación	mutación	selección	Total
I. Tam 8	5.413	0.705	10.551	0.031	7.478	24.178
II. van Camp 10	32.378	3.896	71.337	0.839	26.360	134.810
III. Bazaraa 14	76.635	10.999	200.349	1.516	42.128	331.627
IV. Armour y Buffa 20	129.739	32.791	487.342	2.619	53.258	705.749

Fuente: elaboración propia

Tal como se observa en la figura 111 las operaciones de evaluación y cruce son los que insumen mayor tiempo en relación con la selección, elitismo, y mutación.

Figura 111*Gráfico lineal de tiempos promedio de los cuatro casos – Paso 2*

Fuente: elaboración propia

Tomando los tiempos promedios presentados para el paso 2 (tabla 52), se presenta la tabla 53 donde se aprecia el equivalente en porcentajes del tiempo total para cada caso y los tiempos promedio generales para cada operación que realiza el algoritmo en este paso. Para el paso 2 los procesos de evaluación, cruce y selección demandan más tiempo que los de elitismo y mutación.

Tabla 53*Tiempos promedios de ejecución expresados en porcentajes – Paso 2*

Caso	cruce	elitismo	evaluación	mutación	selección	Total
I. Tam 8	22.00%	3.00%	44.00%	0.13%	30.87%	100.00%
II. van Camp 10	26.00%	3.00%	51.00%	1.00%	19.00%	100.00%
III. Bazaraa 14	23.00%	3.00%	60.00%	1.00%	13.00%	100.00%
IV. Armour y Buffa 20	18.00%	5.00%	68.63%	0.37%	8.00%	100.00%
Porcentaje promedio	22.25%	3.50%	56.00%	0.63%	17.72%	100.00%

Fuente: elaboración propia

Teniendo los tiempos promedio de cada paso se presenta la tabla 54 que resume los tiempos promedio totales en segundos. De acuerdo con la ecuación 17 y la figura 14, estos resultados confirman el hecho que a mayor número de instalaciones es mayor el tiempo de procesamiento de búsqueda de solución.

Tabla 54

Tiempos promedios totales

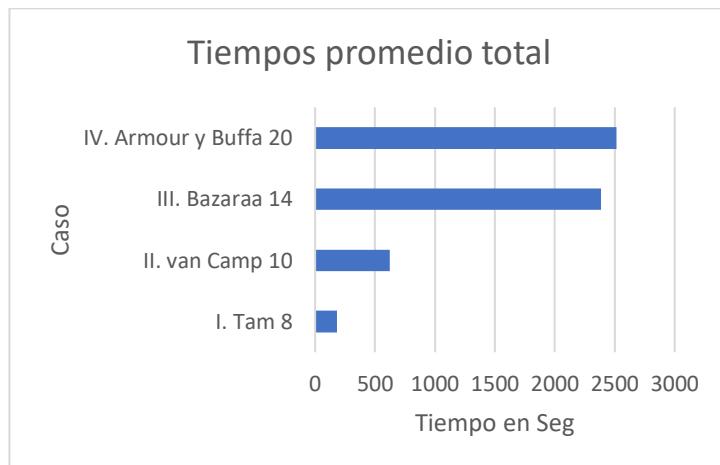
Caso	Tiempo promedio total en Seg
I. Tam 8	182.72
II. van Camp 10	623.95
III. Bazaraa 14	2,385.28
IV. Armour y Buffa 20	2,514.07

Fuente: elaboración propia

Tomando los datos de la tabla 54, se presenta en la figura 112 el histograma de los tiempos promedios totales en cada caso, corroborando la afirmación del párrafo anterior.

Figura 112

Histograma de los tiempos promedios totales



Fuente: elaboración propia

4.3 Comparación de resultados

Para realizar la comparación de resultados del algoritmo es pertinente establecer la certeza de los mismos conjuntos de datos (matriz de flujos, dimensiones y áreas, ratios, matriz de flujos, etc.) y también se debe asegurar similitud de condiciones de ejecución (hardware) tanto para el algoritmo propuesto como para los de aquellos autores que resuelven los casos presentados en este documento, a fin de obtener comparaciones válidas en cuanto a los resultados obtenidos. No obstante, es deseable proponer una comparación de resultados de los casos del presente documento, con otros trabajos.

La tabla 55 presenta los datos iniciales de los cuatro casos estudiados en cuanto a: número de instalaciones, dimensiones del layout, espacio sin asignar en porcentaje, restricciones de forma, referencia de datos, según la propuesta y solución inicial de sus autores. La columna de la derecha en esta tabla presenta el porcentaje de espacio sin asignar obtenido por Algocym el cual en todos los casos de estudio es de cero; esto significa que la propuesta utiliza el cien por ciento del área asignada teniendo en cuenta la ratio total del área y las ratios mínimas y máximas de cada instalación. Se destaca que Algocym considera de suma importancia el cumplimiento de las restricciones geométricas y relacionales, en la búsqueda de la solución óptima.

Tabla 55

Resumen de datos iniciales de los cuatro casos

Problema	Número de instalaciones	Dimensiones del Layout WxH	Espacio sin asignar (%)	Restricción de forma	Referencia de datos	Espacio sin asignar con Algocym(%)
Tam 8	8	14.57 x 9.7	14.88	Rmin = 1	Tam K.Y. & Li, S.G. 1991	0
van Camp 10	10	51 x 25	0	Rmin = 5	van Camp et al. 1992	0
Bazaraa 14	14	9 x 7	2	Rmin = 1	Bazaraa, 1975	0
Armour & Buffa 20	20	30 X 20	0	Rmax = 4	Armour & Buffa, 1963	0

Fuente: elaboración propia

En la tabla 55 se observa que, a diferencia de las propuestas iniciales, Algocym consigue que el espacio sin asignar sea cero; esto significa que el algoritmo obtiene el 100% de asignación de la instalación cumpliendo las restricciones geométricas impuestas por el problema.

Es pertinente recordar que de acuerdo con la tabla 2, la aplicación de los algoritmos genéticos (GA) para resolver FLP se realiza con técnicas como: QAP (incluye Unequal QAP), MIP, LP, Slicing Tree, DP, y simulación (ver 2.3.1). De todas estas técnicas como se presenta en el presente documento, el algoritmo en estudio aplica algoritmos genéticos con la estructura de árboles de corte en dos fases o dos pasos.

Para establecer la comparación de los valores de los costos o función de adaptación de la propuesta con otros autores se presenta la tabla 56. En ella, se consigna el autor, año, la técnica usada y el valor óptimo encontrado. Lo cierto es que no todos los autores han trabajado con los mismos casos de estudio de la presente tesis. De estos, quienes han usado GA con árboles de corte son Tam K.Y, 1991 y Diego-Más, 2006, por ello estos pueden ser referentes que permiten una comparación aceptable. Así, para Tam K.Y., 1991; se tiene para Tam 8 (T8) un valor de 878.00 y Algocym con un valor de 88.98, lo cual equivale a una reducción de 89.87%.

Tabla 56

Comparación de valores de la función de adaptación con otros autores

Problema	Mejor valor de la función de adaptación						
	Tam. K.Y.,199 1 Using GA with Slicing Tree	Shebanie II, 2004 QAP Block Layout GA using Flex Bay Structure	Liu & Meller, 2007 Using MIP model with GA	Diego- Mas, 2006 Using Two-Step GA with Slicing Tree	Ripon et al., 2013 Using Adaptive variable neighborhood search	Gonçalves,J. & Resende,M.; 2015 Using a biased Ran- dom-key GA	Algocym (Ruiz,E. 2021) Using Two-Step GA with Slicing Tree
Tam 8	878.00	-	-	-	-	-	88.98
van Camp 10	-	4,632.24	-	-	19,901.32	19,951.17	98.51
Bazaraa 14	-	4,991.78	5,004.00	-	4,712.33	4,628.79	11,213.90
Armour & Buffa 20	16,393.0 0	462.49	5,668.00	11,432.34	3,878.24	5,021.17	10,347.87

Fuente: elaboración propia

Continuando con el análisis de la tabla 56, en el caso de Armour y Buffa (AB20) se reporta un valor de 16,393.00, en tanto que Algocym obtiene un valor de 10,347.87; lo cual se traduce en una reducción o mejora de 36.88%. De otro lado Diego-Más,2006; trabaja en común con AB20 y obtiene un valor de 11,432.34, en tanto que Algocym obtiene un valor de 10,347.87; lo que significa una reducción o mejora de 9.49%. Por otro lado, Ripon, 2013; Gonçalves, 2015 y Liu & Meller, 2007; obtienen valores semejantes y cercanos entre ellos.

Respecto a los valores de los otros autores reportados en la tabla 56 se consideran referenciales, aunque no necesariamente comparables con el trabajo aquí presentado, pues si bien es cierto ellos aplican algoritmos genéticos, difieren en la técnica con el cual se combinan; esto explicaría la variabilidad de los resultados obtenidos por cada autor.

En cuanto a los tiempos de ejecución en la búsqueda de la solución es pertinente indicar que estos dependen de más de un factor como son: características del hardware, tamaño de la muestra, número de iteraciones (generaciones), intensidad de los operadores de cruce, mutación y los procesos de evaluación. Los detalles de los tiempos de Algocym se han presentado en el inciso 4.2 para cada una de estas operaciones en los cuatro casos de estudio.

La Tabla 57 presenta los tiempos en segundos reportados en la literatura del FLP y los tiempos de la propuesta. En esta tabla se tiene el autor, año, técnica usada y el tiempo promedio en segundos incurrido en hallar la solución.

Tabla 57*Tiempos en segundos empleados en obtener la solución*

Problema	Tiempo de la solución en segundos						
	Tam. K.Y.,1991 Using GA with Slicing Tree	Shebanie II, 2004 QAP Block Lay- out GA using Flex Bay Struc- ture	Liu & Meller, 2007 Using MIP model with GA	Diego- Mas, 2006 Using Two-Step GA with Slicing Tree	Ripon et al., 2013 Using Adaptive variable neighborhood search	Gonçalves,J. & Resende,M.; 2015 Using a biased Ran- dom-key GA	Algocym (Ruiz,E. 2021) Using Two-Step GA with Slicing Tree
Tam 8	12.45	-	-	-	-	-	182.72
van Camp 10	-	6,696.00	6,660.00	-	14.29	46.4	623.95
Bazaraa 14	-	28,764.00	2,880.00	-	46.23	160.46	2,385.28
Armour & Buffa 20	5.35	41,832.00	12,456.00	213.41	367.2	426.09	2,514.07

Fuente: elaboración propia

Comparando resultados se tiene que (Ripon et al.,2013) aplica un algoritmo genético adaptativo del tipo VNS (búsqueda del vecino más cercano) presenta los mejores tiempos en los casos vC10, B14 y AB20. En tanto (Gonçalves, J. & Resende, M., 2015) que aplican un algoritmo del tipo Biased Random-key GA con MIP obtienen los segundos mejores tiempos. Los resultados de Algocym en cuanto a los tiempos insumidos en la búsqueda de la solución óptima pueden compararse con los presentados por (Liu & Meller, 2007). Así, se tiene para VC10 los autores obtienen 6660 segundos frente a Algocym que obtiene 623.95 segundos los cual es una mejora evidente. En el caso B14 los autores reportan 2,880.00 segundos y Algocym obtiene 2385.28 segundos, lo cual representa una mejora del 17.18%. En el caso AB20 los autores reportan 12,456.00 segundos y Algocym obtiene 2,514.07 segundos lo cual es una mejora del 79.82%.

Los resultados de (Shebanie II, 2004) pueden compararse con los de (Liu & Meller, 2007) siendo en general estos segundos, mejores que el primero.

4.4 Aportes de la tesis

El desarrollo del algoritmo propuesto está basado en las publicaciones de Tam K.Y. & Li, 1991, 1992, 1998 y Diego-Más, 2006 y 2009. En las propuestas iniciales Tam, plantea la utilización del árbol de cortes con algoritmos genéticos, mostrando la codificación de los árboles, su representación y solución para el FLP, propuesta que es mejorada en 1998 considerando las restricciones geométricas (restricciones de forma) de las instalaciones y el análisis estadístico experimental de la aplicación para este tipo de problema. Diego-Más, hace suya la propuesta de Tam, y junto con la propuesta de Santamarina M.C., 1995 titulada "Métodos de optimización en la generación de distribuciones de plantas industriales mediante la aplicación de algoritmos genéticos y técnicas basadas en árboles de corte" (Tesis Doctoral), propone una mejora centrándose en la importancia de la geometría de las actividades para la distribución en planta en instalaciones industriales.

Tomando los trabajos anteriores se elabora Algocym respetando la geometría de las actividades mediante los criterios geométricos y relacionales, así mismo se crea una base de datos que guarda las soluciones obtenidas en cada generación lo cual permitirá su uso con fines de un análisis posterior.

Como aporte de la presente tesis se tiene el uso y aplicación de programación concurrente, que permite lanzar un determinado número de ejecuciones del algoritmo logrando el procesamiento en paralelo de las corridas para obtener resultados en simultáneo (ver figura 65).

En 3.5.1 se tiene la ecuación 17, tabla 6, y figura 14; que muestran que a medida que el número n de instalaciones aumenta, se incrementa considerablemente el número de árboles de corte candidatos a solución, lo que significa que la complejidad del problema, su procesamiento (gran volumen de cálculo) y tiempo de solución va en aumento. Diego-Más en su informe reporta el uso de un servidor y una red de doce computadoras dedicadas a la ejecución de su propuesta.

En 3.6.1, 3.6.2, 3.6.3 y 3.6.4 se presentan para cada caso en estudio los datos de entrada y las salidas o resultados de Algocym. De estos se puede destacar la presentación grafica o visual del árbol de cortes que representa el layout óptimo (que no lo tienen otros autores), la lista o secuencia de nodos del árbol, el tipo de corte y el valor de la función de adaptación. Adicionalmente, Algocym presenta en una caja de texto detalles del árbol optimo encontrado tales como: número de cluster, estado (0 si es nodo, 1 si es instalación) el área asignada, valor del lado, tipo de corte, valor del incumplimiento asignado a cada instalación (ver 3.6.1). También se presenta en cada caso la disposición del layout obtenido por Algocym.

En metaheurísticas es importante asegurar que el algoritmo utilizado sea capaz de explorar todo el espacio de búsqueda, para lograrlo también debe ser capaz de escapar de los óptimos locales. En este sentido Algocym demuestra que es capaz de escapar de los óptimos locales y continuar explorando el espacio de búsqueda de nuevas y mejores soluciones camino a la solución óptima. Así, en el caso T8 las figuras 26 y 28, en el caso vC10 las figuras 30 y 32, en el caso B14 las figuras 34 y 36, y finalmente en el caso AB20 las figuras 38 y 40 muestran la evolución del algoritmo en el transcurso de las generaciones mostrando la convergencia del algoritmo hacia la solución óptima.

Otro aporte importante del trabajo se indica en 3.12. Algocym se ha escrito en lenguaje Python, implementado en Odoo (una herramienta ERP de uso libre), montado en un servidor Linux Ubuntu 20.04, cuya configuración general se presenta en la tabla 24, complementándose con la herramienta PostgreSQL para gestionar las bases de datos generadas en cada caso y también con los servicios de Docker. Para hacer posible los experimentos presentados y la puesta a prueba del algoritmo, se contrató los servicios de Google Cloud. Esto permite mostrar el uso y aplicación de las nuevas herramientas de programación y tecnología en la propuesta, desarrollo e implementación de nuevas soluciones a temas complejos como el presentado en este documento de tesis.

CONCLUSIONES

1. El algoritmo genético Algocym optimiza la distribución en planta en organizaciones de manufactura. Para demostrarlo se toman cuatro casos clásicos cuyos tamaños son 8, 10, 14 y 20 instalaciones. Los datos iniciales de estos casos son: área total, área de cada instalación, ratios mínimo y máximo de cada instalación, matriz de flujo de materiales o el costo entre instalaciones; estos datos se presentan en las tablas 8 a 13. Los resultados se discuten en la sección 4.3 presentando la tabla 55 donde se muestra que la propuesta obtiene en todos los casos de estudio el 0% de espacio sin asignar; es decir, todas las instalaciones son asignadas cumpliendo con las restricciones geométricas impuestas en cada caso. La tabla 56 presenta los valores de la función de adaptación de otros autores y los obtenidos por la propuesta encontrándose mejoras frente a las propuestas de Liu & Meller, 2007 y Shebanie II, 2004.
2. La aplicación de la estructura del árbol de cortes (SST) que representa un individuo o solución permite mediante el algoritmo genético en el paso 1 encontrar el mejor árbol de cortes y a partir de este; en el paso 2 aplicar los cortes que conducen a la colocación de las instalaciones dentro del área asignada respetando las restricciones geométricas. Se considera que se tiene el mejor árbol de corte cuando el valor del incumplimiento geométrico para cada instalación es cero. La forma de determinar el mejor árbol de cortes se presenta en 2.4.1 y las fórmulas de cálculo del incumplimiento geométrico se presentan en 2.4.2. En 3.6.1, 3.6.2, 3.6.3 y 3.6.4 se presentan respectivamente los datos de entrada y las salidas de los cuatro casos de estudio. En cada caso se obtiene el área asignada a cada instalación y los valores del

incumplimiento geométrico siendo este valor cero, lo cual permiten aseverar que se optimiza el área de la distribución en planta.

3. La elaboración del algoritmo genético Algocym permite alcanzar una solución óptima al problema de distribución en planta. Al respecto en la tabla 55 se muestra para cada uno de los cuatro casos en estudio un porcentaje de espacio sin asignar con valor cero; esto implica que el algoritmo propuesto consigue la colocación de todas las instalaciones dentro del área total, siendo su incumplimiento geométrico 0 para cada instalación, respetando las restricciones geométricas impuestas por el problema.

4. Los experimentos numéricos permiten cuantificar los resultados del algoritmo genético Algocym. La tabla 26 presenta el diseño de experimentos para determinar el tamaño de la muestra. Los resultados numéricos de los costos de la función de adaptación que obtiene Algocym para tamaños de 30, 60 y 100 individuos se presentan en las tablas 60, 61 y 62 respectivamente (ver anexo 3). Hecho el análisis de varianzas se concluye que un tamaño de muestra igual a 30 individuos es significativo.

Para averiguar la influencia que ejercen las variables independientes (cruce y mutación) sobre la variable dependiente (resultados del algoritmo genético ALGOCYM); se plantean experimentos numéricos, en la tabla 29 se presenta el diseño de experimentos para encontrar el mejor árbol de cortes, allí se tiene para el operador de cruce niveles de 60, 70, 80 y 90 por ciento; para el operador de mutación niveles de 5, 10, 20, 30, 40 por ciento o más. En ese orden de ideas para cada caso en estudio se realiza en cada una de estas combinaciones, 10 ejecuciones para el paso 1, y 14 ejecuciones para el paso 2. Los valores de la función de adaptación son presentados en las tablas 22, 23 para AB20; las tablas 63, 64 muestran los resultados para T8 (ver anexo 3); las tablas 65, 66 ilustran los resultados para vC10 (ver anexo 4) y las tablas 67, 68 presentan los resultados de B14.

Realizado el análisis de varianza a los resultados encontrados para cada caso, se concluye que el operador de cruce en niveles de 60, 70, 80 y 90 por ciento, es no significativo, mientras que el operador de mutación con un nivel de porcentaje de 5% es significativo.

De otro lado en cada uno de los cuatro casos se tienen los tiempos promedios de ejecución insumidos por Algocym en el paso 1 (ver tabla 50), en el paso 2 (ver tabla 52) y finalmente en la tabla 54 se presentan los tiempos promedio totales de los casos en estudio. En 4.2 se realiza el análisis y discusión de los tiempos de ejecución, de allí se puede concluir que para el paso 1, el tiempo promedio de las operaciones de evaluación es de 71%, la selección 19.7% , cruce 4.2%, mutación 3.65% y elitismo 0.86%; esto significa que las operaciones de evaluación y selección insumen mayor tiempo frente a las de cruce, mutación y elitismo (tabla 50). En tanto para el paso 2 (tabla 52), en tiempos promedio se tiene: evaluación 56%, cruce 22.5%, selección 17.72%, elitismo 3.5%, mutación 0.63%; lo que significa que en el paso 2, las operaciones de evaluación de evaluación, cruce y selección insumen mayor tiempo frente a las operaciones de mutación y elitismo. Finalmente, la tabla 54 presenta los promedios totales de ambos pasos en cada caso.

5. El diseño e implementación de la aplicación informática permite probar la bondad del algoritmo genético Algocym. En la sección 3.12.1, se establecen tres objetivos:

(1) Crear un software a medida para la resolución del problema FLP.-

Como se ha expuesto en dicha sección se ha creado un módulo de nombre Algocym que es la aplicación informática escrita en lenguaje de programación Python, para usarse sobre Odoo (un ERP de software libre), el que funciona sobre el browser Google Chrome, sobre el cual se permite el ingreso o edición de los datos del problema FLP a resolver, y también muestra los resultados de la

aplicación. Las figuras 55 a 86 presentan en mayor detalle el uso de la aplicación informática y su convergencia a la solución.

- (2) *Ejecutar la aplicación aplicando programación concurrente y cloud computing.*- Dado la complejidad de este tipo de problemas y el planteamiento experimental cuyo “diseño factorial de dos factores aleatorios” propuesto por (Montgomery, 2004) se requiere de un servidor potente y una red de computadoras para su realización. Por ello se configura la aplicación informática que utiliza programación concurrente y a su vez se ejecuta mediante los servicios de Google Cloud Platform (GCP) montado en un servidor Linux 20.04 y una red de CPU virtuales. La tabla 24 presenta la configuración del servidor en la nube.
- (3) Almacenar los resultados experimentales en una base datos de manera tal que estén disponibles para su uso y explotación posterior.- Para el cumplimiento de este objetivo se utiliza el gestor de base de datos PostgreSQL 2021, una herramienta del software libre para bases de datos medianas a grandes. Así para cada caso la aplicación informática genera una base de datos con todas las soluciones exploradas hasta llegar a la convergencia a la solución.

Como se ha expuesto el cumplimiento de estos objetivos se concluye que la bondad del algoritmo genético propuesto SI consigue llegar a la solución óptima.

RECOMENDACIONES

1. Se recomienda aplicar el algoritmo Algocym para casos de tamaño mayor como 30, 40 o más instalaciones.
2. El algoritmo presentado en esta investigación; por su naturaleza metaheurística proporciona buenas soluciones a problemas N-P difíciles como es el caso del FLP. En ese sentido es posible aplicar la metodología aquí expuesta a problemas como el diseño de colocación de chips en una tarjeta, el de cortes rectangulares en una plancha, el diseño del layout de una página web.
3. Como trabajos futuros se puede ampliar el estudio a fin de contemplar el layout de instalaciones en 3D.

REFERENCIAS

- Aiello, G., Enea, M., Galante, G., & La Scalia, G. (2013). Multi objective genetic algorithms for unequal area facility layout problems: A survey. *Proceedings of the Summer School Francesco Turco, 11-13-Sept*, 95–100.
- Aiello, Giuseppe, La Scalia, G., & Enea, M. (2012). A multi objective genetic algorithm for the facility layout problem based upon slicing structure encoding. *Expert Systems with Applications*, 39(12), 10352–10358. <https://doi.org/10.1016/j.eswa.2012.01.125>
- Aiello, Giussepe, La Scalia, G., & Enea, M. (2013). A non dominated ranking Multi Objective Genetic Algorithm and electre method for unequal area facility layout problems. *Expert Systems with Applications*, 40(12), 4812–4819. <https://doi.org/10.1016/j.eswa.2013.02.026>
- Alba, E. (2005). Parallel Metaheuristics: A New Class of Algorithms. In *John Wiley & Sons* (Vol. 47). <https://doi.org/10.1002/0471739383>
- Allahyari, M. Z., & Azab, A. (2015). A novel bi-level continuous formulation for the cellular manufacturing system facility layout problem. *Procedia CIRP*, 33, 87–92. <https://doi.org/10.1016/j.procir.2015.06.017>
- Amaral, A. R. S. (2017). A Mip Model for the Layout Problem With Departments of Unequal Area. *XL SBPO*, 2017–2028.
- Anjos, M. F., & Vieira, M. V. C. (2017). Mathematical optimization approaches for facility layout problems: The state-of-the-art and future research directions. *European Journal of Operational Research*, 261(1), 1–16. <https://doi.org/10.1016/j.ejor.2017.01.049>
- Armour, G. C. ., & Buffa, E. S. . (1963). A Heuristic Algorithm and Simulation Approach to Relative Location of Facilities Author (s): Published by :

- INFORMS Stable URL : <http://www.jstor.org/stable/2627408> Accessed : 02-05-2016 02 : 19 UTC Your use of the. *Science, Management, 9(2)*, 294–309.
- Atencio, F. N., & Rodado, D. N. (2016). A Sule's Method initiated genetic algorithm for solving QAP formulation in facility layout design: A real world application. *Journal of Theoretical and Applied Information Technology, 84(2)*, 157–196.
- Azarbonyad, H., & Babazadeh, R. (2015). A Genetic Algorithm for solving Quadratic Assignment Problem (QAP). *ArXiv Preprint ArXiv, 4*, 2–5.
- Bazaraa, M. S., & Goode, J. J. (1975). A cutting-plane algorithm for the quadratic set-covering problem. *Operations Research, 23(1)*, 150-158.
- Blum, C., Puchinger, J., Raidl, G., & Roli, A. (2008). Hybrid metaheuristics. In *Springer Optimization and Its Applications* (Vol. 45). Springer-Verlag Berlin Heidelberg. https://doi.org/10.1007/978-1-4419-1644-0_9
- Boschetti, Marco Antonio;Maniezzo, Vittorio;Roffilli, Matteo;Röhler, B. (2009). *Matheuristics : Optimization , Simulation and Control. October.* <https://doi.org/10.1007/978-3-642-04918-7>
- Burke, E., Kendall, G., Newall, J., Hart, E., Ross, P., & Schulenburg, S. (2003). Hyper-Heuristics: An Emerging Direction in Modern Search Technology. In *Handbook of Metaheuristics* (pp. 457–474). https://doi.org/10.1007/0-306-48056-5_16
- Caputo, A. C., Pelagagge, P. M., Palumbo, M., & Salini, P. (2015). Safety-based process plant layout using genetic algorithm. *Journal of Loss Prevention in the Process Industries, 34*, 139–150. <https://doi.org/10.1016/j.jlp.2015.01.021>
- Chakraborty, P. (2015). *Centre Based Placement strategy for UnEQual Area static Facility Layout Problem*. Université de Nantes.
- Chang, Y. W. (2019). *Floorplanning* (pp. 1–19).
- Chen, Yanru;Jiang, Yangsheng;Wahab, M. I.M.;Long, X. (2015). The facility layout problem in non-rectangular logistics parks with split lines. *Expert Systems with Applications, 42(21)*, 7768–7780. <https://doi.org/10.1016/j.eswa.2015.06.009>
- Chen, X., Kong, Y., Dang, L., Hou, Y., & Ye, X. (2016). Erratum: Exact and metaheuristic approaches for a bi-objective school bus scheduling

- problem(PLoS ONE 10:7(E0132600) 10.1371/journal.pone.0132600).
PLoS ONE, 11(4), 1–2. <https://doi.org/10.1371/journal.pone.0153614>
- Chraibi, A., Osman, I. H., & Kharraja, S. (2019). Adaptive layout for operating theatre in hospitals: different mathematical models for optimal layouts. *Annals of Operations Research*, 272(1–2), 493–527.
<https://doi.org/10.1007/s10479-018-2799-x>
- De Jong, K. A., & Spears, W. M. (1991). An analysis of the interacting roles of population size and crossover in genetic algorithms. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 496 LNCS, 38–47.
<https://doi.org/10.1007/BFb0029729>
- Diego-Más, J. A. (2006). *Optimización de la distribución en planta de instalaciones industriales mediante algoritmos genéticos. Aportación al control de la geometría de las actividades*.
- Diego-Mas, J. A., Santamarina-Siurana, M. C., Cloquell-Ballester, V. A., & Alcaide-Marzal, J. (2008). Slicing tree's geometric potential: An indicator for layout problems based on slicing tree structure. *International Journal of Production Research*, 46(4), 1071–1087.
<https://doi.org/10.1080/00207540600932061>
- Digalakis, J. G., & Margaritis, K. G. (2001). On benchmarking functions for genetic algorithms. *International Journal of Computer Mathematics*, 77(4), 481–506. <https://doi.org/10.1080/00207160108805080>
- Docker, L. (2021). Qué es Docker y cómo funciona, introducción a Docker. Recuperado 1 de febrero de 2021, de Servidores Dedicados Administrados website: <https://www.servidoresadmin.com/que-es-docker-y-como-funciona-introduccion-a-docker/>
- Doerner, K., Focke, A., & Gutjahr, W. J. (2007). Multicriteria tour planning for mobile healthcare facilities in a developing country. *European Journal of Operational Research*, 179(3), 1078–1096.
<https://doi.org/10.1016/j.ejor.2005.10.067>
- Drira, A., Pierreval, H., & Hajri-Gabouj, S. (2007). Facility layout problems: A survey. *Annual Reviews in Control*, 31(2), 255–267.
<https://doi.org/10.1016/j.arcontrol.2007.04.001>
- Erfani, B., Ebrahimnejad, S., & Moosavi, A. (2020). An Integrated Dynamic

- Facility Layout and Job Shop Scheduling Problem: A Hybrid NSGA-II and Local Search Algorithm. *Journal of Industrial and Management Optimization*, 16(4), 1801–1834. <https://doi.org/10.3934/jimo.2019030>
- Fortnow, L. (2013). *The Golden Ticket: P, NP, and the Search for the Impossible*. Princeton University Press.
- Fowosere, S. O. (2017). *Solving the Facility Layout Problem Using Genetic and Progressive Algorithms*. University of Regina.
- García-Hernández, L., Palomo-Romero, J. M., Salas-Morera, L., Arauzo-Azofra, A., & Pierreval, H. (2015). A novel hybrid evolutionary approach for capturing decision maker knowledge into the unequal area facility layout problem. *Expert Systems with Applications*, 42(10), 4697–4708. <https://doi.org/10.1016/j.eswa.2015.01.037>
- Garcia-Hernandez, L., Salas-Morera, L., Carmona-Munoz, C., Abraham, A., & Salcedo-Sanz, S. (2020). A Hybrid Coral Reefs Optimization-Variable Neighborhood Search Approach for the Unequal Area Facility Layout Problem. *IEEE Access*, 8(1), 134042–134050. <https://doi.org/10.1109/ACCESS.2020.3010577>
- Ghosal, P., Samanta, T., Rahaman, H., & Dasgupta, P. (2005). Recent trends in the application of meta-heuristics to VLSI layout design. *Proceedings of the 2nd Indian International Conference on Artificial Intelligence, IICAI 2005*, 232–251.
- Goldberg, D. E. (1989). *Genetic Algorithms in Search, Optimization and Machine Learning* (1st ed.). Adisson-Wesley.
- Gómez-Cruz, N. A., & Maldonado, C. E. (2011). Sistemas bio-inspirados: un marco teórico para la ingeniería de sistemas complejos. *Ingeniería de Sistemas Complejos. Compilación de Las Conferencias Presentadas En La Cuarta Asamblea de La Red Cartagena de Ingeniería*.
- Gonçalves, J. F., & Resende, M. G. C. (2015). A biased random-key genetic algorithm for the unequal area facility layout problem. *European Journal of Operational Research*, 246(1), 86–107. <https://doi.org/10.1016/j.ejor.2015.04.029>
- Google cloud. (2021). Recuperado 1 de febrero de 2021, de Google Cloud Web Services website: <https://cloud.google.com/>
- Grefenstette, J. J. (1986). Optimization of control parameters for genetic

- algorithms. *IEEE Transactions on systems, man, and cybernetics*, 16(1), 122-128.
- Hasda, R. K. (2017). *Contribution to the optimization of Unequal Area*. Ecole centrale de Nantes.
- Hasda, R. K., Bhattacharjya, R. K., & Bennis, F. (2017). Modified genetic algorithms for solving facility layout problems. *International Journal on Interactive Design and Manufacturing*, 11(3), 713–725.
<https://doi.org/10.1007/s12008-016-0362-z>
- Hernández-Sampieri, R., & Mendoza, C. (2018). Metodología de la investigación. Las rutas cuantitativa, cualitativa y mixta. In M. G. Hill (Ed.), *Metodología de la investigación. Las rutas cuantitativa, cualitativa y mixta* (1st ed.).
- Hernández Gress, E. S., Mora-Vargas, J., Herrera Del Canto, L. E., & Díaz-Santillán, E. (2011). A genetic algorithm for optimal unequal-area block layout design. *International Journal of Production Research*, 49(8), 2183–2195. <https://doi.org/10.1080/00207540903130868>
- Hosseini-Nasab, H., Fereidouni, S., Fatemi Ghomi, S. M. T., & Fakhrzad, M. B. (2018). Classification of facility layout problems: a review study. *International Journal of Advanced Manufacturing Technology*, 94(1–4), 957–977. <https://doi.org/10.1007/s00170-017-0895-8>
- Jaafari, A. A., Krishnan, K. K., Hossein, S., Doulabi, H., & Davoudpour, H. (2009). A Multi-Objective Formulation for Facility Layout Problem. *Lecture Notes in Engineering and Computer Science*, 2179(1), 1238–1243.
- Jadid, A. O., & Firouz, Mohammad; Snyder, L. V. (2016). *Simulation based approach for solving Unequal Area Facility Layout Problems in Stochastic condition by Genetic Algorithm*. 484, 32.
<http://arxiv.org/abs/1608.08321>
- Jerin Leno, I., Saravana Sankar, S., & Ponnambalam, S. G. (2016). An elitist strategy genetic algorithm using simulated annealing algorithm as local search for facility layout design. *International Journal of Advanced Manufacturing Technology*, 84(5–8), 787–799.
<https://doi.org/10.1007/s00170-013-5519-3>
- Johnes.Jill. (2016). Operational Research In Education. *Technological*

- Forecasting & Social Change*, 204(3), 683–696.
<https://core.ac.uk/download/pdf/30731174.pdf>
- Kulturel-Konak, S. (2017). A Matheuristic Approach for Solving the Dynamic Facility Layout Problem. *Procedia Computer Science*, 108(June), 1374–1383. <https://doi.org/10.1016/j.procs.2017.05.234>
- Kumar Perumalla, A. (2016). *A genetic algorithm for ASIC floorplannig* [Wright State University]. <https://doi.org/10.1108/AA-02-2014-018>
- Kundu, A.;Dan, P. K. (2010). THE SCOPE OF GENETIC ALGORITHMS IN DEALING WITH FACILITY LAYOUT PROBLEMS. *South African Journal of Industrial Engineering*, 21(2), 39–49.
- La Scalia, G., Micale, R., Giallanza, A., & Marannano, G. (2019). Firefly algorithm based upon slicing structure encoding for unequal facility layout problem. *International Journal of Industrial Engineering Computations*, 10(3), 349–360. <https://doi.org/10.5267/j.ijiec.2019.2.003>
- Maldonado, C. E. (2013). Un problema fundamental en la investigación: Los problemas P vs . NP. *Revista Logos, Ciencia & Tecnología*, 4(2), 10–20. <https://doi.org/10.22335/rlct.v4i2.186>
- Maldonado, C. E. (2015). ¿Qué es un sistema complejo? *Revista Colombiana de Filosofía de La Ciencia*, 6(9), 3752–3760. [https://doi.org/10.13040/IJPSR.0975-8232.6\(9\).3752-60](https://doi.org/10.13040/IJPSR.0975-8232.6(9).3752-60)
- Maldonado, C. E. (2016). Metaheurísticas y resolución de problemas complejos. *Revista Colombiana de Filosofía de La Ciencia*, 16(33), 169–185. <https://doi.org/10.18270/rcfc.v16i33.1938>
- Masel, D., & Marinchek, D. (2016). Non-Traditional Aisle Design for a Manufacturing Facility Layout. *International Material Handling Research Colloquium*, 1–11.
- Michalewicz, Z.;Fogel, D. B. (2000). How to Solve It: Modern Heuristics. In S. Verlag (Ed.), *ACM SIGACT News* (Vol. 32, Issue 1, pp. 8–12). <https://doi.org/10.1145/568438.568443>
- Michalewicz, Z. (1997). Genetic algorithms + data structures = evolution programs. In *Artificial Intelligence in Medicine* (Vol. 9, Issue 3, pp. 283–286). [https://doi.org/10.1016/s0933-3657\(96\)00378-8](https://doi.org/10.1016/s0933-3657(96)00378-8)
- Montgomery, D. (2004). Diseño y análisis de experimentos. In *Limusa Wiley*.
- Moreno Vega, J., Melián Batista, M., & Moreno Pérez, J. (2003).

- Metaheuristicas: Una visión global. *Inteligencia Artificial. Revista Iberoamericana de Inteligencia Artificial*, 7(19), 7–28.
- Nathan, A. J., & Scobell, A. (2012). How China sees America. In G. A. G. Frec & Kochenberger (Eds.), *Foreign Affairs* (Vol. 91, Issue 5). Publishers, Kluwer Academic Publishers.
- <https://doi.org/10.1017/CBO9781107415324.004>
- Nawaz-Ripon, K. S., Nizam-Khan, K., Glette, K., Hovin, M., & Torresen, J. (2011). Using pareto-optimality for solving multi-objective unequal area facility layout problem. *Genetic and Evolutionary Computation Conference, GECCO'11*, 681–688.
- <https://doi.org/10.1145/2001576.2001670>
- Niebles, F., Escobar, I., Agudelo, L., & Jimenez, G. (2016). A comparative analysis of genetic algorithms and QAP formulation for facility layout problem: An application in a real context. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 9713 LNCS(July 2018), 59–75.
- https://doi.org/10.1007/978-3-319-41009-8_7
- Odoo, E. L. (2021). ¿Qué es Odoo?. Recuperado 11 de enero de 2021, de Odoo website: <http://odoo.rgbconsulting.com/es/que-es-odoo/>
- Paes, F. G., Pessoa, A. A., & Vidal, T. (2017). A hybrid genetic algorithm with decomposition phases for the Unequal Area Facility Layout Problem. *European Journal of Operational Research*, 256(3), 742–756.
- <https://doi.org/10.1016/j.ejor.2016.07.022>
- Papadaki, I. N., & Chassiakos, A. P. (2016). Multi-objective Construction Site Layout Planning Using Genetic Algorithms. *Procedia Engineering*, 164(June), 20–27. <https://doi.org/10.1016/j.proeng.2016.11.587>
- Peng, Y., Zeng, T., Fan, L., Han, Y., Xia, B., & Wang, X. (2018). An Improved Genetic Algorithm Based Robust Approach for Stochastic Dynamic Facility Layout Problem. *Discrete Dynamics in Nature and Society*, 2018.
- <https://doi.org/10.1155/2018/1529058>
- Perea González, A. V. (2015). *Diseño De Un Procedimiento Basado En Algoritmos Genéticos Para Dar Solución Al Problema De Scheduling Admitiendo Rechazos En Escenarios Flexible Flow Shop*. Universidad Distrital Francisco José de Caldas.

- PostgreSQL: The World's Most Advanced Open Source Relational Database. (2021). Recuperado 2 de enero de 2021, de PosgreSQL website: <https://www.postgresql.org/>
- Pourvaziri, H., Pierreval, H., & Marian, H. (2020). Integrating Facility Layout Design and Aisle Structure in Manufacturing Systems : Formulation and Exact Solution. *European Journal of Operational Research, September*. <https://doi.org/10.1016/j.ejor.2020.08.012>
- Riffi, M. E., Saji, Y., & Barkatou, M. (2017). Incorporating a modified uniform crossover and 2-exchange neighborhood mechanism in a discrete bat algorithm to solve the quadratic assignment problem Incorporating a modified uniform crossover and 2-exchange neighborhood mechanism. *Egyptian Informatics Journal, 18*(3), 221–232. <https://doi.org/10.1016/j.eij.2017.02.003>
- Ruiz, E. (2014). Optimización multi-objetivo al problema de distribución de planta usando algoritmos genéticos: cuestiones previas para una propuesta de solución. *Industrial Data, 17*(2), 120. <https://doi.org/10.15381/idata.v17i2.12057>
- Santamarina, M.C. (1995) Métodos de optimización en la generación de distribuciones de plantas industriales mediante la aplicación de algoritmos genéticos y técnicas basadas en árboles de cortes. Tesis doctoral, Universidad Politécnica de Valencia, España.
- Saraswat, A., Venkatadri, U., & Castillo, I. (2015). A framework for multi-objective facility layout design. *Computers and Industrial Engineering, 90*, 167–176. <https://doi.org/10.1016/j.cie.2015.09.006>
- Sghir, I., Hao, J. K., Jaafar, I. Ben, & Ghédira, K. (2015). A multi-agent based optimization method applied to the quadratic assignment problem. *Expert Systems with Applications, 42*(23), 9252–9262. <https://doi.org/10.1016/j.eswa.2015.07.070>
- Sharma, P., & Singhal, S. (2017). Analysis of facility layout alternatives using proposed integrated approach. *Opsearch, 54*(1), 1–20. <https://doi.org/10.1007/s12597-016-0266-5>
- Shebanie II, C. R. (2004). *An integrated, evolutionary approach to facility layout and detailed design*. University of Pittsburgh.

- Sun, X., Lai, L. F., Chou, P., Chen, L. R., & Wu, C. C. (2018). On GPU implementation of the island model genetic algorithm for solving the unequal area facility layout problem. *Applied Sciences (Switzerland)*, 8(9). <https://doi.org/10.3390/app8091604>
- Sunardi, Ananda Esyah, J., & Santoso, B. (2020). Redesign of the Production Facility Layout by Using Systematic Layout Planning Method at Cahaya Bintang Mas Company Surabaya. *Journal of Physics: Conference Series*, 1569(3). <https://doi.org/10.1088/1742-6596/1569/3/032007>
- TAHA, H. A. (2012). *Investigación de Operaciones* (Pearson (ed.); 9na ed.).
- Talbi, E.-G. (2009). From Design To Implementation. In J. Wiley (Ed.), *Metaheuristics: From design to implementation.*
<https://doi.org/10.1002/9780470496916>
- Tam, K. Y. (1992a). A simulated annealing algorithm for allocating space to manufacturing cells. *International Journal of Production Research*, 30(1), 63–87. <https://doi.org/10.1080/00207549208942878>
- Tam, K. Y. (1992b). Genetic algorithms, function optimization, and facility layout design. *European Journal of Operational Research*, 63(2), 322–346. [https://doi.org/10.1016/0377-2217\(92\)90034-7](https://doi.org/10.1016/0377-2217(92)90034-7)
- Tam, K. Y., & Chan, S. K. (1998). Solving facility layout problems with geometric constraints using parallel genetic algorithms: Experimentation and findings. *International Journal of Production Research*, 36(12), 3253–3272. <https://doi.org/10.1080/002075498192058>
- Tam, K. Y., & Li, S. G. (1991). A hierarchical approach to the facility layout problem. *International Journal of Production Research*, 29(1), 165–184. <https://doi.org/10.1080/00207549108930055>
- Tompkins, J.A. y White, J.A., "Facilities planning", Edit.: John Wiley & Sons, New York, 1984.
- Troncoso, J. C. (2015). *Metodología Para La Optimización Del Diseño De Distribuciones En Plantas Industriales* [Universidad de Vigo].
<https://doi.org/10.1174/021435502753511268>
- van Camp, D. J., Carter, M. W., & Vannelli, A. (1992). A nonlinear optimization approach for solving facility layout problems. *European Journal of Operational Research*, 57(2), 174–189.
[https://doi.org/10.1016/0377-2217\(92\)90041-7](https://doi.org/10.1016/0377-2217(92)90041-7)

- Xiao, X., Hu, Y., Wang, W., & Ren, W. (2019). A robust optimization approach for unequal-area dynamic facility layout with demand uncertainty. *Procedia CIRP*, 81, 594–599.
<https://doi.org/10.1016/j.procir.2019.03.161>
- Xiao, Y., Xie, Y., Kulturel-Konak, S., & Konak, A. (2017). A problem evolution algorithm with linear programming for the dynamic facility layout problem—A general layout formulation. *Computers and Operations Research*, 88(July), 187–207. <https://doi.org/10.1016/j.cor.2017.06.025>
- Zha, S., Guo, Y., Huang, S., Wang, F., & Huang, X. (2017). Robust Facility Layout Design under Uncertain Product Demands. *Procedia CIRP*, 63(2012), 354–359. <https://doi.org/10.1016/j.procir.2017.03.079>

ANEXOS

ANEXO 1

Tabla 58

Operacionalización de variables

Variable	Tipo	Definición conceptual	Definición operacional	Dimensiones	Indicadores
VD: Optimización de la distribución en planta.	Dependiente	"El FLP pertenece al grupo de problemas de optimización, consistente en la participación de una región plana de dimensiones conocidas (generalmente rectangular) en departamentos de área conocida, de tal manera que se minimice el costo asociado con las instalaciones previstas entre dichos departamentos" (Tate & Smith, 1995).	La optimización de la distribución en planta consiste en obtener la mejor distribución física de un número dado de departamentos o máquinas con una configuración determinada tal que se minimicen los costos asociados.	Cruce y mutación.	Porcentaje de cruce y mutación.
VD 1: Optimización del área de la distribución en planta.	Dependiente	"La aplicación de la estructura de árboles de corte SST(Slicing Structure Tree) y algoritmos genéticos permiten obtener soluciones a problemas clásicos FLP de áreas rectangulares y desiguales; pero con una geometría flexible, estableciendo que el ratio largo/ancho puede variar dentro de ciertos márgenes establecidos."(Tam, 1992b)	La optimización del área de la distribución en planta se logra aplicando los árboles de corte y los algoritmos genéticos considerando las ratios largo/ancho en los que estos pueden variar.	Área	Área asignada.
VD 2: Solución óptima al problema de la distribución en planta.	Dependiente	"Solución factible que tiene el valor más favorable (máximo o mínimo) a la función objetivo", (TAHA, 2012).	Solución aceptable que tiene el valor más cercano a la función objetivo.	Colocación	Porcentaje de colocación de las instalaciones.
VD 3: Resultados del algoritmo genético ALGOYM.	Dependiente	"Distribución en planta óptima que se obtiene luego de la aplicación de un algoritmo genético". (Diego-Mas et al., 2008).	Distribución en planta resultante de la aplicación del algoritmo genético ALGOCYD que se obtiene para un determinado problema.	Costo de la distribución en planta.	Valor de la función de adaptación.
VD 4: Bondad del algoritmo genético ALGOCYD.	Dependiente	Capacidad del algoritmo genético para obtener una solución óptima al problema (Kundu, A.;Dan, 2010).	Capacidad del algoritmo genético ALGOCYD para obtener una solución al problema.	Solución óptima.	Si / No

Variable	Tipo	Definición conceptual	Definición operacional	Dimensiones	Indicadores
VI: Algoritmo genético de operadores de cruce y mutación	Independiente	"Los Algoritmos Genéticos, son una clase de métodos aproximados que están diseñados para resolver problemas difíciles de optimización combinatoria, donde los métodos tradicionales, no son efectivos" (Glover & Melián, 2003).	Los algoritmos genéticos son métodos aproximados que permiten resolver problemas difíciles de optimización combinatoria como es el problema de la distribución en planta - FLP.	Distribución en planta	Valor óptimo de la función de adaptación.
VI1: Árboles de corte por Algoritmos Genéticos.	Independiente	"Los árboles de corte ST(Slicing Tree) y algoritmos genéticos permiten obtener soluciones a problemas clásicos FLP de áreas rectangulares y desiguales" (Tam, 1992b).	La aplicación de los árboles de corte y los algoritmos genéticos permiten resolver el problema de la distribución en planta - FLP.	Árbol de corte	Mejor árbol de corte.
VI2: Algoritmo genético ALGOCYM.	Independiente	"El Algoritmo genético utiliza el árbol de cortes para generar una distribución en planta óptima (o al menos sub-óptima) desde el punto de vista del cumplimiento de las restricciones geométricas impuestas a las actividades" (Diego-Más, 2006).	El algoritmo genético utiliza el árbol de cortes y debe cumplir con las restricciones geométricas de las actividades para generar una óptima distribución en planta.	Incumplimiento geométrico	Valor del incumplimiento geométrico.
VI3: Experimentos numéricos para el algoritmo genético ALGOCYM.	Independiente	"Los experimentos numéricos permiten establecer los parámetros adecuados para mostrar la funcionalidad del algoritmo genético" (Diego-Más, 2006).	Se plantea un conjunto de experimentos numéricos para 4 formulaciones del FLP a fin de determinar los niveles de cruce y mutación que muestran la funcionalidad del algoritmo ALGOCYM propuesto.	Cruce y mutación.	Porcentaje significativo.
VI4: Diseño e implementación de la aplicación informática del algoritmo ALGOCYM.	Independiente	"Un algoritmo genético se implementa mediante un lenguaje de programación que exprese sus características y funcionalidad" (Goldberg, 1989).	El algoritmo genético ALGOCYM se implementa mediante el lenguaje de programación Python® bajo el sistema operativo Linux Ubuntu ® 20.04.	Aplicación informática.	Convergencia a la solución.

ANEXO 2

La matriz de consistencia

Tabla 59

Algoritmo genético de operadores de cruce y mutación (ALGOCYM) para la optimización de la distribución en planta en organizaciones de manufactura

PROBLEMA GENERAL	OBJETIVO GENERAL	HIPOTESIS GENERAL	VARIABLES	DIMENSIÓN	INDICADORES
¿Cómo debe ser el algoritmo genético de operadores de cruce y mutación ALGOCYM que permita optimizar la distribución en planta en organizaciones de manufactura?	Desarrollar el algoritmo genético de operadores de cruce y mutación ALGOCYM que permite optimizar la distribución en planta en organizaciones de manufactura.	Utilizando el Algoritmo Genético de operadores de cruce y mutación ALGOCYM se optimiza La distribución en planta en las organizaciones de manufactura.	VI: Algoritmo genético de operadores de cruce y mutación VD: Optimización de la distribución en planta	Cruce y Mutación Distribución en planta	Porcentaje de cruce y de mutación Valor óptimo de la función de adaptación
PROBLEMAS ESPECIFICOS	OBJETIVOS ESPECIFICOS	HIPOTESIS ESPECIFICAS	VARIABLES	DIMENSIÓN	INDICADORES
a) ¿Como se aplica el árbol de cortes por algoritmos genéticos para optimizar el área de la distribución en planta?	a) Aplicar el árbol de cortes por algoritmos genéticos para optimizar el área de la distribución en planta.	a) La aplicación del árbol de cortes por algoritmos genéticos permite optimizar el área de la distribución en planta.	VI 1: Árbol de cortes por algoritmos genéticos. VD 1: Optimización del área de la distribución en planta.	Árbol de cortes Área	Mejor árbol Área asignada
b) ¿Cómo es el algoritmo genético ALGOCYM que genere una solución óptima del problema de distribución en planta?	b) Elaborar un algoritmo genético (ALGOCYM) que genere una solución óptima al problema de la distribución en planta.	b) La elaboración del algoritmo genético ALGOCYM permite alcanzar una solución óptima al problema de distribución en planta.	VI 2: Algoritmo genético ALGOCYM. VD 2: Solución óptima al problema de la distribución en planta.	Incumplimiento geométrico Colocación	Valor del incumplimiento geométrico Porcentaje de colocación de las instalaciones
c) ¿Cómo se plantean los experimentos numéricos con el algoritmo genético ALGOCYM para cuantificar sus resultados?	c) Plantear experimentos numéricos, para cuantificar los resultados del algoritmo genético ALGOCYM.	c) Los experimentos numéricos, permiten cuantificar los resultados del algoritmo genético ALGOCYM.	VI 3: Niveles de cruce y mutación para el algoritmo genético ALGOCYM. VD 3: Resultados del algoritmo genético ALGOCYM.	Cruce y mutación Costo de la distribución en planta	Porcentaje significativo Valor de la función de adaptación
d) ¿Cómo es el diseño e implementación de la aplicación informática que pruebe la bondad del algoritmo genético ALGOCYM?	d) Diseñar e implementar la aplicación informática que pruebe la bondad del algoritmo genético ALGOCYM.	d) El diseño e implementación de la aplicación informática permite probar la bondad del algoritmo genético ALGOCYM.	VI 4: Diseño e Implementación de la aplicación informática del algoritmo ALGOCYM. VD 4: Bondad del algoritmo genético ALGOCYM.	Aplicación informática Solución optima	Convergencia a la solución Si/No

ANEXO 3

Resultados experimentales caso I.- Tam 8

Determinación del tamaño de la población

Tabla 60

Experimentos para una población de 30 individuos

Tamaño población	30	Número de generaciones	500	Costo de la función de adaptación											
Solución	pc	pm	Ejec 1	Ejec 2	Ejec 3	Ejec 4	Ejec 5	Ejec 6	Ejec 7	Ejec 8	Ejec 9	Ejec 10	costo minimo	Aciertos	%
P1Tam8_1A	0.6	0.05	11044.71817	10135.60329	10689.82796	10188.84565	11125.71845	9710.026741	9710.026741	9710.026741	10689.82796	9,710.026741	4	0.4	
P1Tam8_1B	0.6	0.08	11015.29924	10780.99008	10780.99008	9710.026741	10188.84565	9710.026741	9710.026741	9710.026741	10234.06424	10234.06424	9,710.026741	4	0.4
P1Tam8_1C	0.6	0.10	9710.026741	10263.86236	9710.026741	10135.60329	10135.60329	10188.84565	9710.026741	9710.026741	9710.026741	9710.026741	9,710.026741	6	0.6
P1Tam8_1D	0.6	0.20	10054.98822	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9,710.026741	9	0.9
P1Tam8_1E	0.6	0.30	9710.026741	9710.026741	9710.026741	9710.026741	10054.98822	9710.026741	9710.026741	9710.026741	10054.98822	10054.98822	9,710.026741	7	0.7
P1Tam8_2A	0.7	0.05	9710.026741	10054.98822	11015.29924	11015.29924	16449.1911	9710.026741	13618.56038	10188.84565	10234.06424	10780.99008	9,710.026741	2	0.2
P1Tam8_2B	0.7	0.08	11015.29924	10234.06424	9710.026741	9710.026741	9710.026741	10054.98822	9710.026741	9710.026741	11044.71817	9710.026741	9,710.026741	6	0.6
P1Tam8_2C	0.7	0.10	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	10188.84565	9710.026741	9710.026741	10135.60329	9710.026741	9,710.026741	8	0.8
P1Tam8_2D	0.7	0.20	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	10188.84565	9710.026741	9710.026741	10188.84565	9710.026741	9,710.026741	8	0.8
P1Tam8_2E	0.7	0.30	9710.026741	10188.84565	9710.026741	9710.026741	9710.026741	10054.98822	9710.026741	9710.026741	9710.026741	10135.60329	9,710.026741	7	0.7
P1Tam8_3A	0.8	0.05	10780.99008	10689.82796	11015.29924	10135.60329	10054.98822	10054.98822	10780.99008	10135.60329	11182.63825	9710.026741	9,710.026741	1	0.1
P1Tam8_3B	0.8	0.08	10234.06424	9710.026741	11015.29924	9710.026741	9710.026741	13618.56038	10054.98822	9710.026741	9710.026741	10188.84565	9,710.026741	5	0.5
P1Tam8_3C	0.8	0.10	9710.026741	9710.026741	10188.84565	9710.026741	9710.026741	10188.84565	10188.84565	10054.98822	10054.98822	9710.026741	9,710.026741	5	0.5
P1Tam8_3D	0.8	0.20	9710.026741	10135.60329	9710.026741	10135.60329	9710.026741	10054.98822	9710.026741	10135.60329	9710.026741	9710.026741	9,710.026741	6	0.6
P1Tam8_3E	0.8	0.30	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	10188.84565	9710.026741	9710.026741	9710.026741	9,710.026741	9	0.9
P1Tam8_4A	0.9	0.05	10188.84565	10188.84565	10704.91443	11182.63825	11488.57874	10135.60329	11182.63825	10135.60329	11044.71817	10608.82383	10,135.603286	0	0.0
P1Tam8_4B	0.9	0.08	10780.99008	10188.84565	9710.026741	10188.84565	9710.026741	9710.026741	10054.98822	10234.06424	10188.84565	9710.026741	9,710.026741	4	0.4
P1Tam8_4C	0.9	0.10	9710.026741	9710.026741	9710.026741	9710.026741	10188.84565	9710.026741	9710.026741	9710.026741	10188.84565	9,710.026741	8	0.8	
P1Tam8_4D	0.9	0.20	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9,710.026741	10	1.0	
P1Tam8_4E	0.9	0.30	9710.026741	10135.60329	10135.60329	10188.84565	9710.026741	9710.026741	9710.026741	9780.137915	9710.026741	9710.026741	9,710.026741	6	0.6

Tabla 61*Experimentos para una población de 60 individuos*

Tamaño población		60																
Número de generaciones		200																
Costo de la función de adaptación																		
Nro.	Solución	pc	pm	Ejec 1	Ejec 2	Ejec 3	Ejec 4	Ejec 5	Ejec 6	Ejec 7	Ejec 8	Ejec 9	Ejec 10	costo minimo	Aciertos	%		
1	P1Tam8_1A	0.6	0.05	9710.026741	9710.026741	10188.84565	9710.026741	9747.460805	10054.98822	10188.84565	9780.137915	9710.026741	9,710.026741	9,710.026741	5	0.5		
2	P1Tam8_1B	0.6	0.08	9747.460805	9710.026741	9710.026741	10234.06424	10188.84565	10188.84565	9780.137915	9710.026741	9780.137915	9,710.026741	9,710.026741	3	0.3		
3	P1Tam8_1C	0.6	0.10	9710.026741	10054.98822	10188.84565	9710.026741	9710.026741	10135.60329	10780.99008	9710.026741	9710.026741	9710.026741	9,710.026741	9,710.026741	6	0.6	
4	P1Tam8_1D	0.6	0.20	10188.84565	9710.026741	10188.84565	9710.026741	9710.026741	10135.60329	9710.026741	9710.026741	10234.06424	10135.60329	9,710.026741	9,710.026741	5	0.5	
5	P1Tam8_1E	0.6	0.30	9710.026741	9710.026741	10054.98822	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9,710.026741	9,710.026741	9	0.9	
6	P1Tam8_2A	0.7	0.05	9710.026741	10054.98822	9710.026741	9710.026741	10135.60329	9710.026741	9710.026741	9710.026741	13618.56038	9710.026741	9,710.026741	9,710.026741	7	0.7	
7	P1Tam8_2B	0.7	0.08	9710.026741	10135.60329	9841.044073	10188.84565	13618.56038	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9,710.026741	9,710.026741	6	0.6	
8	P1Tam8_2C	0.7	0.10	9747.460805	9710.026741	10054.98822	9710.026741	9747.460805	9710.026741	10188.84565	9710.026741	9710.026741	9710.026741	9710.026741	9,710.026741	9,710.026741	6	0.6
9	P1Tam8_2D	0.7	0.20	9747.460805	9710.026741	10135.60329	10054.98822	10135.60329	9710.026741	9710.026741	9710.026741	9710.026741	10054.98822	9,710.026741	9,710.026741	5	0.5	
10	P1Tam8_2E	0.7	0.30	10188.84565	10135.60329	9710.026741	9710.026741	10054.98822	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	10135.60329	9,710.026741	6	0.6	
11	P1Tam8_3A	0.8	0.05	10135.60329	10780.99008	9710.026741	10054.98822	9980.895941	9780.137915	11015.29924	10188.84565	9710.026741	10263.86236	9,710.026741	2	0.2		
12	P1Tam8_3B	0.8	0.08	9710.026741	10054.98822	10054.98822	9710.026741	9710.026741	9710.026741	13618.56038	9980.895941	9710.026741	9710.026741	9,710.026741	6	0.6		
13	P1Tam8_3C	0.8	0.10	9710.026741	9710.026741	9710.026741	10054.98822	10263.86236	10188.84565	9710.026741	9710.026741	10188.84565	10234.06424	9,710.026741	5	0.5		
14	P1Tam8_3D	0.8	0.20	10054.98822	9710.026741	9747.460805	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9,710.026741	8	0.8		
15	P1Tam8_3E	0.8	0.30	10135.60329	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	10188.84565	9710.026741	9747.460805	9,710.026741	7	0.7		
16	P1Tam8_4A	0.9	0.05	9710.026741	9710.026741	9780.137915	11044.71817	9710.026741	10608.82383	11044.71817	10135.60329	9710.026741	10799.40941	9,710.026741	4	0.4		
17	P1Tam8_4B	0.9	0.08	11044.71817	9710.026741	10234.06424	9710.026741	9710.026741	9710.026741	9747.460805	9710.026741	9710.026741	9780.137915	9,710.026741	6	0.6		
18	P1Tam8_4C	0.9	0.10	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9747.460805	9710.026741	10054.98822	10234.06424	9710.026741	9,710.026741	7	0.7		
19	P1Tam8_4D	0.9	0.20	10234.06424	9710.026741	9710.026741	9710.026741	10188.84565	9710.026741	10188.84565	9710.026741	10188.84565	9710.026741	10188.84565	9,710.026741	6	0.6	
20	P1Tam8_4E	0.9	0.30	9710.026741	10135.60329	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	10054.98822	9710.026741	10054.98822	10188.84565	9,710.026741	6	0.6	

Tabla 62*Experimentos para una población de 100 individuos*

Tamaño población		100	Costo de la función de adaptación														
Número de generaciones		200															
Nro.	Solución	pc	pm	Ejec 1	Ejec 2	Ejec 3	Ejec 4	Ejec 5	Ejec 6	Ejec 7	Ejec 8	Ejec 9	Ejec 10	costo minimo	Aciertos	%	
1	P1Tam8_1A	0.6	0.05	10505.32764	11407.05259	10054.98822	10505.32764	10188.84565	9780.137915	9780.137915	16449.1911	9780.137915	10188.84565	9,780.137915	0	0	
2	P1Tam8_1B	0.6	0.08	9710.026741	9710.026741	10054.98822	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9,710.026741	9	0.9	
3	P1Tam8_1C	0.6	0.10	9710.026741	10135.60329	9710.026741	9747.460805	9710.026741	9710.026741	9710.026741	9710.026741	10188.84565	10054.98822	9,710.026741	6	0.6	
4	P1Tam8_1D	0.6	0.20	9710.026741	9710.026741	9780.137915	9710.026741	9710.026741	10188.84565	9710.026741	9710.026741	9710.026741	9710.026741	9,710.026741	8	0.8	
5	P1Tam8_1E	0.6	0.30	9710.026741	10188.84565	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9747.460805	9710.026741	9,710.026741	8	0.8	
6	P1Tam8_2A	0.7	0.05	10188.84565	10054.98822	10135.60329	9710.026741	10135.60329	9710.026741	9710.026741	9710.026741	10188.84565	10608.82383	9,710.026741	4	0.4	
7	P1Tam8_2B	0.7	0.08	10054.98822	9710.026741	10054.98822	9710.026741	9710.026741	9710.026741	9710.026741	10054.98822	9710.026741	9747.460805	9,710.026741	6	0.6	
8	P1Tam8_2C	0.7	0.10	9710.026741	9710.026741	9710.026741	10054.98822	9710.026741	9710.026741	9710.026741	9710.026741	9780.137915	10188.84565	9,710.026741	7	0.7	
9	P1Tam8_2D	0.7	0.20	10054.98822	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9,710.026741	9	0.9	
10	P1Tam8_2E	0.7	0.30	10054.98822	9710.026741	10188.84565	9710.026741	9710.026741	9747.460805	9710.026741	9710.026741	9710.026741	10054.98822	9,710.026741	6	0.6	
11	P1Tam8_3A	0.8	0.05	10234.06424	13618.56038	9710.026741	9710.026741	10333.97353	10135.60329	9710.026741	10263.86236	9710.026741	9,710.026741	5	0.5		
12	P1Tam8_3B	0.8	0.08	9710.026741	10135.60329	10188.84565	9710.026741	9710.026741	9710.026741	10188.84565	9710.026741	9710.026741	10135.60329	9,710.026741	6	0.6	
13	P1Tam8_3C	0.8	0.10	9710.026741	9710.026741	9710.026741	10135.60329	10135.60329	9710.026741	9710.026741	10054.98822	10234.06424	9710.026741	9,710.026741	6	0.6	
14	P1Tam8_3D	0.8	0.20	9710.026741	9710.026741	9710.026741	9710.026741	10054.98822	9710.026741	9710.026741	10188.84565	9780.137915	10188.84565	9,710.026741	6	0.6	
15	P1Tam8_3E	0.8	0.30	9710.026741	9710.026741	9710.026741	10188.84565	9710.026741	9710.026741	9710.026741	9780.137915	9710.026741	9710.026741	9,710.026741	8	0.8	
16	P1Tam8_4A	0.9	0.05	9710.026741	9710.026741	9841.044073	10054.98822	10188.84565	11407.05259	9710.026741	9710.026741	10234.06424	9710.026741	9,710.026741	5	0.5	
17	P1Tam8_4B	0.9	0.08	9710.026741	10368.3603	10054.98822	9710.026741	10188.84565	10188.84565	9710.026741	9710.026741	9710.026741	9710.026741	9,710.026741	6	0.6	
18	P1Tam8_4C	0.9	0.10	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	10054.98822	9710.026741	9,710.026741	9	0.9	
19	P1Tam8_4D	0.9	0.20	9710.026741	9710.026741	9710.026741	9710.026741	10054.98822	9710.026741	9710.026741	9710.026741	10188.84565	10188.84565	9,710.026741	7	0.7	
20	P1Tam8_4E	0.9	0.30	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9780.137915	9710.026741	9,710.026741	9	0.9	

Tabla 63*Tam 8: Paso 1 Obtener el mejor árbol de cortes*

Tamaño población		30	Costo de la función de adaptación														
Número de generaciones		500	pc	pm	Ejec 1	Ejec 2	Ejec 3	Ejec 4	Ejec 5	Ejec 6	Ejec 7	Ejec 8	Ejec 9	Ejec 10	costo minimo	Aciertos	%
P1Tam8_1A	0.6	0.05	11044.71817	10135.60329	10689.82796	10188.84565	11125.71845	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	10689.82796	9,710.026741	4	0.4
P1Tam8_1B	0.6	0.08	11015.29924	10780.99008	10780.99008	9710.026741	10188.84565	9710.026741	9710.026741	9710.026741	10234.06424	10234.06424	9,710.026741	9,710.026741	4	0.4	
P1Tam8_1C	0.6	0.10	9710.026741	10263.86236	9710.026741	10135.60329	10135.60329	10188.84565	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9,710.026741	6	0.6
P1Tam8_1D	0.6	0.20	10054.98822	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9,710.026741	9,710.026741	9	0.9
P1Tam8_1E	0.6	0.30	9710.026741	9710.026741	9710.026741	9710.026741	10054.98822	9710.026741	9710.026741	9710.026741	10054.98822	10054.98822	9,710.026741	9,710.026741	7	0.7	
P1Tam8_2A	0.7	0.05	9710.026741	10054.98822	11015.29924	11015.29924	16449.1911	9710.026741	13618.56038	10188.84565	10234.06424	10780.99008	9,710.026741	9,710.026741	2	0.2	
P1Tam8_2B	0.7	0.08	11015.29924	10234.06424	9710.026741	9710.026741	9710.026741	10054.98822	9710.026741	9710.026741	11044.71817	9710.026741	9,710.026741	9,710.026741	6	0.6	
P1Tam8_2C	0.7	0.10	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	10188.84565	9710.026741	9710.026741	10135.60329	9710.026741	9,710.026741	9,710.026741	8	0.8	
P1Tam8_2D	0.7	0.20	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	10188.84565	9710.026741	9710.026741	10188.84565	9710.026741	9,710.026741	9,710.026741	8	0.8	
P1Tam8_2E	0.7	0.30	9710.026741	10188.84565	9710.026741	9710.026741	9710.026741	10054.98822	9710.026741	9710.026741	9710.026741	10135.60329	9,710.026741	9,710.026741	7	0.7	
P1Tam8_3A	0.8	0.05	10780.99008	10689.82796	11015.29924	10135.60329	10054.98822	10054.98822	10780.99008	10135.60329	11182.63825	9710.026741	9,710.026741	9,710.026741	1	0.1	
P1Tam8_3B	0.8	0.08	10234.06424	9710.026741	11015.29924	9710.026741	9710.026741	13618.56038	10054.98822	9710.026741	9710.026741	10188.84565	9,710.026741	9,710.026741	5	0.5	
P1Tam8_3C	0.8	0.10	9710.026741	9710.026741	10188.84565	9710.026741	9710.026741	10188.84565	10188.84565	10054.98822	10054.98822	9710.026741	9,710.026741	9,710.026741	5	0.5	
P1Tam8_3D	0.8	0.20	9710.026741	10135.60329	9710.026741	10135.60329	9710.026741	10054.98822	9710.026741	10135.60329	9710.026741	9710.026741	9,710.026741	9,710.026741	6	0.6	
P1Tam8_3E	0.8	0.30	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	10188.84565	9710.026741	9710.026741	9710.026741	9,710.026741	9,710.026741	9	0.9	
P1Tam8_4A	0.9	0.05	10188.84565	10188.84565	10704.91443	11182.63825	11488.57874	10135.60329	11182.63825	10135.60329	11044.71817	10608.82383	10,135.603286	0	0.0		
P1Tam8_4B	0.9	0.08	10780.99008	10188.84565	9710.026741	10188.84565	9710.026741	9710.026741	10054.98822	10234.06424	10188.84565	9710.026741	9,710.026741	9,710.026741	4	0.4	
P1Tam8_4C	0.9	0.10	9710.026741	9710.026741	9710.026741	9710.026741	10188.84565	9710.026741	9710.026741	9710.026741	9710.026741	10188.84565	9,710.026741	9,710.026741	8	0.8	
P1Tam8_4D	0.9	0.20	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9710.026741	9,710.026741	9,710.026741	10	1.0	
P1Tam8_4E	0.9	0.30	9710.026741	10135.60329	10135.60329	10188.84565	9710.026741	9710.026741	9710.026741	9780.137915	9710.026741	9710.026741	9,710.026741	9,710.026741	6	0.6	

Tabla 64

Tam 8: Paso 2 Obtener el mejor layout

ANEXO 4

Resultados experimentales caso II.- van Camp vC10

Tabla 65

Van Camp vC10: Paso 1 Obtener el mejor árbol de cortes

Tamaño de población		30														
Número de generación		2000														
Costo de la función de adaptación																
Nro.	Solución	pc	pm	Ejec 1	Ejec 2	Ejec 3	Ejec 4	Ejec 5	Ejec 6	Ejec 7	Ejec 8	Ejec 9	Ejec 10	costo minimo	Aciertos	%
1	P1VC10_1A	0.6	0.05	304.736909	304.736909	306.633045	306.633045	306.633045	304.736909	304.736909	307.860232	304.736909	304.736909	304.736909	6	0.6
2	P1VC10_1B	0.6	0.1	304.736909	304.736909	304.736909	304.736909	307.860232	304.736909	304.736909	307.860232	304.736909	304.736909	304.736909	8	0.8
3	P1VC10_1C	0.6	0.2	304.736909	304.736909	304.736909	305.849647	304.736909	304.736909	304.736909	307.860232	304.736909	304.736909	304.736909	8	0.8
4	P1VC10_1D	0.6	0.3	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	10	1.0
5	P1VC10_1E	0.6	0.4	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	10	1.0
6	P1VC10_1F	0.6	0.5	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	10	1.0
7	P1VC10_1G	0.6	0.6	304.736909	306.633045	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	9	0.9
8	P1VC10_1H	0.6	0.7	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	10	1.0
9	P1VC10_1J	0.6	0.8	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	10	1.0
10	P1VC10_2A	0.7	0.05	304.736909	307.464567	304.736909	306.633045	309.524978	307.464567	309.524978	307.860232	304.736909	304.736909	304.736909	4	0.4
11	P1VC10_2B	0.7	0.1	304.736909	304.736909	307.860232	304.736909	307.860232	307.464567	304.736909	307.860232	304.736909	305.849647	304.736909	6	0.6
12	P1VC10_2C	0.7	0.2	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	306.633045	304.736909	304.736909	9	0.9
13	P1VC10_2D	0.7	0.3	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	10	1.0
14	P1VC10_2E	0.7	0.4	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	10	1.0
15	P1VC10_2F	0.7	0.5	306.633045	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	307.860232	304.736909	304.736909	8	0.8
16	P1VC10_2G	0.7	0.6	304.736909	304.736909	304.736909	304.736909	307.627997	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	9	0.9
17	P1VC10_2H	0.7	0.7	304.736909	307.860232	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	9	0.9
18	P1VC10_2J	0.7	0.8	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	305.849647	304.736909	304.736909	9	0.9
19	P1VC10_3A	0.8	0.05	307.860232	306.67081	306.633045	304.736909	304.736909	307.860232	304.736909	307.860232	304.736909	307.860232	304.736909	3	0.3
20	P1VC10_3B	0.8	0.1	304.736909	304.736909	304.736909	304.736909	304.736909	307.860232	304.736909	304.736909	304.736909	304.736909	304.736909	9	0.9
21	P1VC10_3C	0.8	0.2	304.736909	304.736909	304.736909	305.849647	304.736909	304.736909	306.633045	307.464567	306.67081	304.736909	304.736909	6	0.6
22	P1VC10_3D	0.8	0.3	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	10	1.0
23	P1VC10_3E	0.8	0.4	304.736909	307.860232	306.633045	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	8	0.8
24	P1VC10_3F	0.8	0.5	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	10	1.0
25	P1VC10_3G	0.8	0.6	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	10	1.0
26	P1VC10_3H	0.8	0.7	304.736909	304.736909	304.736909	304.736909	307.464567	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	9	0.9
27	P1VC10_3J	0.8	0.8	304.736909	307.464567	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	307.860232	304.736909	304.736909	8	0.8
28	P1VC10_4A	0.9	0.05	304.736909	306.633045	307.464567	307.860232	305.849647	307.860232	306.633045	307.860232	307.204574	304.736909	304.736909	2	0.2
29	P1VC10_4B	0.9	0.1	304.736909	307.860232	304.736909	304.736909	307.860232	307.860232	304.736909	307.860232	305.849647	307.860232	304.736909	4	0.4
30	P1VC10_4C	0.9	0.2	307.860232	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	9	0.9
31	P1VC10_4D	0.9	0.3	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	10	1.0
32	P1VC10_4E	0.9	0.4	304.736909	307.860232	304.736909	304.736909	304.736909	307.860232	304.736909	304.736909	304.736909	304.736909	304.736909	7	0.7
33	P1VC10_4F	0.9	0.5	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	10	1.0
34	P1VC10_4G	0.9	0.6	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	304.736909	10	1.0
35	P1VC10_4H	0.9	0.7	304.736909	304.736909	307.860232	304.736909	304.736909	307.860232	307.860232	304.736909	304.736909	305.849647	304.736909	6	0.6
36	P1VC10_4J	0.9	0.8	304.736909	304.736909	306.633045	304.736909	304.736909	304.736909	304.736909	307.860232	304.736909	304.736909	304.736909	8	0.8

Tabla 66

Van Camp vC10: Paso 2 Obtener el mejor layout

ANEXO 5

Resultados experimentales caso III.- Bazaraa 14

Tabla 67

Bazaraa 14: Paso 1 Obtener el mejor árbol de cortes

Tamaño de población Número de generaciones			30	3000	Costo de la función de adaptación										Costo mínimo	Aciertos	%
Nro.	Solución	pc	pm	Ejec 1	Ejec 2	Ejec 3	Ejec 4	Ejec 5	Ejec 6	Ejec 7	Ejec 8	Ejec 9	Ejec 10				
1	P1B14_1A	0.6	0.05	610.693179	644.049956	794.374142	615.263366	609.187585	635.712315	671.132362	613.960881	606.401753	614.996027	606.401753	1	1	
2	P1B14_1B	0.6	0.1	615.263366	610.123002	608.729611	607.186616	607.357838	642.070555	626.615065	625.998041	617.200051	615.354505	607.186616	0	0	
3	P1B14_1C	0.6	0.2	607.186616	606.401753	619.689995	608.729611	606.401753	615.263366	609.472699	629.110437	630.948801	617.602138	606.401753	2	2	
4	P1B14_1D	0.6	0.3	607.357838	612.588863	615.6333683	606.401753	608.729611	613.960881	607.357838	636.865531	607.357838	618.267069	606.401753	1	1	
5	P1B14_1E	0.6	0.4	609.092006	607.357838	606.401753	606.401753	607.357838	615.228431	621.447651	606.401753	607.357838	606.401753	606.401753	4	4	
6	P1B14_1F	0.6	0.5	609.472699	606.717603	606.401753	607.357838	608.893839	625.191768	606.401753	613.960881	613.960881	629.411878	606.401753	2	2	
7	P1B14_1G	0.6	0.6	609.472699	613.960881	606.401753	615.263366	615.228431	606.401753	607.357838	606.401753	613.960881	613.960881	606.401753	3	3	
8	P1B14_1H	0.6	0.7	609.472699	609.472699	642.706697	609.472699	606.401753	612.442848	607.907416	629.421518	606.401553	629.421518	606.401553	1	1	
9	P1B14_1J	0.6	0.8	606.401753	612.475281	631.154045	607.357838	612.442848	607.357838	606.401753	612.442848	608.729611	610.662066	606.401753	2	2	
10	P1B14_2A	0.7	0.05	629.421518	614.996027	615.228431	614.996027	644.627621	615.228431	629.941377	641.657496	612.475281	613.174199	612.475281	0	0	
11	P1B14_2B	0.7	0.1	606.401753	610.693179	609.281204	613.960881	606.401753	610.142861	606.401753	611.069695	607.357838	607.357838	606.401753	3	3	
12	P1B14_2C	0.7	0.2	606.717603	606.401753	606.401753	613.960881	615.425000	608.893839	606.401753	613.960881	607.357838	606.401753	606.401753	4	4	
13	P1B14_2D	0.7	0.3	608.729611	608.893839	615.228431	609.187585	612.475281	606.401753	607.357838	615.260863	611.069695	608.893839	606.401753	1	1	
14	P1B14_2E	0.7	0.4	606.401753	606.401753	606.401753	613.790089	608.893839	626.568184	614.323727	607.357838	607.357838	614.996027	606.401753	3	3	
15	P1B14_2F	0.7	0.5	615.228431	606.401753	613.960881	613.960881	607.357838	606.401753	607.357838	606.401753	621.447651	606.401753	606.401753	4	4	
16	P1B14_2G	0.7	0.6	610.693179	606.401753	608.893839	630.418406	606.401753	607.357838	606.401753	607.186616	608.893839	607.186616	606.401753	3	3	
17	P1B14_2H	0.7	0.7	607.357838	606.401753	608.893839	608.893839	610.123002	607.357838	607.357838	613.487071	608.729611	613.960881	606.401753	1	1	
18	P1B14_2J	0.7	0.8	606.401753	612.588863	617.542676	613.960881	610.123002	612.442848	616.901922	608.729611	612.588863	606.401753	606.401753	2	2	
19	P1B14_3A	0.8	0.05	611.191148	674.282414	642.070555	611.972253	615.228431	615.6333683	609.472699	615.228431	607.186616	606.401753	606.401753	1	1	
20	P1B14_3B	0.8	0.1	648.206612	610.123002	609.187585	639.657507	612.442848	607.186616	613.960881	615.263366	606.401753	607.357838	606.401753	1	1	
21	P1B14_3C	0.8	0.2	608.729611	608.729611	606.401753	617.704184	607.186616	615.425000	615.228431	607.357838	607.186616	607.907416	606.401753	1	1	
22	P1B14_3D	0.8	0.3	607.357838	610.693179	615.343316	608.893839	606.401753	612.442848	609.472699	615.228431	613.960881	606.401753	606.401753	2	2	
23	P1B14_3E	0.8	0.4	609.127505	613.960881	606.401753	606.401753	606.401753	609.472699	606.401753	615.263366	609.472699	606.401753	5	5		
24	P1B14_3F	0.8	0.5	606.401753	606.401753	607.186616	606.401753	606.401753	606.401753	613.960881	606.401753	606.401753	606.401753	8	8		
25	P1B14_3G	0.8	0.6	608.729611	613.960881	612.644974	611.028616	614.323727	609.472699	607.357838	615.633683	607.357838	613.960881	607.357838	0	0	
26	P1B14_3H	0.8	0.7	607.186616	606.401753	606.401753	608.893839	611.191148	606.401753	607.198006	607.357838	608.729611	606.401753	606.401753	4	4	
27	P1B14_3J	0.8	0.8	608.893839	614.996027	614.095284	611.191148	618.113502	613.960881	608.729611	607.186616	612.588863	610.662066	607.186616	0	0	
28	P1B14_4A	0.9	0.05	609.472699	663.412913	644.638021	610.693179	613.790089	607.186616	683.541586	617.704184	681.499967	629.941377	607.186616	0	0	
29	P1B14_4B	0.9	0.1	607.357838	606.717603	610.123002	613.960881	614.996027	606.401753	614.996027	606.401753	607.198006	615.228431	606.401753	2	2	
30	P1B14_4C	0.9	0.2	614.996027	613.960881	610.693179	608.729611	608.729611	606.401753	606.401753	606.401753	613.960881	608.893839	606.401753	3	3	
31	P1B14_4D	0.9	0.3	608.729611	606.401753	612.442848	606.401753	613.960881	612.475281	606.401753	606.401753	608.729611	613.960881	606.401753	4	4	
32	P1B14_4E	0.9	0.4	613.960881	614.910070	606.401753	607.357838	606.401753	610.693179	625.191768	606.401753	610.693179	606.401753	606.401753	4	4	
33	P1B14_4F	0.9	0.5	610.662066	613.960881	606.401753	616.480049	612.442848	607.357838	612.588863	614.409071	613.960881	606.401753	606.401753	2	2	
34	P1B14_4G	0.9	0.6	606.401753	608.729611	614.095284	612.442848	606.401753	606.401753	606.401753	609.187585	608.729611	606.401753	606.401753	5	5	
35	P1B14_4H	0.9	0.7	608.729611	607.357838	608.729611	609.187585	613.960881	608.729611	608.893839	606.401753	606.401753	607.186616	606.401753	2	2	
36	P1B14_4J	0.9	0.8	629.421518	608.893839	607.357838	606.401753	613.960881	607.357838	606.401753	606.401753	608.893839	612.442848	606.401753	3	3	

Tabla 68

Bazaraa 14: Paso 2 Obtener el mejor layout

Tamaño de población Número de generaciones				Costos de la función de adaptación															
Nro.	Solución	pc	pm	Ejec 1	Ejec 2	Ejec 3	Ejec 4	Ejec 5	Ejec 6	Ejec 7	Ejec 8	Ejec 9	Ejec 10	Ejec 11	Ejec 12	Ejec 13	Ejec 14	Aciertos	
1	P1B14_3F	0.6	0.1	11213.901786	13145.100632	13349.183590	13112.259485	11213.901786	13084.720204	11213.901786	13181.884875	11213.901786	11213.901786	13112.259485	13058.282883	13064.943106	13185.454093	5	
2	P1B14_3F	0.6	0.2	11213.901786	12421.658672	11213.901786	11213.901786	13058.282883	11213.901786	13064.943106	13171.886354	13181.884875	13058.282883	11213.901786	11213.901786	13058.282883	13171.886354	6	
3	P1B14_3F	0.6	0.3	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	13112.259485	11213.901786	11213.901786	13258.780939	13058.282883	13084.720204	13258.780939	11213.901786	9	
4	P1B14_3F	0.6	0.4	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11	
5	P1B14_3F	0.6	0.5	13058.282883	11213.901786	11213.901786	13084.720204	11213.901786	13058.282883	13084.720204	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	9	
6	P1B14_3F	0.6	0.6	11213.901786	13058.282883	11213.901786	13058.282883	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	9	
7	P1B14_3F	0.6	0.7	13058.282883	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	11	
8	P1B14_3F	0.6	0.8	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	12
9	P1B14_3F	0.7	0.1	13058.282883	11213.901786	13369.632964	12421.658672	13181.884875	11213.901786	13058.282883	11213.901786	13181.884875	13112.259485	13185.454093	13058.282883	11213.901786	11213.901786	4	
10	P1B14_3F	0.7	0.2	11213.901786	13181.884875	13199.691187	13181.884875	13058.282883	13064.943106	11213.901786	13258.780939	13084.720204	13064.943106	11213.901786	13084.720204	13084.720204	13084.720204	3	
11	P1B14_3F	0.7	0.3	11213.901786	11213.901786	11213.901786	13064.943106	13181.884875	13145.100632	11213.901786	13084.720204	11213.901786	11213.901786	11213.901786	11213.901786	13230.270653	11213.901786	9	
12	P1B14_3F	0.7	0.4	13084.720204	11213.901786	11213.901786	13058.282883	11213.901786	13258.780939	13171.886354	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	10	
13	P1B14_3F	0.7	0.5	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	11213.901786	11213.901786	10	
14	P1B14_3F	0.7	0.6	11213.901786	11213.901786	13084.720204	13058.282883	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	13064.943106	10	
15	P1B14_3F	0.7	0.7	11213.901786	11213.901786	11213.901786	11213.901786	13064.943106	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	13058.282883	11213.901786	10		
16	P1B14_3F	0.7	0.8	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	13064.943106	11213.901786	11213.901786	13058.282883	12	
17	P1B14_3F	0.8	0.1	13058.282883	13058.282883	11213.901786	11213.901786	13058.282883	13145.100632	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	11213.901786	11213.901786	9	
18	P1B14_3F	0.8	0.2	13112.259485	11213.901786	13064.943106	11213.901786	11213.901786	13185.454093	11213.901786	13058.282883	13230.270653	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	8	
19	P1B14_3F	0.8	0.3	11213.901786	11213.901786	13112.259485	13058.282883	13112.259485	13064.943106	13084.720204	13112.259485	13112.259485	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	5	
20	P1B14_3F	0.8	0.4	13058.282883	13058.282883	11213.901786	13171.886354	13197.046923	11213.901786	13084.720204	13058.282883	13058.282883	13258.780939	13121.259485	11213.901786	13258.780939	11213.901786	4	
21	P1B14_3F	0.8	0.5	13058.282883	13058.282883	11213.901786	11213.901786	13058.282883	13145.100632	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	11213.901786	11213.901786	9	
22	P1B14_3F	0.8	0.6	11213.901786	13058.282883	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	13084.720204	11213.901786	11213.901786	13064.943106	11213.901786	11	
23	P1B14_3F	0.8	0.7	11213.901786	11213.901786	13058.282883	13058.282883	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	10		
24	P1B14_3F	0.8	0.8	13064.943106	11213.901786	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	12	
25	P1B14_3F	0.9	0.1	13064.943106	13058.282883	13181.884875	13112.259485	13181.884875	13084.720204	13145.100632	11213.901786	13185.454093	13277.093803	12421.658672	11213.901786	13191.345781	2		
26	P1B14_3F	0.9	0.2	12421.658672	13084.720204	13181.884875	13058.282883	13064.943106	11213.901786	13145.100632	13185.454093	13058.282883	13112.259485	12421.658672	11213.901786	13112.259485	3		
27	P1B14_3F	0.9	0.3	13058.282883	11213.901786	13171.886354	11213.901786	11213.901786	13112.259485	11213.901786	11213.901786	13258.780939	13121.259485	11213.901786	13112.259485	11213.901786	9		
28	P1B14_3F	0.9	0.4	11213.901786	11213.901786	13112.259485	13084.720204	13058.282883	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	13112.259485	13171.886354	11213.901786	11213.901786	9	
29	P1B14_3F	0.9	0.5	11213.901786	13058.282883	11213.901786	11213.901786	13084.720204	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	11213.901786	13058.282883	11213.901786	7		
30	P1B14_3F	0.9	0.6	11213.901786	11213.901786	11213.901786	11213.901786	13084.720204	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	13064.943106	11213.901786	11		
31	P1B14_3F	0.9	0.7	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	13084.720204	11213.901786	11		
32	P1B14_3F	0.9	0.8	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	11213.901786	13058.282883	11213.901786	11	